

高等统计学中文学习笔记

第一章：从样本到经验分布

翻译、整理与学习注记

Studyer-Tang

<https://github.com/Studyer-Tang>

本文为个人课程学习记录，依据 Fang Yao 老师的课程讲义整理，并加入中文翻译、直观解释与例题。感谢 Fang Yao 老师提供清晰的课程框架和原始讲义。本文并非官方讲义或官方译本，如有疏漏，以课程原材料与课堂讲授为准。

2026 年 9 月

目录

第 1 章 从样本到经验分布	1
1.1 概率论回顾	1
1.1.1 测度论的基本语言	1
1.1.2 Radon–Nikodym 导数与概率密度	3
1.1.3 变量变换、条件期望与积分	4
1.2 总体分布、样本与经验分布函数	6
1.3 经验测度与代入原理	7
1.3.1 统计泛函与代入原理	7
1.3.2 M-估计与 Z-估计	8
1.4 收敛方式与随机阶	10
1.4.1 四种收敛	10
1.4.2 矩不等式	10
1.4.3 随机阶	11
1.5 极限定理与变换	11
1.5.1 大数定律与中心极限定理	11
1.5.2 Lindeberg 中心极限定理	12
1.5.3 连续映射定理与 Slutsky 定理	13
1.5.4 Delta 方法	14
本章总结	16

第 1 章 从样本到经验分布

数理统计以概率规律以及随机样本如何代表这些规律为起点。本章先复习描述分布、密度、条件期望和积分所需的测度论语言，再引入经验分布函数和经验测度，最后利用大数定律、中心极限定理、连续映射定理、Slutsky 定理和 Delta 方法建立基本渐近工具。

本章的主线可以概括为

总体分布 $P \rightarrow$ 随机样本 $X_1, \dots, X_n \rightarrow$ 经验分布 $P_n, F_n \rightarrow$ 大样本极限理论.

1.1 概率论回顾

1.1.1 测度论的基本语言

定义 1.1.1: σ -域

设 $\mathcal{F}$ 是样本空间 Ω 的若干子集组成的非空集合族。若

$$A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}, \quad A_i \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F},$$

则称 $\mathcal{F}$ 为一个 σ -域。由 De Morgan 律，它也对可列交封闭。实数轴上的 Borel σ -域 $\mathcal{B}(\mathbb{R})$ 是包含所有开集的最小 σ -域。

概率模型写作三元组

$$(\Omega, \mathcal{F}, P),$$

其中 Ω 给出全部基本结果， $\mathcal{F}$ 规定哪些集合是可测事件， P 则为事件分配概率。

定义 1.1.2: 测度与概率

测度 μ 是定义在 $(\Omega, \mathcal{F})$ 上的非负、可列可加集合函数。若 A_i 两两不交，则

$$\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i).$$

若再有 $\mu(\Omega) = 1$ ，则 μ 是概率测度。只在一个 P -零测集上可能失败的命题称为几乎必然成立，记为 a.s.。

连续空间中最常见的参考测度是 Lebesgue 测度 λ ，满足

$$\lambda((a, b)) = b - a.$$

可数空间中最常见的是计数测度

$$\#(A) = |A|.$$

若存在 $A_1, A_2, \dots \in \mathcal{F}$, 使得

$$\Omega = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty,$$

则称 μ 为 σ -有限测度。Lebesgue 测度在 $\mathbb{R}$ 上是 σ -有限的, 因为 $\mathbb{R} = \bigcup_n [-n, n]$; 而 $\mathbb{R}$ 上的计数测度不是 σ -有限的。

定义 1.1.3: 离散概率测度

若概率测度 P 集中在有限或可数集合 $\{x_1, x_2, \dots\}$ 上, 且

$$P(E) = \sum_i p_i \mathbf{1}_{\{x_i \in E\}}, \quad p_i \geq 0, \quad \sum_i p_i = 1,$$

则称 P 为离散概率测度。

定义 1.1.4: 绝对连续

若对每个 $E \in \mathcal{F}$ 都有

$$\nu(E) = 0 \Rightarrow \mu(E) = 0,$$

则称 μ 关于 ν 绝对连续, 记为 $\mu \ll \nu$, 也称 μ 被 ν 控制。

绝对连续的直觉

ν 可以看作参考尺子。 $\mu \ll \nu$ 并不表示 $\mu(E) \leq \nu(E)$, 它只比较零测集: ν 完全看不见的集合, μ 不能在上面放置正质量。

例如, 若 $P(X=0) = 0.4$ 、 $P(X=1) = 0.6$, 则

$$\lambda(\{0\}) = 0, \quad P_X(\{0\}) = 0.4,$$

所以 $P_X \not\ll \lambda$ 。但在其可数支撑上, $P_X \ll \#$ 。

定义 1.1.5: 随机变量与概率律

随机变量是可测映射 $X: \Omega \rightarrow \mathbb{R}$, 即对所有 $a \in \mathbb{R}$,

$$X^{-1}((-\infty, a]) = \{\omega : X(\omega) \leq a\} \in \mathcal{F}.$$

它的概率律是 $\mathcal{B}(\mathbb{R})$ 上的概率测度

$$P_X(B) = P(X^{-1}(B)) = P(X \in B).$$

这里 P 只能直接测量 Ω 中的事件，而 B 位于数值空间 $\mathbb{R}$ 。原像

$$X^{-1}(B) = \{\omega : X(\omega) \in B\}$$

把 B 拉回到原样本空间，再由 P 计算概率。注意 P_X 是概率测度， $P_X(B)$ 才是一个具体概率值。

1.1.2 Radon–Nikodym 导数与概率密度

定理 1.1.1: Radon–Nikodym 定理

设 μ, ν 是 $(\Omega, \mathcal{F})$ 上的 σ -有限测度。若 $\mu \ll \nu$ ，则存在非负可测函数 f ，使得

$$\mu(E) = \int_E f \, d\nu, \quad E \in \mathcal{F}.$$

函数 f 称为 μ 关于 ν 的 Radon–Nikodym 导数，记为

$$f = \frac{d\mu}{d\nu}.$$

它在 ν -几乎处处意义下唯一。

RN 导数表示“每单位 ν -测度含有多少 μ -质量”。核心恒等式是

$$\mu(E) = \int_E \frac{d\mu}{d\nu} \, d\nu.$$

在离散空间中，以计数测度为参考，

$$\frac{dP}{d\#}(x) = P(\{x\}),$$

就是 PMF。在连续空间中，若 $P_X \ll \lambda$ ，则

$$f_X = \frac{dP_X}{d\lambda}$$

就是通常的 PDF，并且

$$P(X \in A) = \int_A f_X(x) \, dx, \quad F_X(x) = \int_{-\infty}^x f_X(y) \, dy.$$

密度依赖参考测度

固定 ψ 时，密度不能脱离参考测度单独存在。同一个概率分布相对于计数测度、Lebesgue 测度或其他控制测度，会有不同的 RN 导数。密度值也可以超过 1；只有对集合积分以后才得到概率。

若 $\mathcal{P}$ 是概率测度族, 并存在同一个 σ -有限测度 ν 使每个 $P \in \mathcal{P}$ 都满足 $P \ll \nu$, 则称 $\mathcal{P}$ 被 ν 控制, 并可由密度族

$$\left\{ \frac{dP}{d\nu} : P \in \mathcal{P} \right\}$$

表示。

RN 导数具有换测度、可加性和链式法则:

$$\int g d\mu = \int g \frac{d\mu}{d\nu} d\nu,$$

$$\frac{d(\mu_1 + \mu_2)}{d\nu} = \frac{d\mu_1}{d\nu} + \frac{d\mu_2}{d\nu},$$

以及当 $\tau \ll \mu \ll \nu$ 时,

$$\frac{d\tau}{d\nu} = \frac{d\tau}{d\mu} \frac{d\mu}{d\nu}.$$

连续 CDF 不一定有密度

Cantor 分布集中在不可数但 Lebesgue 测度为零的 Cantor 集 C 上:

$$P_X(C) = 1, \quad \lambda(C) = 0.$$

同时它没有单点质量, 因此 CDF 处处连续。这说明 CDF 连续只能排除点质量, 却不能排除概率集中在零长度的不可数集合上:

$$\text{CDF 连续} \not\Rightarrow P_X \ll \lambda.$$

1.1.3 变量变换、条件期望与积分

设 $f: (\Omega, \mathcal{F}, \nu) \rightarrow (\Lambda, \mathcal{G})$ 可测。它诱导推前测度

$$(\nu \circ f^{-1})(B) = \nu(f^{-1}(B)).$$

定理 1.1.2: 变量变换

对任意非负可测函数或可积函数 g ,

$$\int_{\Omega} g \circ f d\nu = \int_{\Lambda} g d(\nu \circ f^{-1}).$$

当 $\nu = P$ 、 $f = X$ 时, 推前测度就是 $P_X = P \circ X^{-1}$, 从而

$$E\{h(X)\} = \int_{\Omega} h(X(\omega)) dP(\omega) = \int_{\mathbb{R}} h(x) dP_X(x).$$

定义 1.1.7: 条件期望

设 X 可积, $\mathcal{G} \subseteq \mathcal{F}$ 。条件期望 $Z = E(X | \mathcal{G})$ 是满足以下条件且 a.s. 唯一的随机变量:

1. Z 是 $\mathcal{G}$ -可测的;
2. 对每个 $A \in \mathcal{G}$,

$$\int_A Z \, dP = \int_A X \, dP.$$

第二个条件等价于

$$E\{(X - Z)\mathbf{1}_A\} = 0, \quad A \in \mathcal{G},$$

即残差在每个已知信息事件上的平均值都为零。给定随机变量 Y 的条件期望定义为

$$E(X | Y) = E\{X | \sigma(Y)\}.$$

塔式性质与全期望公式分别为

$$\mathcal{H} \subseteq \mathcal{G} \Rightarrow E(X | \mathcal{H}) = E\{E(X | \mathcal{G}) | \mathcal{H}\},$$

$$E\{E(X | \mathcal{G})\} = E X.$$

完全信息下 $E(X | \mathcal{F}) = X$ a.s.; 平凡信息下 $E(X | \mathcal{G}) = E X$ 。

若 (X, Y) 具有联合密度, 则当 $f_Y(y) > 0$ 时,

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{f_{X,Y}(x, y)}{\int f_{X,Y}(u, y) \, du}.$$

定理 1.1.3: Fubini–Tonelli 定理

设 $(\Omega_i, \mathcal{F}_i, \nu_i)$ ($i = 1, 2$) 是两个 σ -有限测度空间, f 是关于 $\mathcal{F}_1 \otimes \mathcal{F}_2$ 可测的函数。若 $f \geq 0$ (Tonelli, 积分允许取 $+\infty$), 或 $\int |f| \, d(\nu_1 \times \nu_2) < \infty$ (Fubini, 积分有限), 则可以交换积分次序:

$$\begin{aligned} \int f \, d(\nu_1 \times \nu_2) &= \int_{\Omega_2} \left[\int_{\Omega_1} f(\omega_1, \omega_2) \, d\nu_1 \right] d\nu_2 \\ &= \int_{\Omega_1} \left[\int_{\Omega_2} f(\omega_1, \omega_2) \, d\nu_2 \right] d\nu_1. \end{aligned}$$

这里明确采用两个测度均为 σ -有限的版本。概率测度与 $\mathbb{R}$ 上的 Lebesgue 测度满足这一条件, 但前面提到的 $\mathbb{R}$ 上计数测度不满足; 涉及非 σ -有限测度时不能直接援用本框中的定理。

基本收敛定理包括: 对 $X_n \geq 0$, Fatou 引理给出

$$E(\liminf_n X_n) \leq \liminf_n E X_n;$$

若 $X_n \xrightarrow{\text{a.s.}} X$ 且 $|X_n| \leq Y$ 、 $EY < \infty$ ，控制收敛定理给出

$$EX_n \rightarrow EX;$$

若 $0 \leq X_n \uparrow X$ a.s.，单调收敛定理同样给出 $EX_n \rightarrow EX$ ，两端允许为无穷大。

1.2 总体分布、样本与经验分布函数

给定概率测度 P ，通常写 $X \sim P$ 。对期望存在的可测函数 f ，记

$$Pf := \int f dP = E\{f(X)\}. \quad (1.1)$$

总体是一个一般观测 X 的概率分布 P ；统计模型是可能总体分布的集合 $\mathcal{P}$ 。参数模型通常写为

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}, \quad \Theta \subseteq \mathbb{R}^d,$$

非参数模型则允许未知参数本身是函数。

定义 1.2.1：随机样本

若

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P,$$

则称其为来自 P 的随机样本。其联合分布是乘积测度 P^n 。观测前 X_i 和统计量 $\bar{X}$ 是随机的；观测后得到的数据 x_i 和数值 $\bar{x}$ 是固定的。

总体 CDF F 未知。落入 $(-\infty, x]$ 的观测比例定义经验 CDF：

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

每个实现样本对应的 F_n 都是阶梯型 CDF。若 $X_{(1)} \leq \dots \leq X_{(n)}$ 是次序统计量，则

$$F_n^{-1}(p) = \inf\{x : F_n(x) \geq p\} = X_{(\lceil np \rceil)}, \quad 0 < p \leq 1.$$

固定 x ，令 $Y_i(x) = \mathbf{1}_{\{X_i \leq x\}}$ 。则

$$Y_i(x) \sim \text{Bernoulli}(F(x)), \quad nF_n(x) \sim \text{Binomial}(n, F(x)). \quad (1.2)$$

定理 1.2.1：经验 CDF 的均值与方差

对每个固定 $x \in \mathbb{R}$ ，

$$EF_n(x) = F(x), \quad \text{Var}(F_n(x)) = \frac{F(x)\{1 - F(x)\}}{n}.$$

该结论是点态的，只控制固定 x ，并不能直接控制

$$\sup_x |F_n(x) - F(x)|.$$

后者需要同时控制整个阈值函数类。

对 $x, y \in \mathbb{R}$ ，令 $x \wedge y = \min\{x, y\}$ ，则

$$\boxed{\text{Cov}(F_n(x), F_n(y)) = \frac{F(x \wedge y) - F(x)F(y)}{n}.} \quad (1.3)$$

1.3 经验测度与代入原理

对随机样本 $X_1, \dots, X_n$ ，定义经验测度

$$\boxed{P_n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i}},$$

其中 δ_x 是点质量测度：

$$\delta_x(A) = \mathbf{1}_A(x), \quad \int f d\delta_x = f(x).$$

因此

$$P_n(A) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_A(X_i), \quad P_n f = \frac{1}{n} \sum_{i=1}^n f(X_i).$$

经验 CDF 是特殊情形

$$F_n(t) = P_n((-\infty, t]) = P_n \mathbf{1}_{(-\infty, t]}.$$

命题 1.3.1：经验积分的均值与方差

若 f 可积，则

$$\mathbb{E}(P_n f) = P f.$$

若 $f \in L^2(P)$ ，则

$$\text{Var}(P_n f) = \frac{\text{Var}(f(X))}{n}.$$

1.3.1 统计泛函与代入原理

定义 1.3.1：统计泛函

设 $\mathcal{Q}$ 包含统计模型 $\mathcal{P}$ 以及所考虑的经验测度。统计泛函是映射

$$T : \mathcal{Q} \rightarrow \mathcal{D}.$$

$T(P)$ 表示总体分布的某个特征。用 P_n 替换未知 P ，得到代入估计量

$$\widehat{\theta}_n = T(P_n).$$

对固定可积函数 ψ ,

$$T_\psi(P) = P\psi = \int \psi dP$$

是关于分布 P 的线性泛函，因为

$$T_\psi(aP_1 + bP_2) = aT_\psi(P_1) + bT_\psi(P_2).$$

代入 P_n 后，

$$T_\psi(P_n) = P_n\psi = \frac{1}{n} \sum_{i=1}^n \psi(X_i).$$

“线性”是对分布而言

$\psi(x)$ 本身不必对 x 线性。例如 $\psi(x) = x^2$ 虽是非线性函数，但 $P \mapsto P(x^2)$ 仍对 P 线性。方差

$$\text{Var}_P(X) = P(x^2) - (Px)^2$$

则不是线性泛函，因为它包含积分结果的平方。

均值与方差是直接代入估计为

$$\bar{X} = P_n x, \quad S_n^2 = P_n(x^2) - (P_n x)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

分位数泛函及其代入估计为

$$T_p(P) = F^{-1}(p), \quad T_p(P_n) = F_n^{-1}(p).$$

1.3.2 M-估计与 Z-估计

设 $m_\theta(x)$ 衡量候选参数 θ 在观测 x 上的表现。总体准则与经验准则分别是

$$M(\theta) = Pm_\theta, \quad M_n(\theta) = P_n m_\theta.$$

M-估计定义为

$$\widehat{\theta}_n \in \arg \max_{\theta \in \Theta} P_n m_\theta.$$

若使用损失 $\rho_\theta = -m_\theta$ ，等价地写为最小化 $P_n \rho_\theta$ 。

平方损失给出样本均值

取 $\rho_\theta(x) = (x - \theta)^2$ 。由于

$$E(X - \theta)^2 = \text{Var}(X) + (\mu - \theta)^2,$$

总体最优点是 $\theta = \mu$ 。经验问题

$$\arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n (X_i - \theta)^2$$

的一阶条件给出 $\hat{\theta}_n = \bar{X}$ 。若取绝对值损失 $|x - \theta|$ ，相应 M-估计量则是样本中位数。

在控制模型中取

$$m_\theta(x) = \log p_\theta(x),$$

便得到最大似然估计。因此 MLE 是 M-估计的特殊情形。

Z-估计从总体估计方程出发：设 $\psi_\theta : \mathcal{X} \rightarrow \mathbb{R}^s$ ，总体参数满足

$$P\psi_{\theta(P)} = 0.$$

用 P_n 替换 P ，得到

$$P_n \psi_{\hat{\theta}_n} = 0.$$

任何解都称为 Z-估计量。

样本均值也是 Z-估计

取 $\psi_\theta(x) = x - \theta$ 。总体方程

$$E(X - \theta) = 0$$

的解为 $\theta = \mu$ ；经验方程

$$\frac{1}{n} \sum_{i=1}^n (X_i - \theta) = 0$$

的解为 $\hat{\theta}_n = \bar{X}$ 。

若 M-准则光滑且最优点位于参数空间内部，其一阶条件通常给出 Z-方程。最大似然中的得分函数

$$\dot{\ell}_\theta(x) = \nabla_\theta \log p_\theta(x)$$

满足

$$0 = \nabla_\theta \ell_n(\hat{\theta}_n) = n P_n \dot{\ell}_{\hat{\theta}_n}.$$

边界最大值和不可微似然不一定满足这个方程，需要单独处理。

1.4 收敛方式与随机阶

1.4.1 四种收敛

设 $\mathbf{Y}_n, \mathbf{Y} \in \mathbb{R}^k$ 。主要收敛概念如下：

$$\mathbf{Y}_n \xrightarrow{\text{a.s.}} \mathbf{Y} \iff P(\lim_n \mathbf{Y}_n = \mathbf{Y}) = 1,$$

$$\mathbf{Y}_n \xrightarrow{L^r} \mathbf{Y} \iff E \|\mathbf{Y}_n - \mathbf{Y}\|_r^r \rightarrow 0,$$

$$\mathbf{Y}_n \xrightarrow{P} \mathbf{Y} \iff P(\|\mathbf{Y}_n - \mathbf{Y}\| > \varepsilon) \rightarrow 0 \quad \forall \varepsilon > 0,$$

$$\mathbf{Y}_n \xrightarrow{d} \mathbf{Y} \iff P_{\mathbf{Y}_n} \Rightarrow P_{\mathbf{Y}}.$$

依分布收敛等价于：对每个有界连续函数 h ,

$$E h(\mathbf{Y}_n) \rightarrow E h(\mathbf{Y}).$$

定理 1.4.1：依概率收敛的子序列刻画

$\mathbf{Y}_n \xrightarrow{P} \mathbf{Y}$ 当且仅当每个子序列 $(\mathbf{Y}_{n_j})$ 都存在一个进一步子序列 $(\mathbf{Y}_{n_{j_\ell}})$, 使

$$\mathbf{Y}_{n_{j_\ell}} \xrightarrow{\text{a.s.}} \mathbf{Y}.$$

标准蕴含关系为

$$\mathbf{Y}_n \xrightarrow{\text{a.s.}} \mathbf{Y} \Rightarrow \mathbf{Y}_n \xrightarrow{P} \mathbf{Y} \Rightarrow \mathbf{Y}_n \xrightarrow{d} \mathbf{Y}.$$

若有 L^r 收敛, 也能由 Markov 不等式推出依概率收敛。

1.4.2 矩不等式

定理 1.4.2：Markov 不等式

若 $Z \geq 0$ 且 $E Z < \infty$, 则对每个 $t > 0$,

$$P(Z \geq t) \leq \frac{E Z}{t}.$$

对 $Z = (X - E X)^2$ 应用 Markov 不等式, 得到 Chebyshev 不等式

$$P(|X - E X| \geq t) \leq \frac{\text{Var}(X)}{t^2}.$$

更一般地,

$$P(\|\mathbf{Y}_n - \mathbf{Y}\|_r > \varepsilon) \leq \frac{E \|\mathbf{Y}_n - \mathbf{Y}\|_r^r}{\varepsilon^r}. \quad (1.4)$$

1.4.3 随机阶

对正确定数列 a_n , 定义

$$Y_n = O_p(a_n) \iff \frac{Y_n}{a_n} \text{ 依概率有界,}$$

$$Y_n = o_p(a_n) \iff \frac{Y_n}{a_n} \xrightarrow{P} 0.$$

更具体地, $Y_n = O_p(a_n)$ 表示对任意 $\varepsilon > 0$, 存在 $C_\varepsilon < \infty$, 使

$$\sup_{n \geq 1} P(|Y_n| > C_\varepsilon a_n) < \varepsilon.$$

基本运算规则包括

$$o_p(a_n)O_p(b_n) = o_p(a_nb_n),$$

$$O_p(a_n) + O_p(b_n) = O_p(a_n + b_n),$$

$$o_p(a_n) + o_p(b_n) = o_p(a_n + b_n).$$

样本均值的随机阶

若 X_i i.i.d., 均值为 μ 、方差为 σ^2 , 则中心极限定理给出

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

因此

$$\bar{X}_n - \mu = O_p(n^{-1/2}) = o_p(1),$$

但一般不是 $o_p(n^{-1/2})$, 因为标准化误差并未收敛到零, 而是收敛到非退化正态分布。

1.5 极限定理与变换

1.5.1 大数定律与中心极限定理

若 X_i i.i.d., 均值为 μ 、方差为 $\sigma^2 < \infty$, Chebyshev 不等式给出

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0. \quad (1.5)$$

定理 1.5.1: 强大数定律

若 $X_i \stackrel{\text{i.i.d.}}{\sim} P$ 且 $P|f| < \infty$, 则

$$P_n f \xrightarrow{\text{a.s.}} P f.$$

特别地, 对每个固定 x , $F_n(x) \xrightarrow{\text{a.s.}} F(x)$ 。

定理 1.5.2: 中心极限定理

若 $Pf^2 < \infty$, $\sigma_f^2 = \text{Var}(f(X)) \in (0, \infty)$, 则

$$\sqrt{n}(P_n - P)f = \frac{1}{\sqrt{n}} \sum_{i=1}^n \{f(X_i) - Pf\} \xrightarrow{d} N(0, \sigma_f^2).$$

固定 x 并取 $f_x(z) = \mathbf{1}_{\{z \leq x\}}$, 可得

$$\sqrt{n}\{F_n(x) - F(x)\} \xrightarrow{d} N(0, F(x)\{1 - F(x)\}).$$

大数定律说明误差消失, 中心极限定理则描述误差在 $n^{-1/2}$ 尺度上的波动。

1.5.2 Lindeberg 中心极限定理

定理 1.5.3: Lindeberg 中心极限定理

对每个 n , 设 $X_{n1}, \dots, X_{nk_n}$ 相互独立。令

$$Y_{nj} = X_{nj} - E X_{nj}, \quad s_n^2 = \sum_{j=1}^{k_n} \text{Var}(X_{nj}) \in (0, \infty).$$

若对每个 $\varepsilon > 0$,

$$\frac{1}{s_n^2} \sum_{j=1}^{k_n} E \left[Y_{nj}^2 \mathbf{1}_{\{|Y_{nj}| > \varepsilon s_n\}} \right] \rightarrow 0, \quad (1.6)$$

则

$$\frac{1}{s_n} \sum_{j=1}^{k_n} Y_{nj} \xrightarrow{d} N(0, 1). \quad (1.7)$$

Lindeberg 条件表示: 相对于总方差 s_n^2 , 异常大项贡献的方差比例趋于零。它排除了由一个或少数几个变量支配全部波动的情形。

异质 Bernoulli 顾客例子

设第 n 天有 n 位独立顾客,

$$X_{nj} \sim \text{Bernoulli}\left(\frac{j}{2n}\right), \quad j = 1, \dots, n.$$

总购买人数 $T_n = \sum_j X_{nj}$ 满足

$$E T_n = \frac{n+1}{4}, \quad s_n^2 = \frac{(n+1)(4n-1)}{24n} \sim \frac{n}{6}.$$

由于 $|X_{nj} - E X_{nj}| \leq 1$ 而 $s_n \rightarrow \infty$, 对固定 $\varepsilon > 0$, 事件

$$|Y_{nj}| > \varepsilon s_n$$

最终不可能发生, 故 Lindeberg 条件成立。因此

$$\frac{T_n - (n+1)/4}{\sqrt{(n+1)(4n-1)/(24n)}} \xrightarrow{d} N(0, 1).$$

各顾客购买概率不同, 但总购买人数仍具有正态极限。

1.5.3 连续映射定理与 Slutsky 定理

定理 1.5.4: 连续映射定理

若 g 在除 P_Y -零测集外的每一点连续, 则

$$Y_n \xrightarrow{\text{a.s.}} Y \Rightarrow g(Y_n) \xrightarrow{\text{a.s.}} g(Y),$$

$$Y_n \xrightarrow{P} Y \Rightarrow g(Y_n) \xrightarrow{P} g(Y),$$

$$Y_n \xrightarrow{d} Y \Rightarrow g(Y_n) \xrightarrow{d} g(Y).$$

例如, 若 $\bar{X}_n \xrightarrow{P} \mu$ 且 g 在 μ 处连续, 则

$$g(\bar{X}_n) \xrightarrow{P} g(\mu).$$

命题 1.5.1: 渐近等价

若

$$U_n \xrightarrow{d} U, \quad \|V_n - U_n\| \xrightarrow{P} 0,$$

则 $V_n \xrightarrow{d} U$ 。

定理 1.5.5: Slutsky 定理

若 $Y_n \xrightarrow{d} Y$ 、 $Z_n \xrightarrow{P} c$, 其中 c 为常数, 则

$$(Y_n, Z_n) \xrightarrow{d} (Y, c).$$

因此

$$Y_n + Z_n \xrightarrow{d} Y + c, \quad Z_n Y_n \xrightarrow{d} cY,$$

且当 $c \neq 0$ 时,

$$\frac{Y_n}{Z_n} \xrightarrow{d} \frac{Y}{c}.$$

学生化样本均值

令

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

中心极限定理给出

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1),$$

而大数定律与连续映射定理给出 $S_n/\sigma \xrightarrow{P} 1$ 。由 Slutsky 定理,

$$\boxed{\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \xrightarrow{d} N(0, 1).}$$

相合的尺度估计量可以替代未知总体尺度, 而不改变一阶极限分布。

1.5.4 Delta 方法

连续映射定理可以处理相合性, 却不能描述非线性变换后的一阶波动。Delta 方法将随机变量的 Taylor 展开与已有渐近分布结合起来。

命题 1.5.2: 随机 Taylor 展开

若 $\mathbf{X}_n \xrightarrow{P} \mathbf{c}$, 且当 $\mathbf{h} \rightarrow 0$ 时

$$g(\mathbf{c} + \mathbf{h}) = g(\mathbf{c}) + \sum_{j=1}^m \frac{1}{j!} D^j g(\mathbf{c})[\mathbf{h}, \dots, \mathbf{h}] + R_m(\mathbf{h}),$$

其中 $R_m(\mathbf{h})/\|\mathbf{h}\|^m \rightarrow 0$, 则

$$\begin{aligned} g(\mathbf{X}_n) &= g(\mathbf{c}) + \sum_{j=1}^m \frac{1}{j!} D^j g(\mathbf{c})[\mathbf{X}_n - \mathbf{c}, \dots, \mathbf{X}_n - \mathbf{c}] \\ &\quad + \|\mathbf{X}_n - \mathbf{c}\|^m Q_n, \quad Q_n = o_p(1). \end{aligned}$$

定理 1.5.6: 一阶 Delta 方法

若 $a_n \rightarrow \infty$,

$$a_n(\mathbf{X}_n - \mathbf{c}) \xrightarrow{d} \mathbf{Y},$$

且 $g: \mathbb{R}^k \rightarrow \mathbb{R}$ 在 $\mathbf{c}$ 处可微, 则

$$a_n \{g(\mathbf{X}_n) - g(\mathbf{c})\} \xrightarrow{d} \nabla g(\mathbf{c})^\top \mathbf{Y}.$$

若 $\mathbf{Y} \sim N_k(0, \Sigma)$, 则极限为

$$N(0, \nabla g(\mathbf{c})^\top \Sigma \nabla g(\mathbf{c})).$$

证明的核心是 Taylor 展开

$$g(\mathbf{X}_n) - g(\mathbf{c}) = \nabla g(\mathbf{c})^\top (\mathbf{X}_n - \mathbf{c}) + \|\mathbf{X}_n - \mathbf{c}\| Q_n,$$

其中 $Q_n = o_p(1)$ 。乘以 a_n 后, 余项是 $O_p(1)o_p(1) = o_p(1)$, 再应用 Slutsky 定理。

若前 $m-1$ 阶导数均在 $\mathbf{c}$ 处为零, 而至少一个 m 阶导数非零, 则需要用 a_n^m 缩放, 并保留 Taylor 展开的第 m 阶齐次多项式。这就是高阶 Delta 方法。

样本均值的平方

由

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

对 $g(t) = t^2$, 当 $\mu \neq 0$ 时, $g'(\mu) = 2\mu$, 故

$$\sqrt{n}(\bar{X}_n^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2).$$

当 $\mu = 0$ 时一阶导数消失, 需要二阶 Delta 方法:

$$n\bar{X}_n^2 \xrightarrow{d} \sigma^2 Z^2, \quad Z \sim N(0, 1).$$

样本方差的渐近分布

若 $P(x^4) < \infty$, 令

$$S_n^2 = P_n(x^2) - (P_n x)^2.$$

对 $\mathbf{W}_i = (X_i, X_i^2)^\top$ 使用二维 CLT, 再对 $h(a, b) = b - a^2$ 使用 Delta 方法。梯度为

$$\nabla h(\mu, Px^2) = (-2\mu, 1)^\top.$$

中心化线性项化简为

$$L(X) = (X - \mu)^2 - \sigma^2,$$

故渐近方差为

$$\text{Var}\{L(X)\} = P\{(x - \mu)^4\} - \sigma^4.$$

最终

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, P\{(x - \mu)^4\} - \sigma^4).$$

使用分母 $n-1$ 的样本方差记为 $\tilde{S}_n^2 = \frac{n}{n-1} S_n^2$ ($n \geq 2$)。由大数定律与连续映射定理, $S_n^2 \xrightarrow{P} \sigma^2$, 因此 $S_n^2 = O_p(1)$ 。在这里所需的 $\sqrt{n}$ 中心化尺度下,

$$\sqrt{n}(\tilde{S}_n^2 - S_n^2) = \frac{\sqrt{n}}{n-1} S_n^2 \xrightarrow{P} 0.$$

于是

$$\sqrt{n}(\tilde{S}_n^2 - \sigma^2) = \sqrt{n}(S_n^2 - \sigma^2) + o_p(1),$$

由 Slutsky 定理得到相同的极限分布。关键是两者的差在 $\sqrt{n}$ 尺度下可以忽略; 仅有乘法因子趋于 1, 一般不足以保证中心化后的极限相同。

本章总结

概率分布与期望描述总体量, 经验测度则给出对应的样本量。Markov 和 Chebyshev 不等式把矩信息转化为概率上界; 大数定律说明估计误差消失; 中心极限定理描述 $n^{-1/2}$ 尺度上的随机波动; 连续映射、Slutsky 定理和 Delta 方法则把这些极限传递到非线性代入估计量。

这些工具将继续支撑后续的集中不等式、一致经验过程以及 M-估计与 Z-估计理论。

复习路线

建议按以下顺序复习:

$$P_n f \rightarrow P f \implies \sqrt{n}(P_n - P)f \xrightarrow{d} N(0, \sigma_f^2) \implies g(P_n f) \text{ 的 Delta 展开.}$$

首先确认估计量是否相合, 再寻找其波动尺度, 最后分析非线性变换和学生化。