

高等统计学中文学习笔记

第一章：从样本到经验分布

翻译、整理与学习注记

Studyer-Tang

<https://github.com/Studyer-Tang>

本文为个人课程学习记录，依据 Fang Yao 老师的课程讲义整理，并加入中文翻译、直观解释与例题。感谢 Fang Yao 老师提供清晰的课程框架和原始讲义。本文并非官方讲义或官方译本，如有疏漏，以课程原材料与课堂讲授为准。

2026 年 9 月

目录

第 1 章 从样本到经验分布	1
1.1 概率论回顾	1
1.1.1 测度论的基本语言	1
1.1.2 Radon–Nikodym 导数与概率密度	3
1.1.3 变量变换、条件期望与积分	4
1.2 总体分布、样本与经验分布函数	6
1.3 经验测度与代入原理	7
1.3.1 统计泛函与代入原理	7
1.3.2 M-估计与 Z-估计	8
1.4 收敛方式与随机阶	9
1.4.1 四种收敛	9
1.4.2 矩不等式	10
1.4.3 随机阶	10
1.5 极限定理与变换	11
1.5.1 大数定律与中心极限定理	11
1.5.2 Lindeberg 中心极限定理	12
1.5.3 连续映射定理与 Slutsky 定理	13
1.5.4 Delta 方法	14
本章总结	15

第 1 章 从样本到经验分布

数理统计以概率规律以及随机样本如何代表这些规律为起点。本章先复习描述分布、密度、条件期望和积分所需的测度论语言，再引入经验分布函数和经验测度，最后利用大数定律、中心极限定理、连续映射定理、Slutsky 定理和 Delta 方法建立基本渐近工具。

本章的主线可以概括为

总体分布 $P \rightarrow$ 随机样本 $X_1, \dots, X_n \rightarrow$ 经验分布 $P_n, F_n \rightarrow$ 大样本极限理论.

1.1 概率论回顾

1.1.1 测度论的基本语言

定义 1.1.1: σ -域

设 $\mathcal{F}$ 是样本空间 Ω 的若干子集组成的非空集合族。若

$$A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}, \quad A_i \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F},$$

则称 $\mathcal{F}$ 为一个 σ -域。由 De Morgan 律，它也对可列交封闭。实数轴上的 Borel σ -域 $\mathcal{B}(\mathbb{R})$ 是包含所有开集的最小 σ -域。

概率模型写作三元组

$$(\Omega, \mathcal{F}, P),$$

其中 Ω 给出全部基本结果， $\mathcal{F}$ 规定哪些集合是可测事件， P 则为事件分配概率。

定义 1.1.2: 测度与概率

测度 μ 是定义在 $(\Omega, \mathcal{F})$ 上的非负、可列可加集合函数。若 A_i 两两不交，则

$$\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i).$$

若再有 $\mu(\Omega) = 1$ ，则 μ 是概率测度。只在一个 P -零测集上可能失败的命题称为几乎必然成立，记为 a.s.。

连续空间中最常见的参考测度是 Lebesgue 测度 λ ，满足

$$\lambda((a, b)) = b - a.$$

可数空间中最常见的是计数测度

$$\#(A) = |A|.$$

若存在 $A_1, A_2, \dots \in \mathcal{F}$, 使得

$$\Omega = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty,$$

则称 μ 为 σ -有限测度。Lebesgue 测度在 $\mathbb{R}$ 上是 σ -有限的, 因为 $\mathbb{R} = \bigcup_n [-n, n]$; 而 $\mathbb{R}$ 上的计数测度不是 σ -有限的。

定义 1.1.3: 离散概率测度

若概率测度 P 集中在有限或可数集合 $\{x_1, x_2, \dots\}$ 上, 且

$$P(E) = \sum_i p_i \mathbf{1}_{\{x_i \in E\}}, \quad p_i \geq 0, \quad \sum_i p_i = 1,$$

则称 P 为离散概率测度。

定义 1.1.4: 绝对连续

若对每个 $E \in \mathcal{F}$ 都有

$$\nu(E) = 0 \Rightarrow \mu(E) = 0,$$

则称 μ 关于 ν 绝对连续, 记为 $\mu \ll \nu$, 也称 μ 被 ν 控制。

绝对连续的直觉

ν 可以看作参考尺子。 $\mu \ll \nu$ 并不表示 $\mu(E) \leq \nu(E)$, 它只比较零测集: ν 完全看不见的集合, μ 不能在上面放置正质量。

例如, 若 $P(X=0) = 0.4$ 、 $P(X=1) = 0.6$, 则

$$\lambda(\{0\}) = 0, \quad P_X(\{0\}) = 0.4,$$

所以 $P_X \not\ll \lambda$ 。但在其可数支撑上, $P_X \ll \#$ 。

定义 1.1.5: 随机变量与概率律

随机变量是可测映射 $X: \Omega \rightarrow \mathbb{R}$, 即对所有 $a \in \mathbb{R}$,

$$X^{-1}((-\infty, a]) = \{\omega : X(\omega) \leq a\} \in \mathcal{F}.$$

它的概率律是 $\mathcal{B}(\mathbb{R})$ 上的概率测度

$$P_X(B) = P(X^{-1}(B)) = P(X \in B).$$

这里 P 只能直接测量 Ω 中的事件，而 B 位于数值空间 $\mathbb{R}$ 。原像

$$X^{-1}(B) = \{\omega : X(\omega) \in B\}$$

把 B 拉回到原样本空间，再由 P 计算概率。注意 P_X 是概率测度， $P_X(B)$ 才是一个具体概率值。

1.1.2 Radon–Nikodym 导数与概率密度

定理 1.1.1: Radon–Nikodym 定理

设 μ, ν 是 $(\Omega, \mathcal{F})$ 上的 σ -有限测度。若 $\mu \ll \nu$ ，则存在非负可测函数 f ，使得

$$\mu(E) = \int_E f \, d\nu, \quad E \in \mathcal{F}.$$

函数 f 称为 μ 关于 ν 的 Radon–Nikodym 导数，记为

$$f = \frac{d\mu}{d\nu}.$$

它在 ν -几乎处处意义下唯一。

RN 导数表示“每单位 ν -测度含有多少 μ -质量”。核心恒等式是

$$\mu(E) = \int_E \frac{d\mu}{d\nu} \, d\nu.$$

在离散空间中，以计数测度为参考，

$$\frac{dP}{d\#}(x) = P(\{x\}),$$

就是 PMF。在连续空间中，若 $P_X \ll \lambda$ ，则

$$f_X = \frac{dP_X}{d\lambda}$$

就是通常的 PDF，并且

$$P(X \in A) = \int_A f_X(x) \, dx, \quad F_X(x) = \int_{-\infty}^x f_X(y) \, dy.$$

密度依赖参考测度

固定 ψ 时，密度不能脱离参考测度单独存在。同一个概率分布相对于计数测度、Lebesgue 测度或其他控制测度，会有不同的 RN 导数。密度值也可以超过 1；只有对集合积分以后才得到概率。

若 $\mathcal{P}$ 是概率测度族，并存在同一个 σ -有限测度 ν 使每个 $P \in \mathcal{P}$ 都满足 $P \ll \nu$ ，则称 $\mathcal{P}$ 被 ν 控制，并可由密度族

$$\left\{ \frac{dP}{d\nu} : P \in \mathcal{P} \right\}$$

表示。

RN 导数具有换测度、可加性和链式法则：

$$\int g d\mu = \int g \frac{d\mu}{d\nu} d\nu,$$

$$\frac{d(\mu_1 + \mu_2)}{d\nu} = \frac{d\mu_1}{d\nu} + \frac{d\mu_2}{d\nu},$$

以及当 $\tau \ll \mu \ll \nu$ 时，

$$\frac{d\tau}{d\nu} = \frac{d\tau}{d\mu} \frac{d\mu}{d\nu}.$$

连续 CDF 不一定有密度

Cantor 分布集中在不可数但 Lebesgue 测度为零的 Cantor 集 C 上：

$$P_X(C) = 1, \quad \lambda(C) = 0.$$

同时它没有单点质量，因此 CDF 处处连续。这说明 CDF 连续只能排除点质量，却不能排除概率集中在零长度的不可数集合上：

$$\text{CDF 连续} \not\Rightarrow P_X \ll \lambda.$$

1.1.3 变量变换、条件期望与积分

设 $f : (\Omega, \mathcal{F}, \nu) \rightarrow (\Lambda, \mathcal{G})$ 可测。它诱导推前测度

$$(\nu \circ f^{-1})(B) = \nu(f^{-1}(B)).$$

定理 1.1.2：变量变换

对任意非负可测函数或可积函数 g ，

$$\int_{\Omega} g \circ f d\nu = \int_{\Lambda} g d(\nu \circ f^{-1}).$$

当 $\nu = P$ 、 $f = X$ 时，推前测度就是 $P_X = P \circ X^{-1}$ ，从而

$$E\{h(X)\} = \int_{\Omega} h(X(\omega)) dP(\omega) = \int_{\mathbb{R}} h(x) dP_X(x).$$

定义 1.1.7: 条件期望

设 X 可积, $\mathcal{G} \subseteq \mathcal{F}$ 。条件期望 $Z = E(X | \mathcal{G})$ 是满足以下条件且 a.s. 唯一的随机变量:

1. Z 是 $\mathcal{G}$ -可测的;
2. 对每个 $A \in \mathcal{G}$,

$$\int_A Z \, dP = \int_A X \, dP.$$

第二个条件等价于

$$E\{(X - Z)\mathbf{1}_A\} = 0, \quad A \in \mathcal{G},$$

即残差在每个已知信息事件上的平均值都为零。给定随机变量 Y 的条件期望定义为

$$E(X | Y) = E\{X | \sigma(Y)\}.$$

塔式性质与全期望公式分别为

$$\mathcal{H} \subseteq \mathcal{G} \Rightarrow E(X | \mathcal{H}) = E\{E(X | \mathcal{G}) | \mathcal{H}\},$$

$$E\{E(X | \mathcal{G})\} = E X.$$

完全信息下 $E(X | \mathcal{F}) = X$ a.s.; 平凡信息下 $E(X | \mathcal{G}) = E X$ 。

若 (X, Y) 具有联合密度, 则当 $f_Y(y) > 0$ 时,

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{f_{X,Y}(x, y)}{\int f_{X,Y}(u, y) \, du}.$$

定理 1.1.3: Fubini–Tonelli 定理

若 $f \geq 0$, 或 $\int |f| \, d(\nu_1 \times \nu_2) < \infty$, 则可以交换积分次序:

$$\begin{aligned} \int f \, d(\nu_1 \times \nu_2) &= \int_{\Omega_2} \left[\int_{\Omega_1} f(\omega_1, \omega_2) \, d\nu_1 \right] d\nu_2 \\ &= \int_{\Omega_1} \left[\int_{\Omega_2} f(\omega_1, \omega_2) \, d\nu_2 \right] d\nu_1. \end{aligned}$$

基本收敛定理包括: 对 $X_n \geq 0$, Fatou 引理给出

$$E(\liminf_n X_n) \leq \liminf_n E X_n;$$

若 $X_n \xrightarrow{\text{a.s.}} X$ 且 $|X_n| \leq Y$ 、 $E Y < \infty$, 控制收敛定理给出

$$E X_n \rightarrow E X;$$

若 $0 \leq X_n \uparrow X$ a.s., 单调收敛定理同样给出 $E X_n \rightarrow E X$, 两端允许为无穷大。

1.2 总体分布、样本与经验分布函数

给定概率测度 P ，通常写 $X \sim P$ 。对期望存在的可测函数 f ，记

$$Pf := \int f dP = E\{f(X)\}. \quad (1.1)$$

总体是一个一般观测 X 的概率分布 P ；统计模型是可能总体分布的集合 $\mathcal{P}$ 。参数模型通常写为

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}, \quad \Theta \subseteq \mathbb{R}^d,$$

非参数模型则允许未知参数本身是函数。

定义 1.2.1: 随机样本

若

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P,$$

则称其为来自 P 的随机样本。其联合分布是乘积测度 P^n 。观测前 X_i 和统计量 $\bar{X}$ 是随机的；观测后得到的数据 x_i 和数值 $\bar{x}$ 是固定的。

总体 CDF F 未知。落入 $(-\infty, x]$ 的观测比例定义经验 CDF:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

每个实现样本对应的 F_n 都是阶梯型 CDF。若 $X_{(1)} \leq \dots \leq X_{(n)}$ 是次序统计量，则

$$F_n^{-1}(p) = \inf\{x : F_n(x) \geq p\} = X_{(\lceil np \rceil)}, \quad 0 < p \leq 1.$$

固定 x ，令 $Y_i(x) = \mathbf{1}_{\{X_i \leq x\}}$ 。则

$$Y_i(x) \sim \text{Bernoulli}(F(x)), \quad nF_n(x) \sim \text{Binomial}(n, F(x)). \quad (1.2)$$

定理 1.2.1: 经验 CDF 的均值与方差

对每个固定 $x \in \mathbb{R}$,

$$E F_n(x) = F(x), \quad \text{Var}(F_n(x)) = \frac{F(x)\{1 - F(x)\}}{n}.$$

该结论是点态的，只控制固定 x ，并不能直接控制

$$\sup_x |F_n(x) - F(x)|.$$

后者需要同时控制整个阈值函数类。

对 $x, y \in \mathbb{R}$ ，令 $x \wedge y = \min\{x, y\}$ ，则

$$\text{Cov}(F_n(x), F_n(y)) = \frac{F(x \wedge y) - F(x)F(y)}{n}. \quad (1.3)$$

1.3 经验测度与代入原理

对随机样本 $X_1, \dots, X_n$, 定义经验测度

$$P_n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i},$$

其中 δ_x 是点质量测度:

$$\delta_x(A) = \mathbf{1}_A(x), \quad \int f d\delta_x = f(x).$$

因此

$$P_n(A) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_A(X_i), \quad P_n f = \frac{1}{n} \sum_{i=1}^n f(X_i).$$

经验 CDF 是特殊情形

$$F_n(t) = P_n((-\infty, t]) = P_n \mathbf{1}_{(-\infty, t]}.$$

命题 1.3.1: 经验积分的均值与方差

若 f 可积, 则

$$E(P_n f) = P f.$$

若 $f \in L^2(P)$, 则

$$\text{Var}(P_n f) = \frac{\text{Var}(f(X))}{n}.$$

1.3.1 统计泛函与代入原理

定义 1.3.1: 统计泛函

设 $\mathcal{Q}$ 包含统计模型 $\mathcal{P}$ 以及所考虑的经验测度。统计泛函是映射

$$T: \mathcal{Q} \rightarrow \mathcal{D}.$$

$T(P)$ 表示总体分布的某个特征。用 P_n 替换未知 P , 得到代入估计量

$$\widehat{\theta}_n = T(P_n).$$

对固定可积函数 ψ ,

$$T_\psi(P) = P\psi = \int \psi dP$$

是关于分布 P 的线性泛函, 因为

$$T_\psi(aP_1 + bP_2) = aT_\psi(P_1) + bT_\psi(P_2).$$

代入 P_n 后,

$$T_\psi(P_n) = P_n\psi = \frac{1}{n} \sum_{i=1}^n \psi(X_i).$$

“线性”是对分布而言

$\psi(x)$ 本身不必对 x 线性。例如 $\psi(x) = x^2$ 虽是非线性函数, 但 $P \mapsto P(x^2)$ 仍对 P 线性。方差

$$\text{Var}_P(X) = P(x^2) - (Px)^2$$

则不是线性泛函, 因为它包含积分结果的平方。

均值与方差的直接代入估计为

$$\bar{X} = P_n x, \quad S_n^2 = P_n(x^2) - (P_n x)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

分位数泛函及其代入估计为

$$T_p(P) = F^{-1}(p), \quad T_p(P_n) = F_n^{-1}(p).$$

1.3.2 M-估计与 Z-估计

设 $m_\theta(x)$ 衡量候选参数 θ 在观测 x 上的表现。总体准则与经验准则分别是

$$M(\theta) = P m_\theta, \quad M_n(\theta) = P_n m_\theta.$$

M-估计定义为

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} P_n m_\theta.$$

若使用损失 $\rho_\theta = -m_\theta$, 等价地写为最小化 $P_n \rho_\theta$ 。

平方损失给出样本均值

取 $\rho_\theta(x) = (x - \theta)^2$ 。由于

$$E(X - \theta)^2 = \text{Var}(X) + (\mu - \theta)^2,$$

总体最优点是 $\theta = \mu$ 。经验问题

$$\arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n (X_i - \theta)^2$$

的一阶条件给出 $\hat{\theta}_n = \bar{X}$ 。若取绝对值损失 $|x - \theta|$, 相应 M-估计量则是样本中位数。

在控制模型中取

$$m_{\theta}(x) = \log p_{\theta}(x),$$

便得到最大似然估计。因此 MLE 是 M-估计的特殊情形。

Z-估计从总体估计方程出发：设 $\psi_{\theta} : \mathcal{X} \rightarrow \mathbb{R}^s$ ，总体参数满足

$$P\psi_{\theta(P)} = 0.$$

用 P_n 替换 P ，得到

$$P_n\psi_{\hat{\theta}_n} = 0.$$

任何解都称为 Z-估计量。

样本均值也是 Z-估计

取 $\psi_{\theta}(x) = x - \theta$ 。总体方程

$$E(X - \theta) = 0$$

的解为 $\theta = \mu$ ；经验方程

$$\frac{1}{n} \sum_{i=1}^n (X_i - \theta) = 0$$

的解为 $\hat{\theta}_n = \bar{X}$ 。

若 M-准则光滑且最优点位于参数空间内部，其一阶条件通常给出 Z-方程。最大似然中的得分函数

$$\dot{\ell}_{\theta}(x) = \nabla_{\theta} \log p_{\theta}(x)$$

满足

$$0 = \nabla_{\theta} \ell_n(\hat{\theta}_n) = n P_n \dot{\ell}_{\hat{\theta}_n}.$$

边界最大值和不可微似然不一定满足这个方程，需要单独处理。

1.4 收敛方式与随机阶

1.4.1 四种收敛

设 $\mathbf{Y}_n, \mathbf{Y} \in \mathbb{R}^k$ 。主要收敛概念如下：

$$\mathbf{Y}_n \xrightarrow{\text{a.s.}} \mathbf{Y} \iff P(\lim_n \mathbf{Y}_n = \mathbf{Y}) = 1,$$

$$\mathbf{Y}_n \xrightarrow{L^r} \mathbf{Y} \iff E \|\mathbf{Y}_n - \mathbf{Y}\|_r^r \rightarrow 0,$$

$$\mathbf{Y}_n \xrightarrow{P} \mathbf{Y} \iff P(\|\mathbf{Y}_n - \mathbf{Y}\| > \varepsilon) \rightarrow 0 \quad \forall \varepsilon > 0,$$

$$\mathbf{Y}_n \xrightarrow{d} \mathbf{Y} \iff P_{\mathbf{Y}_n} \Rightarrow P_{\mathbf{Y}}.$$

依分布收敛等价于：对每个有界连续函数 h ,

$$E h(\mathbf{Y}_n) \rightarrow E h(\mathbf{Y}).$$

定理 1.4.1: 依概率收敛的子序列刻画

$\mathbf{Y}_n \xrightarrow{P} \mathbf{Y}$ 当且仅当每个子序列 $(\mathbf{Y}_{n_j})$ 都存在一个进一步子序列 $(\mathbf{Y}_{n_{j_\ell}})$, 使

$$\mathbf{Y}_{n_{j_\ell}} \xrightarrow{\text{a.s.}} \mathbf{Y}.$$

标准蕴含关系为

$$\mathbf{Y}_n \xrightarrow{\text{a.s.}} \mathbf{Y} \Rightarrow \mathbf{Y}_n \xrightarrow{P} \mathbf{Y} \Rightarrow \mathbf{Y}_n \xrightarrow{d} \mathbf{Y}.$$

若有 L^r 收敛, 也能由 Markov 不等式推出依概率收敛。

1.4.2 矩不等式

定理 1.4.2: Markov 不等式

若 $Z \geq 0$ 且 $E Z < \infty$, 则对每个 $t > 0$,

$$P(Z \geq t) \leq \frac{E Z}{t}.$$

对 $Z = (X - E X)^2$ 应用 Markov 不等式, 得到 Chebyshev 不等式

$$P(|X - E X| \geq t) \leq \frac{\text{Var}(X)}{t^2}.$$

更一般地,

$$P(\|\mathbf{Y}_n - \mathbf{Y}\|_r > \varepsilon) \leq \frac{E \|\mathbf{Y}_n - \mathbf{Y}\|_r^r}{\varepsilon^r}. \quad (1.4)$$

1.4.3 随机阶

对正确定数列 a_n , 定义

$$Y_n = O_p(a_n) \iff \frac{Y_n}{a_n} \text{ 依概率有界,}$$

$$Y_n = o_p(a_n) \iff \frac{Y_n}{a_n} \xrightarrow{P} 0.$$

更具体地, $Y_n = O_p(a_n)$ 表示对任意 $\varepsilon > 0$, 存在 $C_\varepsilon < \infty$, 使

$$\sup_{n \geq 1} P(|Y_n| > C_\varepsilon a_n) < \varepsilon.$$

基本运算规则包括

$$\begin{aligned} o_p(a_n)O_p(b_n) &= o_p(a_nb_n), \\ O_p(a_n) + O_p(b_n) &= O_p(a_n + b_n), \\ o_p(a_n) + o_p(b_n) &= o_p(a_n + b_n). \end{aligned}$$

样本均值的随机阶

若 X_i i.i.d., 均值为 μ 、方差为 σ^2 , 则中心极限定理给出

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

因此

$$\bar{X}_n - \mu = O_p(n^{-1/2}) = o_p(1),$$

但一般不是 $o_p(n^{-1/2})$, 因为标准化误差并未收敛到零, 而是收敛到非退化正态分布。

1.5 极限定理与变换

1.5.1 大数定律与中心极限定理

若 X_i i.i.d., 均值为 μ 、方差为 $\sigma^2 < \infty$, Chebyshev 不等式给出

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0. \quad (1.5)$$

定理 1.5.1: 强大数定律

若 $X_i \stackrel{\text{i.i.d.}}{\sim} P$ 且 $P|f| < \infty$, 则

$$P_n f \xrightarrow{\text{a.s.}} P f.$$

特别地, 对每个固定 x , $F_n(x) \xrightarrow{\text{a.s.}} F(x)$ 。

定理 1.5.2: 中心极限定理

若 $Pf^2 < \infty$, $\sigma_f^2 = \text{Var}(f(X)) \in (0, \infty)$, 则

$$\sqrt{n}(P_n - P)f = \frac{1}{\sqrt{n}} \sum_{i=1}^n \{f(X_i) - Pf\} \xrightarrow{d} N(0, \sigma_f^2).$$

固定 x 并取 $f_x(z) = \mathbf{1}_{\{z \leq x\}}$, 可得

$$\sqrt{n}\{F_n(x) - F(x)\} \xrightarrow{d} N(0, F(x)\{1 - F(x)\}).$$

大数定律说明误差消失，中心极限定理则描述误差在 $n^{-1/2}$ 尺度上的波动。

1.5.2 Lindeberg 中心极限定理

定理 1.5.3: Lindeberg 中心极限定理

对每个 n ，设 $X_{n1}, \dots, X_{nk_n}$ 相互独立。令

$$Y_{nj} = X_{nj} - \mathbb{E} X_{nj}, \quad s_n^2 = \sum_{j=1}^{k_n} \text{Var}(X_{nj}) \in (0, \infty).$$

若对每个 $\varepsilon > 0$,

$$\frac{1}{s_n^2} \sum_{j=1}^{k_n} \mathbb{E} \left[Y_{nj}^2 \mathbf{1}_{\{|Y_{nj}| > \varepsilon s_n\}} \right] \rightarrow 0, \quad (1.6)$$

则

$$\boxed{\frac{1}{s_n} \sum_{j=1}^{k_n} Y_{nj} \xrightarrow{d} N(0, 1).} \quad (1.7)$$

Lindeberg 条件表示：相对于总方差 s_n^2 ，异常大项贡献的方差比例趋于零。它排除了由一个或少数几个变量支配全部波动的情形。

异质 Bernoulli 顾客例子

设第 n 天有 n 位独立顾客，

$$X_{nj} \sim \text{Bernoulli}\left(\frac{j}{2n}\right), \quad j = 1, \dots, n.$$

总购买人数 $T_n = \sum_j X_{nj}$ 满足

$$\mathbb{E} T_n = \frac{n+1}{4}, \quad s_n^2 = \frac{(n+1)(4n-1)}{24n} \sim \frac{n}{6}.$$

由于 $|X_{nj} - \mathbb{E} X_{nj}| \leq 1$ 而 $s_n \rightarrow \infty$ ，对固定 $\varepsilon > 0$ ，事件

$$|Y_{nj}| > \varepsilon s_n$$

最终不可能发生，故 Lindeberg 条件成立。因此

$$\frac{T_n - (n+1)/4}{\sqrt{(n+1)(4n-1)/(24n)}} \xrightarrow{d} N(0, 1).$$

各顾客购买概率不同，但总购买人数仍具有正态极限。

1.5.3 连续映射定理与 Slutsky 定理

定理 1.5.4: 连续映射定理

若 g 在除 P_Y -零测集外的每一点连续, 则

$$Y_n \xrightarrow{\text{a.s.}} Y \Rightarrow g(Y_n) \xrightarrow{\text{a.s.}} g(Y),$$

$$Y_n \xrightarrow{P} Y \Rightarrow g(Y_n) \xrightarrow{P} g(Y),$$

$$Y_n \xrightarrow{d} Y \Rightarrow g(Y_n) \xrightarrow{d} g(Y).$$

例如, 若 $\bar{X}_n \xrightarrow{P} \mu$ 且 g 在 μ 处连续, 则

$$g(\bar{X}_n) \xrightarrow{P} g(\mu).$$

命题 1.5.1: 渐近等价

若

$$U_n \xrightarrow{d} U, \quad \|V_n - U_n\| \xrightarrow{P} 0,$$

则 $V_n \xrightarrow{d} U$ 。

定理 1.5.5: Slutsky 定理

若 $Y_n \xrightarrow{d} Y$ 、 $Z_n \xrightarrow{P} c$, 其中 c 为常数, 则

$$(Y_n, Z_n) \xrightarrow{d} (Y, c).$$

因此

$$Y_n + Z_n \xrightarrow{d} Y + c, \quad Z_n Y_n \xrightarrow{d} cY,$$

且当 $c \neq 0$ 时,

$$\frac{Y_n}{Z_n} \xrightarrow{d} \frac{Y}{c}.$$

学生化样本均值

令

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

中心极限定理给出

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1),$$

而大数定律与连续映射定理给出 $S_n/\sigma \xrightarrow{P} 1$ 。由 Slutsky 定理,

$$\boxed{\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \xrightarrow{d} N(0, 1).}$$

相合的尺度估计量可以替代未知总体尺度, 而不改变一阶极限分布。

1.5.4 Delta 方法

连续映射定理可以处理相合性, 却不能描述非线性变换后的一阶波动。Delta 方法将随机变量的 Taylor 展开与已有渐近分布结合起来。

命题 1.5.2: 随机 Taylor 展开

若 $\mathbf{X}_n \xrightarrow{P} \mathbf{c}$, 且当 $\mathbf{h} \rightarrow 0$ 时

$$g(\mathbf{c} + \mathbf{h}) = g(\mathbf{c}) + \sum_{j=1}^m \frac{1}{j!} D^j g(\mathbf{c})[\mathbf{h}, \dots, \mathbf{h}] + R_m(\mathbf{h}),$$

其中 $R_m(\mathbf{h})/\|\mathbf{h}\|^m \rightarrow 0$, 则

$$\begin{aligned} g(\mathbf{X}_n) &= g(\mathbf{c}) + \sum_{j=1}^m \frac{1}{j!} D^j g(\mathbf{c})[\mathbf{X}_n - \mathbf{c}, \dots, \mathbf{X}_n - \mathbf{c}] \\ &\quad + \|\mathbf{X}_n - \mathbf{c}\|^m Q_n, \quad Q_n = o_p(1). \end{aligned}$$

定理 1.5.6: 一阶 Delta 方法

若 $a_n \rightarrow \infty$,

$$a_n(\mathbf{X}_n - \mathbf{c}) \xrightarrow{d} \mathbf{Y},$$

且 $g: \mathbb{R}^k \rightarrow \mathbb{R}$ 在 $\mathbf{c}$ 处可微, 则

$$\boxed{a_n\{g(\mathbf{X}_n) - g(\mathbf{c})\} \xrightarrow{d} \nabla g(\mathbf{c})^\top \mathbf{Y}.}$$

若 $\mathbf{Y} \sim N_k(0, \Sigma)$, 则极限为

$$N(0, \nabla g(\mathbf{c})^\top \Sigma \nabla g(\mathbf{c})).$$

证明的核心是 Taylor 展开

$$g(\mathbf{X}_n) - g(\mathbf{c}) = \nabla g(\mathbf{c})^\top (\mathbf{X}_n - \mathbf{c}) + \|\mathbf{X}_n - \mathbf{c}\| Q_n,$$

其中 $Q_n = o_p(1)$ 。乘以 a_n 后, 余项是 $O_p(1)o_p(1) = o_p(1)$, 再应用 Slutsky 定理。

若前 $m - 1$ 阶导数均在 c 处为零，而至少一个 m 阶导数非零，则需要用 a_n^m 缩放，并保留 Taylor 展开的第 m 阶齐次多项式。这就是高阶 Delta 方法。

样本均值的平方

由

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

对 $g(t) = t^2$ ，当 $\mu \neq 0$ 时， $g'(\mu) = 2\mu$ ，故

$$\sqrt{n}(\bar{X}_n^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2).$$

当 $\mu = 0$ 时一阶导数消失，需要二阶 Delta 方法：

$$n\bar{X}_n^2 \xrightarrow{d} \sigma^2 Z^2, \quad Z \sim N(0, 1).$$

样本方差的渐近分布

若 $P(x^4) < \infty$ ，令

$$S_n^2 = P_n(x^2) - (P_n x)^2.$$

对 $\mathbf{W}_i = (X_i, X_i^2)^\top$ 使用二维 CLT，再对 $h(a, b) = b - a^2$ 使用 Delta 方法。梯度为

$$\nabla h(\mu, Px^2) = (-2\mu, 1)^\top.$$

中心化线性项化简为

$$L(X) = (X - \mu)^2 - \sigma^2,$$

故渐近方差为

$$\text{Var}\{L(X)\} = P\{(x - \mu)^4\} - \sigma^4.$$

最终

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, P\{(x - \mu)^4\} - \sigma^4).$$

使用分母 $n - 1$ 的样本方差是 $\frac{n}{n-1}S_n^2$ ，因该因子趋于 1，二者具有相同的一阶极限分布。

本章总结

概率分布与期望描述总体量，经验测度则给出对应的样本量。Markov 和 Chebyshev 不等式把矩信息转化为概率上界；大数定律说明估计误差消失；中心极限定理描述 $n^{-1/2}$ 尺度上的随机波动；连续映射、Slutsky 定理和 Delta 方法则把这些极限传递到非线性代入估计量。

这些工具将继续支撑后续的集中不等式、一致经验过程以及 M-估计与 Z-估计理论。

复习路线

建议按以下顺序复习：

$$P_n f \rightarrow P f \implies \sqrt{n}(P_n - P)f \xrightarrow{d} N(0, \sigma_f^2) \implies g(P_n f) \text{ 的 Delta 展开.}$$

首先确认估计量是否相合，再寻找其波动尺度，最后分析非线性变换和学生化。