

高等统计学中文学习笔记

第二章：模型与信息压缩

翻译、整理与学习注记

Studyer-Tang

<https://github.com/Studyer-Tang>

本文为个人课程学习记录，依据 Fang Yao 老师的课程讲义整理，并加入中文翻译、直观解释与例题。感谢 Fang Yao 老师提供清晰的课程框架和原始讲义。本文并非官方讲义或官方译本，如有疏漏，以课程原材料与课堂讲授为准。

2026 年 9 月

目录

第 2 章 统计模型、指数族、充分性与完备性	1
2.1 统计模型	1
2.1.1 从具体样本到模型	1
2.1.2 密度与似然：同一个公式的两个视角	2
2.1.3 最大似然估计与边界	3
2.1.4 参数无关因子与参数相关支撑	4
2.2 指数族	5
2.2.1 为什么整理成指数形式？	5
2.2.2 学习追问：满秩的两条分别检查什么？	6
2.2.3 学习追问：弯曲指数族“弯”的是哪一边？	7
2.3 充分性	7
2.3.1 定义：知道摘要后，还剩什么随机性？	7
2.3.2 共同支配概率：为什么突然引入一个新分布？	8
2.3.3 Fisher–Neyman 因子分解定理	9
2.3.4 典型充分统计量与模型依赖性	11
2.4 最小充分性	12
2.4.1 为什么充分之后还需要最小？	12
2.4.2 学习追问：为什么在小模型里证明，还能推广到大模型？	12
2.4.3 可数模型的显式构造	13
2.4.4 似然比判别与典型例子	14
2.5 完备性	15
2.5.1 从压缩信息转向函数唯一性	15
2.5.2 有界完备且充分推出最小充分	16
2.5.3 两种直接证明：多项式与积分上限	17
2.5.4 指数族完备性及开集的作用	18
2.6 辅助统计量与 Basu 定理	19
2.6.1 辅助性要求整个分布不含参数	19
2.6.2 Basu 定理的条件与完整证明	19
2.6.3 正态与指数模型的独立性应用	20
2.6.4 反例：最小充分并不意味着完备	21
2.7 总结与学习检查	21

第 2 章 统计模型、指数族、充分性与完备性

本章依据 Fang Yao 老师《第 02 章-讲义》整理，原文件共 22 页，对应讲义正文第 27-48 页。定义、定理及例子的编号沿用讲义；“学习注记”和“补充证明”记录个人理解与讨论中的展开，不是讲义逐字译文。Slides 的编号与讲义不同，例如 Slides 引理 2.7 对应讲义引理 2.3.1，Slides 命题 2.9 对应讲义命题 2.4.1。

学习起点：本章到底要做什么？

第一章主要问：样本量增大时，经验分布和估计量怎样逼近总体？第二章先固定样本量，问：在指定模型下，原始数据中的哪些部分真正参与对参数的比较？

本章依次研究三个问题：怎样用似然比较候选参数；怎样压缩样本而保持充分性；怎样用完备性得到函数唯一性、用 Basu 定理得到独立性。“已整理”不等于已经能够独立证明，实际追问和待复习内容另见本章学习历程。

2.1 统计模型

2.1.1 从具体样本到模型

想估计硬币正面概率 p ，独立抛掷 n 次，把正面记作 1。例如

$$x = (1, 0, 1, 1, 0), \quad y = (0, 1, 1, 0, 1)$$

都有三次成功。独立性给出

$$P_p(\mathbf{X} = x) = p(1-p)pp(1-p) = p^3(1-p)^2 = P_p(\mathbf{X} = y).$$

一般地，记 $s = \sum_i x_i$ ，则

$$P_p(\mathbf{X} = x) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^s (1-p)^{n-s}.$$

固定 n 后，这个公式只需要成功次数，不需要成功顺序。后面要把“似乎可以丢弃顺序”变成严格的充分性结论。

具体排列与成功次数不是同一个事件

某一个排列的概率是 $p^s(1-p)^{n-s}$ ；成功次数等于 s 的概率要对所有相容排列求和，才有组合数：

$$P_p(S=s) = \binom{n}{s} p^s (1-p)^{n-s}.$$

知道 S 通常不能恢复完整样本，但这不必然意味着损失了关于 p 的信息。

参数模型是一族共同样本空间上的概率分布：

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}.$$

这里 Θ 是允许的参数集合， θ 是未知常数， P_θ 是对应的数据生成规律。i.i.d. 样本的联合模型为

$$\mathcal{P}^{(n)} = \{P_\theta^{\otimes n} : \theta \in \Theta\}.$$

$\mathbf{X} = (X_1, \dots, X_n)$ 表示随机样本， $\mathbf{x} = (x_1, \dots, x_n)$ 表示已观测到的实现值。统计量是计算规则不含未知参数的数据函数；若 μ 未知， $\bar{X} - \mu$ 不是直接可计算的统计量。

定义 2.1.1：可识别性

模型可识别是指

$$P_\theta = P_{\theta'} \implies \theta = \theta'.$$

等号指两个概率测度对每个事件都给出相同概率，不是某份样本的两个似然值碰巧相同。

已知方差的正态位置模型可识别：分布相同则期望相同，故均值参数相同。反之，模型 $N(\alpha\beta, 1)$ 中， $(\alpha, \beta) = (1, 2)$ 和 $(2, 1)$ 产生同一分布，只能识别乘积，不能在整个模型中分别识别两者。增加样本量不能消除这种参数化问题。

2.1.2 密度与似然：同一个公式的两个视角**定义 2.1.2：受支配分布族**

若存在共同的 σ -有限测度 ν ，使

$$P \ll \nu \quad \forall P \in \mathcal{P},$$

则称模型受 ν 支配。记 $p_\theta = dP_\theta/d\nu$ 。

计数测度对应离散 PMF，Lebesgue 测度对应通常的连续 PDF。密度满足

$$P_\theta(A) = \int_A p_\theta d\nu.$$

独立同分布样本的联合密度与似然为

$$p_{\theta}^{(n)}(\mathbf{x}) = \prod_i p_{\theta}(x_i), \quad L_{\mathbf{x}}^{(n)}(\theta) = p_{\theta}^{(n)}(\mathbf{x}).$$

固定 θ ，它描述数据的概率规律；固定 $\mathbf{x}$ ，它比较候选参数。连续模型使用密度值，不是通常为零的单点概率。

似然不是参数的概率分布

当 $n = 5, s = 3$ 时， $L(p) = p^3(1-p)^2$ ，但

$$\int_0^1 L(p) dp = \frac{1}{4} - \frac{2}{5} + \frac{1}{6} = \frac{1}{60} \neq 1.$$

比较 $L(0.6)/L(0.2) = 6.75$ ，只是比较同一数据在两个候选参数下的概率，不是两个参数自身的概率比。后验分布还需要先验和归一化。

2.1.3 最大似然估计与边界

定义 2.1.3：最大似然估计

若统计量 $\hat{\theta}(\mathbf{X})$ 的观测值满足

$$\hat{\theta}(\mathbf{x}) \in \arg \max_{\theta \in \Theta} L_{\mathbf{x}}^{(n)}(\theta),$$

则称为 MLE。 $\arg \max$ 是最大化参数的集合，不是最大的函数值。

对数严格递增，故最大化似然等价于最大化扩展对数似然，约定 $\log 0 = -\infty$ ：

$$\ell_{\mathbf{x}}^{(n)}(\theta) = \sum_i \log p_{\theta}(x_i).$$

这与第一章相接：

$$n^{-1} \ell_{\mathbf{X}}^{(n)}(\theta) = P_n \log p_{\theta}.$$

本章先研究有限样本结构，后续一致性理论才讨论这个经验准则的极限。非空紧参数空间上的上半连续似然可以保证最大值取到；严格凹性可以保证已存在的最大化解唯一，但不会自动保证存在性。

例 2.1.2：Bernoulli 的 MLE

固定二元样本，令 $s = \sum_i x_i$ 。在 $0 < s < n$ 时，

$$\ell(p) = s \log p + (n-s) \log(1-p), \quad \ell'(p) = \frac{s}{p} - \frac{n-s}{1-p}.$$

因为 $p(1-p) > 0$,

$$\ell'(p) = 0 \iff s(1-p) = (n-s)p \iff s = np \iff p = s/n.$$

又

$$\ell''(p) = -s/p^2 - (n-s)/(1-p)^2 < 0,$$

所以这是唯一内点最大值。若 $s = 0$, $L(p) = (1-p)^n$ 递减; 若 $s = n$, $L(p) = p^n$ 递增。在 $[0, 1]$ 上分别得到边界 MLE 0, 1, 在 $(0, 1)$ 上却都没有 MLE, 因为上确界只能在被排除的边界逼近。

2.1.4 参数无关因子与参数相关支撑

若固定样本上 $a(\mathbf{x}) > 0$, 且

$$p_{\theta}^{(n)}(\mathbf{x}) = a(\mathbf{x})b_{\theta}(\mathbf{x}),$$

其中 a 不含参数, 则相同因子在参数之间的似然比中消去, 也不改变最大化位置。它仍是概率模型的一部分, 计算样本事件概率时不能删除。

Poisson 样本满足

$$p_{\lambda}^{(n)}(\mathbf{x}) = e^{-n\lambda} \lambda^{\sum_i x_i} \prod_i \frac{1}{x_i!}.$$

例如 $(0, 2)$ 与 $(1, 1)$ 的似然分别为

$$\frac{1}{2}e^{-2\lambda}\lambda^2, \quad e^{-2\lambda}\lambda^2.$$

二者不相等, 却始终成固定比例, 对任意两个参数的相对比较相同。

给定总和为 2, 三个可能样本为 $(0, 2)$ 、 $(1, 1)$ 、 $(2, 0)$ 。它们的条件概率依次为 $1/4$ 、 $1/2$ 、 $1/4$, 不等概率但都不含参数。

对 $U(0, \theta)$, 联合密度则为

$$p_{\theta}^{(n)}(\mathbf{x}) = \theta^{-n} \mathbf{1}_{\{x_{(n)} < \theta\}} \mathbf{1}_{\{x_{(1)} > 0\}}.$$

示性函数含参数, 不能忽略。若最大观测是 3, 则 $\theta = 2$ 与数据不相容; 仅保留 θ^{-n} 会错误地给它正似然。

两种似然比较, 以及与后文的联系

固定同一个样本, 比较 $L_{\mathbf{x}}(\theta)/L_{\mathbf{x}}(\theta')$, 用于参数推断; 比较两组样本的整条似然是否满足

$$L_{\mathbf{x}}(\theta) = c(\mathbf{x}, \mathbf{y})L_{\mathbf{y}}(\theta) \quad \forall \theta, \quad c(\mathbf{x}, \mathbf{y}) > 0$$

且 c 不含参数, 用于判断哪些样本可以合并。

参数依赖支撑时要同时比较零值区域，不能只在公共正值区域约分。按严格端点密度 $\mathbf{1}_{\{x < \theta\}}$ ，均匀模型的 MLE 可能只有未取到的上确界；改用含端点密度会改变逐点最大化。计算时应保持同一密度版本。

2.2 指数族

2.2.1 为什么整理成指数形式？

前面发现 Bernoulli 和 Poisson 的参数比较都只需要总和。指数族为这种现象提供统一形式：参数和数据通过一个有限维内积相结合，独立样本相乘后变成自然统计量的求和。

定义 2.2.1：自然指数族

相对于共同 σ -有限测度 ν ，密度为

$$p_{\eta}(x) = \exp\{\eta^{\top} T(x) - \zeta(\eta)\} h(x), \quad \eta \in \Xi \subseteq \mathbb{R}^k.$$

这里 T 是自然统计量， η 是自然参数， $h \geq 0$ 不含参数，而

$$\zeta(\eta) = \log \int e^{\eta^{\top} T(x)} h(x) \nu(dx)$$

负责归一化。最大自然参数空间由该积分有限且为正的参数组成；实际子模型可只使用其中一部分。

积分核对：

$$\int p_{\eta} d\nu = e^{-\zeta(\eta)} \int e^{\eta^{\top} T(x)} h(x) d\nu = 1.$$

若用可逆矩阵 A 替换为 $\tilde{T} = AT$ 、 $\tilde{\eta} = A^{-\top} \eta$ ，内积不变。这说明表示不唯一，统计意义取决于所生成的信息，而不取决于选用的坐标名称。

例 2.2.1–2.2.3：从密度中识别自然参数

Bernoulli 模型中，对 $x \in \{0, 1\}$ ，

$$p^x (1-p)^{1-x} = \exp \left\{ x \log \frac{p}{1-p} + \log(1-p) \right\}.$$

取 $\eta = \log[p/(1-p)]$ ，反解得 $p = e^{\eta}/(1 + e^{\eta})$ ，所以

$$T(x) = x, \quad \zeta(\eta) = \log(1 + e^{\eta}), \quad \Xi = \mathbb{R}.$$

Poisson 模型中，

$$e^{-\lambda} \lambda^x / x! = e^{x\eta - e^{\eta}} / x!, \quad \eta = \log \lambda \in \mathbb{R}.$$

所以 $T(x) = x$ 、 $h(x) = 1/x!$ 、 $\zeta(\eta) = e^\eta$ 。

正态两参数模型中，

$$-\frac{(x-\mu)^2}{2\sigma^2} = \frac{\mu}{\sigma^2}x - \frac{x^2}{2\sigma^2} - \frac{\mu^2}{2\sigma^2}.$$

可取

$$T(x) = (x, x^2), \quad \eta_1 = \mu/\sigma^2, \quad \eta_2 = -1/(2\sigma^2), \quad h(x) = 1,$$

$$\zeta(\eta) = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2} \log \frac{-\pi}{\eta_2}, \quad \Xi = \mathbb{R} \times (-\infty, 0).$$

对于 i.i.d. 样本，

$$\begin{aligned} p_\eta^{(n)}(\mathbf{x}) &= \prod_i e^{\eta^\top T(x_i) - \zeta(\eta)} h(x_i) \\ &= \exp \left\{ \eta^\top \sum_i T(x_i) - n\zeta(\eta) \right\} \prod_i h(x_i). \end{aligned}$$

因此参数相关部分只需要 $T_n = \sum_i T(X_i)$ 。正态模型对应 $(\sum_i X_i, \sum_i X_i^2)$ ，第二项是“平方后求和”，不是 $(\bar{X})^2$ 。

2.2.2 学习追问：满秩的两条分别检查什么？

讲义对满秩的约定同时要求：

1. 统计量一侧没有仿射冗余：

$$a^\top T(X) = b \text{ 几乎必然} \implies a = 0;$$

2. 自然参数一侧含非空开集：

$$\text{int}_{\mathbb{R}^k} \Xi \neq \emptyset.$$

第一条的 a.s. 按共同载体测度或其等价概率版本理解；“rank”是指指数族表示的性质，不是在计算某个观测向量的矩阵秩。

追问：是不是统计量各分量线性无关？

还要把常数 1 算进去。 $T = (X, 2X)$ 满足 $2T_1 - T_2 = 0$ ，有冗余； $T = (X, X+1)$ 满足 $T_2 - T_1 = 1$ ，也有冗余。需排除的是右侧为任意常数的非平凡仿射关系，而不只是齐次线性关系。

对具有正态分布的 X ， $T = (X, X^2)$ 没有仿射冗余：若 $a_1x + a_2x^2 = b$ 几乎处处成立，连续多项式必恒等于零，从而 $a_1 = a_2 = b = 0$ 。其取值虽在抛物线上，却不被一条直线包含。没有仿射冗余既不意味着分量独立，也不排除非线性函数关系。

“本质值域”忽略零概率修改。对于欧氏空间中的随机向量，点 t 属于本质值域意味着每个邻域都有正概率：

$$P(\|T - t\| < \varepsilon) > 0 \quad \forall \varepsilon > 0.$$

不要求 $P(T = t) > 0$ 。例如将 $(X, 2X)$ 在正态零概率事件 $\{X = 0\}$ 上改为 $(0, 100)$ ，仍不能消除几乎必然的仿射冗余。

第二条则要求自然参数集合内至少容得下一个 k 维开球。正态两参数模型的 $\Xi = \mathbb{R} \times (-\infty, 0)$ 可容纳以 $(0, -1)$ 为中心、半径 $1/2$ 的圆盘，因此满足第二条。

2.2.3 学习追问：弯曲指数族“弯”的是哪一边？

通常在光滑、正则的参数化下，弯曲族写为

$$\eta = \eta(\theta) \in \mathbb{R}^k, \quad \theta \in \Theta \subseteq \mathbb{R}^d, \quad d < k.$$

原始参数 θ 只有 d 个自由方向，决定了 k 个自然参数坐标，所以自然参数只能沿低维曲面变化。仅凭任意映射 $d < k$ 不能保证其像为光滑曲面，这里使用通常的正则参数化语境。

例如 $X \sim N(\theta, \theta^2)$, $\theta > 0$ ，仍有 $T = (X, X^2)$ ，但

$$\eta_1 = 1/\theta, \quad \eta_2 = -1/(2\theta^2) \implies \eta_2 = -\eta_1^2/2.$$

参数在二维平面中沿一条抛物线变化，不能包含二维开球。

两个抛物线，为什么结论不同？

统计量 (x, x^2) 落在抛物线上，不违反第一条，因为第一条仅排除仿射超平面，二维中即直线。自然参数落在抛物线上，却违反第二条，因为第二条要求真正的二维开区域。

因此，统计量无仿射冗余，并不推出整个表示满秩。缺少开集也只意味着后面的指数族完备性定理不能直接使用，并非自动证明不完备；不完备需要另构造反例。

2.3 充分性

2.3.1 定义：知道摘要后，还剩什么随机性？

定义 2.3.1：充分统计量

若样本 $\mathbf{X}$ 给定 $T(\mathbf{X})$ 的条件分布可以对所有参数选取同一个不含参数的版本，则称 T 充分。

充分性不要求 T 的边缘分布不含参数，也不表示 $\mathbf{X}$ 与 T 独立。完整样本本身总是充分，故“充分”也不自动表示低维或简洁。

Bernoulli 样本中，若 $\sum_i x_i = t$ ，则

$$P_p(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{p^t(1-p)^{n-t}}{\binom{n}{t} p^t(1-p)^{n-t}} = \binom{n}{t}^{-1}.$$

否则条件概率为零。给定成功次数后，所有相容排列的条件规律都不含 p ，故总和充分。

2.3.2 共同支配概率：为什么突然引入一个新分布？

引理 2.3.1：共同支配概率

非空模型 $\mathcal{P}$ 若被某个 σ -有限测度支配，则可选有限或可数个 $P_j \in \mathcal{P}$ 及严格正权重 w_j ，使

$$\sum_j w_j = 1, \quad Q = \sum_j w_j P_j, \quad P \ll Q \quad \forall P \in \mathcal{P}.$$

讲义用无穷序列表示；有限族也可用重复分布写成序列，或直接用有限和。

追问：是不是统一在一个概率分布下研究？

可以这样理解，但统一的是参考分布，并没有把不同的 P_θ 变成同一个分布：

$$E_\theta f(X) = E_Q \left[f(X) \frac{dP_\theta}{dQ}(X) \right].$$

不同分布的差异保留在各自的权重中。 Q 固定，不随当前研究的 θ 改变； Q 不必属于原模型，也不表示真实数据来自混合机制。引理只适用于满足共同 σ -有限支配条件的模型，不是所有可能的离散、连续分布都可任意混在一起。

定义上， $P \ll Q$ 意味着 $Q(A) = 0 \Rightarrow P(A) = 0$ ，不是 $P(A) \leq Q(A)$ 。严格正权重保证

$$Q(A) = 0 \Rightarrow P_j(A) = 0 \quad \forall j.$$

单个模型成员未必能支配整个族。对 $\{U(0, \theta) : \theta > 0\}$ ，可取

$$Q = \sum_{j \geq 1} 2^{-j} U(0, j).$$

任取 θ ，选整数 $j \geq \theta$ ，则 $U(0, \theta) \ll U(0, j) \ll Q$ 。选择 j 可以依赖 θ ，但 Q 已经固定。

补充证明：用可数个正密度区域覆盖整个模型

讲义以“本质上确界可由可数子族实现”为工具。下面给出针对本引理的集合版本，避免直接调用那个函数定理。

首先将支配测度 ν 换成等价有限测度。取可数可测分割 $\mathcal{X} = \bigcup_m E_m$ ，每个 $\nu(E_m) < \infty$ ，令

$$\mu(A) = \sum_{m \geq 1} 2^{-m} \frac{\nu(A \cap E_m)}{1 + \nu(E_m)}.$$

则 $\mu(\mathcal{X}) \leq 1$ ，且 $\mu(A) = 0 \iff \nu(A) = 0$ 。

对每个 P 取密度 $p_P = dP/d\nu$, 记 $S_P = \{p_P > 0\}$, 定义

$$M = \sup\{\mu(S_{P_1} \cup \dots \cup S_{P_r}) : r \geq 1, P_i \in \mathcal{P}\}.$$

M 有限。对每个 n , 选一个有限并 B_n 使 $\mu(B_n) > M - 1/n$, 再令 $B = \bigcup_n B_n$ 。由下连续性和有限并的定义,

$$\mu(B) = M.$$

确实, $\mu(B) \geq \mu(B_n) > M - 1/n$; 另一方面每个 $B_1 \cup \dots \cup B_N$ 仍是有限个正密度区域的并, 其测度不超过 M 。

任取其他分布 P , 同理 $\mu(B \cup S_P) \leq M$, 所以

$$\mu(S_P \setminus B) = 0, \quad \nu(S_P \setminus B) = 0.$$

组成 B 的模型成员至多可数, 将它们记为 P_j , 取正权重构成 Q 。它的密度是

$$q = \sum_j w_j p_j, \quad \{q > 0\} = B.$$

若 $Q(A) = 0$, 则 $\int_A q d\nu = 0$, 由 $q > 0$ 于 B 得 $\nu(A \cap B) = 0$ 。任意 p_P 又在 B 外几乎处处为零, 故

$$P(A) = \int_A p_P d\nu = 0.$$

因此每个 $P \ll Q$, 引理得证。

2.3.3 Fisher–Neyman 因子分解定理

定理 2.3.1: 因子分解

在讲义的标准 Borel 样本空间和值域、共同 σ -有限支配等条件下, T 充分, 当且仅当联合密度可写为

$$p_\theta(x) = a_\theta(T(x))h(x)$$

(按相应几乎处处意义理解), 其中 h 不含参数。这里为简化记号, 把完整样本也写作 X , 其联合分布记为 P_θ 。

方向一: 因子分解推出充分性

离散情形下, 在同一个纤维 $\{x : T(x) = t\}$ 内,

$$P_\theta(X = x \mid T = t) = \frac{a_\theta(t)h(x)}{a_\theta(t) \sum_{y: T(y)=t} h(y)} = \frac{h(x)}{\sum_{y: T(y)=t} h(y)}.$$

分母为正时参数因子消去。连续模型不能直接除以零概率事件, 故使用共同概率 Q 。

由引理，取 $Q = \sum_j w_j P_{\theta_j}$ 。其密度为

$$q(x) = h(x)\bar{a}(T(x)), \quad \bar{a}(t) = \sum_j w_j a_{\theta_j}(t).$$

在有效正密度集合上，

$$\frac{dP_\theta}{dQ}(x) = \frac{a_\theta(T(x))}{\bar{a}(T(x))} =: r_\theta(T(x)).$$

零集上任意补定义。换分布时的权重只依赖 T ，这正是离散消因子的测度论版本。

对任意事件 A ，先在固定的 Q 下定义

$$K_A(T) = E_Q(\mathbf{1}_A | T).$$

它是与参数无关的同一个函数。要证明其也是 P_θ 下的条件概率，除可测性外，只需对每个 $C \in \sigma(T)$ 验证积分：

$$\begin{aligned} \int_C K_A(T) dP_\theta &= \int_C K_A(T) r_\theta(T) dQ \\ &= \int_C \mathbf{1}_A r_\theta(T) dQ \\ &= P_\theta(A \cap C). \end{aligned}$$

第二步使用 $\mathbf{1}_C r_\theta(T)$ 为 $\sigma(T)$ -可测非负权重；无界时先截断，再用单调收敛。由条件期望唯一性， $K_A(T) = E_\theta(\mathbf{1}_A | T)$ ， P_θ -a.s.。在标准 Borel 条件下可通过 Q 下的正则条件分布核统一组织这些等式，从而 T 充分。

方向二：充分性推出因子分解

充分性给出不含参数的共同版本

$$E_\theta(\mathbf{1}_A | T) = K_A(T).$$

混合各个分布，对于 $C \in \sigma(T)$ ，

$$\int_C K_A(T) dQ = \sum_j w_j P_{\theta_j}(A \cap C) = Q(A \cap C).$$

所以 $K_A(T) = E_Q(\mathbf{1}_A | T)$ ， Q -a.s.。

令 P_θ^T, Q^T 为 T 的边缘分布。由 $P_\theta \ll Q$ 得 $P_\theta^T \ll Q^T$ ，定义

$$r_\theta(t) = \frac{dP_\theta^T}{dQ^T}(t).$$

这是边缘密度比，不是条件期望。对每个事件 A ,

$$\begin{aligned} P_\theta(A) &= E_\theta K_A(T) = \int K_A(t) dP_\theta^T(t) \\ &= \int K_A(t) r_\theta(t) dQ^T(t) \\ &= E_Q[K_A(T) r_\theta(T)] \\ &= E_Q[\mathbf{1}_A r_\theta(T)] = \int_A r_\theta(T) dQ. \end{aligned}$$

故 $dP_\theta/dQ = r_\theta(T)$, Q -a.s.。取 $h = dQ/d\nu$, RN 链式法则给出

$$p_\theta(x) = r_\theta(T(x))h(x) \quad \nu\text{-a.e.}$$

因子分解得证。

这一大段证明到底在做什么？

引理提供一个固定参考概率 Q ；因子分解使换测度权重只依赖 T ；条件期望定义把“纤维内相对权重不变”变成严谨的共同条件分布。

样本空间积分 $E_Q[\phi(T)]$ 与边缘空间积分 $\int \phi(t) dQ^T(t)$ 相等，但空间和测度不同。不能把 Q 与 Q^T 、条件期望与边缘密度比混为一谈。

2.3.4 典型充分统计量与模型依赖性

因子分解给出：Bernoulli、Poisson 样本的总和充分； $U(0, \theta)$ 的最大值充分。正态两参数模型中，充分统计量可以写为

$$\left(\sum_i X_i, \sum_i X_i^2 \right).$$

令 $V = \sum_i (X_i - \bar{X})^2$, 有

$$\begin{aligned} \bar{X} &= \frac{1}{n} \sum_i X_i, \quad V = \sum_i X_i^2 - n\bar{X}^2, \\ \sum_i X_i &= n\bar{X}, \quad \sum_i X_i^2 = V + n\bar{X}^2. \end{aligned}$$

所以 $(\bar{X}, V)$ 是同一信息的另一种编码。

已知正态方差时仅 $\bar{X}$ 已充分；两参数未知时一般还需 V 。在全部连续密度构成的 i.i.d. 模型中，排序后的完整样本充分：给定排序值，所有排列等概率且与密度无关。讲义同时给出该大模型的最小充分性结论；这里不把它当作已从头证明的非参数定理。

若 T 充分且 $T = \phi(S)$, 由

$$p_\theta(x) = a_\theta(\phi(S(x)))h(x)$$

可知 S 也充分。增加信息不破坏充分性，但对充分统计量任意取函数可能丢失信息。

2.4 最小充分性

2.4.1 为什么充分之后还需要最小？

充分性排除信息损失，却不排除无关细节。已知正态方差的模型中，完整样本、两块样本均值和总体样本均值都充分，但保留的细节不同。

定义 2.4.1：最小充分统计量

T 对 $\mathcal{P}$ 充分，且对任意其他充分统计量 S ，存在同一个不含参数的可测函数 ϕ ，使

$$T = \phi(S) \quad P\text{-a.s.}, \quad \forall P \in \mathcal{P},$$

则 T 最小充分。

追问：“最粗的精确压缩”是什么意思？

$T = \phi(S)$ 的方向是“知道 S 就能恢复 T ”，因此 S 至少包含 T 的信息。最小充分统计量是每一种充分摘要都必须保留的共同核心。

统计量把样本按相同取值分组。摘要越粗，合并的样本越多；最小充分性要求在保持充分性的前提下尽可能合并。它不是简单比较向量维数。具有可测逆的一一变换仅改变编码，不改变信息。

2.4.2 学习追问：为什么在小模型里证明，还能推广到大模型？

命题 2.4.1：最小充分性的推广原则

设 $\mathcal{P}_0 \subseteq \mathcal{P}$ ，且对每个事件 A ，

$$[P(A) = 0 \quad \forall P \in \mathcal{P}_0] \implies [P(A) = 0 \quad \forall P \in \mathcal{P}].$$

若 T 对 $\mathcal{P}$ 充分，并对 $\mathcal{P}_0$ 最小充分，则 T 对 $\mathcal{P}$ 最小充分。

这里“大、小”指候选分布的多少，不是样本量。例如正态均值遍历 $\mathbb{R}$ 是大模型，只保留均值为 0, 1 的两个候选分布是小模型，观察的样本向量并未改变。

证明分四步。

1. 任取对大模型充分的 S 。同一个条件分布版本当然也适用于小模型，所以 S 对小模型充分。
2. 由 T 对小模型最小充分，存在同一个 ϕ ，使 $T = \phi(S)$ 在每个 $P \in \mathcal{P}_0$ 下 a.s. 成立。
3. 定义等式失败的事件

$$N = \{T \neq \phi(S)\}.$$

则 $P(N) = 0$ 对小模型每个分布成立。由假设，它对大模型每个分布也成立。

4. 因此任意大模型充分统计量 S 都能恢复 T 。结合已经假设的“大模型下 T 充分”，得到最小充分性。

为什么不能省略共同零事件条件？

取小模型 $\{U(0, 1)\}$ ，大模型 $\{U(0, 1), U(0, 2)\}$ 。事件 $(1, 2)$ 在小模型下概率为零，却在在大模型某成员下有概率 $1/2$ 。一个等式在小模型几乎必然成立，不能自动推广到大模型。

证明中的异常集必须是 $\{T \neq \phi(S)\}$ 。若复制文本显示成等号，却又写其概率为零，应核对 PDF 中的不等号。

共同支配引理恰好提供满足零事件条件的可数小模型。若

$$Q = \sum_j w_j P_j, \quad P \ll Q \quad \forall P \in \mathcal{P},$$

取 $\mathcal{P}_0 = \{P_j\}$ ，则

$$P_j(A) = 0 \quad \forall j \Rightarrow Q(A) = 0 \Rightarrow P(A) = 0 \quad \forall P \in \mathcal{P}.$$

这就是引理、推广原则和下面可数模型构造之间的衔接。

2.4.3 可数模型的显式构造

定理 2.4.1：可数混合构造

设 $\mathcal{P}_0 = \{P_j : j \in J\}$ 为有限或可数族，取

$$Q = \sum_j w_j P_j, \quad r_j = \frac{dP_j}{dQ}, \quad w_j > 0, \quad \sum_j w_j = 1.$$

则 $R = (r_j)_{j \in J}$ 最小充分。若族内某个 P_0 已支配所有 P_j ，也可用 $(dP_j/dP_0)_j$ 。

证明。取共同测度 ν ，记 $p_j = dP_j/d\nu$ 、 $q = dQ/d\nu$ 。因为 $p_j = r_j q$ ，因子分解给出 R 充分。

任取充分统计量 S ，因子分解写为 $p_j(x) = a_j(S(x))h(x)$ 。由 J 可数，可以合并各个等式的异常零集。于是

$$q(x) = h(x) \sum_j w_j a_j(S(x)).$$

在有效正密度集合上，

$$r_j(x) = \frac{a_j(S(x))}{\sum_\ell w_\ell a_\ell(S(x))}.$$

每个坐标都是 S 的函数，因此整个可数向量 $R = \phi(S)$ ， Q -a.s.。由 $P_j \ll Q$ ，这个表示对每个 P_j 也成立，故最小充分。用 P_0 作参考时，同样由 $p_j/p_0 = a_j(S)/a_0(S)$ 得到结论。

2.4.4 似然比判别与典型例子

定理 2.4.2：似然比判别准则

在讲义的受支配、标准 Borel 框架下，设 T 已充分。使用讲义指定的密度版本，且在同一个共同零集之外，若

$$[p_P(x) = c(x, y)p_P(y) \quad \forall P, \quad c(x, y) > 0 \text{ 不含 } P] \Rightarrow T(x) = T(y),$$

则 T 最小充分。

讲义的版本约定不可省略：使用证明中最小充分统计量 S 给出的密度 $p_P(x) = a_P(S(x))h(x)$ ，并在共同满测 Borel 集上进行比较。不可数个参数分别拥有的零集，其并不一定还是零集。

讲义证明的逻辑。 引用 Bahadur 的存在性结果得到最小充分统计量 S 。在共同满测集上取 $0 < h < \infty$ 。若 $S(x) = S(y)$ ，则

$$p_P(x) = p_P(y) \frac{h(x)}{h(y)} \quad \forall P.$$

假设推出 $T(x) = T(y)$ 。Blackwell–Mackey 定理及 Doob–Dynkin 引理保证 $T = \psi(S)$ 可测地成立。任意充分统计量 U 都能恢复 S ，进而恢复 T ；加上 T 充分，故最小充分。这里的存在性和可测表示结果是讲义引用的基础定理，本笔记不从描述集合论重新证明。

例 2.4.1：Bernoulli 与 Poisson

Bernoulli 中，令 $\Delta = \sum_i x_i - \sum_i y_i$ ，

$$\frac{p_p^{(n)}(x)}{p_p^{(n)}(y)} = \left(\frac{p}{1-p} \right)^\Delta.$$

$p/(1-p)$ 遍历正半轴，比值与 p 无关当且仅当 $\Delta = 0$ 。

Poisson 中，

$$\frac{p_\lambda^{(n)}(x)}{p_\lambda^{(n)}(y)} = \lambda^\Delta \frac{\prod_i y_i!}{\prod_i x_i!},$$

同样当且仅当 $\Delta = 0$ 。结合充分性，两个模型中的总和均最小充分。

正态两参数模型中，令 $\Delta_1 = \sum_i x_i - \sum_i y_i$ 、 $\Delta_2 = \sum_i x_i^2 - \sum_i y_i^2$ ，则

$$\log \frac{p_{\mu, \sigma^2}^{(n)}(x)}{p_{\mu, \sigma^2}^{(n)}(y)} = \frac{\mu}{\sigma^2} \Delta_1 - \frac{1}{2\sigma^2} \Delta_2.$$

固定方差改变均值，得 $\Delta_1 = 0$ ；再改变方差，得 $\Delta_2 = 0$ 。反之两差为零时比值为 1。因此 $(\sum_i X_i, \sum_i X_i^2)$ 最小充分。

例 2.4.3：指数族的两条证明路线

设自然统计量维数为 k ，存在 $\theta_0, \dots, \theta_k$ ，使

$$v_i = \eta(\theta_i) - \eta(\theta_0), \quad i = 1, \dots, k$$

线性无关。

第一条路线是选有限子模型。其对数密度比为

$$\log \frac{p_{\theta_i}(x)}{p_{\theta_0}(x)} = v_i^\top T(x) - [\zeta(\eta(\theta_i)) - \zeta(\eta(\theta_0))].$$

把 $v_i^\top$ 排成可逆矩阵 V ，就可从这些对数比恢复 VT ，继而恢复 T 。比值向量在有限子模型中最小充分，所以 T 也最小充分。共同正支撑保证共同零事件条件，再用命题 2.4.1 推广到整个模型。

第二条路线是直接比较整条似然。若 $p_\theta(x)/p_\theta(y)$ 与 θ 无关，令 $\Delta T = T(x) - T(y)$ ，对数等式减去 θ_0 时的等式得

$$v_i^\top \Delta T = 0, \quad i = 1, \dots, k.$$

V 可逆，故 $\Delta T = 0$ ，由判别准则得最小充分。

这里“存在 $k+1$ 个仿射独立自然参数”比“包含开集”更弱。弯曲族仍可能满足本条最小充分性条件，不能把它与后面的完备性开集条件混淆。

对 $U(0, \theta)$ 的正样本，似然为正的参数范围是 $(x_{(n)}, \infty)$ 。两条完整似然成比例当且仅当最大值相同，因此最大值最小充分。

2.5 完备性

2.5.1 从压缩信息转向函数唯一性

充分性和最小充分性讨论保留哪些数据。完备性改问：两个关于 T 的可积函数，如果在所有参数下期望相同，是否必须几乎必然相同？

定义 2.5.1：完备与有界完备

对任意不含未知参数的可测函数 g ，若

$$E_\theta |g(T)| < \infty, \quad E_\theta g(T) = 0 \quad \forall \theta$$

必推出

$$g(T) = 0 \quad P_\theta\text{-a.s.}, \quad \forall \theta,$$

则 T 完备。若只对有界可测 g 要求该结论，则称有界完备。

完备推出有界完备。不能取 $g(T) = T - \theta$ 来证明不完备，因为这个函数含有未知参数。结论是随机变量几乎必然为零，不要求 g 在不可能取到的点上也为零。

定义期望变换 $(Kg)(\theta) = E_\theta g(T)$ ，则完备性表示其核只有几乎必然为零的函数。若 $a(T), b(T)$ 均可积且对所有参数期望相同，对差 $g = a - b$ 应用完备性就有 $a(T) = b(T)$ 。这保证同一完备统计量的无偏函数的唯一性，但不保证无偏估计存在，也不表示所有基于完整数据的无偏估计都相同。

2.5.2 有界完备且充分推出最小充分

定理 2.5.1

在讲义的标准 Borel 条件下， T 有界完备且充分，则 T 最小充分。

证明。任取充分统计量 U ，选 T 值域上的有界一一 Borel 编码 b ，其像上的逆可测。实值统计量可取 $b(t) = \arctan t$ 。定义

$$q(U) = E_\theta[b(T) | U], \quad r(T) = E_\theta[q(U) | T].$$

由 U, T 充分，两个条件期望依次可取同一个不含参数的版本。它们有界，且全期望给出

$$E_\theta[r(T) - b(T)] = 0 \quad \forall \theta.$$

有界完备性推出 $r(T) = b(T)$ a.s.。分别对 U, T 条件化，

$$\begin{aligned} E_\theta[b(T)q(U)] &= E_\theta[q(U)E_\theta(b(T) | U)] = E_\theta[q(U)^2], \\ E_\theta[b(T)q(U)] &= E_\theta[b(T)E_\theta(q(U) | T)] = E_\theta[b(T)^2]. \end{aligned}$$

故

$$E_\theta[(b(T) - q(U))^2] = E_\theta b(T)^2 - 2E_\theta[b(T)q(U)] + E_\theta q(U)^2 = 0.$$

非负变量期望为零，得 $b(T) = q(U)$ a.s.，反解即 $T = b^{-1}(q(U))$ a.s.。由于 U 任意， T 最小充分。

为什么不能直接用塔式性质？

事先不知道 $\sigma(T)$ 与 $\sigma(U)$ 谁包含谁，不能直接断言 $E_\theta[E_\theta(b(T) | U) | T] = b(T)$ 。证明中是先由完备性得到这个等式，再由平方期望消除残差。

2.5.3 两种直接证明：多项式与积分上限

例 2.5.1–2.5.2：二项分布的完备性

令 $T \sim \text{Binomial}(n, p)$, $p \in (0, 1)$ 。若所有参数下 $E_p g(T) = 0$, 则

$$\sum_{t=0}^n g(t) \binom{n}{t} p^t (1-p)^{n-t} = 0.$$

除以 $(1-p)^n > 0$, 令 $u = p/(1-p)$, 得到

$$\sum_{t=0}^n g(t) \binom{n}{t} u^t = 0 \quad \forall u > 0.$$

一个有限次多项式在整个区间上为零, 所有系数必须为零。由 $\binom{n}{t} > 0$, 得 $g(t) = 0$ 对 $t = 0, \dots, n$ 成立。故 T 完备, Bernoulli 样本总和因而完备充分。

若把模型限制为单个已知 $p_0 \in (0, 1)$, $n \geq 1$, 则 $g(T) = T - np_0$ 是合法的固定非零零期望函数, 完备性反而失效。完备性也相对于整族参数定义。

例 2.5.3：均匀上端点模型的完备性

若 X_i 独立同分布于 $U(0, \theta)$, $T = X_{(n)}$, 则对 $0 < t < \theta$,

$$P_\theta(T \leq t) = (t/\theta)^n, \quad f_\theta^T(t) = nt^{n-1}\theta^{-n}.$$

任取在所有参数下可积的 g , 零期望给出

$$\int_0^\theta g(t) t^{n-1} dt = 0 \quad \forall \theta > 0.$$

对每个 $B > 0$, 可积性保证 $g(t)t^{n-1}$ 在 $(0, B)$ 绝对可积。因此 $F(b) = \int_0^b g(t)t^{n-1} dt$ 在 $[0, B]$ 绝对连续, 且

$$F'(b) = g(b)b^{n-1} \quad \text{Lebesgue-a.e.}$$

F 恒为零且 $b > 0$, 故 $g(b) = 0$ a.e.。对正整数 B 取可数并得到整个正半轴上的结论。 T 有 Lebesgue 密度, 所以每个参数下 $g(T) = 0$ a.s., 完备性成立。

2.5.4 指数族完备性及开集的作用

定理 2.5.2：指数族完备性

若 T 的分布相对于 ν 的密度为

$$q_\eta(t) = e^{\eta^\top t - \zeta(\eta)} h_*(t), \quad \eta \in \Xi \subseteq \mathbb{R}^k,$$

且 Ξ 包含非空开集，则 T 完备。这里 ν 不必是 k 维 Lebesgue 测度。

证明展开。任取所有参数下可积且零期望的 g ，写 $g = g^+ - g^-$ 。选内点 η_0 与 $\varepsilon > 0$ 使 $B(\eta_0, \varepsilon) \subseteq \Xi$ 。消去密度中的归一化因子，得到

$$\int g^+(t) e^{\eta_0^\top t} h_*(t) \nu(dt) = \int g^-(t) e^{\eta_0^\top t} h_*(t) \nu(dt).$$

在 η_0 处记共同有限值为 C 。若 $C = 0$ ，非负积分为零，直接得到 $g = 0$ 于载体测度 $h_*\nu$ 几乎处处。

若 $C > 0$ ，定义两个概率密度

$$f_\pm(t) = C^{-1} g^\pm(t) e^{\eta_0^\top t} h_*(t).$$

对于 $\|s\| < \varepsilon$ ，使用参数 $\eta_0 + s$ 的积分恒等式，

$$\begin{aligned} \int e^{s^\top t} f_+(t) \nu(dt) &= C^{-1} \int g^+(t) e^{(\eta_0+s)^\top t} h_*(t) \nu(dt) \\ &= C^{-1} \int g^-(t) e^{(\eta_0+s)^\top t} h_*(t) \nu(dt) \\ &= \int e^{s^\top t} f_-(t) \nu(dt). \end{aligned}$$

可积性保证两边在该邻域有限。引用原点邻域内有限的多元矩母函数唯一性，得到两个概率测度相同，进而 $f_+ = f_-$ ， ν -a.e.。约去正因子可得 $g(t)h_*(t) = 0$ ， ν -a.e.。所有模型分布都关于载体测度绝对连续，故 $g(T) = 0$ 在每个参数下 a.s. 成立。

开集允许所有足够小方向的指数倾斜，提供一个原点邻域上的矩母函数信息。“所有阶矩相同必同分布”没有一般保证，不能替代这里的唯一性定理。

弯曲族的不完备必须另证

单观测 $X \sim N(\theta, \theta^2)$ ， $\theta > 0$ 时，

$$X/\theta \sim N(1, 1), \quad P_\theta(X < 0) = \Phi(-1).$$

令 $T = (X, X^2)$ ，取

$$g(T) = \mathbf{1}_{\{X < 0\}} - \Phi(-1).$$

该函数有界、对所有参数期望为零，但两个可能取值均非零。因此此例不有界完备，也不完备。证明依据是这个具体反例函数，而不只是自然参数空间没有开集。

2.6 辅助统计量与 Basu 定理

2.6.1 辅助性要求整个分布不含参数

定义 2.6.1：辅助统计量

若 $A = A(\mathbf{X})$ 的分布不依赖 θ ，即对每个可测集合 B ， $P_\theta(A \in B)$ 都是关于参数的常数，则 A 辅助。

均值恒定不够。例如 $X \sim N(0, \sigma^2)$ 的均值始终为零，但分布随方差变化，因此 X 对该模型不辅助。

正态样本 $n \geq 2$ 时，标准化残差方向

$$A = \frac{(X_1 - \bar{X}, \dots, X_n - \bar{X})}{\{\sum_i (X_i - \bar{X})^2\}^{1/2}}$$

对完整位置尺度模型辅助。写 $X_i = \mu + \sigma Z_i$ ，其中 Z_i 独立标准正态，中心化消去 μ ，归一化消去正数 σ ，所以 A 成为标准正态向量的固定函数。分母为零是概率零事件，可任意补定义。

2.6.2 Basu 定理的条件与完整证明

定理 2.6.1：Basu 定理

若 T 有界完备且充分， A 辅助，则它们在模型中的每个分布下独立。

证明。任取 A 值域内的可测集合 B ，辅助性给出不含参数的常数

$$c_B = P_\theta(A \in B).$$

充分性给出不含参数的共同版本

$$q_B(T) = E_\theta[\mathbf{1}_{\{A \in B\}} \mid T], \quad 0 \leq q_B \leq 1.$$

全期望公式给出 $E_\theta[q_B(T) - c_B] = 0$ 对所有参数成立。差是 T 的固定有界函数，由有界完备性，

$$q_B(T) = c_B \quad P_\theta\text{-a.s.}$$

再取 T 值域内的可测集合 C ，

$$\begin{aligned} P_\theta(T \in C, A \in B) &= E_\theta[\mathbf{1}_{\{T \in C\}} E_\theta(\mathbf{1}_{\{A \in B\}} \mid T)] \\ &= E_\theta[\mathbf{1}_{\{T \in C\}} q_B(T)] \\ &= P_\theta(T \in C) P_\theta(A \in B). \end{aligned}$$

这就是独立性；若从联合测度角度表述，可由矩形集上的相等延拓到乘积 σ -域。

三个条件各用在哪里？

辅助性使 c_B 不含参数；充分性使 q_B 可以统一选择；有界完备性使“所有参数下均值为零”升级为“几乎必然为零”。无条件概率不含参数，不能直接推出条件概率是同一常数。

2.6.3 正态与指数模型的独立性应用

例 2.6.2：正态均值与样本方差独立

设 $n \geq 2$, X_i 独立同分布于 $N(\mu, \sigma^2)$ 。先固定任意 $\sigma^2 > 0$ ，仅令 μ 变化。联合密度的参数项为

$$\exp \left\{ \frac{\mu}{\sigma^2} \sum_i x_i - \frac{n\mu^2}{2\sigma^2} \right\}.$$

所以 $\sum_i X_i$ 充分；自然参数 μ/σ^2 遍历 $\mathbb{R}$ ，由指数族定理完备。 $\bar{X}$ 与总和一一对应，也完备充分。

写 $X_i = \mu + \sigma Z_i$ ，则

$$S^2 = \frac{\sigma^2}{n-1} \sum_i (Z_i - \bar{Z})^2.$$

在固定方差的子模型中，其分布不含 μ ，所以辅助。Basu 定理给出 $\bar{X}$ 与 S^2 独立；固定的 σ^2 任意，因此对整个两参数正态模型中的每个参数点都成立。

不能直接说 S^2 对完整两参数模型辅助，因为其分布依赖 σ^2 。上述证明也没有预先使用均值、方差独立性，避免循环论证。

例 2.6.3：指数尺度族

设 X_i 独立同分布，密度为 $\theta^{-1}e^{-x/\theta}\mathbf{1}_{\{x>0\}}$ 。总和充分，自然参数 $-1/\theta$ 遍历 $(-\infty, 0)$ ，故总和及其一一变换 $\bar{X}$ 完备充分。

令 $Z_i = X_i/\theta$ ，则 Z_i 独立同分布于尺度为 1 的指数分布，且

$$\frac{X_1}{\bar{X}} = \frac{Z_1}{\bar{Z}}.$$

比例的分布不含参数，因此辅助。Basu 定理给出

$$\bar{X} \perp\!\!\!\perp X_1/\bar{X}.$$

$n=1$ 时比例恒为 1； $n \geq 2$ 时是非平凡结论。它不表示 X_1 与 $\bar{X}$ 独立。

2.6.4 反例：最小充分并不意味着完备

例 2.6.4：均匀位置族

设 X_i 独立同分布于 $U(\theta, \theta + 1)$, $\theta \in \mathbb{R}$, $n \geq 2$ 。联合似然为

$$p_{\theta}^{(n)}(\mathbf{x}) = \mathbf{1}_{\{x_{(n)} - 1 < \theta < x_{(1)}\}}.$$

在极差小于 1 的共同满测样本集上，两条非零似然成比例当且仅当参数区间两个端点相同。因而 $T = (X_{(1)}, X_{(n)})$ 最小充分。

写 $X_i = \theta + U_i$, U_i 独立同分布于 $U(0, 1)$ 。极差

$$R = X_{(n)} - X_{(1)} = U_{(n)} - U_{(1)}$$

是 T 的辅助函数。极小、极大的联合密度为

$$f(u, v) = n(n-1)(v-u)^{n-2}, \quad 0 < u < v < 1.$$

令 $r = v - u$, Jacobian 为 1, 在 $0 < u < 1 - r$ 上积分得

$$f_R(r) = n(n-1)r^{n-2}(1-r), \quad 0 < r < 1.$$

因此

$$ER = n(n-1) \int_0^1 r^{n-1}(1-r) dr = n(n-1) \left(\frac{1}{n} - \frac{1}{n+1} \right) = \frac{n-1}{n+1}.$$

于是 $g(T) = R - (n-1)/(n+1)$ 有界、所有参数下零期望，而 R 有连续密度，故 $g(T) \neq 0$ 的概率为 1。 T 不有界完备，也不完备。

这里是区间长度固定、位置未知的模型，不能与上端点未知的 $U(0, \theta)$ 混淆。若假定此 T 有界完备，Basu 还会迫使其函数 R 与 T 独立，从而与自身独立而退化，同样矛盾。

2.7 总结与学习检查

四个概念分别回答什么问题？

充分性：给定摘要后，剩下样本的条件分布是否与参数无关？

最小充分性：每个充分摘要是否都必须保留这份共同核心？

完备性：一个固定可积函数能否在所有参数下均值为零，却不几乎必然为零？

辅助性：统计量自身的整个分布是否与参数无关？

本章的可靠逻辑关系是

完备 $\Rightarrow$ 有界完备, 有界完备且充分 $\Rightarrow$ 最小充分 $\Rightarrow$ 充分.

最小充分不推出完备。常数统计量对任意模型都完备，却在分布随参数改变的模型中不充分，说明完备不是“信息最多”。

考场证明的起手与收尾

1. 证明充分：写全联合密度和支撑，明确 $g_\theta(T(x))$ 与 $h(x)$ ，引用因子分解。
2. 证明最小充分：先有充分性，再证明完整似然成比例推出 $T(x) = T(y)$ ；或选择合适小模型并核对共同零事件。
3. 证明完备：任取所有参数下可积的固定函数 g ，从零期望推出 $g(T) = 0$ a.s.。用指数族定理时写明自然参数及其开集。
4. 否定完备：明确构造与未知参数无关的 g ，核对可积、所有参数下零期望、至少一个参数下不几乎必然为零。
5. 应用 Basu：明确当前模型，分别核对充分、完备、辅助；若固定干扰参数使用子模型，最后说明所固定值任意。

下一次独立复习的问题

1. 不看答案，解释为什么统计量和自然参数都落在曲线上时，两条满秩条件的判断仍可能不同。
2. 从条件期望定义出发，重写因子分解两个方向，标明每一步使用的测度。
3. 说明共同支配引理、可数混合构造与推广原则怎样共同支持最小充分性证明。
4. 独立证明二项与均匀最大值的完备性，并构造均匀位置族的不完备反例。
5. 不预先使用卡方分布或独立性结论，应用 Basu 证明正态样本均值与方差独立。

来源与引用说明

主要来源为 Fang Yao《Advanced Mathematical Statistics》第二章讲义，正文第 27–48 页，并结合第二章 Slides 与本次学习讨论整理。原讲义文件未随笔记重新发布。一般最小充分性证明沿用讲义引用：Bahadur (1954), Theorem 6.2; Srivastava (1998), *A Course on Borel Sets*, Theorem 4.5.7; Kallenberg (2002), *Foundations of Modern Probability*, 2nd ed., Lemma 1.13。书目与编号按课程材料记录，未另行核对相应书籍全文。