高等统计学中文学习笔记

第 3 章：决策、估计与信息下界

定义、证明与习题

Studyer-Tang

https://github.com/Studyer-Tang

依据 Fang Yao 的 Advanced Mathematical Statistics 课程材料及相关学习推导整理。感谢原课程作者提供讲义与课程框架。本笔记为个人学习记录，非官方讲义或官方译本；原课件与作业未随笔记发布，相关权利归原作者所有。具体范围与校订记录见仓库 SOURCES.md 与 ERRATA.md。

2026 年 10 月 24 日修订

目录

第 3 章 决策、估计与信息下界 **1**

3.1 决策问题与风险比较 1
3.1.1 从估计规则到风险函数 1
3.1.2 支配、可容许与极小极大 2
3.1.3 检验也是决策 2
3.2 偏差、方差与收缩 3
3.2.1 均方误差分解 3
3.2.2 二项比例的加权估计 3
3.2.3 对称收缩的极小极大计算 4
3.3 无偏性、一致性与渐近尺度 5
3.3.1 三种性质应分别检验 5
3.3.2 一阶相同不等于有限样本相同 6
3.4 得分与 Fisher 信息 7
3.4.1 定义与正则条件 7
3.4.2 指数族的归一化函数 8
3.4.3 参数变换与 Jacobian 的方向 8
3.4.4 常见模型核对 9
3.5 Cramér–Rao 下界与等号条件 10
3.5.1 标量下界的完整证明 10
3.5.2 投影分解与下界不可达的可能性 10
3.5.3 有偏估计的修正 11
3.6 向量参数与矩阵信息下界 11
3.7 达到下界与指数族结构 13
3.7.1 自然统计量达到哪个目标的下界 13
3.7.2 处处取等反推一维指数族 14
3.7.3 一点取等不足以推断整族结构 14
3.8 非正则模型、效率与 MLE 展开 15
3.8.1 移动支撑为什么使正则恒等式失效 15
3.8.2 有限样本效率与渐近效率 16
3.8.3 从得分方程到渐近正态 16

第 3 章　决策、估计与信息下界

评价一个统计方法，须先指定模型、估计目标、损失函数及允许比较的规则类。无偏性约束估计量的均值，一致性描述样本量增大时的集中，而风险同时计入误差的大小与发生概率。本章先建立这些比较标准，再由得分恒等式推导 Cramér–Rao 下界，并讨论等号、参数变换和非正则模型。

3.1　决策问题与风险比较

3.1.1　从估计规则到风险函数

统计决策问题

给定统计模型 $\mathcal{P}=\{P_\theta:\theta\in\Theta\}$、行动空间 $\mathcal{A}$、非负损失 $L(\theta,a)$，以及一类可测规则 $\mathcal{D}$。规则 $\delta:\mathcal{X}\to\mathcal{A}$ 的风险为

$$R_\theta(\delta)=\mathrm{E}_\theta\, L(\theta,\delta(X)).$$

固定参数时，损失 $L(\theta,\delta(X))$ 是随机变量，风险是对样本分布取平均后的数值；改变参数，便得到整条风险函数。

估计 $g(\theta)\in\mathbb{R}^k$ 时，常用平方损失 $\|a-g(\theta)\|^2$、绝对距离损失 $\|a-g(\theta)\|$，或加权二次损失

$$L(\theta,a)=(a-g(\theta))^\top W_\theta(a-g(\theta)),\qquad W_\theta\succeq 0.$$

平方损失下的风险称均方误差。权重可以改变不同方向的代价，但这种二次损失仍对误差的正负对称。高估与低估代价不同时，应另设非对称损失。

正态均值：两条相交的风险曲线

设 $X_1,\dots,X_n\overset{\text{i.i.d.}}{\sim}N(\mu,\sigma^2)$，$\sigma^2$ 已知，估计 μ。平方损失下，

$$R_\mu(\bar X)=\frac{\sigma^2}{n},\qquad R_\mu(m)=(m-\mu)^2,$$

其中 m 是事先固定的常数。若 $|\mu-m|<\sigma/\sqrt{n}$，常数规则的风险较低；区间外则样本均值较低。常数规则在 $\mu=m$ 处风险为零，并不能使它成为整个模型中的好规则。

风险的定义先固定参数，只对数据平均。给参数配置先验 π 后再平均，才得到 Bayes

风险

$$r_\pi(\delta) = \int_\Theta R_\theta(\delta)\,\pi(\mathrm{d}\theta).$$

这两个期望的对象不同。

3.1.2 支配、可容许与极小极大

三种风险比较

若 $R_\theta(\delta_1) \le R_\theta(\delta_2)$ 对所有 θ 成立，且至少一点严格小于，称 δ_1 支配 δ_2。在指定规则类中不受任何规则支配的规则称可容许。

若某个 δ^* 满足

$$R_\theta(\delta^*) \le R_\theta(\delta) \quad \text{对所有}\theta \in \Theta,\ \delta \in \mathcal{D},$$

则它逐点最优。极小极大规则则要求达到

$$\inf_{\delta\in\mathcal{D}} \sup_{\theta\in\Theta} R_\theta(\delta).$$

逐点最优必然可容许；若逐点最优规则存在，任何可容许规则都须与它具有相同风险函数，否则便被支配。可容许性本身不提供风险的大小：它仅排除一种统一改进。规则类扩大后，原来的可容许性也可能失效。

例如 $X_i \sim N(\theta,1)$ 且 $n \ge 2$，X_1 与 $\bar X$ 均无偏，但风险分别为 1 与 $1/n$，故 X_1 不可容许。这个比较尚未证明 $\bar X$ 优于所有估计量。又如 $X \sim N(\theta,1)$，在只含 X 与常数 3 的两元素规则类中，二者风险相交，因此都可容许，却无逐点最优规则。

极小极大比较先固定规则，再找它最坏的参数点，最后在规则间优化。交换这两个优化顺序，会变成知道参数后另选行动的问题。一个实用下界为

$$\inf_\delta \sup_\theta R_\theta(\delta) \ge \inf_\delta r_\pi(\delta),$$

因为任意规则的最大风险不小于其先验平均风险。若某个规则的最大风险等于右端，就证明了它的极小极大性。

3.1.3 检验也是决策

检验 $H_0 : \theta \in \Theta_0$ 对 $H_1 : \theta \in \Theta_1$，约定拒绝为行动 1。随机化检验 $\varphi(X) \in [0,1]$ 表示给定数据后的拒绝概率，可用独立 $V \sim U(0,1)$ 实现为 $\mathbf{1}\{V \le \varphi(X)\}$。记功效

$$\beta_\varphi(\theta) = \mathrm{E}_\theta\,\varphi(X).$$

若错误行动的损失为 1、正确行动为 0，则

$$R_\theta(\varphi) = \begin{cases} \beta_\varphi(\theta), & \theta \in \Theta_0, \\ 1 - \beta_\varphi(\theta), & \theta \in \Theta_1. \end{cases}$$

水平不超过 α 要求 $\sup_{\Theta_0}\beta_\varphi \le \alpha$。随后提高备择下的功效，才是带水平约束的风险优化。总不拒绝虽然没有第一类错误，却没有发现备择的能力。

复习题

1. 在上面的正态均值例中，把损失改成 $|a-\mu|$，求 $\bar X$ 与常数 m 的风险及交点。
2. 逐点最优、可容许、极小极大是否是同一个概念？说明其量词或优化对象的区别。

答案线索

第一题：$R_\mu(\bar X)=\sigma\sqrt{2/(\pi n)}$，$R_\mu(m)=|m-\mu|$。第二题：逐点最优比较每个竞争者在每个参数点的风险；可容许只排除支配；极小极大只比较最大风险。有限规则类中的结论不能直接推广到所有可测规则。

3.2 偏差、方差与收缩

3.2.1 均方误差分解

设 T 二阶可积，目标为 $g(\theta)\in\mathbb{R}$，偏差记作

$$b_\theta(T)=\mathrm{E}_\theta T-g(\theta).$$

将误差拆为 $T-\mathrm{E}_\theta T+b_\theta(T)$，平方后取期望，交叉项因中心化消失，故

$$\mathrm{MSE}_\theta(T)=\mathrm{Var}_\theta(T)+b_\theta(T)^2.$$

无偏性只使第二项为零，不保证第一项小。允许适当偏差，有时可以显著降低方差。

固定系数的正态收缩

设 $X\sim N(\theta,1)$，$0<a<1$，比较 aX 与 X。有

$$b_\theta(aX)=(a-1)\theta,\qquad R_\theta(aX)=a^2+(1-a)^2\theta^2.$$

因此

$$R_\theta(aX)<R_\theta(X)=1\iff|\theta|<\sqrt{\frac{1+a}{1-a}}.$$

收缩降低了方差，却引入随 $|\theta|$ 增大的偏差；整个实参数空间上不存在这里的统一支配关系。

3.2.2 二项比例的加权估计

设 $Y\sim\mathrm{Bin}(n,p)$，$a,b\ge0$，考虑

$$\delta_{a,b}=\frac{Y+a}{n+a+b}.$$

当 $a+b>0$ 时，它是样本比例与固定中心的加权平均：

$$\delta_{a,b}=w\frac{Y}{n}+(1-w)q,\qquad w=\frac{n}{n+a+b},\quad q=\frac{a}{a+b}.$$

直接计算得

$$b_p(\delta_{a,b})=\frac{a-(a+b)p}{n+a+b},\qquad R_p(\delta_{a,b})=\frac{np(1-p)+\{a-(a+b)p\}^2}{(n+a+b)^2}.$$

取 $n=16,a=b=1$，令 $u=p(1-p)$，则两个风险分别为 $(1+12u)/324$ 与 $u/16$。前者较小当且仅当

$$u>\frac{4}{33}\iff\left|p-\frac{1}{2}\right|<\frac{1}{2}\sqrt{\frac{17}{33}}.$$

靠近中心时，减少的方差补偿了偏差；靠近端点时则相反。

3.2.3 对称收缩的极小极大计算

在 $\delta_c=(Y+c)/(n+2c)$、$c\geq 0$ 的规则类内，风险为

$$R_p(c)=\frac{np(1-p)+c^2(1-2p)^2}{(n+2c)^2},\qquad \frac{\partial R_p(c)}{\partial p}=\frac{(n-4c^2)(1-2p)}{(n+2c)^2}.$$

当 $c<\sqrt{n}/2$，最大风险在 $p=1/2$；当 $c>\sqrt{n}/2$，在 $p=0,1$。因而

$$\sup_{0\leq p\leq 1}R_p(c)=\begin{cases}\dfrac{n}{4(n+2c)^2}, & 0\leq c\leq\sqrt{n}/2,\\[2ex] \dfrac{c^2}{(n+2c)^2}, & c\geq\sqrt{n}/2.\end{cases}$$

第一段随 c 递减，第二段递增。最优选择是

$$c^*=\frac{\sqrt{n}}{2},\qquad R_p(c^*)=\frac{1}{4(\sqrt{n}+1)^2},$$

此时风险不依赖 p。

从类内优化到全部规则：还需一个下界

上述微分计算只证明对称规则类内的极小极大性。本例可以再补一步：取真先验 $p\sim\mathrm{Beta}(c^*,c^*)$。平方损失下的后验均值正是 δ_{c^*}，因为条件均方误差由后验均值最小化。它的 Bayes 风险等于常数风险 $1/\{4(\sqrt{n}+1)^2\}$。Bayes 下界与该规则的最大风险相等，故它实际上也在全部规则中极小极大。若不补这个论证，便不能扩大原有结论的范围。

固定 a,b 时，加权估计的偏差为 $O(n^{-1})$；但 $c^*=\sqrt{n}/2$ 随样本量改变，偏差一般仅为 $O(n^{-1/2})$。两种渐近比较的前提不同。

复习题

1. 设独立 X_i 具有共同均值 θ 与方差 $\sigma^2 > 0$。证明所有确定权重的线性无偏估计 $\sum_i c_i X_i$ 中，$\bar{X}$ 的方差最小，并求等号条件。
2. 当 $n = 16$ 时，分别计算 Y/n 与 δ_{c^*} 的最大风险。偏差是否必然增加最大均方误差?

答案线索

第一题：无偏要求 $\sum_i c_i = 1$，Cauchy–Schwarz 给出 $\sum_i c_i^2 \geq 1/n$；等号当且仅当所有 $c_i = 1/n$。结论只在线性无偏类中成立。第二题：最大风险分别为 $1/64$ 与 $1/100$，故有偏规则也可能降低最大风险。

3.3 无偏性、一致性与渐近尺度

3.3.1 三种性质应分别检验

无偏、渐近无偏与一致

T_n 对 $g(\theta)$ 无偏，指每个 n 均有 $\mathrm{E}_\theta T_n = g(\theta)$。若期望存在且 $\mathrm{E}_\theta T_n \to g(\theta)$，称渐近无偏。若对每个固定 θ、每个 $\varepsilon > 0$，

$$P_\theta(|T_n - g(\theta)| > \varepsilon) \to 0,$$

则称一致。给定 $a_n \to \infty$，若 $a_n(T_n - g(\theta)) = O_{P_\theta}(1)$，称具有 a_n-一致性。

依概率有界可推出 $T_n - g(\theta) = O_{P_\theta}(a_n^{-1}) \xrightarrow{P} 0$。这些都是固定参数下的陈述，未必在整个参数空间上一致，也未声称该速度最优。

由 Markov 不等式，

$$P_\theta(|T_n - g(\theta)| > \varepsilon) \leq \frac{\mathrm{E}_\theta(T_n - g(\theta))^2}{\varepsilon^2}.$$

故偏差与方差都趋零足以推出一致；反向需要额外的尾部控制。

无偏性与一致性互不替代

设 $X_i \sim N(\mu, 1)$。

1. $T_n = (1 - 1/n)\bar{X}$ 有偏，偏差 $-\mu/n$，方差 $(1 - 1/n)^2/n$，却一致。
2. $T_n = X_1$ 每个样本量均无偏，但

$$P_\mu(|T_n - \mu| > \varepsilon) = P(|Z| > \varepsilon) > 0, \quad Z \sim N(0, 1),$$

所以不一致。

3. 允许外加随机化，取与数据独立的 $U \sim U(0, 1)$，令

$$T_n = \bar{X} + n\mathbf{1}\{U \leq 1/n\}.$$

则 $\mathrm{E}_\mu T_n = \mu + 1$，不渐近无偏，但

$$P_\mu(|T_n - \mu| > \varepsilon) \le \frac{1}{n\varepsilon^2} + \frac{1}{n} \to 0.$$

此时均方误差为 $1/n + n$，甚至发散。若规则只允许原始样本的确定函数，这个随机化例子须先把 U 纳入实验。

证明不一致应回到尾概率，而不能仅以“方差未趋零”代替。相反，上例说明依概率收敛本身并不保证期望或二阶矩收敛。

3.3.2 一阶相同不等于有限样本相同

设 $X_i \sim N(\mu, \sigma^2)$，$\sigma^2$ 已知，估计 μ^2。考虑

$$T_n = \bar{X}^2, \qquad U_n = \bar{X}^2 - \frac{\sigma^2}{n}.$$

前者偏差为 σ^2/n，后者无偏。利用恒等式

$$\bar{X}^2 - \mu^2 = 2\mu(\bar{X} - \mu) + (\bar{X} - \mu)^2$$

及 $\sqrt{n}(\bar{X} - \mu) = O_P(1)$，有

$$\sqrt{n}(T_n - \mu^2) = 2\mu\sqrt{n}(\bar{X} - \mu) + o_P(1).$$

当 $\mu \neq 0$，两个估计量均满足

$$\sqrt{n}(T_n - \mu^2),\ \sqrt{n}(U_n - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2),$$

因为 $\sqrt{n}(T_n - U_n) = \sigma^2/\sqrt{n} \to 0$。

在 $\mu = 0$ 处，一阶导数消失。写 $Z_n = \sqrt{n}\bar{X}/\sigma \sim N(0,1)$，便有精确分布

$$nT_n \overset{d}{=} \sigma^2\chi_1^2, \qquad nU_n \overset{d}{=} \sigma^2(\chi_1^2 - 1).$$

此处应使用 n 尺度，且偏差修正改变极限分布。尺度和有效的一阶展开可能随参数点改变。

复习题

1. 若 $\sqrt{n}(T_n - g(\theta)) \xrightarrow{d} N(0, V)$，能否推出一致性？能否直接推出 $n\,\mathrm{MSE}_\theta(T_n) \to V$？
2. 计算上述 U_n 的精确方差，比较 $\mu = 0$ 与 $\mu \neq 0$ 时的误差尺度。

答案线索

第一题：弱收敛蕴含依概率有界，因此推出一致；矩收敛不能直接推出，需统一可积性等附加条件。第二题：令 $Z=\bar{X}-\mu$，使用 $\mathrm{E}\,Z^3=0$、$\mathrm{E}\,Z^4=3\sigma^4/n^2$，得到

$$\mathrm{Var}_\mu(U_n)=\frac{4\mu^2\sigma^2}{n}+\frac{2\sigma^4}{n^2}.$$

3.4 得分与 Fisher 信息

3.4.1 定义与正则条件

令 $\theta\in\Theta\subset\mathbb{R}^d$，单次观测密度为 p_θ，得分取列向量：

$$\ell_\theta(x)=\log p_\theta(x),\qquad s_\theta(x)=\nabla_\theta\ell_\theta(x),\qquad I(\theta)=\mathrm{E}_\theta[s_\theta(X)s_\theta(X)^\top].$$

信息矩阵总半正定，因为 $a^\top I(\theta)a=\mathrm{E}_\theta(a^\top s_\theta)^2\ge 0$，但不一定可逆。导数针对参数，求导时观测值固定；把 X 代入后，得分才成为随机向量。

以下是一组足以使用信息恒等式的局部条件：参数点位于开放参数空间内部；各密度在同一支撑上为正；除一个共同测度零集外，密度关于参数二次连续可微；密度的一、二阶导数在真值邻域内具有可积包络；得分二阶矩与对数密度 Hessian 的期望存在。这些条件使微分与积分可以交换。

得分与信息恒等式

在上述条件下，

$$\mathrm{E}_\theta\, s_\theta(X)=0,\qquad I(\theta)=\mathrm{Cov}_\theta(s_\theta(X))=-\,\mathrm{E}_\theta\,\nabla_\theta^2\ell_\theta(X).$$

证明 由 $\nabla p_\theta=p_\theta s_\theta$ 和密度归一化，

$$\mathrm{E}_\theta\, s_\theta=\int\nabla p_\theta\,\mathrm{d}\nu=\nabla\int p_\theta\,\mathrm{d}\nu=0.$$

逐坐标使用乘积法则，

$$\nabla^2 p_\theta=p_\theta\{\nabla^2\ell_\theta+s_\theta s_\theta^\top\}.$$

再对两边积分，左边为归一化常数的二阶导数 0，故得第二条恒等式。单个观测的负 Hessian 不必半正定；这里等于信息矩阵的是它的期望。

对于 i.i.d. 样本，记

$$\ell_n(\theta)=\sum_{i=1}^n\ell_\theta(X_i),\quad S_n(\theta)=\sum_{i=1}^n s_\theta(X_i),\quad H_n(\theta)=\nabla_\theta^2\ell_n(\theta).$$

独立性与得分均值为零使外积中的交叉项消失，故

$$I_n(\theta) = \mathrm{E}_\theta\, S_n S_n^\top = nI(\theta).$$

独立但不同分布时信息仍逐项相加；存在依赖时不能直接写成 nI。

3.4.2 指数族的归一化函数

自然指数族写成

$$p_\eta(x) = h(x)\exp\{\eta^\top T(x) - \zeta(\eta)\}, \qquad Z(\eta) = e^{\zeta(\eta)}.$$

在自然参数空间内部，直接微分归一化积分得到

$$\nabla\zeta(\eta) = \frac{\nabla Z(\eta)}{Z(\eta)} = \mathrm{E}_\eta\, T,$$

$$\nabla^2\zeta(\eta) = \frac{\nabla^2 Z}{Z} - \frac{\nabla Z \nabla Z^\top}{Z^2} = \mathrm{Cov}_\eta(T).$$

另一方面，$s_\eta = T - \nabla\zeta$，所以 $I(\eta) = \nabla^2\zeta(\eta)$。若 T 无非平凡的几乎必然仿射关系，则任意非零 a 均有 $\mathrm{Var}(a^\top T) > 0$，信息矩阵正定。

微分合法性来自参数空间的内部性。一维时，选取 $\eta_0 \pm 2a$ 仍在自然参数空间内。对 $m = 1, 2$ 及 $|\eta - \eta_0| \le a$，

$$|t|^m e^{\eta t} \le C_{m,a}\{e^{(\eta_0+2a)t} + e^{(\eta_0-2a)t}\}.$$

乘 h 后右边可积，给出导数所需的局部包络。多维时可用参数邻域内有限个立方体顶点的指数项之和控制。

3.4.3 参数变换与 Jacobian 的方向

设新参数 $\lambda \in \mathbb{R}^r$，旧参数为 $\theta = \psi(\lambda) \in \mathbb{R}^d$，Jacobian 定义为

$$J(\lambda) = D\psi(\lambda) = \left(\frac{\partial\theta_j}{\partial\lambda_r}\right)_{j,r} \in \mathbb{R}^{d\times r}.$$

链式法则给出

$$s_\lambda(X) = J(\lambda)^\top s_\theta(X), \qquad I_\lambda(\lambda) = J(\lambda)^\top I_\theta(\psi(\lambda))J(\lambda).$$

导数方向是“旧参数对新参数”，因为新得分对 λ 求导。这里没有变换样本 X；Jacobian 来自参数的链式求导，不是密度换元的行列式。

指数分布：尺度与率

尺度参数模型 $p_\theta(x)=\theta^{-1}e^{-x/\theta}\mathbf{1}\{x>0\}$ 有

$$s_\theta(x)=\frac{x-\theta}{\theta^2},\qquad I_\theta(\theta)=\frac{1}{\theta^2}.$$

改用率 $\lambda=1/\theta$，$J=\mathrm{d}\theta/\mathrm{d}\lambda=-1/\lambda^2$，因此

$$I_\lambda(\lambda)=\frac{1}{\lambda^4}\,I_\theta(1/\lambda)=\frac{1}{\lambda^2}.$$

直接对 $\log p_\lambda(x)=\log\lambda-\lambda x$ 求导，也有 $s_\lambda=1/\lambda-X$，其方差为 $1/\lambda^2$。只把 $\theta=1/\lambda$ 代入旧信息所得的 λ^2，仍是旧坐标导数的二阶矩，缺少链式因子。

3.4.4 常见模型核对

模型与参数	单次得分	单次信息
$N(\mu,\sigma^2)$，σ^2 已知	$(X-\mu)/\sigma^2$	$1/\sigma^2$
Bernoulli(p)	$(X-p)/\{p(1-p)\}$	$1/\{p(1-p)\}$
Poisson(λ)	$X/\lambda-1$	$1/\lambda$
指数分布，尺度 θ	$(X-\theta)/\theta^2$	$1/\theta^2$

Bernoulli 的自然参数为 $\eta=\log\{p/(1-p)\}$，其信息为 $p(1-p)$，不是原参数 p 下的信息。信息的数值必须连同参数坐标一起解释。

复习题

1. 若 Poisson 均值改写为 $\lambda=e^\eta$，用链式法则计算 I_η，再用对数密度直接验证。
2. 为什么从 $\int p_\theta=1$ 合法求导，尚不足以保证可以从 $\int Tp_\theta$ 合法求导?

答案线索

第一题：$I_\eta=(e^\eta)^2/e^\eta=e^\eta$；新得分是 $X-e^\eta$。第二题：多出的 T 可能无界，需要另行控制 $T\,\partial_\theta p_\theta$ 的可积性，例如提供局部可积包络。

3.5 Cramér–Rao 下界与等号条件

3.5.1 标量下界的完整证明

标量 Cramér–Rao 不等式

设标量参数模型满足前述得分恒等式，$0 < I_n(\theta) < \infty$。统计量 T 无偏估计可微目标 $g(\theta)$，且 $\mathrm{E}_\theta\, T^2 < \infty$。另假设在 $\mathrm{E}_\theta\, T = \int T p_\theta^{(n)}\, \mathrm{d}\nu^n$ 中可以交换微分与积分。则

$$\mathrm{Cov}_\theta(T, S_n) = g'(\theta), \qquad \mathrm{Var}_\theta(T) \geq \frac{g'(\theta)^2}{I_n(\theta)}.$$

i.i.d. 情形 $I_n = nI$。

证明 $T = T(x)$ 不依赖未知参数。对无偏性求导，

$$\begin{aligned} g'(\theta) &= \int T(x)\, \partial_\theta p_\theta^{(n)}(x)\, \mathrm{d}\nu^n(x) \\ &= \mathrm{E}_\theta[T S_n(\theta)] = \mathrm{Cov}_\theta(T, S_n), \end{aligned}$$

末步用了 $\mathrm{E}_\theta\, S_n = 0$。Cauchy–Schwarz 不等式给出

$$g'(\theta)^2 = \{\mathrm{E}_\theta[(T - g(\theta))S_n]\}^2 \leq \mathrm{Var}_\theta(T) I_n(\theta).$$

除以正的信息即得下界。等号成立当且仅当

$$T - g(\theta) = \frac{g'(\theta)}{I_n(\theta)} S_n(\theta) \quad P_\theta\text{-a.s.}$$

当 $g'(\theta) = 0$，下界为零，取等要求 $T = g(\theta)$ 几乎必然，而非任意估计量均取等。

3.5.2 投影分解与下界不可达的可能性

令

$$r = T - g(\theta) - \frac{g'(\theta)}{I_n(\theta)} S_n(\theta).$$

则 $\mathrm{E}_\theta\, r = 0$、$\mathrm{E}_\theta(r S_n) = 0$。平方展开得到精确分解

$$\mathrm{Var}_\theta(T) = \frac{g'(\theta)^2}{I_n(\theta)} + \mathrm{E}_\theta\, r^2.$$

这是 $L^2(P_\theta)$ 中把误差投影到得分方向的勾股关系。残差正交表示不相关，不一般表示独立。投影项可能依赖未知参数，因此不能自动把残差删去、构造一个合法的更好估计量；信息下界可能不可达。

正态均值与均值平方

已知 σ^2 时，$S_n(\mu)=n(\bar X-\mu)/\sigma^2$，$I_n=n/\sigma^2$。估计 $g(\mu)=\mu$，样本均值满足等号条件，方差 σ^2/n 达到下界。
估计 $g(\mu)=\mu^2$ 时，下界为 $4\mu^2\sigma^2/n$，而无偏估计 $U_n=\bar X^2-\sigma^2/n$ 的方差为

$$\operatorname{Var}_\mu(U_n)=\frac{4\mu^2\sigma^2}{n}+\frac{2\sigma^4}{n^2}.$$

它未达到有限样本下界。在 $\mu=0$，下界甚至为零。这并不证明存在方差更小的无偏估计，第四章的最优无偏理论还需单独判断。

3.5.3 有偏估计的修正

若 $\mathrm{E}_\theta T=g(\theta)+b(\theta)$，$b$ 可微且同样允许求导交换，则

$$\operatorname{Cov}_\theta(T,S_n)=g'(\theta)+b'(\theta).$$

因此

$$\operatorname{Var}_\theta(T)\ge\frac{\{g'(\theta)+b'(\theta)\}^2}{I_n(\theta)},$$

$$\operatorname{MSE}_\theta(T)\ge b(\theta)^2+\frac{\{g'(\theta)+b'(\theta)\}^2}{I_n(\theta)}.$$

例如 $X\sim N(\theta,1)$、$T=aX$，$g'=1$、$b'=a-1$，修正后的方差下界是 a^2，恰与实际方差相等。不能把无偏下界 1 用于这个有偏估计。

复习题

1. 指数尺度模型中，证明 $\bar X$ 达到估计 θ 的信息下界。
2. 正态均值模型下，常数估计 $T=m$ 方差为零，为何不违反信息下界？用有偏版本核对。

答案线索

第一题：$I_n=n/\theta^2$，$S_n=n(\bar X-\theta)/\theta^2$，等号条件直接成立。第二题：常数规则并非在整个模型中无偏，$b(\theta)=m-\theta$，故 $g'+b'=0$，有偏下界给出 $\mathrm{MSE}\ge(m-\theta)^2$，正好取等。

3.6 向量参数与矩阵信息下界

设 $\theta\in\mathbb{R}^d$，目标 $g(\theta)\in\mathbb{R}^k$，$T\in\mathbb{R}^k$ 无偏，Jacobian 约定为

$$Dg(\theta)=\left(\frac{\partial g_j}{\partial\theta_r}\right)_{j,r}\in\mathbb{R}^{k\times d}.$$

在二阶矩存在、均值逐分量可交换微分积分、得分正则及 $I_n(\theta)$ 正定的条件下，

$$\mathrm{Cov}_\theta(T, S_n) = Dg(\theta),$$

矩阵 Cramér–Rao 不等式

$$\mathrm{Cov}_\theta(T) \succeq Dg(\theta) I_n(\theta)^{-1} Dg(\theta)^\top.$$

$A \succeq B$ 指 $A - B$ 半正定，即 $u^\top (A-B) u \geq 0$ 对所有 u 成立，并非逐元素大小。估计参数本身时，下界为 I_n^{-1}。

证明 记 $E = T - g(\theta)$、$A = Dg(\theta)$、$B = I_n(\theta)$。则 $\mathrm{Cov}(E, S_n) = A$、$\mathrm{Cov}(S_n) = B$。令

$$U = E - AB^{-1} S_n,$$

得到 $\mathrm{E}\, U = 0$、$\mathrm{Cov}(U, S_n) = A - AB^{-1}B = 0$。因此

$$\mathrm{Cov}(T) = AB^{-1}A^\top + \mathrm{E}(UU^\top).$$

末项半正定，得到结论。矩阵等号成立当且仅当 $\mathrm{E}\,\|U\|^2 = 0$，即

$$T - g(\theta) = Dg(\theta) I_n(\theta)^{-1} S_n(\theta) \quad P_\theta\text{-a.s.}$$

这个证明也给出维度核对：$(k \times d)(d \times d)(d \times k) = k \times k$。

正态均值与未知方差

以 $\theta = (\mu, v)^\top$ 参数化 $N(\mu, v)$，$v > 0$。单次得分为

$$s_\theta(X) = \begin{pmatrix} (X-\mu)/v \\ -1/(2v) + (X-\mu)^2/(2v^2) \end{pmatrix}, \qquad I(\theta) = \begin{pmatrix} 1/v & 0 \\ 0 & 1/(2v^2) \end{pmatrix}.$$

交叉信息为零来自中心正态的三阶矩为零；右下项来自四阶矩 $3v^2$。估计 μ 时 $Dg = (1, 0)$，下界仍为 v/n，由 $\bar{X}$ 达到。
估计 v 时下界为 $2v^2/n$。无偏样本方差 S^2 的方差为 $2v^2/(n-1)$（$n \geq 2$），故未达到此界。方差参数的下界应由整个信息矩阵的逆取得，不能一般地直接用信息矩阵对角元的倒数。

若把 $\theta = (\psi, \lambda)$ 分为目标与干扰参数，对标量目标 ψ，分块信息在 $I_{\lambda\lambda}$ 可逆时给出

$$(I^{-1})_{\psi\psi} = \{I_{\psi\psi} - I_{\psi\lambda} I_{\lambda\lambda}^{-1} I_{\lambda\psi}\}^{-1}.$$

这解释了为何未知干扰参数一般会减少有效信息。正态例中的交叉块为零是一个特殊情形。

复习题

1. 对目标 $g(\theta)=c^\top\theta$，写出标量方差下界。为什么不能逐元素解释矩阵不等式？
2. 在正态例中，改用参数 (μ,σ)，其中 $v=\sigma^2$，求新信息矩阵。

答案线索

第一题：下界为 $c^\top I(\theta)^{-1}c/n$；矩阵偏序同时约束全部线性方向的方差。第二题：旧参数对新参数的 Jacobian 是 $\mathrm{diag}(1,2\sigma)$，故新信息矩阵为 $\mathrm{diag}(1/\sigma^2,2/\sigma^2)$。

3.7 达到下界与指数族结构

3.7.1 自然统计量达到哪个目标的下界

固定样本量，将整份样本密度写作

$$p_\eta^{(n)}(x)=h_n(x)\exp\{\eta T(x)-\zeta(\eta)\}.$$

假设自然参数在归一化积分有限的开区间内变化，且 $\zeta''(\eta)>0$。由归一化函数的导数，

$$\mathrm{E}_\eta\,T=\zeta'(\eta),\qquad \mathrm{Var}_\eta(T)=I_n(\eta)=\zeta''(\eta).$$

对目标 $g(\eta)=\zeta'(\eta)$，信息下界恰为

$$\frac{g'(\eta)^2}{I_n(\eta)}=\zeta''(\eta)=\mathrm{Var}_\eta(T).$$

所以 T 达到其均值目标的下界。这里的 ζ 已是联合模型的归一化函数，不能再给信息乘一个 n。目标是 $\zeta'(\eta)$，并不自动是自然参数 η 本身。

Bernoulli 的自然参数

令 $\eta=\log\{p/(1-p)\}$，$Y=\sum_i X_i$，则

$$p_\eta^{(n)}(x)=\exp\{\eta Y-n\log(1+e^\eta)\}.$$

Y 的均值为 np，方差与样本信息均为 $np(1-p)$；Y 达到估计 np 的下界。相应地，Y/n 达到估计 p 的下界，但这没有提供自然参数 η 的无偏有效估计。

3.7.2 处处取等反推一维指数族

CR 等号的逆向结论

固定样本量，设标量参数在开区间 Θ 内变化，模型满足标量 CR 条件；密度在共同支撑上严格为正，除同一个固定测度零集外关于参数连续可微。另设 $I_n(\theta) > 0$ 与 $g'(\theta) \neq 0$ 连续。

若同一个无偏统计量 T 在每个 $\theta \in \Theta$ 均达到下界，则在一个共同满测度样本集合上，

$$p_\theta^{(n)}(x) = h_n(x) \exp\{\eta(\theta)T(x) - \zeta(\eta(\theta))\},$$

其中 $\eta'(\theta) = I_n(\theta)/g'(\theta) \neq 0$，并有 $g(\theta) = \zeta'(\eta(\theta))$。

证明 令 $k(\theta) = I_n(\theta)/g'(\theta)$。CR 等号给出

$$\partial_\theta \log p_\theta^{(n)}(x) = k(\theta)\{T(x) - g(\theta)\} \quad P_\theta\text{-a.s.}$$

不能直接固定 x 对整个参数区间积分，因为此时异常零集可能随参数改变。

取可数稠密集 $D \subset \Theta$。共同支撑上的密度严格为正，所以每个 $q \in D$ 下的概率零集也是支撑内的控制测度零集。把这些可数零集及密度连续可微的固定异常集一并剔除，得到共同满测度集合 F。对 $x \in F$，上式在所有 $q \in D$ 成立；由两边关于参数连续，遂在全部 Θ 成立。

固定参考点 θ_* 与 $x \in F$，对参数积分：

$$\log p_\theta^{(n)}(x) - \log p_{\theta_*}^{(n)}(x) = \left(\int_{\theta_*}^{\theta} k(t)\,\mathrm{d}t\right) T(x) - \int_{\theta_*}^{\theta} k(t)g(t)\,\mathrm{d}t.$$

定义 $\eta(\theta) = \int_{\theta_*}^{\theta} k(t)\,\mathrm{d}t$、$c(\theta) = \int_{\theta_*}^{\theta} k(t)g(t)\,\mathrm{d}t$，取 $h_n = p_{\theta_*}^{(n)}$，便得到指数形式。k 连续非零，在区间上不能变号，故 η 严格单调，其像为开区间。归一化给出

$$c(\theta) = \log \int h_n(x) e^{\eta(\theta)T(x)}\,\mathrm{d}\nu^n(x) = \zeta(\eta(\theta)).$$

最后由 $c' = kg$、$\eta' = k \neq 0$ 得 $\zeta'(\eta(\theta)) = g(\theta)$。

3.7.3 一点取等不足以推断整族结构

在样本空间 $\{-1, 0, 1\}$ 上，设

$$p_\theta(x) = \frac{1}{3}\left[1 + \theta x + \theta^2\left(x^2 - \frac{2}{3}\right)\right], \qquad |\theta| < \frac{1}{2}.$$

三点概率均为正且总和为 1。取 $T = X$，则 $g(\theta) = 2\theta/3$。在 $\theta = 0$，得分为 X，$I(0) = \mathrm{Var}_0(X) = 2/3$，故

$$\frac{g'(0)^2}{I(0)} = \frac{2}{3} = \mathrm{Var}_0(X).$$

但若该族能以同一个 $T(x)=x$ 写成一维指数形式，则 $p_\theta(1)p_\theta(-1)/p_\theta(0)^2$ 必为常数，而实际等于

$$\frac{1-\theta^2/3+\theta^4/9}{1-4\theta^2/3+4\theta^4/9},$$

会随 θ 改变。这个反例否定的是“一点取等推出以 X 为自然统计量的整族结构”，不是否定模型嵌入更高维指数族的可能性。

复习题

1. 逆向证明中，为什么不能直接合并全部参数点的异常零集？可数稠密集之后为何还要连续性?
2. 联合 Poisson 模型中，$Y=\sum_i X_i$ 的自然参数归一化函数为 $\zeta(\eta)=ne^\eta$。说明 Y 和 Y/n 分别达到哪个目标的下界。

答案线索

第一题：不可数个零集的并未必为零集；可数稠密集先统一样本异常集，连续性再把等式推广至整个区间，才能固定样本点积分。第二题：Y 对 $n\lambda$ 有效，Y/n 对 λ 有效，方差分别为 $n\lambda$ 与 λ/n。

3.8 非正则模型、效率与 MLE 展开

3.8.1 移动支撑为什么使正则恒等式失效

均匀模型的边界项

设 $X_i\sim U(0,\theta)$，$\theta>0$。只在内部 $0<x<\theta$ 对 $\log p_\theta(x)=-\log\theta$ 求导，会得到形式上的内部得分 $-1/\theta$，其均值不为零。实际上

$$\frac{\mathrm{d}}{\mathrm{d}\theta}\int_0^\theta \frac{1}{\theta}\,\mathrm{d}x=\int_0^\theta -\frac{1}{\theta^2}\,\mathrm{d}x+\frac{1}{\theta}=0.$$

移动端点贡献的第二项不能省略。因此内部导数的平方均值 $1/\theta^2$ 不能直接代入正则 CR 公式。

记 $M_n=\max_i X_i$。在 $0<m<\theta$ 上，

$$P_\theta(M_n\le m)=(m/\theta)^n,\qquad \mathrm{E}_\theta\, M_n^r=\frac{n}{n+r}\theta^r\quad(r>0).$$

故 $T_n=(n+1)M_n/n$ 无偏，且

$$\mathrm{Var}_\theta(T_n)=\frac{\theta^2}{n(n+2)}.$$

这比误用正则公式得到的 θ^2/n 小，并不构成对定理的反例。模型的正则条件已经失效。

它的自然误差尺度是 n。对固定 $z \geq 0$，

$$P_\theta\{n(1 - M_n/\theta) > z\} = (1 - z/n)^n \to e^{-z}.$$

因此 $n(1 - M_n/\theta) \xrightarrow{d} E$、$E \sim \mathrm{Exp}(1)$，并有

$$n(T_n - \theta) \xrightarrow{d} \theta(1 - E).$$

更快速度来自支撑边界携带的信息；这里的非正态极限不应混同于正则模型中孤立参数点的超效率现象。

3.8.2 有限样本效率与渐近效率

无偏估计量达到正确的 CR 协方差界，称达到有限样本信息效率。这足以保证它在相应无偏类中无法被方差统一改进；未达到下界则不自动意味着可以改进，因为下界可能不可达。

正则模型中，估计可微目标 $g(\theta)$ 的一阶信息基准为

$$\sqrt{n}\{T_n - g(\theta)\} \xrightarrow{d} N_k\Big(0, Dg(\theta)I(\theta)^{-1}Dg(\theta)^\top\Big).$$

渐近效率的比较涉及适当的局部正则估计量类，不要求每个有限样本量都精确无偏。不能把有限样本无偏下界直接令 $n \to \infty$，便声称对一切估计量序列成立；弱收敛不自动给出风险收敛，偏差和局部行为也须控制。

3.8.3 从得分方程到渐近正态

设真参数为 θ_0，$\widehat{\theta}_n$ 是内部 MLE 或一个选定的得分根，并假设 $S_n(\widehat{\theta}_n) = 0$。多维时使用积分 Hessian，避免给所有分量强设同一个中间点：

$$\widetilde{H}_n = \int_0^1 H_n\{\theta_0 + t(\widehat{\theta}_n - \theta_0)\}\,\mathrm{d}t.$$

在线段位于可微参数邻域的事件上，微积分基本定理给出精确等式

$$0 = S_n(\theta_0) + \widetilde{H}_n(\widehat{\theta}_n - \theta_0).$$

若沿线段矩阵最终可逆，则

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) = \left(-\frac{\widetilde{H}_n}{n}\right)^{-1} \frac{S_n(\theta_0)}{\sqrt{n}}.$$

得分的多元中心极限定理给出

$$S_n(\theta_0)/\sqrt{n} \xrightarrow{d} N_d(0, I(\theta_0)).$$

若另有 $-\widetilde{H}_n/n \xrightarrow{P} I(\theta_0)$，且 $I(\theta_0)$ 正定，则由矩阵求逆的连续性与 Slutsky 定理，

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) \xrightarrow{d} N_d(0, I(\theta_0)^{-1}).$$

展开之外必须补的条件

固定点的大数定律 $-H_n(\theta_0)/n \xrightarrow{P} I(\theta_0)$ 尚不足以控制随机线段上的 Hessian。一组可用的充分条件是：所选根存在且一致；真值附近有凸邻域；该邻域内 $-H_n(v)/n$ 一致收敛到连续函数 $J_{\theta_0}(v)$，并满足 $J_{\theta_0}(\theta_0) = I(\theta_0)$ 正定。于是随机线段收缩至真值，得到所需收敛。

MLE 是否存在、所选根是否一致、最终是否位于内部、多个根如何选择，都不是得分方程本身保证的。边界极值也未必满足得分为零。本段给出的是在这些条件落实后的证明，不是无条件的一般 MLE 定理。

正态均值中的展开是精确恒等式

已知方差时，$S_n(\mu) = n(\bar{X} - \mu)/\sigma^2$，$H_n = -n/\sigma^2$ 为常数，MLE 为 $\bar{X}$。于是

$$\sqrt{n}(\bar{X} - \mu) = \sigma^2 \frac{S_n(\mu)}{\sqrt{n}} \sim N(0, \sigma^2).$$

这里没有 Taylor 余项，且极限方差 $I(\mu)^{-1} = \sigma^2$ 同时也是精确分布的方差。

复习题

1. 在均匀模型中，证明 $n(T_n - \theta) = O_{P_\theta}(1)$，并说明它为何不违背正则模型的信息下界。
2. MLE 渐近正态性的证明中，分别指出使用中心极限定理、大数型控制及 Slutsky 定理的位置。固定点 Hessian 收敛还缺少什么?

答案线索

第一题：$n^2 \operatorname{Var}(T_n) = n\theta^2/(n+2) \le \theta^2$，由 Chebyshev 即得随机有界；该模型支撑依赖参数，正则得分恒等式失效。第二题：CLT 用于真值处的得分，局部一致控制用于随机线段上的 Hessian，Slutsky 用于两者的乘积；仅有固定点收敛不能替代随机邻域控制。