高等统计学中文学习笔记

第一至五章与习题解答

定义、证明与习题

Studyer-Tang

https://github.com/Studyer-Tang

依据 Fang Yao 的 Advanced Mathematical Statistics 课程材料及相关学习推导整理。感谢原课程作者提供讲义与课程框架。本笔记为个人学习记录，非官方讲义或官方译本；原课件与作业未随笔记发布，相关权利归原作者所有。具体范围与校订记录见仓库 SOURCES.md 与 ERRATA.md。

2026 年 10 月 24 日修订

目录

阅读说明 **1**

第 1 章 从样本到经验分布 **2**

1.1 概率论回顾 2

1.1.1 测度论的基本语言 2

1.1.2 Radon–Nikodym 导数与概率密度 4

1.1.3 变量变换、条件期望与积分 5

1.2 总体分布、样本与经验分布函数 7

1.3 经验测度与代入原理 8

1.3.1 统计泛函与代入原理 8

1.3.2 M-估计与 Z-估计 9

1.4 收敛方式与随机阶 11

1.4.1 四种收敛 11

1.4.2 矩不等式 12

1.4.3 随机阶 12

1.5 极限定理与变换 13

1.5.1 大数定律与中心极限定理 13

1.5.2 Lindeberg 中心极限定理 14

1.5.3 连续映射定理与 Slutsky 定理 15

1.5.4 Delta 方法 16

本章总结 19

练习与核对 19

第 2 章 统计模型、指数族、充分性与完备性 **21**

2.1 统计模型 21

2.1.1 从具体样本到模型 21

2.1.2 密度与似然：同一个公式的两个视角 22

2.1.3 最大似然估计与边界 23

2.1.4 参数无关因子与参数相关支撑 24

2.2 指数族 25

2.2.1 指数形式与自然参数 25

2.2.2 满秩表示的两个条件 26

2.2.3 弯曲指数族与参数约束 27

2.3 充分性 27

2.3.1 充分性的条件分布定义 27

2.3.2 共同支配概率的构造与用途 28

2.3.3 Fisher–Neyman 因子分解定理 29

2.3.4 典型充分统计量与模型依赖性 31

2.4 最小充分性 . . . 31
2.4.1 最小充分性的定义 . . . 31
2.4.2 从子模型推广最小充分性 . . . 32
2.4.3 可数模型的显式构造 . . . 33
2.4.4 似然比判别与典型例子 . . . 34
2.5 完备性 . . . 35
2.5.1 完备性与函数唯一性 . . . 35
2.5.2 有界完备且充分推出最小充分 . . . 36
2.5.3 两种直接证明：多项式与积分上限 . . . 37
2.5.4 指数族完备性及开集的作用 . . . 38
2.6 辅助统计量与 Basu 定理 . . . 39
2.6.1 辅助性要求整个分布不含参数 . . . 39
2.6.2 Basu 定理的条件与完整证明 . . . 39
2.6.3 正态与指数模型的独立性应用 . . . 40
2.6.4 反例：最小充分并不意味着完备 . . . 41
2.7 总结与学习检查 . . . 42

第 3 章 决策、估计与信息下界 44
3.1 决策问题与风险比较 . . . 44
3.1.1 从估计规则到风险函数 . . . 44
3.1.2 支配、可容许与极小极大 . . . 45
3.1.3 检验也是决策 . . . 45
3.2 偏差、方差与收缩 . . . 46
3.2.1 均方误差分解 . . . 46
3.2.2 二项比例的加权估计 . . . 46
3.2.3 对称收缩的极小极大计算 . . . 47
3.3 无偏性、一致性与渐近尺度 . . . 48
3.3.1 三种性质应分别检验 . . . 48
3.3.2 一阶相同不等于有限样本相同 . . . 49
3.4 得分与 Fisher 信息 . . . 50
3.4.1 定义与正则条件 . . . 50
3.4.2 指数族的归一化函数 . . . 51
3.4.3 参数变换与 Jacobian 的方向 . . . 51
3.4.4 常见模型核对 . . . 52
3.5 Cramér–Rao 下界与等号条件 . . . 53
3.5.1 标量下界的完整证明 . . . 53
3.5.2 投影分解与下界不可达的可能性 . . . 53
3.5.3 有偏估计的修正 . . . 54
3.6 向量参数与矩阵信息下界 . . . 54
3.7 达到下界与指数族结构 . . . 56
3.7.1 自然统计量达到哪个目标的下界 . . . 56
3.7.2 处处取等反推一维指数族 . . . 57
3.7.3 一点取等不足以推断整族结构 . . . 57

3.8 非正则模型、效率与 MLE 展开 . . . 58
3.8.1 移动支撑为什么使正则恒等式失效 . . . 58
3.8.2 有限样本效率与渐近效率 . . . 59
3.8.3 从得分方程到渐近正态 . . . 59

第 4 章 最优无偏估计与 U 统计量 61
4.1 条件化与一致最小方差无偏估计 . . . 61
4.1.1 UMVUE 的比较范围 . . . 61
4.1.2 条件期望的正交性质 . . . 61
4.1.3 Rao–Blackwell 定理及共同版本 . . . 62
4.1.4 Lehmann–Scheffé 定理 . . . 63
4.2 UMVUE 的几种构造 . . . 64
4.2.1 均匀分布：积分方程与端点条件 . . . 64
4.2.2 Poisson 分布：下降阶乘与幂级数 . . . 65
4.2.3 正态分布：偏差修正 . . . 66
4.2.4 指数分布：条件概率 . . . 66
4.3 正交判别与参数空间的影响 . . . 67
4.3.1 与所有零均值方向正交 . . . 67
4.3.2 限制均匀模型中的改进 . . . 68
4.4 U 统计量：在所有子样本上平均 . . . 69
4.4.1 核与总体泛函 . . . 69
4.4.2 独立随机子集的条件化解释 . . . 70
4.4.3 均值的幂与样本方差 . . . 71
4.5 条件核与精确方差 . . . 71
4.5.1 重叠下标决定协方差 . . . 71
4.5.2 方差速度与退化阶数 . . . 72
4.6 Hájek 投影与非退化极限 . . . 73
4.6.1 投影到单变量加性函数 . . . 73
4.6.2 U 统计量的一阶项与余项 . . . 73
4.6.3 样本方差：与 Delta 方法的核对 . . . 74
4.7 两样本秩统计量 . . . 76
4.7.1 Mann–Whitney 与 Wilcoxon 秩和 . . . 76
4.7.2 两个一阶投影与余项控制 . . . 76
4.7.3 相同分布原假设下的检验 . . . 77
4.8 一阶退化与中心化卡方极限 . . . 78
4.8.1 乘积核的直接计算 . . . 78
4.8.2 积分算子是矩阵作用的推广 . . . 78
4.8.3 第一步：严格降到二阶核 . . . 79
4.8.4 第二步：固定有限谱应用 CLT . . . 80
4.8.5 第三步：以统一均方界处理无限尾项 . . . 80
4.9 综合练习 . . . 81

第 5 章 假设检验与置信集合 83

5.1 检验、功效与比较的范围 . . . 83
5.2 p 值与离散边界随机化 . . . 84
5.2.1 观察值与重复抽样 . . . 84
5.2.2 与嵌套拒绝域的联系 . . . 84
5.2.3 均匀性、超均匀性与复合原假设 . . . 85
5.2.4 离散概率质量怎样补足 . . . 86
5.3 Neyman–Pearson 引理 . . . 87
5.3.1 定理及临界值的存在 . . . 87
5.3.2 最优性与等号条件的证明 . . . 88
5.3.3 似然比平台与不同的最优规则 . . . 88
5.4 单调似然比与单侧 UMP . . . 89
5.4.1 单调似然比与随机单调性 . . . 89
5.4.2 Karlin–Rubin 定理及证明 . . . 90
5.4.3 例子与方向 . . . 90
5.5 双侧困难与无偏约束 . . . 91
5.5.1 正态双侧问题不存在 UMP . . . 91
5.5.2 无偏性给出的两个矩方程 . . . 92
5.6 广义 Neyman–Pearson 引理 . . . 93
5.6.1 多个矩约束下的符号规则 . . . 93
5.6.2 存在性与逆结论的证明 . . . 93
5.7 一参数指数族的双侧 UMPU . . . 95
5.7.1 定理、可行性与双尾结构 . . . 95
5.7.2 同一个规则对全部备择都最优 . . . 96
5.8 干扰参数与条件 UMPU . . . 97
5.8.1 相似性、Neyman 结构与完备性 . . . 97
5.8.2 条件似然比与两个条件矩 . . . 98
5.8.3 未知方差的正态均值检验 . . . 99
5.8.4 两个 Poisson 强度的条件检验 . . . 100
5.9 检验反演与最优置信集合 . . . 100
5.9.1 覆盖率与错误候选的纳入概率 . . . 100
5.9.2 UMP 与 UMA 的对偶 . . . 101
5.9.3 UMPU 与无偏置信集合 . . . 101
5.10 本章结果的使用条件 . . . 102

附录 A 充分性与分布变换习题 103
A.1 柯西位置尺度族的最小充分统计量 . . . 103
A.2 均匀位置族：最小充分但不完备 . . . 103
A.3 可以恢复充分统计量的统计量仍充分 . . . 104
A.4 完备充分统计量与最小充分统计量的关系 . . . 104
A.5 平移指数分布的间距与独立性 . . . 104
A.6 两段支撑模型的最小充分统计量 . . . 105

附录 B 估计、信息与 U 统计量习题 107

B.1 第 1 题二项分布中不存在 1/p 的无偏估计 . . . 107
B.2 第 2 题平方误差下的最优规则与最优线性无偏估计 . . . 107
B.2.1 (a) 所有估计量组成的规则类中不存在统一最优规则 . . . 108
B.2.2 (b) 独立、方差不同时的最优权重 . . . 108
B.2.3 (c) 同分布且任意两项具有相同相关系数 . . . 109
B.3 第 3 题有限参数空间中的一致性与任意收敛速度 . . . 110
B.3.1 (a) 一致性当且仅当选对概率趋于 1 . . . 110
B.3.2 (b) 任意正数列放大后的误差仍依概率趋于零 . . . 111
B.4 第 4 题样本均值与样本中程的风险比较 . . . 111
B.4.1 (a) 正态模型中样本均值严格优于中程 . . . 112
B.4.2 (b) 单位长度均匀模型中中程严格优于样本均值 . . . 113
B.4.3 (c) 构造互不支配的模型族 . . . 114
B.5 第 5 题统计量不能增加 Fisher 信息 . . . 114
B.5.1 准备得分恒等式 . . . 115
B.5.2 (a) 信息差为非负定矩阵 . . . 115
B.5.3 (b) 充分统计量保留全部 Fisher 信息 . . . 116
B.6 第 6 题用似然比差分推导无偏估计的方差下界 . . . 117
B.6.1 (a) 一般下界 . . . 117
B.6.2 (b) 整数均值的正态模型 . . . 118
B.7 第 7 题一个有限离散模型中的 UMVUE 存在性 . . . 119
B.7.1 准备一 UMVUE 的正交判别及证明 . . . 120
B.7.2 准备二求所有均值恒为零的统计量 . . . 120
B.7.3 准备三把正交条件化为三个函数值相等 . . . 121
B.7.4 (a) p 不存在 UMVUE . . . 121
B.7.5 (b) p(1-p) 存在 UMVUE . . . 122
B.8 第 8 题正态均值指数函数的 UMVUE 与 CR 下界 . . . 122
B.8.1 (a) 构造并证明 UMVUE . . . 122
B.8.2 (b) 精确方差严格大于 CR 下界 . . . 123
B.8.3 (c) 方差与下界之比趋于 1 . . . 124
B.9 第 9 题 U 统计量的条件投影及协方差 . . . 124
B.9.1 (a) 逐次积分恒等式 . . . 125
B.9.2 (b) 中心化 U 统计量等于中心化核的平均 . . . 126
B.9.3 (c) 重叠下标数决定两个核的协方差 . . . 126
B.9.4 (d) 投影方差随保留的变量个数单调不减 . . . 127
B.10 第 10 题三个观测之和为负的 U 统计量 . . . 127
B.10.1 第一步约定分布函数并处理严格不等号 . . . 127
B.10.2 第二步写出 U 统计量 . . . 128
B.10.3 第三步计算条件投影 . . . 128
B.10.4 第四步计算三个投影方差 . . . 129
B.11 第 11 题均值与倒数均值乘积的 U 统计量 . . . 129
B.11.1 (a) 构造对称二元核并验证无偏性 . . . 130
B.11.2 (b) 计算一阶投影方差与核方差 . . . 131

B.11.3 (c) 通过核项重叠计数求精确方差 131
B.11.4 (d) 一般的一阶渐近分布 132
B.11.5 (e) 一阶退化时的极限 133

阅读说明

本册将课件内容与学习中反复核对的推导合并编排。正文按数学主题组织，不逐页复制课件。第一、二章分别建立渐近工具与模型结构，第三章讨论风险和信息，第四章转向无偏估计与 U 统计量，第五章研究最优检验及置信集合。

定义和定理用蓝色框，例题用白底侧线框，条件与辨析用灰底框。原有第一、二章的编号继续保留；新增章节按本文结构编号，不与原 Slides 页码逐项对应。概率中的“几乎必然”一般按每个模型分布分别解释；若证明需要共同版本或共同零集，则在相应位置单列说明。

附录 A 整理第一次作业实际讨论的第 7–12 题，附录 B 整理第二次作业全部 11 题。重复讨论的题目合并成一份解答，较短证明保留足够的计算步骤，较长证明把使用条件写在相应等式之前。课件已整理为笔记并不表示已经独立完成全部证明；复习时宜先遮住答案，核对条件、推理和退化情形。

第五章完整收录至置信集合。若按原课程 Slides 的 UMP 范围复习，对应第 1–27 页；UMPU 从第 28 页开始，属于本册保留的后续材料。该范围仅记录已有课程讨论，不能替代后续考试通知。

第 1 章　从样本到经验分布

数理统计以概率规律以及随机样本如何代表这些规律为起点。本章先复习描述分布、密度、条件期望和积分所需的测度论语言，再引入经验分布函数和经验测度，最后利用大数定律、中心极限定理、连续映射定理、Slutsky 定理和 Delta 方法建立基本渐近工具。

本章各部分的关系是

$$\text{总体分布} P \longrightarrow \text{随机样本} X_1,\dots,X_n \longrightarrow \text{经验分布} P_n, F_n \longrightarrow \text{大样本极限理论}.$$

1.1　概率论回顾

1.1.1　测度论的基本语言

定义 1.1.1：σ-域

设 $\mathcal{F}$ 是样本空间 Ω 的若干子集组成的非空集合族。若

$$A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}, \qquad A_i \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F},$$

则称 $\mathcal{F}$ 为一个 σ-域。由 De Morgan 律，它也对可列交封闭。实数轴上的 Borel σ-域 $\mathcal{B}(\mathbb{R})$ 是包含所有开集的最小 σ-域。

概率模型写作三元组

$$(\Omega, \mathcal{F}, P),$$

其中 Ω 给出全部基本结果，$\mathcal{F}$ 规定哪些集合是可测事件，P 则为事件分配概率。

定义 1.1.2：测度与概率

测度 μ 是定义在 $(\Omega,\mathcal{F})$ 上的非负、可列可加集合函数，且 $\mu(\varnothing)=0$。若 A_i 两两不交，则

$$\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i).$$

若再有 $\mu(\Omega)=1$，则 μ 是概率测度。只在一个 P-零测集上可能失败的命题称为几乎必然成立，记为 a.s.。

连续空间中最常见的参考测度是 Lebesgue 测度 λ，满足

$$\lambda((a,b)) = b-a.$$

可数空间中最常见的是计数测度

$$\#(A) = |A|.$$

若存在 $A_1, A_2, \ldots \in \mathcal{F}$，使得

$$\Omega = \bigcup_{n=1}^{\infty} A_n, \qquad \mu(A_n) < \infty,$$

则称 μ 为 σ-有限测度。Lebesgue 测度在 $\mathbb{R}$ 上是 σ-有限的，因为 $\mathbb{R} = \bigcup_n [-n, n]$；而 $\mathbb{R}$ 上的计数测度不是 σ-有限的。

定义 1.1.3：离散概率测度

若概率测度 P 集中在有限或可数集合 $\{x_1, x_2, \ldots\}$ 上，且

$$P(E) = \sum_i p_i \mathbf{1}_{\{x_i \in E\}}, \qquad p_i \geq 0, \qquad \sum_i p_i = 1,$$

则称 P 为离散概率测度。

定义 1.1.4：绝对连续

若对每个 $E \in \mathcal{F}$ 都有

$$\nu(E) = 0 \Rightarrow \mu(E) = 0,$$

则称 μ 关于 ν 绝对连续，记为 $\mu \ll \nu$，也称 μ 被 ν 控制。

绝对连续的直觉

ν 可以看作参考尺子。$\mu \ll \nu$ 并不表示 $\mu(E) \leq \nu(E)$，它只比较零测集：ν 完全看不见的集合，μ 不能在上面放置正质量。
例如，若 $P(X = 0) = 0.4$、$P(X = 1) = 0.6$，则

$$\lambda(\{0\}) = 0, \qquad P_X(\{0\}) = 0.4,$$

所以 $P_X \not\ll \lambda$。但在其可数支撑上，$P_X \ll \#$。

定义 1.1.5：随机变量与概率律

随机变量是可测映射 $X : \Omega \to \mathbb{R}$，即对所有 $a \in \mathbb{R}$，

$$X^{-1}((-\infty, a]) = \{\omega : X(\omega) \leq a\} \in \mathcal{F}.$$

它的概率律是 $\mathcal{B}(\mathbb{R})$ 上的概率测度

$$\boxed{P_X(B) = P\big(X^{-1}(B)\big) = P(X \in B)}.$$

这里 P 只能直接测量 Ω 中的事件，而 B 位于数值空间 $\mathbb{R}$。原像

$$X^{-1}(B) = \{\omega : X(\omega) \in B\}$$

把 B 拉回到原样本空间，再由 P 计算概率。注意 P_X 是概率测度，$P_X(B)$ 才是一个具体概率值。

1.1.2 Radon–Nikodym 导数与概率密度

定理 1.1.1：Radon–Nikodym 定理

设 μ, ν 是 $(\Omega, \mathcal{F})$ 上的 σ-有限测度。若 $\mu \ll \nu$，则存在非负可测函数 f，使得

$$\mu(E) = \int_E f \, \mathrm{d}\nu, \qquad E \in \mathcal{F}.$$

函数 f 称为 μ 关于 ν 的 Radon–Nikodym 导数，记为

$$f = \frac{\mathrm{d}\mu}{\mathrm{d}\nu}.$$

它在 ν-几乎处处意义下唯一。

RN 导数表示“每单位 ν-测度含有多少 μ-质量”。核心恒等式是

$$\boxed{\mu(E) = \int_E \frac{\mathrm{d}\mu}{\mathrm{d}\nu} \, \mathrm{d}\nu.}$$

在离散空间中，以计数测度为参考，

$$\frac{\mathrm{d}P}{\mathrm{d}\#}(x) = P(\{x\}),$$

就是 PMF。在连续空间中，若 $P_X \ll \lambda$，则

$$f_X = \frac{\mathrm{d}P_X}{\mathrm{d}\lambda}$$

就是通常的 PDF，并且

$$P(X \in A) = \int_A f_X(x) \, \mathrm{d}x, \qquad F_X(x) = \int_{-\infty}^{x} f_X(y) \, \mathrm{d}y.$$

密度依赖参考测度

密度必须连同参考测度理解。对同一个概率分布，若不同参考测度均允许相应的 RN 表示，所得密度可能不同；并不是任意分布对计数测度或 Lebesgue 测度都有密度。密度值也可以超过 1；只有对集合积分以后才得到概率。

若 $\mathcal{P}$ 是概率测度族，并存在同一个 σ-有限测度 ν 使每个 $P \in \mathcal{P}$ 都满足 $P \ll \nu$，则称 $\mathcal{P}$ 被 ν 控制，并可由密度族

$$\left\{ \frac{\mathrm{d}P}{\mathrm{d}\nu} : P \in \mathcal{P} \right\}$$

表示。

RN 导数具有换测度、可加性和链式法则：

$$\int g \,\mathrm{d}\mu = \int g \frac{\mathrm{d}\mu}{\mathrm{d}\nu} \,\mathrm{d}\nu,$$

$$\frac{\mathrm{d}(\mu_1 + \mu_2)}{\mathrm{d}\nu} = \frac{\mathrm{d}\mu_1}{\mathrm{d}\nu} + \frac{\mathrm{d}\mu_2}{\mathrm{d}\nu},$$

以及当 $\tau \ll \mu \ll \nu$ 时，

$$\frac{\mathrm{d}\tau}{\mathrm{d}\nu} = \frac{\mathrm{d}\tau}{\mathrm{d}\mu} \frac{\mathrm{d}\mu}{\mathrm{d}\nu}.$$

连续 CDF 不一定有密度

Cantor 分布集中在不可数但 Lebesgue 测度为零的 Cantor 集 C 上：

$$P_X(C) = 1, \qquad \lambda(C) = 0.$$

同时它没有单点质量，因此 CDF 处处连续。这说明 CDF 连续只能排除点质量，却不能排除概率集中在零长度的不可数集合上：

$$\text{CDF 连续} \not\Rightarrow P_X \ll \lambda.$$

1.1.3 变量变换、条件期望与积分

设 $f : (\Omega, \mathcal{F}, \nu) \to (\Lambda, \mathcal{G})$ 可测。它诱导推前测度

$$(\nu \circ f^{-1})(B) = \nu(f^{-1}(B)).$$

定理 1.1.2：变量变换

对任意非负可测函数或可积函数 g，

$$\int_\Omega g \circ f \,\mathrm{d}\nu = \int_\Lambda g \,\mathrm{d}(\nu \circ f^{-1}).$$

当 $\nu = P$、$f = X$ 时，推前测度就是 $P_X = P \circ X^{-1}$，从而

$$\mathrm{E}\{h(X)\} = \int_\Omega h(X(\omega)) \,\mathrm{d}P(\omega) = \int_{\mathbb{R}} h(x) \,\mathrm{d}P_X(x).$$

定义 1.1.7：条件期望

设 X 可积，$\mathcal{G} \subseteq \mathcal{F}$。条件期望 $Z = \mathrm{E}(X \mid \mathcal{G})$ 是满足以下条件且 a.s. 唯一的随机变量：

1. Z 是 $\mathcal{G}$-可测的；
2. 对每个 $A \in \mathcal{G}$，
$$\int_A Z \,\mathrm{d}P = \int_A X \,\mathrm{d}P.$$

第二个条件等价于

$$\mathrm{E}\{(X - Z)\mathbf{1}_A\} = 0, \qquad A \in \mathcal{G},$$

即残差在每个已知信息事件上的平均值都为零。给定随机变量 Y 的条件期望定义为

$$\mathrm{E}(X \mid Y) = \mathrm{E}\{X \mid \sigma(Y)\}.$$

塔式性质与全期望公式分别为

$$\mathcal{H} \subseteq \mathcal{G} \Rightarrow \mathrm{E}(X \mid \mathcal{H}) = \mathrm{E}\{\mathrm{E}(X \mid \mathcal{G}) \mid \mathcal{H}\},$$

$$\mathrm{E}\{\mathrm{E}(X \mid \mathcal{G})\} = \mathrm{E}\, X.$$

完全信息下 $\mathrm{E}(X \mid \mathcal{F}) = X$ a.s.；平凡信息下 $\mathrm{E}(X \mid \mathcal{G}) = \mathrm{E}\, X$。

若 (X, Y) 具有联合密度，则当 $f_Y(y) > 0$ 时，

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{f_{X,Y}(x, y)}{\int f_{X,Y}(u, y) \,\mathrm{d}u}.$$

定理 1.1.3：Fubini–Tonelli 定理

设 $(\Omega_i, \mathcal{F}_i, \nu_i)$ $(i = 1, 2)$ 是两个 σ-有限测度空间，f 是关于 $\mathcal{F}_1 \otimes \mathcal{F}_2$ 可测的函数。若 $f \geq 0$（Tonelli，积分允许取 $+\infty$），或 $\int |f| \,\mathrm{d}(\nu_1 \times \nu_2) < \infty$（Fubini，积分有限），则可以交换积分次序：

$$\begin{aligned}\int f \,\mathrm{d}(\nu_1 \times \nu_2) &= \int_{\Omega_2} \left[\int_{\Omega_1} f(\omega_1, \omega_2) \,\mathrm{d}\nu_1 \right] \mathrm{d}\nu_2 \\ &= \int_{\Omega_1} \left[\int_{\Omega_2} f(\omega_1, \omega_2) \,\mathrm{d}\nu_2 \right] \mathrm{d}\nu_1.\end{aligned}$$

这里明确采用两个测度均为 σ-有限的版本。概率测度与 $\mathbb{R}$ 上的 Lebesgue 测度满足这一条件，但前面提到的 $\mathbb{R}$ 上计数测度不满足；涉及非 σ-有限测度时不能直接援用本框中的定理。

基本收敛定理包括：对 $X_n \geq 0$，Fatou 引理给出

$$\mathrm{E}(\liminf_n X_n) \leq \liminf_n \mathrm{E}\, X_n;$$

若 $X_n \xrightarrow{\text{a.s.}} X$ 且 $|X_n| \le Y$、$\mathrm{E}\,Y < \infty$，控制收敛定理给出

$$\mathrm{E}\,X_n \to \mathrm{E}\,X;$$

若 $0 \le X_n \uparrow X$ a.s.，单调收敛定理同样给出 $\mathrm{E}\,X_n \to \mathrm{E}\,X$，两端允许为无穷大。

1.2 总体分布、样本与经验分布函数

给定概率测度 P，通常写 $X \sim P$。对期望存在的可测函数 f，记

$$\boxed{Pf := \int f \,\mathrm{d}P = \mathrm{E}\{f(X)\}.} \tag{1.1}$$

总体是一个一般观测 X 的概率分布 P；统计模型是可能总体分布的集合 $\mathcal{P}$。参数模型通常写为

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}, \qquad \Theta \subseteq \mathbb{R}^d,$$

非参数模型则允许未知参数本身是函数。

定义 1.2.1：随机样本

若

$$X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} P,$$

则称其为来自 P 的随机样本。其联合分布是乘积测度 P^n。观测前 X_i 和统计量 $\bar{X}$ 是随机的；观测后得到的数据 x_i 和数值 $\bar{x}$ 是固定的。

总体 CDF F 未知。落入 $(-\infty, x]$ 的观测比例定义经验 CDF：

$$\boxed{F_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}_{\{X_i \le x\}}.}$$

每个实现样本对应的 F_n 都是阶梯型 CDF。若 $X_{(1)} \le \cdots \le X_{(n)}$ 是次序统计量，则

$$F_n^{-1}(p) = \inf\{x : F_n(x) \ge p\} = X_{(\lceil np \rceil)}, \qquad 0 < p \le 1.$$

固定 x，令 $Y_i(x) = \mathbf{1}_{\{X_i \le x\}}$。则

$$Y_i(x) \sim \text{Bernoulli}(F(x)), \qquad nF_n(x) \sim \text{Binomial}(n, F(x)). \tag{1.2}$$

定理 1.2.1：经验 CDF 的均值与方差

对每个固定 $x \in \mathbb{R}$，

$$\mathrm{E}\,F_n(x) = F(x), \qquad \mathrm{Var}(F_n(x)) = \frac{F(x)\{1 - F(x)\}}{n}.$$

该结论是点态的，只控制固定 x，并不能直接控制

$$\sup_x |F_n(x) - F(x)|.$$

后者需要同时控制整个阈值函数类。

对 $x, y \in \mathbb{R}$，令 $x \wedge y = \min\{x, y\}$，则

$$\boxed{\mathrm{Cov}(F_n(x), F_n(y)) = \frac{F(x \wedge y) - F(x)F(y)}{n}.} \tag{1.3}$$

1.3 经验测度与代入原理

对随机样本 $X_1, \ldots, X_n$，定义经验测度

$$\boxed{P_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{X_i}},$$

其中 δ_x 是点质量测度：

$$\delta_x(A) = \mathbf{1}_A(x), \qquad \int f \, \mathrm{d}\delta_x = f(x).$$

因此

$$P_n(A) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_A(X_i), \qquad P_n f = \frac{1}{n} \sum_{i=1}^{n} f(X_i).$$

经验 CDF 是特殊情形

$$F_n(t) = P_n((-\infty, t]) = P_n \mathbf{1}_{(-\infty, t]}.$$

命题 1.3.1：经验积分的均值与方差

若 f 可积，则

$$\mathrm{E}(P_n f) = P f.$$

若 $f \in L^2(P)$，则

$$\mathrm{Var}(P_n f) = \frac{\mathrm{Var}(f(X))}{n}.$$

1.3.1 统计泛函与代入原理

定义 1.3.1：统计泛函

设 $\mathcal{Q}$ 包含统计模型 $\mathcal{P}$ 以及所考虑的经验测度。统计泛函是映射

$$T : \mathcal{Q} \to \mathcal{D}.$$

$T(P)$ 表示总体分布的某个特征。用 P_n 替换未知 P，得到代入估计量

$$\boxed{\widehat{\theta}_n = T(P_n).}$$

对固定可积函数 ψ，

$$T_\psi(P) = P\psi = \int \psi \, \mathrm{d}P$$

是关于分布 P 的线性泛函，因为

$$T_\psi(aP_1 + bP_2) = aT_\psi(P_1) + bT_\psi(P_2).$$

代入 P_n 后，

$$T_\psi(P_n) = P_n\psi = \frac{1}{n}\sum_{i=1}^{n} \psi(X_i).$$

“线性”是对分布而言

$\psi(x)$ 本身不必对 x 线性。例如 $\psi(x) = x^2$ 虽是非线性函数，但 $P \mapsto P(x^2)$ 仍对 P 线性。方差

$$\mathrm{Var}_P(X) = P(x^2) - (Px)^2$$

则不是线性泛函，因为它包含积分结果的平方。

均值与方差的直接代入估计为

$$\bar{X} = P_n x, \qquad S_n^2 = P_n(x^2) - (P_n x)^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

分位数泛函及其代入估计为

$$T_p(P) = F^{-1}(p), \qquad T_p(P_n) = F_n^{-1}(p).$$

1.3.2 M-估计与 Z-估计

设 $m_\theta(x)$ 衡量候选参数 θ 在观测 x 上的表现。总体准则与经验准则分别是

$$M(\theta) = Pm_\theta, \qquad M_n(\theta) = P_n m_\theta.$$

M-估计定义为

$$\boxed{\widehat{\theta}_n \in \arg\max_{\theta\in\Theta} P_n m_\theta.}$$

若使用损失 $\rho_\theta = -m_\theta$，等价地写为最小化 $P_n\rho_\theta$。

平方损失给出样本均值

取 $\rho_\theta(x) = (x-\theta)^2$。由于

$$\mathrm{E}(X-\theta)^2 = \mathrm{Var}(X) + (\mu-\theta)^2,$$

总体最优点是 $\theta = \mu$。经验问题

$$\arg\min_\theta \frac{1}{n}\sum_{i=1}^n (X_i-\theta)^2$$

的一阶条件给出 $\widehat{\theta}_n = \bar{X}$。若取绝对值损失 $|x-\theta|$，相应 M-估计量则是样本中位数。

在受支配模型中取

$$m_\theta(x) = \log p_\theta(x),$$

便得到最大似然估计。因此 MLE 是 M-估计的特殊情形。

Z-估计从总体估计方程出发：设 $\psi_\theta : \mathcal{X} \to \mathbb{R}^s$，总体参数满足

$$P\psi_{\theta(P)} = 0.$$

用 P_n 替换 P，得到

$$\boxed{P_n\psi_{\widehat{\theta}_n} = 0.}$$

任何解都称为 Z-估计量。

样本均值也是 Z-估计

取 $\psi_\theta(x) = x-\theta$。总体方程

$$\mathrm{E}(X-\theta) = 0$$

的解为 $\theta = \mu$；经验方程

$$\frac{1}{n}\sum_{i=1}^n (X_i-\theta) = 0$$

的解为 $\widehat{\theta}_n = \bar{X}$。

若 M-准则光滑且最优点位于参数空间内部，其一阶条件通常给出 Z-方程。最大似然中的得分函数

$$\dot{\ell}_\theta(x) = \nabla_\theta \log p_\theta(x)$$

满足

$$0 = \nabla_\theta \ell_n(\widehat{\theta}_n) = nP_n\dot{\ell}_{\widehat{\theta}_n}.$$

边界最大值和不可微似然不一定满足这个方程，需要单独处理。

1.4 收敛方式与随机阶

1.4.1 四种收敛

设 $\boldsymbol{Y}_n, \boldsymbol{Y} \in \mathbb{R}^k$。主要收敛概念如下：

$$\begin{aligned}
\boldsymbol{Y}_n \xrightarrow{\text{a.s.}} \boldsymbol{Y} &\iff P(\lim_n \boldsymbol{Y}_n = \boldsymbol{Y}) = 1,\\
\boldsymbol{Y}_n \xrightarrow{L^r} \boldsymbol{Y} &\iff \mathrm{E}\,\|\boldsymbol{Y}_n - \boldsymbol{Y}\|_r^r \to 0,\\
\boldsymbol{Y}_n \xrightarrow{P} \boldsymbol{Y} &\iff P(\|\boldsymbol{Y}_n - \boldsymbol{Y}\| > \varepsilon) \to 0 \quad \forall \varepsilon > 0,\\
\boldsymbol{Y}_n \xrightarrow{d} \boldsymbol{Y} &\iff P_{\boldsymbol{Y}_n} \Rightarrow P_{\boldsymbol{Y}}.
\end{aligned}$$

依分布收敛等价于：对每个有界连续函数 h，

$$\mathrm{E}\,h(\boldsymbol{Y}_n) \to \mathrm{E}\,h(\boldsymbol{Y}).$$

定理 1.4.1：依概率收敛的子序列刻画

$\boldsymbol{Y}_n \xrightarrow{P} \boldsymbol{Y}$ 当且仅当每个子序列 $(\boldsymbol{Y}_{n_j})$ 都存在一个进一步子序列 $(\boldsymbol{Y}_{n_{j_\ell}})$，使

$$\boldsymbol{Y}_{n_{j_\ell}} \xrightarrow{\text{a.s.}} \boldsymbol{Y}.$$

证明。若 $\boldsymbol{Y}_n \xrightarrow{P} \boldsymbol{Y}$，对任意子序列可递归选取进一步子序列，使

$$P(\|\boldsymbol{Y}_{n_{j_\ell}} - \boldsymbol{Y}\| > 2^{-\ell}) < 2^{-\ell}.$$

这些概率之和有限，由第一 Borel–Cantelli 引理，以概率一只有有限多个相应事件发生，故进一步子序列几乎必然收敛。

反之，若不依概率收敛，可选 $\varepsilon, \eta > 0$ 及子序列，使每项均有 $P(\|\boldsymbol{Y}_{n_j} - \boldsymbol{Y}\| > \varepsilon) \geq \eta$。按假设，它有几乎必然收敛的进一步子序列；相应事件的示性函数趋于零，被常数 1 控制，由控制收敛定理其概率趋零，矛盾。

弱收敛的闭集判别及证明

欧氏空间中，$Y_n \xrightarrow{d} Y$ 等价于对每个闭集 F 有

$$\limsup_n P(Y_n \in F) \leq P(Y \in F).$$

这称为 Portmanteau 定理的闭集刻画。
先假定弱收敛。对非空闭集取连续函数 $h_\delta(x) = \max\{1 - d(x, F)/\delta, 0\}$，则 $\mathbf{1}_F \leq h_\delta \leq 1$，$h_\delta \downarrow \mathbf{1}_F$ 当 $\delta \downarrow 0$。弱收敛及控制收敛给出

$$\limsup_n P(Y_n \in F) \leq \mathrm{E}\,h_\delta(Y) \downarrow P(Y \in F).$$

空集情形显然。
反之，闭集不等式取补集便得到开集概率的下极限不等式。若 h 连续且 $0 \le h \le M$，由分层积分与 Fatou 引理，

$$\begin{aligned}\liminf_n \mathrm{E}\, h(Y_n) &= \liminf_n \int_0^M P\{h(Y_n) > t\}\,\mathrm{d}t \\ &\ge \int_0^M \liminf_n P\{h(Y_n) > t\}\,\mathrm{d}t \ge \mathrm{E}\, h(Y).\end{aligned}$$

再对 $M - h$ 应用同一结论得上极限不等式。一般有界连续函数先平移到非负，故其期望收敛，得到弱收敛。

标准蕴含关系为

$$\boxed{\boldsymbol{Y}_n \xrightarrow{\text{a.s.}} \boldsymbol{Y} \Rightarrow \boldsymbol{Y}_n \xrightarrow{P} \boldsymbol{Y} \Rightarrow \boldsymbol{Y}_n \xrightarrow{d} \boldsymbol{Y}.}$$

若有 L^r 收敛，也能由 Markov 不等式推出依概率收敛。

1.4.2 矩不等式

定理 1.4.2：Markov 不等式

若 $Z \ge 0$ 且 $\mathrm{E}\, Z < \infty$，则对每个 $t > 0$，

$$P(Z \ge t) \le \frac{\mathrm{E}\, Z}{t}.$$

对 $Z = (X - \mathrm{E}\, X)^2$ 应用 Markov 不等式，得到 Chebyshev 不等式

$$\boxed{P(|X - \mathrm{E}\, X| \ge t) \le \frac{\mathrm{Var}(X)}{t^2}.}$$

更一般地，

$$P(\|\boldsymbol{Y}_n - \boldsymbol{Y}\|_r > \varepsilon) \le \frac{\mathrm{E}\,\|\boldsymbol{Y}_n - \boldsymbol{Y}\|_r^r}{\varepsilon^r}. \tag{1.4}$$

1.4.3 随机阶

对正确定数列 a_n，定义

$$Y_n = O_p(a_n) \iff \frac{Y_n}{a_n} \text{ 依概率有界},$$

$$Y_n = o_p(a_n) \iff \frac{Y_n}{a_n} \xrightarrow{P} 0.$$

更具体地，$Y_n = O_p(a_n)$ 表示对任意 $\varepsilon > 0$，存在 $C_\varepsilon < \infty$，使

$$\sup_{n \ge 1} P(|Y_n| > C_\varepsilon a_n) < \varepsilon.$$

基本运算规则包括

$$o_p(a_n)O_p(b_n) = o_p(a_n b_n),$$
$$O_p(a_n) + O_p(b_n) = O_p(a_n + b_n),$$
$$o_p(a_n) + o_p(b_n) = o_p(a_n + b_n).$$

样本均值的随机阶

若 X_i i.i.d.，均值为 μ、方差为 σ^2，则中心极限定理给出

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

因此

$$\bar{X}_n - \mu = O_p(n^{-1/2}) = o_p(1),$$

但一般不是 $o_p(n^{-1/2})$，因为标准化误差并未收敛到零，而是收敛到非退化正态分布。

1.5 极限定理与变换

1.5.1 大数定律与中心极限定理

若 X_i i.i.d.，均值为 μ、方差为 $\sigma^2 < \infty$，Chebyshev 不等式给出

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \to 0. \tag{1.5}$$

定理 1.5.1：强大数定律

若 $X_i \overset{\text{i.i.d.}}{\sim} P$ 且 $P|f| < \infty$，则

$$\boxed{P_n f \xrightarrow{\text{a.s.}} Pf.}$$

特别地，对每个固定 x，$F_n(x) \xrightarrow{\text{a.s.}} F(x)$。

定理 1.5.2：中心极限定理

若 $Pf^2 < \infty$，$\sigma_f^2 = \mathrm{Var}(f(X)) \in (0, \infty)$，则

$$\boxed{\sqrt{n}(P_n - P)f = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \{f(X_i) - Pf\} \xrightarrow{d} N(0, \sigma_f^2).}$$

固定 x 并取 $f_x(z) = \mathbf{1}_{\{z \leq x\}}$，可得

$$\sqrt{n}\{F_n(x) - F(x)\} \xrightarrow{d} N(0, F(x)\{1 - F(x)\}).$$

大数定律说明误差消失，中心极限定理则描述误差在 $n^{-1/2}$ 尺度上的波动。

1.5.2 Lindeberg 中心极限定理

定理 1.5.3：Lindeberg 中心极限定理

对每个 n，设 $X_{n1},\dots,X_{nk_n}$ 相互独立。令

$$Y_{nj}=X_{nj}-\mathrm{E}\,X_{nj},\qquad s_n^2=\sum_{j=1}^{k_n}\mathrm{Var}(X_{nj})\in(0,\infty).$$

若对每个 $\varepsilon>0$，

$$\frac{1}{s_n^2}\sum_{j=1}^{k_n}\mathrm{E}\Big[Y_{nj}^2\mathbf{1}_{\{|Y_{nj}|>\varepsilon s_n\}}\Big]\to 0, \tag{1.6}$$

则

$$\boxed{\frac{1}{s_n}\sum_{j=1}^{k_n}Y_{nj}\xrightarrow{d}N(0,1).} \tag{1.7}$$

Lindeberg 条件表示：相对于总方差 s_n^2，异常大项贡献的方差比例趋于零。它排除了由一个或少数几个变量支配全部波动的情形。

异质 Bernoulli 顾客例子

设第 n 天有 n 位独立顾客，

$$X_{nj}\sim\mathrm{Bernoulli}\left(\frac{j}{2n}\right),\qquad j=1,\dots,n.$$

总购买人数 $T_n=\sum_j X_{nj}$ 满足

$$\mathrm{E}\,T_n=\frac{n+1}{4},\qquad s_n^2=\frac{(n+1)(4n-1)}{24n}\sim\frac{n}{6}.$$

由于 $|X_{nj}-\mathrm{E}\,X_{nj}|\le 1$ 而 $s_n\to\infty$，对固定 $\varepsilon>0$，事件

$$|Y_{nj}|>\varepsilon s_n$$

最终不可能发生，故 Lindeberg 条件成立。因此

$$\frac{T_n-(n+1)/4}{\sqrt{(n+1)(4n-1)/(24n)}}\xrightarrow{d}N(0,1).$$

各顾客购买概率不同，但总购买人数仍具有正态极限。

1.5.3 连续映射定理与 Slutsky 定理

定理 1.5.4：连续映射定理

设 g 为 Borel 可测映射。若 g 在除 $P_{\boldsymbol{Y}}$-零测集外的每一点连续，则

$$\boldsymbol{Y}_n \xrightarrow{\text{a.s.}} \boldsymbol{Y} \Rightarrow g(\boldsymbol{Y}_n) \xrightarrow{\text{a.s.}} g(\boldsymbol{Y}),$$

$$\boldsymbol{Y}_n \xrightarrow{P} \boldsymbol{Y} \Rightarrow g(\boldsymbol{Y}_n) \xrightarrow{P} g(\boldsymbol{Y}),$$

$$\boldsymbol{Y}_n \xrightarrow{d} \boldsymbol{Y} \Rightarrow g(\boldsymbol{Y}_n) \xrightarrow{d} g(\boldsymbol{Y}).$$

证明。设 g 可测，D_g 为其不连续点集，$P(\boldsymbol{Y} \in D_g) = 0$。几乎必然收敛时，在 $\boldsymbol{Y}_n(\omega) \to \boldsymbol{Y}(\omega)$ 且 $\boldsymbol{Y}(\omega) \notin D_g$ 的概率一事件上应用连续性定义即可。

依概率收敛时，任取子序列。由子序列刻画，可选进一步子序列几乎必然收敛到 $\boldsymbol{Y}$，其像也几乎必然收敛。再用一次子序列刻画，得 $g(\boldsymbol{Y}_n) \xrightarrow{P} g(\boldsymbol{Y})$。

依分布收敛时，取像空间中的闭集 F。若 $x \in \overline{g^{-1}(F)}$ 且 $x \notin D_g$，可取 $x_j \in g^{-1}(F)$ 收敛到 x；由连续性与 F 的闭性，$g(x) \in F$。故

$$\overline{g^{-1}(F)} \subseteq g^{-1}(F) \cup D_g.$$

由 Portmanteau 定理的闭集不等式，

$$\begin{aligned}\limsup_n P\{g(\boldsymbol{Y}_n) \in F\} &\le \limsup_n P\{\boldsymbol{Y}_n \in \overline{g^{-1}(F)}\} \\ &\le P\{\boldsymbol{Y} \in \overline{g^{-1}(F)}\} \le P\{g(\boldsymbol{Y}) \in F\}.\end{aligned}$$

再次使用 Portmanteau 定理即得结论，不要求 g 处处连续。

例如，若 $\bar{X}_n \xrightarrow{P} \mu$ 且 g 在 μ 处连续，则

$$g(\bar{X}_n) \xrightarrow{P} g(\mu).$$

命题 1.5.1：渐近等价

若

$$\boldsymbol{U}_n \xrightarrow{d} \boldsymbol{U}, \qquad \|\boldsymbol{V}_n - \boldsymbol{U}_n\| \xrightarrow{P} 0,$$

则 $\boldsymbol{V}_n \xrightarrow{d} \boldsymbol{U}$。

渐近等价的证明。对 $h \in C_c(\mathbb{R}^k)$，令 $M = \sup|h|$。紧支撑连续函数在整个空间一致连续，故给定 $\eta > 0$，可选 $\delta > 0$ 使距离不超过 δ 时函数值之差不超过 η。于是

$$|\operatorname{E} h(\boldsymbol{V}_n) - \operatorname{E} h(\boldsymbol{U}_n)| \le \eta + 2MP(\|\boldsymbol{V}_n - \boldsymbol{U}_n\| > \delta).$$

先令 $n \to \infty$，再令 $\eta \downarrow 0$，左侧趋于零。由 $\boldsymbol{U}_n \xrightarrow{d} \boldsymbol{U}$，得到 $\operatorname{E} h(\boldsymbol{V}_n) \to \operatorname{E} h(\boldsymbol{U})$。在欧氏空间，对所有 C_c 函数的积分收敛到一个概率律即可推出弱收敛：用紧支撑连续函数

$0 \le \chi_R \le 1$ 截断，先控制尾部概率，再把有界连续函数写成 $h\chi_R + h(1-\chi_R)$。因此 $\boldsymbol{V}_n \xrightarrow{d} \boldsymbol{U}$。一般有界连续函数未必一致连续，不能直接套用上述 δ。

定理 1.5.5：Slutsky 定理

若 $Y_n \xrightarrow{d} Y$、$Z_n \xrightarrow{P} c$，其中 c 为常数，则

$$(Y_n, Z_n) \xrightarrow{d} (Y, c).$$

因此

$$Y_n + Z_n \xrightarrow{d} Y + c, \qquad Z_n Y_n \xrightarrow{d} cY,$$

且当 $c \neq 0$ 时，

$$\frac{Y_n}{Z_n} \xrightarrow{d} \frac{Y}{c}.$$

Slutsky 定理的证明。连续映射 $y \mapsto (y, c)$ 给出 $(Y_n, c) \xrightarrow{d} (Y, c)$，且

$$\|(Y_n, Z_n) - (Y_n, c)\| = \|Z_n - c\| \xrightarrow{P} 0.$$

由渐近等价命题得到联合收敛，再对加法、乘法、除法应用连续映射定理。除法在分母非零处连续，故需 $c \neq 0$；若某些 n 的分母为零，可在该事件任意补定义，其概率趋于零。

学生化样本均值

设样本独立同分布，且有限方差 $\sigma^2 > 0$。令

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2.$$

中心极限定理给出

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0,1),$$

而大数定律与连续映射定理给出 $S_n/\sigma \xrightarrow{P} 1$。由 Slutsky 定理，

$$\boxed{\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \xrightarrow{d} N(0,1).}$$

相合的尺度估计量可以替代未知总体尺度，而不改变一阶极限分布。

1.5.4 Delta 方法

连续映射定理可以处理相合性，却不能描述非线性变换后的一阶波动。Delta 方法将随机变量的 Taylor 展开与已有渐近分布结合起来。

命题 1.5.2：随机 Taylor 展开

若 $\boldsymbol{X}_n \xrightarrow{P} \boldsymbol{c}$，且当 $\boldsymbol{h} \to 0$ 时

$$g(\boldsymbol{c}+\boldsymbol{h}) = g(\boldsymbol{c}) + \sum_{j=1}^{m} \frac{1}{j!} D^j g(\boldsymbol{c})[\boldsymbol{h},\dots,\boldsymbol{h}] + R_m(\boldsymbol{h}),$$

其中 $R_m(\boldsymbol{h})/\|\boldsymbol{h}\|^m \to 0$，则

$$g(\boldsymbol{X}_n) = g(\boldsymbol{c}) + \sum_{j=1}^{m} \frac{1}{j!} D^j g(\boldsymbol{c})[\boldsymbol{X}_n-\boldsymbol{c},\dots,\boldsymbol{X}_n-\boldsymbol{c}] + \|\boldsymbol{X}_n-\boldsymbol{c}\|^m Q_n, \qquad Q_n = o_p(1).$$

随机 Taylor 展开的证明。令 $q(h) = R_m(h)/\|h\|^m$ $(h \neq 0)$，并令 $q(0)=0$。由 Peano 余项假设，$q(h)\to 0$ 当 $h\to 0$。取 $Q_n = q(\boldsymbol{X}_n - \boldsymbol{c})$。给定 $\varepsilon>0$，可选 $\delta>0$ 使 $\|h\|<\delta$ 时 $|q(h)|\le\varepsilon$，于是

$$P(|Q_n|>\varepsilon) \le P(\|\boldsymbol{X}_n-\boldsymbol{c}\|\ge\delta) \to 0.$$

故 $Q_n = o_p(1)$，代回确定性展开即可；这不要求每条样本路径都收敛。

定理 1.5.6：一阶 Delta 方法

若 $a_n \to \infty$，

$$a_n(\boldsymbol{X}_n - \boldsymbol{c}) \xrightarrow{d} \boldsymbol{Y},$$

且 $g:\mathbb{R}^k\to\mathbb{R}$ 在 $\boldsymbol{c}$ 处可微，则

$$\boxed{a_n\{g(\boldsymbol{X}_n)-g(\boldsymbol{c})\} \xrightarrow{d} \nabla g(\boldsymbol{c})^{\mathsf{T}}\boldsymbol{Y}.}$$

若 $\boldsymbol{Y}\sim N_k(0,\boldsymbol{\Sigma})$，则极限为

$$N\big(0, \nabla g(\boldsymbol{c})^{\mathsf{T}}\boldsymbol{\Sigma}\nabla g(\boldsymbol{c})\big).$$

证明。弱收敛序列依概率有界，所以 $H_n = a_n(\boldsymbol{X}_n-\boldsymbol{c}) = O_p(1)$。因 $a_n\to\infty$，$\boldsymbol{X}_n \xrightarrow{P} \boldsymbol{c}$。随机 Taylor 展开给出

$$a_n\{g(\boldsymbol{X}_n)-g(\boldsymbol{c})\} = \nabla g(\boldsymbol{c})^{\mathsf{T}} H_n + \|H_n\| Q_n.$$

第一项由连续映射定理依分布收敛，第二项为 $O_p(1)o_p(1) = o_p(1)$。这里乘积规则来自

$$P(|A_nB_n|>\varepsilon) \le P(|A_n|>K) + P(|B_n|>\varepsilon/K):$$

先选 K 控制第一项，再令 $n\to\infty$ 控制第二项。由 Slutsky 定理得证。

高阶 Delta 方法

若 $a_n(\boldsymbol{X}_n - \boldsymbol{c}) \xrightarrow{d} \boldsymbol{Y}$，$a_n \to \infty$，$g$ 在 $\boldsymbol{c}$ 有 m 阶 Peano 展开，且 $D^j g(\boldsymbol{c}) = 0$ 对 $1 \le j < m$ 成立，则

$$a_n^m\{g(\boldsymbol{X}_n) - g(\boldsymbol{c})\} \xrightarrow{d} \frac{1}{m!} D^m g(\boldsymbol{c})[\boldsymbol{Y}, \dots, \boldsymbol{Y}].$$

一维时右端为 $g^{(m)}(c)Y^m/m!$。

证明。令 $H_n = a_n(\boldsymbol{X}_n - \boldsymbol{c})$，由低阶导数消失，

$$a_n^m\{g(\boldsymbol{X}_n) - g(\boldsymbol{c})\} = \frac{1}{m!} D^m g(\boldsymbol{c})[H_n, \dots, H_n] + \|H_n\|^m Q_n.$$

m 重线性映射在对角线上是连续齐次多项式，第一项由连续映射定理收敛；$H_n = O_p(1)$ 使余项为 $o_p(1)$。再用 Slutsky 定理。即使 $D^m g(\boldsymbol{c}) \neq 0$，$\boldsymbol{Y}$ 也可能落在该多项式的零集上，使极限退化。

样本均值的平方

由

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

对 $g(t) = t^2$，当 $\mu \neq 0$ 时，$g'(\mu) = 2\mu$，故

$$\sqrt{n}(\bar{X}_n^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2).$$

当 $\mu = 0$ 时一阶导数消失，需要二阶 Delta 方法：

$$n\bar{X}_n^2 \xrightarrow{d} \sigma^2 Z^2, \qquad Z \sim N(0,1).$$

样本方差的渐近分布

若 $P(x^4) < \infty$，令

$$S_n^2 = P_n(x^2) - (P_n x)^2.$$

对 $\boldsymbol{W}_i = (X_i, X_i^2)^\mathsf{T}$ 使用二维 CLT，再对 $h(a,b) = b - a^2$ 使用 Delta 方法。梯度为

$$\nabla h(\mu, Px^2) = (-2\mu, 1)^\mathsf{T}.$$

记 $\mu = \mathrm{E}\, X$、$m_j = \mathrm{E}\, X^j$、$\mu_4 = \mathrm{E}(X-\mu)^4$。二维 CLT 的协方差矩阵为

$$\boldsymbol{\Sigma} = \begin{pmatrix} m_2 - \mu^2 & m_3 - \mu m_2 \\ m_3 - \mu m_2 & m_4 - m_2^2 \end{pmatrix}.$$

二次型 $(-2\mu, 1)\boldsymbol{\Sigma}(-2\mu, 1)^\mathsf{T}$ 是线性组合的方差。其中心化变量为

$$(X^2 - m_2) - 2\mu(X - \mu) = (X-\mu)^2 - (m_2 - \mu^2).$$

因此中心化线性项化简为

$$L(X) = (X-\mu)^2 - \sigma^2,$$

故渐近方差为

$$\mathrm{Var}\{L(X)\} = P\{(x-\mu)^4\} - \sigma^4.$$

最终

$$\boxed{\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N\left(0, P\{(x-\mu)^4\} - \sigma^4\right).}$$

使用分母 $n-1$ 的样本方差记为 $\widetilde{S}_n^2 = \frac{n}{n-1}S_n^2$ $(n \geq 2)$。由大数定律与连续映射定理，$S_n^2 \xrightarrow{P} \sigma^2$，因此 $S_n^2 = O_p(1)$。在这里所需的 $\sqrt{n}$ 中心化尺度下，

$$\sqrt{n}(\widetilde{S}_n^2 - S_n^2) = \frac{\sqrt{n}}{n-1}S_n^2 \xrightarrow{P} 0.$$

于是

$$\sqrt{n}(\widetilde{S}_n^2 - \sigma^2) = \sqrt{n}(S_n^2 - \sigma^2) + o_p(1),$$

由 Slutsky 定理得到相同的极限分布。关键是两者的差在 $\sqrt{n}$ 尺度下可以忽略；仅有乘法因子趋于 1，一般不足以保证中心化后的极限相同。

本章总结

概率分布与期望描述总体量，经验测度则给出对应的样本量。Markov 和 Chebyshev 不等式把矩信息转化为概率上界；大数定律说明估计误差消失；中心极限定理描述 $n^{-1/2}$ 尺度上的随机波动；连续映射、Slutsky 定理和 Delta 方法则把这些极限传递到非线性代入估计量。

第三章的一致性分析、第四章的 U 统计量极限分布都需要这些工具。

复习路线

建议按以下顺序复习：

$$P_n f \to Pf \quad \Longrightarrow \quad \sqrt{n}(P_n - P)f \xrightarrow{d} N(0, \sigma_f^2) \quad \Longrightarrow \quad g(P_n f) \text{ 的 Delta 展开.}$$

首先确认估计量是否相合，再寻找其波动尺度，最后分析非线性变换和学生化。

练习与核对

1. 若 X_i 独立同分布于 Bernoulli(p)，求 $\bar{X}_n(1-\bar{X}_n)$ 在 $p \neq 1/2$ 与 $p = 1/2$ 时适当缩放的极限分布。

2. $A_n \xrightarrow{d} A$、$B_n \xrightarrow{d} B$ 能否推出 $A_n + B_n \xrightarrow{d} A + B$? 说明 Slutsky 定理为何要求其中一个量收敛到常数。
3. 在四阶中心矩有限时，直接证明 $S_n^2 - \sigma^2 = (P_n - P)(x - \mu)^2 - (\bar{X}_n - \mu)^2$，据此重做样本方差的极限分布。

答案线索。(1) $p \neq 1/2$ 时，$\sqrt{n}$ 极限为 $N(0, (1-2p)^2 p(1-p))$；$p = 1/2$ 时，$n\{\bar{X}_n(1 - \bar{X}_n) - 1/4\} \xrightarrow{d} -Z^2/4$, $Z \sim N(0,1)$。(2) 不能：取标准正态 Z, $A_n = Z$、$B_n = (-1)^n Z$, 各边缘律不变, 和却在 $2Z$ 与 0 之间交替。(3) 展开中心化平方, 余项的 $\sqrt{n}$ 倍为 $O_p(n^{-1/2})$。若 $\mu_4 = \sigma^4$，正态极限退化为零，不能据此做非退化正态近似。

第 2 章　统计模型、指数族、充分性与完备性

本章依据 Fang Yao 老师《第 02 章-讲义》整理，原文件共 22 页，对应讲义正文第 27–48 页。定义、定理及例子的编号沿用讲义；“学习注记” 和 “补充证明” 记录个人理解与讨论中的展开，不是讲义逐字译文。Slides 的编号与讲义不同，例如 Slides 引理 2.7 对应讲义引理 2.3.1，Slides 命题 2.9 对应讲义命题 2.4.1。

学习起点：本章到底要做什么？

第一章主要问：样本量增大时，经验分布和估计量怎样逼近总体？第二章先固定样本量，问：在指定模型下，原始数据中的哪些部分真正参与对参数的比较？
本章依次研究三个问题：怎样用似然比较候选参数；怎样压缩样本而保持充分性；怎样用完备性得到函数唯一性、用 Basu 定理得到独立性。“已整理” 不等于已经能够独立证明，实际追问和待复习内容另见本章学习历程。

2.1　统计模型

2.1.1　从具体样本到模型

想估计硬币正面概率 p，独立抛掷 n 次，把正面记作 1。例如

$$x = (1, 0, 1, 1, 0), \qquad y = (0, 1, 1, 0, 1)$$

都有三次成功。独立性给出

$$P_p(\mathbf{X} = x) = p(1-p)pp(1-p) = p^3(1-p)^2 = P_p(\mathbf{X} = y).$$

一般地，记 $s = \sum_i x_i$，则

$$P_p(\mathbf{X} = x) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^s(1-p)^{n-s}.$$

固定 n 后，这个公式只需要成功次数，不需要成功顺序。后面要把 “似乎可以丢弃顺序” 变成严格的充分性结论。

具体排列与成功次数不是同一个事件

某一个排列的概率是 $p^s(1-p)^{n-s}$；成功次数等于 s 的概率要对所有相容排列求和，才有组合数：

$$P_p(S=s)=\binom{n}{s}p^s(1-p)^{n-s}.$$

知道 S 通常不能恢复完整样本，但这不必然意味着损失了关于 p 的信息。

参数模型是一族共同样本空间上的概率分布：

$$\mathcal{P}=\{P_\theta:\theta\in\Theta\}.$$

这里 Θ 是允许的参数集合，θ 是未知常数，P_θ 是对应的数据生成规律。i.i.d. 样本的联合模型为

$$\mathcal{P}^{(n)}=\{P_\theta^{\otimes n}:\theta\in\Theta\}.$$

$\mathbf{X}=(X_1,\dots,X_n)$ 表示随机样本，$\mathbf{x}=(x_1,\dots,x_n)$ 表示已观测到的实现值。统计量是计算规则不含未知参数的数据函数；若 μ 未知，$\bar{X}-\mu$ 不是直接可计算的统计量。

定义 2.1.1：可识别性

模型可识别是指

$$P_\theta=P_{\theta'}\implies\theta=\theta'.$$

等号指两个概率测度对每个事件都给出相同概率，不是某份样本的两个似然值碰巧相同。

已知方差的正态位置模型可识别：分布相同则期望相同，故均值参数相同。反之，模型 $N(\alpha\beta,1)$ 中，$(\alpha,\beta)=(1,2)$ 和 $(2,1)$ 产生同一分布，只能识别乘积，不能在整个模型中分别识别两者。增加样本量不能消除这种参数化问题。

2.1.2 密度与似然：同一个公式的两个视角

定义 2.1.2：受支配分布族

若存在共同的 σ-有限测度 ν，使

$$P\ll\nu\quad\forall P\in\mathcal{P},$$

则称模型受 ν 支配。记 $p_\theta=\mathrm{d}P_\theta/\mathrm{d}\nu$。

计数测度对应离散 PMF，Lebesgue 测度对应通常的连续 PDF。密度满足

$$P_\theta(A)=\int_A p_\theta\,\mathrm{d}\nu.$$

独立同分布样本的联合密度与似然为

$$p_\theta^{(n)}(\mathbf{x}) = \prod_i p_\theta(x_i), \qquad L_{\mathbf{x}}^{(n)}(\theta) = p_\theta^{(n)}(\mathbf{x}).$$

固定 θ，它描述数据的概率规律；固定 $\mathbf{x}$，它比较候选参数。连续模型使用密度值，不是通常为零的单点概率。

似然不是参数的概率分布

当 $n = 5, s = 3$ 时，$L(p) = p^3(1-p)^2$，但

$$\int_0^1 L(p)\,\mathrm{d}p = \frac{1}{4} - \frac{2}{5} + \frac{1}{6} = \frac{1}{60} \neq 1.$$

比较 $L(0.6)/L(0.2) = 6.75$，只是比较同一数据在两个候选参数下的概率，不是两个参数自身的概率比。后验分布还需要先验和归一化。

2.1.3 最大似然估计与边界

定义 2.1.3：最大似然估计

若统计量 $\widehat{\theta}(\mathbf{X})$ 的观测值满足

$$\widehat{\theta}(\mathbf{x}) \in \arg\max_{\theta\in\Theta} L_{\mathbf{x}}^{(n)}(\theta),$$

则称为 MLE。$\arg\max$ 是最大化参数的集合，不是最大的函数值。

对数严格递增，故最大化似然等价于最大化扩展对数似然，约定 $\log 0 = -\infty$：

$$\ell_{\mathbf{x}}^{(n)}(\theta) = \sum_i \log p_\theta(x_i).$$

这与第一章相接：

$$n^{-1}\ell_{\mathbf{X}}^{(n)}(\theta) = P_n \log p_\theta.$$

本章先研究有限样本结构，后续一致性理论才讨论这个经验准则的极限。非空紧参数空间上的上半连续似然可以保证最大值取到；严格凹性可以保证已存在的最大化解唯一，但不自动保证存在性。

例 2.1.2：Bernoulli 的 MLE

固定二元样本，令 $s = \sum_i x_i$。在 $0 < s < n$ 时，

$$\ell(p) = s\log p + (n-s)\log(1-p), \qquad \ell'(p) = \frac{s}{p} - \frac{n-s}{1-p}.$$

因为 $p(1-p)>0$，

$$\ell'(p)=0 \iff s(1-p)=(n-s)p \iff s=np \iff p=s/n.$$

又

$$\ell''(p)=-s/p^2-(n-s)/(1-p)^2<0,$$

所以这是唯一内点最大值。若 $s=0$，$L(p)=(1-p)^n$ 递减；若 $s=n$，$L(p)=p^n$ 递增。在 $[0,1]$ 上分别得到边界 MLE $0,1$，在 $(0,1)$ 上却都没有 MLE，因为上确界只能在被排除的边界逼近。

2.1.4 参数无关因子与参数相关支撑

若固定样本上 $a(\mathbf{x})>0$，且

$$p_\theta^{(n)}(\mathbf{x})=a(\mathbf{x})b_\theta(\mathbf{x}),$$

其中 a 不含参数，则相同因子在参数之间的似然比中消去，也不改变最大化位置。它仍是概率模型的一部分，计算样本事件概率时不能删除。

Poisson 样本满足

$$p_\lambda^{(n)}(\mathbf{x})=e^{-n\lambda}\lambda^{\sum_i x_i}\prod_i \frac{1}{x_i!}.$$

例如 $(0,2)$ 与 $(1,1)$ 的似然分别为

$$\tfrac{1}{2}e^{-2\lambda}\lambda^2, \qquad e^{-2\lambda}\lambda^2.$$

二者不相等，却始终成固定比例，对任意两个参数的相对比较相同。

给定总和为 2，三个可能样本为 $(0,2)$、$(1,1)$、$(2,0)$。它们的条件概率依次为 $1/4$、$1/2$、$1/4$，不等概率但都不含参数。

对 $U(0,\theta)$，联合密度则为

$$p_\theta^{(n)}(\mathbf{x})=\theta^{-n}\mathbf{1}_{\{x_{(n)}<\theta\}}\mathbf{1}_{\{x_{(1)}>0\}}.$$

示性函数含参数，不能忽略。若最大观测是 3，则 $\theta=2$ 与数据不相容；仅保留 θ^{-n} 会错误地给它正似然。

两种似然比较，以及与后文的联系

固定同一个样本，比较 $L_{\mathbf{x}}(\theta)/L_{\mathbf{x}}(\theta')$，用于参数推断；比较两组样本的整条似然是否满足

$$L_{\mathbf{x}}(\theta)=c(\mathbf{x},\mathbf{y})L_{\mathbf{y}}(\theta) \quad \forall\theta, \qquad c(\mathbf{x},\mathbf{y})>0$$

且 c 不含参数，用于判断哪些样本可以合并。

参数依赖支撑时要同时比较零值区域，不能只在公共正值区域约分。按严格端点密度 $\mathbf{1}_{\{x<\theta\}}$，均匀模型的 MLE 可能只有未取到的上确界；改用含端点密度会改变逐点最大化。计算时应保持同一密度版本。

2.2 指数族

2.2.1 指数形式与自然参数

前面发现 Bernoulli 和 Poisson 的参数比较都只需要总和。指数族为这种现象提供统一形式：参数和数据通过一个有限维内积相结合，独立样本相乘后变成自然统计量的求和。

定义 2.2.1：自然指数族

相对于共同 σ-有限测度 ν，密度为

$$p_\eta(x) = \exp\{\eta^\top T(x) - \zeta(\eta)\}h(x), \qquad \eta \in \Xi \subseteq \mathbb{R}^k.$$

这里 T 是自然统计量，η 是自然参数，$h \geq 0$ 不含参数，而

$$\zeta(\eta) = \log \int e^{\eta^\top T(x)} h(x)\, \nu(\mathrm{d}x)$$

负责归一化。最大自然参数空间由该积分有限且为正的参数组成；实际子模型可只使用其中一部分。

积分核对：

$$\int p_\eta \,\mathrm{d}\nu = e^{-\zeta(\eta)} \int e^{\eta^\top T(x)} h(x)\,\mathrm{d}\nu = 1.$$

若用可逆矩阵 A 替换为 $\widetilde{T} = AT$、$\widetilde{\eta} = A^{-\top}\eta$，内积不变。这说明表示不唯一，统计意义取决于所生成的信息，而不取决于选用的坐标名称。

例 2.2.1–2.2.3：从密度中识别自然参数

Bernoulli 模型中，对 $x \in \{0,1\}$，

$$p^x(1-p)^{1-x} = \exp\left\{x \log\frac{p}{1-p} + \log(1-p)\right\}.$$

取 $\eta = \log[p/(1-p)]$，反解得 $p = e^\eta/(1+e^\eta)$，所以

$$T(x) = x, \quad \zeta(\eta) = \log(1+e^\eta), \quad \Xi = \mathbb{R}.$$

Poisson 模型中，

$$e^{-\lambda}\lambda^x/x! = e^{x\eta - e^\eta}/x!, \qquad \eta = \log\lambda \in \mathbb{R}.$$

所以 $T(x)=x$、$h(x)=1/x!$、$\zeta(\eta)=e^{\eta}$。
正态两参数模型中，

$$-\frac{(x-\mu)^2}{2\sigma^2}=\frac{\mu}{\sigma^2}x-\frac{x^2}{2\sigma^2}-\frac{\mu^2}{2\sigma^2}.$$

可取

$$T(x)=(x,x^2),\quad \eta_1=\mu/\sigma^2,\quad \eta_2=-1/(2\sigma^2),\quad h(x)=1,$$

$$\zeta(\eta)=-\frac{\eta_1^2}{4\eta_2}+\frac{1}{2}\log\frac{-\pi}{\eta_2},\qquad \Xi=\mathbb{R}\times(-\infty,0).$$

对于 i.i.d. 样本，

$$\begin{aligned}p_\eta^{(n)}(\mathbf{x})&=\prod_i e^{\eta^\top T(x_i)-\zeta(\eta)}h(x_i)\\&=\exp\left\{\eta^\top\sum_i T(x_i)-n\zeta(\eta)\right\}\prod_i h(x_i).\end{aligned}$$

因此参数相关部分只需要 $T_n=\sum_i T(X_i)$。正态模型对应 $(\sum_i X_i,\sum_i X_i^2)$，第二项是“平方后求和”，不是 $(\bar{X})^2$。

2.2.2 满秩表示的两个条件

讲义对满秩的约定同时要求：

1. 统计量一侧没有仿射冗余：

$$a^\top T(X)=b \text{ 几乎必然}\quad\Longrightarrow\quad a=0;$$

2. 自然参数一侧含非空开集：

$$\operatorname{int}_{\mathbb{R}^k}\Xi\neq\varnothing.$$

第一条的 a.s. 按共同载体测度或其等价概率版本理解；“rank”是指数族表示的性质，不是在计算某个观测向量的矩阵秩。

追问：是不是统计量各分量线性无关？

还要把常数 1 算进去。$T=(X,2X)$ 满足 $2T_1-T_2=0$，有冗余；$T=(X,X+1)$ 满足 $T_2-T_1=1$，也有冗余。需排除的是右侧为任意常数的非平凡仿射关系，而不只是齐次线性关系。
对具有正态分布的 X，$T=(X,X^2)$ 没有仿射冗余：若 $a_1x+a_2x^2=b$ 几乎处处成立，连续多项式必恒等于零，从而 $a_1=a_2=b=0$。其取值虽在抛物线上，却不被一条直线包含。没有仿射冗余既不意味着分量独立，也不排除非线性函数关系。

“本质值域”忽略零概率修改。对于欧氏空间中的随机向量，点 t 属于本质值域意味着每个邻域都有正概率：

$$P(\|T-t\|<\varepsilon)>0\quad\forall\varepsilon>0.$$

不要求 $P(T=t)>0$。例如将 $(X,2X)$ 在正态零概率事件 $\{X=0\}$ 上改为 $(0,100)$，仍不能消除几乎必然的仿射冗余。

第二条则要求自然参数集合内至少容得下一个 k 维开球。正态两参数模型的 $\Xi=\mathbb{R}\times(-\infty,0)$ 可容纳以 $(0,-1)$ 为中心、半径 $1/2$ 的圆盘，因此满足第二条。

2.2.3 弯曲指数族与参数约束

通常在光滑、正则的参数化下，弯曲族写为

$$\eta=\eta(\theta)\in\mathbb{R}^k,\qquad \theta\in\Theta\subseteq\mathbb{R}^d,\quad d<k.$$

原始参数 θ 只有 d 个自由方向，决定了 k 个自然参数坐标，所以自然参数只能沿低维曲面变化。仅凭任意映射 $d<k$ 不能保证其像为光滑曲面，这里使用通常的正则参数化语境。

例如 $X\sim N(\theta,\theta^2)$，$\theta>0$，仍有 $T=(X,X^2)$，但

$$\eta_1=1/\theta,\qquad \eta_2=-1/(2\theta^2)\quad\Longrightarrow\quad \eta_2=-\eta_1^2/2.$$

参数在二维平面中沿一条抛物线变化，不能包含二维开球。

两个抛物线，为什么结论不同？

统计量 (x,x^2) 落在抛物线上，不违反第一条，因为第一条仅排除仿射超平面，二维中即直线。自然参数落在抛物线上，却违反第二条，因为第二条要求真正的二维开区域。

因此，统计量无仿射冗余，并不推出整个表示满秩。缺少开集也只意味着后面的指数族完备性定理不能直接使用，并非自动证明不完备；不完备需要另构造反例。

2.3 充分性

2.3.1 充分性的条件分布定义

定义 2.3.1：充分统计量

若样本 $\mathbf{X}$ 给定 $T(\mathbf{X})$ 的条件分布可以对所有参数选取同一个不含参数的版本，则称 T 充分。

充分性不要求 T 的边缘分布不含参数，也不表示 $\mathbf{X}$ 与 T 独立。完整样本本身总是充分，故“充分”也不自动表示低维或简洁。

Bernoulli 样本中，若 $\sum_i x_i=t$，则

$$P_p(\mathbf{X}=\mathbf{x}\mid T=t)=\frac{p^t(1-p)^{n-t}}{\binom{n}{t}p^t(1-p)^{n-t}}=\binom{n}{t}^{-1}.$$

否则条件概率为零。给定成功次数后，所有相容排列的条件规律都不含 p，故总和充分。

2.3.2 共同支配概率的构造与用途

引理 2.3.1：共同支配概率

非空模型 $\mathcal{P}$ 若被某个 σ-有限测度支配，则可选有限或可数个 $P_j \in \mathcal{P}$ 及严格正权重 w_j，使

$$\sum_j w_j = 1, \qquad Q = \sum_j w_j P_j, \qquad P \ll Q \quad \forall P \in \mathcal{P}.$$

讲义用无穷序列表示；有限族也可用重复分布写成序列，或直接用有限和。

追问：是不是统一在一个概率分布下研究？

可以这样理解，但统一的是参考分布，并没有把不同的 P_θ 变成同一个分布：

$$E_\theta f(X) = E_Q\left[f(X)\frac{\mathrm{d}P_\theta}{\mathrm{d}Q}(X)\right].$$

不同分布的差异保留在各自的权重中。Q 固定，不随当前研究的 θ 改变；Q 不必属于原模型，也不表示真实数据来自混合机制。引理只适用于满足共同 σ-有限支配条件的模型，不是所有可能的离散、连续分布都可任意混在一起。

定义上，$P \ll Q$ 意味着 $Q(A) = 0 \Rightarrow P(A) = 0$，不是 $P(A) \le Q(A)$。严格正权重保证

$$Q(A) = 0 \Rightarrow P_j(A) = 0 \quad \forall j.$$

单个模型成员未必能支配整个族。对 $\{U(0,\theta) : \theta > 0\}$，可取

$$Q = \sum_{j \ge 1} 2^{-j} U(0, j).$$

任取 θ，选整数 $j \ge \theta$，则 $U(0,\theta) \ll U(0,j) \ll Q$。选择 j 可以依赖 θ，但 Q 已经固定。

补充证明：用可数个正密度区域覆盖整个模型

讲义以“本质上确界可由可数子族实现”为工具。下面给出针对本引理的集合版本，避免直接调用那个函数定理。

首先将支配测度 ν 换成等价有限测度。取可数可测分割 $\mathcal{X} = \bigcup_m E_m$，每个 $\nu(E_m) < \infty$，令

$$\mu(A) = \sum_{m \ge 1} 2^{-m} \frac{\nu(A \cap E_m)}{1 + \nu(E_m)}.$$

则 $\mu(\mathcal{X}) \le 1$，且 $\mu(A) = 0 \iff \nu(A) = 0$。

对每个 P 取密度 $p_P = \mathrm{d}P/\mathrm{d}\nu$，记 $S_P = \{p_P > 0\}$，定义

$$M = \sup\{\mu(S_{P_1} \cup \cdots \cup S_{P_r}) : r \ge 1,\ P_i \in \mathcal{P}\}.$$

M 有限。对每个 n，选一个有限并 B_n 使 $\mu(B_n) > M - 1/n$，再令 $B = \bigcup_n B_n$。由下连续性和有限并的定义，

$$\mu(B) = M.$$

确实，$\mu(B) \geq \mu(B_n) > M - 1/n$；另一方面每个 $B_1 \cup \cdots \cup B_N$ 仍是有限个正密度区域的并，其测度不超过 M。

任取其他分布 P，同理 $\mu(B \cup S_P) \leq M$，所以

$$\mu(S_P \setminus B) = 0, \qquad \nu(S_P \setminus B) = 0.$$

组成 B 的模型成员至多可数，将它们记为 P_j，取正权重构成 Q。它的密度是

$$q = \sum_j w_j p_j, \qquad \{q > 0\} = B.$$

若 $Q(A) = 0$，则 $\int_A q \, \mathrm{d}\nu = 0$，由 $q > 0$ 于 B 得 $\nu(A \cap B) = 0$。任意 p_P 又在 B 外几乎处处为零，故

$$P(A) = \int_A p_P \, \mathrm{d}\nu = 0.$$

因此每个 $P \ll Q$，引理得证。

2.3.3 Fisher–Neyman 因子分解定理

定理 2.3.1：因子分解

在讲义的标准 Borel 样本空间和值域、共同 σ-有限支配等条件下，T 充分，当且仅当联合密度可写为

$$p_\theta(x) = a_\theta(T(x))h(x)$$

（按相应几乎处处意义理解），其中 h 不含参数。这里为简化记号，把完整样本也写作 X，其联合分布记为 P_θ。

方向一：因子分解推出充分性

离散情形下，在同一个纤维 $\{x : T(x) = t\}$ 内，

$$P_\theta(X = x \mid T = t) = \frac{a_\theta(t)h(x)}{a_\theta(t)\sum_{y:T(y)=t} h(y)} = \frac{h(x)}{\sum_{y:T(y)=t} h(y)}.$$

分母为正时参数因子消去。连续模型不能直接除以零概率事件，故使用共同概率 Q。

由引理，取 $Q = \sum_j w_j P_{\theta_j}$。其密度为

$$q(x) = h(x)\bar{a}(T(x)), \qquad \bar{a}(t) = \sum_j w_j a_{\theta_j}(t).$$

在有效正密度集合上，

$$\frac{\mathrm{d}P_\theta}{\mathrm{d}Q}(x) = \frac{a_\theta(T(x))}{\bar{a}(T(x))} =: r_\theta(T(x)).$$

零集上任意补定义。换分布时的权重只依赖 T，这正是离散消因子的测度论版本。

对任意事件 A，先在固定的 Q 下定义

$$K_A(T) = E_Q(\mathbf{1}_A \mid T).$$

它是与参数无关的同一个函数。要证明其也是 P_θ 下的条件概率，除可测性外，只需对每个 $C \in \sigma(T)$ 验证积分：

$$\begin{aligned}\int_C K_A(T)\,\mathrm{d}P_\theta &= \int_C K_A(T) r_\theta(T)\,\mathrm{d}Q \\ &= \int_C \mathbf{1}_A r_\theta(T)\,\mathrm{d}Q \\ &= P_\theta(A \cap C).\end{aligned}$$

第二步使用 $\mathbf{1}_C r_\theta(T)$ 为 $\sigma(T)$-可测非负权重；无界时先截断，再用单调收敛。由条件期望唯一性，$K_A(T) = E_\theta(\mathbf{1}_A \mid T)$，$P_\theta$-a.s.。在标准 Borel 条件下可通过 Q 下的正则条件分布核统一组织这些等式，从而 T 充分。

方向二：充分性推出因子分解

充分性给出不含参数的共同版本

$$E_\theta(\mathbf{1}_A \mid T) = K_A(T).$$

混合各个分布，对于 $C \in \sigma(T)$，

$$\int_C K_A(T)\,\mathrm{d}Q = \sum_j w_j P_{\theta_j}(A \cap C) = Q(A \cap C).$$

所以 $K_A(T) = E_Q(\mathbf{1}_A \mid T)$，$Q$-a.s.。

令 P_θ^T, Q^T 为 T 的边缘分布。由 $P_\theta \ll Q$ 得 $P_\theta^T \ll Q^T$，定义

$$r_\theta(t) = \frac{\mathrm{d}P_\theta^T}{\mathrm{d}Q^T}(t).$$

这是边缘密度比，不是条件期望。对每个事件 A，

$$\begin{aligned}P_\theta(A) = E_\theta K_A(T) &= \int K_A(t)\,\mathrm{d}P_\theta^T(t) \\ &= \int K_A(t) r_\theta(t)\,\mathrm{d}Q^T(t) \\ &= E_Q[K_A(T) r_\theta(T)] \\ &= E_Q[\mathbf{1}_A r_\theta(T)] = \int_A r_\theta(T)\,\mathrm{d}Q.\end{aligned}$$

故 $\mathrm{d}P_\theta/\mathrm{d}Q = r_\theta(T)$，$Q$-a.s.。取 $h = \mathrm{d}Q/\mathrm{d}\nu$，RN 链式法则给出

$$p_\theta(x) = r_\theta(T(x))h(x) \quad \nu\text{-a.e.}$$

因子分解得证。

证明中各测度的作用

引理提供一个固定参考概率 Q；因子分解使换测度权重只依赖 T；条件期望定义把“纤维内相对权重不变”变成严谨的共同条件分布。
样本空间积分 $E_Q[\phi(T)]$ 与边缘空间积分 $\int \phi(t)\,\mathrm{d}Q^T(t)$ 相等，但空间和测度不同。
不能把 Q 与 Q^T、条件期望与边缘密度比混为一谈。

2.3.4 典型充分统计量与模型依赖性

因子分解给出：Bernoulli、Poisson 样本的总和充分；$U(0,\theta)$ 的最大值充分。正态两参数模型中，充分统计量可以写为

$$\left(\sum_i X_i, \sum_i X_i^2\right).$$

令 $V = \sum_i (X_i - \bar{X})^2$，有

$$\bar{X} = \frac{1}{n}\sum_i X_i, \quad V = \sum_i X_i^2 - n\bar{X}^2,$$

$$\sum_i X_i = n\bar{X}, \qquad \sum_i X_i^2 = V + n\bar{X}^2.$$

所以 $(\bar{X}, V)$ 是同一信息的另一种编码。

已知正态方差时仅 $\bar{X}$ 已充分；两参数未知时一般还需 V。在全部连续密度构成的 i.i.d. 模型中，排序后的完整样本充分：给定排序值，所有排列等概率且与密度无关。讲义同时给出该大模型的最小充分性结论；这里不把它当作已从头证明的非参数定理。

若 T 充分且 $T = \phi(S)$，由

$$p_\theta(x) = a_\theta(\phi(S(x)))h(x)$$

可知 S 也充分。增加信息不破坏充分性，但对充分统计量任意取函数可能丢失信息。

2.4 最小充分性

2.4.1 最小充分性的定义

充分性排除信息损失，却不排除无关细节。已知正态方差的模型中，完整样本、两块样本均值和总体样本均值都充分，但保留的细节不同。

定义 2.4.1：最小充分统计量

T 对 $\mathcal{P}$ 充分，且对任意其他充分统计量 S，存在同一个不含参数的可测函数 ϕ，使

$$T = \phi(S) \qquad P\text{-a.s.}, \quad \forall P \in \mathcal{P},$$

则 T 最小充分。

追问："最粗的精确压缩"是什么意思？

$T = \phi(S)$ 的方向是"知道 S 就能恢复 T"，因此 S 至少包含 T 的信息。最小充分统计量是每一种充分摘要都必须保留的共同核心。
统计量把样本按相同取值分组。摘要越粗，合并的样本越多；最小充分性要求在保持充分性的前提下尽可能合并。它不是简单比较向量维数。具有可测逆的一一变换仅改变编码，不改变信息。

2.4.2 从子模型推广最小充分性

命题 2.4.1：最小充分性的推广原则

设 $\mathcal{P}_0 \subseteq \mathcal{P}$，且对每个事件 A，

$$[P(A) = 0 \ \forall P \in \mathcal{P}_0] \implies [P(A) = 0 \ \forall P \in \mathcal{P}].$$

若 T 对 $\mathcal{P}$ 充分，并对 $\mathcal{P}_0$ 最小充分，则 T 对 $\mathcal{P}$ 最小充分。

这里"大、小"指候选分布的多少，不是样本量。例如正态均值遍历 $\mathbb{R}$ 是大模型，只保留均值为 $0, 1$ 的两个候选分布是小模型，观察的样本向量并未改变。

证明分四步。

1. 任取对大模型充分的 S。同一个条件分布版本当然也适用于小模型，所以 S 对小模型充分。
2. 由 T 对小模型最小充分，存在同一个 ϕ，使 $T = \phi(S)$ 在每个 $P \in \mathcal{P}_0$ 下 a.s. 成立。
3. 定义等式失败的事件
$$N = \{T \neq \phi(S)\}.$$
则 $P(N) = 0$ 对小模型每个分布成立。由假设，它对大模型每个分布也成立。
4. 因此任意大模型充分统计量 S 都能恢复 T。结合已经假设的"大模型下 T 充分"，得到最小充分性。

为什么不能省略共同零事件条件？

取小模型 $\{U(0,1)\}$，大模型 $\{U(0,1), U(0,2)\}$。事件 $(1,2)$ 在小模型下概率为零，却在大模型某成员下有概率 $1/2$。一个等式在小模型几乎必然成立，不能自动推广

到大模型。
证明中的异常集必须是 $\{T \neq \phi(S)\}$。

共同支配引理恰好提供满足零事件条件的可数小模型。若

$$Q = \sum_j w_j P_j, \qquad P \ll Q \quad \forall P \in \mathcal{P},$$

取 $\mathcal{P}_0 = \{P_j\}$，则

$$P_j(A) = 0 \ \forall j \Rightarrow Q(A) = 0 \Rightarrow P(A) = 0 \ \forall P \in \mathcal{P}.$$

这就是引理、推广原则和下面可数模型构造之间的衔接。

2.4.3 可数模型的显式构造

定理 2.4.1：可数混合构造

设 $\mathcal{P}_0 = \{P_j : j \in J\}$ 为有限或可数族，取

$$Q = \sum_j w_j P_j, \quad r_j = \frac{\mathrm{d}P_j}{\mathrm{d}Q}, \quad w_j > 0, \quad \sum_j w_j = 1.$$

则 $R = (r_j)_{j \in J}$ 最小充分。若族内某个 P_0 已支配所有 P_j，也可用 $(\mathrm{d}P_j/\mathrm{d}P_0)_j$。

证明。取共同测度 ν，记 $p_j = \mathrm{d}P_j/\mathrm{d}\nu$、$q = \mathrm{d}Q/\mathrm{d}\nu$。因为 $p_j = r_j q$，因子分解给出 R 充分。

任取充分统计量 S，因子分解写为 $p_j(x) = a_j(S(x))h(x)$。由 J 可数，可以合并各个等式的异常零集。于是

$$q(x) = h(x) \sum_j w_j a_j(S(x)).$$

在有效正密度集合上，

$$r_j(x) = \frac{a_j(S(x))}{\sum_\ell w_\ell a_\ell(S(x))}.$$

每个坐标都是 S 的函数，因此整个可数向量 $R = \phi(S)$，Q-a.s.。由 $P_j \ll Q$，这个表示对每个 P_j 也成立，故最小充分。用 P_0 作参考时，同样由 $p_j/p_0 = a_j(S)/a_0(S)$ 得到结论。

2.4.4 似然比判别与典型例子

定理 2.4.2：似然比判别准则

在讲义的受支配、标准 Borel 框架下，设 T 已充分。使用讲义指定的密度版本，且在同一个共同零集之外，若

$$[p_P(x) = c(x,y)p_P(y)\ \forall P,\quad c(x,y) > 0\ \text{不含}P] \Rightarrow T(x) = T(y),$$

则 T 最小充分。

讲义的版本约定不可省略：使用证明中最小充分统计量 S 给出的密度 $p_P(x) = a_P(S(x))h(x)$，并在共同满测 Borel 集上进行比较。不可数个参数分别拥有的零集，其并不一定还是零集。

讲义证明的逻辑。引用 Bahadur 的存在性结果得到最小充分统计量 S。在共同满测集上取 $0 < h < \infty$。若 $S(x) = S(y)$，则

$$p_P(x) = p_P(y)\frac{h(x)}{h(y)} \quad \forall P.$$

假设推出 $T(x) = T(y)$。Blackwell–Mackey 定理及 Doob–Dynkin 引理保证 $T = \psi(S)$ 可测地成立。任意充分统计量 U 都能恢复 S，进而恢复 T；加上 T 充分，故最小充分。这里的存在性和可测表示结果是讲义引用的基础定理，本笔记不从描述集合论重新证明。

例 2.4.1：Bernoulli 与 Poisson

Bernoulli 中，令 $\Delta = \sum_i x_i - \sum_i y_i$，

$$\frac{p_p^{(n)}(x)}{p_p^{(n)}(y)} = \left(\frac{p}{1-p}\right)^{\Delta}.$$

$p/(1-p)$ 遍历正半轴，比值与 p 无关当且仅当 $\Delta = 0$。
Poisson 中，

$$\frac{p_\lambda^{(n)}(x)}{p_\lambda^{(n)}(y)} = \lambda^{\Delta}\frac{\prod_i y_i!}{\prod_i x_i!},$$

同样当且仅当 $\Delta = 0$。结合充分性，两个模型中的总和均最小充分。

正态两参数模型中，令 $\Delta_1 = \sum_i x_i - \sum_i y_i$、$\Delta_2 = \sum_i x_i^2 - \sum_i y_i^2$，则

$$\log\frac{p_{\mu,\sigma^2}^{(n)}(x)}{p_{\mu,\sigma^2}^{(n)}(y)} = \frac{\mu}{\sigma^2}\Delta_1 - \frac{1}{2\sigma^2}\Delta_2.$$

固定方差改变均值，得 $\Delta_1 = 0$；再改变方差，得 $\Delta_2 = 0$。反之两差为零时比值为 1。因此 $(\sum_i X_i, \sum_i X_i^2)$ 最小充分。

例 2.4.3：指数族的两条证明路线

设自然统计量维数为 k，存在 $\theta_0,\dots,\theta_k$，使

$$v_i=\eta(\theta_i)-\eta(\theta_0),\quad i=1,\dots,k$$

线性无关。

第一条路线是选有限子模型。其对数密度比为

$$\log\frac{p_{\theta_i}(x)}{p_{\theta_0}(x)}=v_i^{\top}T(x)-[\zeta(\eta(\theta_i))-\zeta(\eta(\theta_0))].$$

把 $v_i^{\top}$ 排成可逆矩阵 V，就可从这些对数比恢复 VT，继而恢复 T。比值向量在有限子模型中最小充分，所以 T 也最小充分。共同正支撑保证共同零事件条件，再用命题 2.4.1 推广到整个模型。

第二条路线是直接比较整条似然。若 $p_\theta(x)/p_\theta(y)$ 与 θ 无关，令 $\Delta T=T(x)-T(y)$，对数等式减去 θ_0 时的等式得

$$v_i^{\top}\Delta T=0,\quad i=1,\dots,k.$$

V 可逆，故 $\Delta T=0$，由判别准则得最小充分。

这里“存在 $k+1$ 个仿射独立自然参数”比“包含开集”更弱。弯曲族仍可能满足本条最小充分性条件，不能把它与后面的完备性开集条件混淆。

对 $U(0,\theta)$ 的正样本，似然为正的参数范围是 $(x_{(n)},\infty)$。两条完整似然成比例当且仅当最大值相同，因此最大值最小充分。

2.5 完备性

2.5.1 完备性与函数唯一性

充分性和最小充分性讨论保留哪些数据。完备性改问：两个关于 T 的可积函数，如果在所有参数下期望相同，是否必须几乎必然相同？

定义 2.5.1：完备与有界完备

对任意不含未知参数的可测函数 g，若

$$E_\theta|g(T)|<\infty,\quad E_\theta g(T)=0\quad\forall\theta$$

必推出

$$g(T)=0\quad P_\theta\text{-a.s.},\quad\forall\theta,$$

则 T 完备。若只对有界可测 g 要求该结论，则称有界完备。

完备推出有界完备。不能取 $g(T)=T-\theta$ 来证明不完备，因为这个函数含有未知参数。结论是随机变量几乎必然为零，不要求 g 在不可能取到的点上也为零。

定义期望变换 $(Kg)(\theta)=E_\theta g(T)$，则完备性表示其核只有几乎必然为零的函数。若 $a(T),b(T)$ 均可积且对所有参数期望相同，对差 $g=a-b$ 应用完备性就有 $a(T)=b(T)$。这保证同一完备统计量的无偏函数的唯一性，但不保证无偏估计存在，也不表示所有基于完整数据的无偏估计都相同。

2.5.2 有界完备且充分推出最小充分

定理 2.5.1

在讲义的标准 Borel 条件下，T 有界完备且充分，则 T 最小充分。

证明。任取充分统计量 U，选 T 值域上的有界一一 Borel 编码 b，其像上的逆可测。实值统计量可取 $b(t)=\arctan t$。定义

$$q(U)=E_\theta[b(T)\mid U],\qquad r(T)=E_\theta[q(U)\mid T].$$

由 U,T 充分，两个条件期望依次可取同一个不含参数的版本。它们有界，且全期望给出

$$E_\theta[r(T)-b(T)]=0\quad\forall\theta.$$

有界完备性推出 $r(T)=b(T)$ a.s.。分别对 U,T 条件化，

$$E_\theta[b(T)q(U)]=E_\theta[q(U)E_\theta(b(T)\mid U)]=E_\theta[q(U)^2],$$
$$E_\theta[b(T)q(U)]=E_\theta[b(T)E_\theta(q(U)\mid T)]=E_\theta[b(T)^2].$$

故

$$E_\theta[(b(T)-q(U))^2]=E_\theta b(T)^2-2E_\theta[b(T)q(U)]+E_\theta q(U)^2=0.$$

非负变量期望为零，得 $b(T)=q(U)$ a.s.。在 b 的像上取可测逆，在像外任意补定义，便有 $T=b^{-1}(q(U))$ a.s.。由于 U 任意，T 最小充分。

为什么不能直接用塔式性质？

事先不知道 $\sigma(T)$ 与 $\sigma(U)$ 谁包含谁，不能直接断言 $E_\theta[E_\theta(b(T)\mid U)\mid T]=b(T)$。证明中是先由完备性得到这个等式，再由平方期望消除残差。

2.5.3 两种直接证明：多项式与积分上限

例 2.5.1–2.5.2：二项分布的完备性

令 $T \sim \text{Binomial}(n,p)$，$p \in (0,1)$。若所有参数下 $E_p g(T) = 0$，则

$$\sum_{t=0}^{n} g(t)\binom{n}{t} p^t (1-p)^{n-t} = 0.$$

除以 $(1-p)^n > 0$，令 $u = p/(1-p)$，得到

$$\sum_{t=0}^{n} g(t)\binom{n}{t} u^t = 0 \quad \forall u > 0.$$

一个有限次多项式在整个区间上为零，所有系数必须为零。由 $\binom{n}{t} > 0$，得 $g(t) = 0$ 对 $t = 0, \ldots, n$ 成立。故 T 完备，Bernoulli 样本总和因而完备充分。

若把模型限制为单个已知 $p_0 \in (0,1)$，$n \geq 1$，则 $g(T) = T - np_0$ 是合法的固定非零零期望函数，完备性反而失效。完备性也相对于整族参数定义。

例 2.5.3：均匀上端点模型的完备性

若 X_i 独立同分布于 $U(0,\theta)$，$T = X_{(n)}$，则对 $0 < t < \theta$，

$$P_\theta(T \leq t) = (t/\theta)^n, \qquad f_\theta^T(t) = n t^{n-1} \theta^{-n}.$$

任取在所有参数下可积的 g，零期望给出

$$\int_0^\theta g(t) t^{n-1} \, \mathrm{d}t = 0 \quad \forall \theta > 0.$$

对每个 $B > 0$，可积性保证 $g(t)t^{n-1}$ 在 $(0,B)$ 绝对可积。因此 $F(b) = \int_0^b g(t)t^{n-1}\,\mathrm{d}t$ 在 $[0,B]$ 绝对连续，且

$$F'(b) = g(b) b^{n-1} \quad \text{Lebesgue-a.e.}$$

F 恒为零且 $b > 0$，故 $g(b) = 0$ a.e.。对正整数 B 取可数并得到整个正半轴上的结论。T 有 Lebesgue 密度，所以每个参数下 $g(T) = 0$ a.s.，完备性成立。

2.5.4 指数族完备性及开集的作用

定理 2.5.2：指数族完备性

若 T 的分布相对于 ν 的密度为

$$q_\eta(t) = e^{\eta^\top t - \zeta(\eta)} h_*(t), \quad \eta \in \Xi \subseteq \mathbb{R}^k,$$

且 Ξ 包含非空开集，则 T 完备。这里 ν 不必是 k 维 Lebesgue 测度。

证明展开。任取所有参数下可积且零期望的 g，写 $g = g^+ - g^-$。选内点 η_0 与 $\varepsilon > 0$ 使 $B(\eta_0, \varepsilon) \subseteq \Xi$。消去密度中的归一化因子，得到

$$\int g^+(t) e^{\eta^\top t} h_*(t)\, \nu(\mathrm{d}t) = \int g^-(t) e^{\eta^\top t} h_*(t)\, \nu(\mathrm{d}t).$$

在 η_0 处记共同有限值为 C。若 $C = 0$，非负积分为零，直接得到 $g = 0$ 于载体测度 $h_*\nu$ 几乎处处。

若 $C > 0$，定义两个概率密度

$$f_\pm(t) = C^{-1} g^\pm(t) e^{\eta_0^\top t} h_*(t).$$

对于 $\|s\| < \varepsilon$，使用参数 $\eta_0 + s$ 的积分恒等式，

$$\begin{aligned}
\int e^{s^\top t} f_+(t)\, \nu(\mathrm{d}t) &= C^{-1} \int g^+(t) e^{(\eta_0+s)^\top t} h_*(t)\, \nu(\mathrm{d}t) \\
&= C^{-1} \int g^-(t) e^{(\eta_0+s)^\top t} h_*(t)\, \nu(\mathrm{d}t) \\
&= \int e^{s^\top t} f_-(t)\, \nu(\mathrm{d}t).
\end{aligned}$$

可积性保证两边在该邻域有限。引用原点邻域内有限的多元矩母函数唯一性，得到两个概率测度相同，进而 $f_+ = f_-$，ν-a.e.。约去正因子可得 $g(t)h_*(t) = 0$，ν-a.e.。所有模型分布都关于载体测度绝对连续，故 $g(T) = 0$ 在每个参数下 a.s. 成立。

开集允许所有足够小方向的指数倾斜，提供一个原点邻域上的矩母函数信息。“所有阶矩相同必同分布”没有一般保证，不能替代这里的唯一性定理。

弯曲族的不完备必须另证

单观测 $X \sim N(\theta, \theta^2)$，$\theta > 0$ 时，

$$X/\theta \sim N(1,1), \qquad P_\theta(X < 0) = \Phi(-1).$$

令 $T = (X, X^2)$，取

$$g(T) = \mathbf{1}_{\{X<0\}} - \Phi(-1).$$

该函数有界、对所有参数期望为零，但两个可能取值均非零。因此此例不有界完备，也不完备。证明依据是这个具体反例函数，而不只是自然参数空间没有开集。

2.6 辅助统计量与 Basu 定理

2.6.1 辅助性要求整个分布不含参数

定义 2.6.1：辅助统计量

若 $A = A(\mathbf{X})$ 的分布不依赖 θ，即对每个可测集合 B，$P_\theta(A \in B)$ 都是关于参数的常数，则 A 辅助。

均值恒定不够。例如 $X \sim N(0, \sigma^2)$ 的均值始终为零，但分布随方差变化，因此 X 对该模型不辅助。

正态样本 $n \geq 2$ 时，标准化残差方向

$$A = \frac{(X_1 - \bar{X}, \ldots, X_n - \bar{X})}{\{\sum_i (X_i - \bar{X})^2\}^{1/2}}$$

对完整位置尺度模型辅助。写 $X_i = \mu + \sigma Z_i$，其中 Z_i 独立标准正态，中心化消去 μ，归一化消去正数 σ，所以 A 成为标准正态向量的固定函数。分母为零是概率零事件，可任意补定义。

2.6.2 Basu 定理的条件与完整证明

定理 2.6.1：Basu 定理

若 T 有界完备且充分，A 辅助，则它们在模型中的每个分布下独立。

证明。任取 A 值域内的可测集合 B，辅助性给出不含参数的常数

$$c_B = P_\theta(A \in B).$$

充分性给出不含参数的共同版本

$$q_B(T) = E_\theta[\mathbf{1}_{\{A \in B\}} \mid T], \qquad 0 \leq q_B \leq 1.$$

全期望公式给出 $E_\theta[q_B(T) - c_B] = 0$ 对所有参数成立。差是 T 的固定有界函数，由有界完备性，

$$q_B(T) = c_B \quad P_\theta\text{-a.s.}$$

再取 T 值域内的可测集合 C，

$$\begin{aligned} P_\theta(T \in C, A \in B) &= E_\theta[\mathbf{1}_{\{T \in C\}} E_\theta(\mathbf{1}_{\{A \in B\}} \mid T)] \\ &= E_\theta[\mathbf{1}_{\{T \in C\}} q_B(T)] \\ &= P_\theta(T \in C) P_\theta(A \in B). \end{aligned}$$

这就是独立性；若从联合测度角度表述，可由矩形集上的相等延拓到乘积 σ-域。

三个条件各用在哪里？

辅助性使 c_B 不含参数；充分性使 q_B 可以统一选择；有界完备性使“所有参数下均值为零”升级为“几乎必然为零”。无条件概率不含参数，不能直接推出条件概率是同一常数。

2.6.3 正态与指数模型的独立性应用

例 2.6.2：正态均值与样本方差独立

设 $n \geq 2$，X_i 独立同分布于 $N(\mu, \sigma^2)$。先固定任意 $\sigma^2 > 0$，仅令 μ 变化。联合密度的参数项为

$$\exp\left\{\frac{\mu}{\sigma^2}\sum_i x_i - \frac{n\mu^2}{2\sigma^2}\right\}.$$

所以 $\sum_i X_i$ 充分；自然参数 μ/σ^2 遍历 $\mathbb{R}$，由指数族定理完备。$\bar{X}$ 与总和一一对应，也完备充分。

写 $X_i = \mu + \sigma Z_i$，则

$$S^2 = \frac{\sigma^2}{n-1}\sum_i (Z_i - \bar{Z})^2.$$

在固定方差的子模型中，其分布不含 μ，所以辅助。Basu 定理给出 $\bar{X}$ 与 S^2 独立；固定的 σ^2 任意，因此对整个两参数正态模型中的每个参数点都成立。

不能直接说 S^2 对完整两参数模型辅助，因为其分布依赖 σ^2。上述证明也没有预先使用均值、方差独立性，避免循环论证。

例 2.6.3：指数尺度族

设 X_i 独立同分布，密度为 $\theta^{-1}e^{-x/\theta}\mathbf{1}_{\{x>0\}}$。总和充分，自然参数 $-1/\theta$ 遍历 $(-\infty, 0)$，故总和及其一一变换 $\bar{X}$ 完备充分。

令 $Z_i = X_i/\theta$，则 Z_i 独立同分布于尺度为 1 的指数分布，且

$$\frac{X_1}{\bar{X}} = \frac{Z_1}{\bar{Z}}.$$

比例的分布不含参数，因此辅助。Basu 定理给出

$$\bar{X} \perp\!\!\!\perp X_1/\bar{X}.$$

$n = 1$ 时比例恒为 1；$n \geq 2$ 时是非平凡结论。它不表示 X_1 与 $\bar{X}$ 独立。

2.6.4 反例：最小充分并不意味着完备

例 2.6.4：均匀位置族

设 X_i 独立同分布于 $U(\theta,\theta+1)$，$\theta\in\mathbb{R}$，$n\geq 2$。联合似然为

$$p_\theta^{(n)}(\mathbf{x})=\mathbf{1}_{\{x_{(n)}-1<\theta<x_{(1)}\}}.$$

在极差小于 1 的共同满测样本集上，两条非零似然成比例当且仅当参数区间两个端点相同。因而 $T=(X_{(1)},X_{(n)})$ 最小充分。
写 $X_i=\theta+U_i$，U_i 独立同分布于 $U(0,1)$。极差

$$R=X_{(n)}-X_{(1)}=U_{(n)}-U_{(1)}$$

是 T 的辅助函数。极小、极大的联合密度为

$$f(u,v)=n(n-1)(v-u)^{n-2},\qquad 0<u<v<1.$$

令 $r=v-u$，Jacobian 为 1，在 $0<u<1-r$ 上积分得

$$f_R(r)=n(n-1)r^{n-2}(1-r),\qquad 0<r<1.$$

因此

$$ER=n(n-1)\int_0^1 r^{n-1}(1-r)\,\mathrm{d}r=n(n-1)\left(\frac{1}{n}-\frac{1}{n+1}\right)=\frac{n-1}{n+1}.$$

于是 $g(T)=R-(n-1)/(n+1)$ 有界、所有参数下零期望，而 R 有连续密度，故 $g(T)\neq 0$ 的概率为 1。T 不有界完备，也不完备。

这里是区间长度固定、位置未知的模型，不能与上端点未知的 $U(0,\theta)$ 混淆。也可反证：若 T 有界完备，Basu 定理给出 $R\perp\!\!\!\perp T$。由于 R 是 T 的函数，事件 $\{R\leq r\}$ 属于 $\sigma(T)$；独立性便给出

$$P_\theta(R\leq r)=P_\theta(R\leq r)^2.$$

所以这个概率只能为 0 或 1。但 R 的密度在 $(0,1)$ 上为正，任意 $r\in(0,1)$ 都满足 $0<P_\theta(R\leq r)<1$，矛盾。这也解释了“一个实随机变量若与自身独立，便只能几乎必然为常数”。

2.7 总结与学习检查

充分、最小充分、完备与辅助

充分性：给定摘要后，剩下样本的条件分布是否与参数无关？
最小充分性：每个充分摘要是否都必须保留这份共同核心？
完备性：一个固定可积函数能否在所有参数下均值为零，却不几乎必然为零？
辅助性：统计量自身的整个分布是否与参数无关？

本章的可靠逻辑关系是

$$\text{完备} \Rightarrow \text{有界完备}, \qquad \text{有界完备且充分} \Rightarrow \text{最小充分} \Rightarrow \text{充分}.$$

最小充分不推出完备。常数统计量对任意模型都完备，却在分布随参数改变的模型中不充分，说明完备不是“信息最多”。

考场证明的起手与收尾

1. 证明充分：写全联合密度和支撑，明确 $g_\theta(T(x))$ 与 $h(x)$，引用因子分解。
2. 证明最小充分：先有充分性，再证明完整似然成比例推出 $T(x) = T(y)$；或选择合适小模型并核对共同零事件。
3. 证明完备：任取所有参数下可积的固定函数 g，从零期望推出 $g(T) = 0$ a.s.。用指数族定理时写明自然参数及其开集。
4. 否定完备：明确构造与未知参数无关的 g，核对可积、所有参数下零期望、至少一个参数下不几乎必然为零。
5. 应用 Basu：明确当前模型，分别核对充分、完备、辅助；若固定干扰参数使用子模型，最后说明所固定值任意。

练习与核对

1. 不看答案，解释为什么统计量和自然参数都落在曲线上时，两条满秩条件的判断仍可能不同。
2. 从条件期望定义出发，重写因子分解两个方向，标明每一步使用的测度。
3. 说明共同支配引理、可数混合构造与推广原则怎样共同支持最小充分性证明。
4. 独立证明二项与均匀最大值的完备性，并构造均匀位置族的不完备反例。
5. 不预先使用卡方分布或独立性结论，应用 Basu 证明正态样本均值与方差独立。

复习题答案线索

第 1 题：对统计量检验 $a^\top T = b$，对自然参数检验同维开球；曲线可以仿射张成平面。第 2 题：先构造共同概率 Q，将密度比写为 T 的函数，再验证条件期望定义，区分原样本测度与边缘测度。第 3 题：由可数混合得到共同零事件，由密度比向量

得到最小充分，最后用推广原则回到全模型。第 4 题：二项模型用多项式系数，均匀上端点用绝对连续积分的导数，位置族用极差减去其常数期望。第 5 题：固定方差，仅令均值变化，此时均值完备充分、样本方差辅助；对每个固定方差应用 Basu。

来源与引用说明

主要来源为 Fang Yao《Advanced Mathematical Statistics》第二章讲义，正文第 27–48 页，并结合第二章 Slides 与相关推导整理。原讲义文件未随笔记重新发布。一般最小充分性证明沿用讲义引用：Bahadur (1954), Theorem 6.2；Srivastava (1998), *A Course on Borel Sets*, Theorem 4.5.7；Kallenberg (2002), *Foundations of Modern Probability*, 2nd ed., Lemma 1.13。书目与编号按课程材料记录，未另行核对相应书籍全文。

第 3 章　决策、估计与信息下界

评价一个统计方法，须先指定模型、估计目标、损失函数及允许比较的规则类。无偏性约束估计量的均值，一致性描述样本量增大时的集中，而风险同时计入误差的大小与发生概率。本章先建立这些比较标准，再由得分恒等式推导 Cramér–Rao 下界，并讨论等号、参数变换和非正则模型。

3.1　决策问题与风险比较

3.1.1　从估计规则到风险函数

统计决策问题

给定统计模型 $\mathcal{P}=\{P_\theta:\theta\in\Theta\}$、行动空间 $\mathcal{A}$、非负损失 $L(\theta,a)$，以及一类可测规则 $\mathcal{D}$。规则 $\delta:\mathcal{X}\to\mathcal{A}$ 的风险为

$$R_\theta(\delta)=\mathrm{E}_\theta\, L(\theta,\delta(X)).$$

固定参数时，损失 $L(\theta,\delta(X))$ 是随机变量，风险是对样本分布取平均后的数值；改变参数，便得到整条风险函数。

估计 $g(\theta)\in\mathbb{R}^k$ 时，常用平方损失 $\|a-g(\theta)\|^2$、绝对距离损失 $\|a-g(\theta)\|$，或加权二次损失

$$L(\theta,a)=(a-g(\theta))^{\top}W_\theta(a-g(\theta)),\qquad W_\theta\succeq 0.$$

平方损失下的风险称均方误差。权重可以改变不同方向的代价，但这种二次损失仍对误差的正负对称。高估与低估代价不同时，应另设非对称损失。

正态均值：两条相交的风险曲线

设 $X_1,\dots,X_n\overset{\text{i.i.d.}}{\sim}N(\mu,\sigma^2)$，$\sigma^2$ 已知，估计 μ。平方损失下，

$$R_\mu(\bar X)=\frac{\sigma^2}{n},\qquad R_\mu(m)=(m-\mu)^2,$$

其中 m 是事先固定的常数。若 $|\mu-m|<\sigma/\sqrt{n}$，常数规则的风险较低；区间外则样本均值较低。常数规则在 $\mu=m$ 处风险为零，并不能使它成为整个模型中的好规则。

风险的定义先固定参数，只对数据平均。给参数配置先验 π 后再平均，才得到 Bayes

风险

$$r_\pi(\delta) = \int_\Theta R_\theta(\delta)\,\pi(\mathrm{d}\theta).$$

这两个期望的对象不同。

3.1.2 支配、可容许与极小极大

三种风险比较

若 $R_\theta(\delta_1) \le R_\theta(\delta_2)$ 对所有 θ 成立，且至少一点严格小于，称 δ_1 支配 δ_2。在指定规则类中不受任何规则支配的规则称可容许。

若某个 δ^* 满足

$$R_\theta(\delta^*) \le R_\theta(\delta) \quad \text{对所有}\theta \in \Theta,\ \delta \in \mathcal{D},$$

则它逐点最优。极小极大规则则要求达到

$$\inf_{\delta\in\mathcal{D}} \sup_{\theta\in\Theta} R_\theta(\delta).$$

逐点最优必然可容许；若逐点最优规则存在，任何可容许规则都须与它具有相同风险函数，否则便被支配。可容许性本身不提供风险的大小：它仅排除一种统一改进。规则类扩大后，原来的可容许性也可能失效。

例如 $X_i \sim N(\theta,1)$ 且 $n \ge 2$，X_1 与 $\bar X$ 均无偏，但风险分别为 1 与 $1/n$，故 X_1 不可容许。这个比较尚未证明 $\bar X$ 优于所有估计量。又如 $X \sim N(\theta,1)$，在只含 X 与常数 3 的两元素规则类中，二者风险相交，因此都可容许，却无逐点最优规则。

极小极大比较先固定规则，再找它最坏的参数点，最后在规则间优化。交换这两个优化顺序，会变成知道参数后另选行动的问题。一个实用下界为

$$\inf_\delta \sup_\theta R_\theta(\delta) \ge \inf_\delta r_\pi(\delta),$$

因为任意规则的最大风险不小于其先验平均风险。若某个规则的最大风险等于右端，就证明了它的极小极大性。

3.1.3 检验也是决策

检验 $H_0 : \theta \in \Theta_0$ 对 $H_1 : \theta \in \Theta_1$，约定拒绝为行动 1。随机化检验 $\varphi(X) \in [0,1]$ 表示给定数据后的拒绝概率，可用独立 $V \sim U(0,1)$ 实现为 $\mathbf{1}\{V \le \varphi(X)\}$。记功效

$$\beta_\varphi(\theta) = \mathrm{E}_\theta\,\varphi(X).$$

若错误行动的损失为 1、正确行动为 0，则

$$R_\theta(\varphi) = \begin{cases} \beta_\varphi(\theta), & \theta \in \Theta_0, \\ 1 - \beta_\varphi(\theta), & \theta \in \Theta_1. \end{cases}$$

水平不超过 α 要求 $\sup_{\Theta_0}\beta_\varphi \le \alpha$。随后提高备择下的功效，才是带水平约束的风险优化。总不拒绝虽然没有第一类错误，却没有发现备择的能力。

复习题

1. 在上面的正态均值例中，把损失改成 $|a-\mu|$，求 $\bar X$ 与常数 m 的风险及交点。
2. 逐点最优、可容许、极小极大是否是同一个概念？说明其量词或优化对象的区别。

答案线索

第一题：$R_\mu(\bar X)=\sigma\sqrt{2/(\pi n)}$，$R_\mu(m)=|m-\mu|$。第二题：逐点最优比较每个竞争者在每个参数点的风险；可容许只排除支配；极小极大只比较最大风险。有限规则类中的结论不能直接推广到所有可测规则。

3.2 偏差、方差与收缩

3.2.1 均方误差分解

设 T 二阶可积，目标为 $g(\theta)\in\mathbb{R}$，偏差记作

$$b_\theta(T)=\mathrm{E}_\theta T-g(\theta).$$

将误差拆为 $T-\mathrm{E}_\theta T+b_\theta(T)$，平方后取期望，交叉项因中心化消失，故

$$\mathrm{MSE}_\theta(T)=\mathrm{Var}_\theta(T)+b_\theta(T)^2.$$

无偏性只使第二项为零，不保证第一项小。允许适当偏差，有时可以显著降低方差。

固定系数的正态收缩

设 $X\sim N(\theta,1)$，$0<a<1$，比较 aX 与 X。有

$$b_\theta(aX)=(a-1)\theta,\qquad R_\theta(aX)=a^2+(1-a)^2\theta^2.$$

因此

$$R_\theta(aX)<R_\theta(X)=1\iff|\theta|<\sqrt{\frac{1+a}{1-a}}.$$

收缩降低了方差，却引入随 $|\theta|$ 增大的偏差；整个实参数空间上不存在这里的统一支配关系。

3.2.2 二项比例的加权估计

设 $Y\sim\mathrm{Bin}(n,p)$，$a,b\ge0$，考虑

$$\delta_{a,b}=\frac{Y+a}{n+a+b}.$$

当 $a+b>0$ 时，它是样本比例与固定中心的加权平均：

$$\delta_{a,b}=w\frac{Y}{n}+(1-w)q,\qquad w=\frac{n}{n+a+b},\quad q=\frac{a}{a+b}.$$

直接计算得

$$b_p(\delta_{a,b})=\frac{a-(a+b)p}{n+a+b},\qquad R_p(\delta_{a,b})=\frac{np(1-p)+\{a-(a+b)p\}^2}{(n+a+b)^2}.$$

取 $n=16,a=b=1$，令 $u=p(1-p)$，则两个风险分别为 $(1+12u)/324$ 与 $u/16$。前者较小当且仅当

$$u>\frac{4}{33}\iff\left|p-\frac{1}{2}\right|<\frac{1}{2}\sqrt{\frac{17}{33}}.$$

靠近中心时，减少的方差补偿了偏差；靠近端点时则相反。

3.2.3 对称收缩的极小极大计算

在 $\delta_c=(Y+c)/(n+2c)$、$c\geq 0$ 的规则类内，风险为

$$R_p(c)=\frac{np(1-p)+c^2(1-2p)^2}{(n+2c)^2},\qquad \frac{\partial R_p(c)}{\partial p}=\frac{(n-4c^2)(1-2p)}{(n+2c)^2}.$$

当 $c<\sqrt{n}/2$，最大风险在 $p=1/2$；当 $c>\sqrt{n}/2$，在 $p=0,1$。因而

$$\sup_{0\leq p\leq 1}R_p(c)=\begin{cases}\dfrac{n}{4(n+2c)^2}, & 0\leq c\leq\sqrt{n}/2,\\[2ex] \dfrac{c^2}{(n+2c)^2}, & c\geq\sqrt{n}/2.\end{cases}$$

第一段随 c 递减，第二段递增。最优选择是

$$c^*=\frac{\sqrt{n}}{2},\qquad R_p(c^*)=\frac{1}{4(\sqrt{n}+1)^2},$$

此时风险不依赖 p。

从类内优化到全部规则：还需一个下界

上述微分计算只证明对称规则类内的极小极大性。本例可以再补一步：取真先验 $p\sim\mathrm{Beta}(c^*,c^*)$。平方损失下的后验均值正是 δ_{c^*}，因为条件均方误差由后验均值最小化。它的 Bayes 风险等于常数风险 $1/\{4(\sqrt{n}+1)^2\}$。Bayes 下界与该规则的最大风险相等，故它实际上也在全部规则中极小极大。若不补这个论证，便不能扩大原有结论的范围。

固定 a,b 时，加权估计的偏差为 $O(n^{-1})$；但 $c^*=\sqrt{n}/2$ 随样本量改变，偏差一般仅为 $O(n^{-1/2})$。两种渐近比较的前提不同。

复习题

1. 设独立 X_i 具有共同均值 θ 与方差 $\sigma^2 > 0$。证明所有确定权重的线性无偏估计 $\sum_i c_i X_i$ 中，$\bar{X}$ 的方差最小，并求等号条件。
2. 当 $n = 16$ 时，分别计算 Y/n 与 δ_{c^*} 的最大风险。偏差是否必然增加最大均方误差?

答案线索

第一题：无偏要求 $\sum_i c_i = 1$，Cauchy–Schwarz 给出 $\sum_i c_i^2 \geq 1/n$；等号当且仅当所有 $c_i = 1/n$。结论只在线性无偏类中成立。第二题：最大风险分别为 $1/64$ 与 $1/100$，故有偏规则也可能降低最大风险。

3.3 无偏性、一致性与渐近尺度

3.3.1 三种性质应分别检验

无偏、渐近无偏与一致

T_n 对 $g(\theta)$ 无偏，指每个 n 均有 $\mathrm{E}_\theta T_n = g(\theta)$。若期望存在且 $\mathrm{E}_\theta T_n \to g(\theta)$，称渐近无偏。若对每个固定 θ、每个 $\varepsilon > 0$，

$$P_\theta(|T_n - g(\theta)| > \varepsilon) \to 0,$$

则称一致。给定 $a_n \to \infty$，若 $a_n(T_n - g(\theta)) = O_{P_\theta}(1)$，称具有 a_n-一致性。

依概率有界可推出 $T_n - g(\theta) = O_{P_\theta}(a_n^{-1}) \xrightarrow{P} 0$。这些都是固定参数下的陈述，未必在整个参数空间上一致，也未声称该速度最优。

由 Markov 不等式，

$$P_\theta(|T_n - g(\theta)| > \varepsilon) \leq \frac{\mathrm{E}_\theta(T_n - g(\theta))^2}{\varepsilon^2}.$$

故偏差与方差都趋零足以推出一致；反向需要额外的尾部控制。

无偏性与一致性互不替代

设 $X_i \sim N(\mu, 1)$。

1. $T_n = (1 - 1/n)\bar{X}$ 有偏，偏差 $-\mu/n$，方差 $(1 - 1/n)^2/n$，却一致。
2. $T_n = X_1$ 每个样本量均无偏，但

$$P_\mu(|T_n - \mu| > \varepsilon) = P(|Z| > \varepsilon) > 0, \quad Z \sim N(0, 1),$$

所以不一致。

3. 允许外加随机化，取与数据独立的 $U \sim U(0, 1)$，令

$$T_n = \bar{X} + n\mathbf{1}\{U \leq 1/n\}.$$

则 $\mathrm{E}_\mu T_n = \mu + 1$，不渐近无偏，但

$$P_\mu(|T_n - \mu| > \varepsilon) \le \frac{1}{n\varepsilon^2} + \frac{1}{n} \to 0.$$

此时均方误差为 $1/n + n$，甚至发散。若规则只允许原始样本的确定函数，这个随机化例子须先把 U 纳入实验。

证明不一致应回到尾概率，而不能仅以“方差未趋零”代替。相反，上例说明依概率收敛本身并不保证期望或二阶矩收敛。

3.3.2 一阶相同不等于有限样本相同

设 $X_i \sim N(\mu, \sigma^2)$，$\sigma^2$ 已知，估计 μ^2。考虑

$$T_n = \bar{X}^2, \qquad U_n = \bar{X}^2 - \frac{\sigma^2}{n}.$$

前者偏差为 σ^2/n，后者无偏。利用恒等式

$$\bar{X}^2 - \mu^2 = 2\mu(\bar{X} - \mu) + (\bar{X} - \mu)^2$$

及 $\sqrt{n}(\bar{X} - \mu) = O_P(1)$，有

$$\sqrt{n}(T_n - \mu^2) = 2\mu\sqrt{n}(\bar{X} - \mu) + o_P(1).$$

当 $\mu \neq 0$，两个估计量均满足

$$\sqrt{n}(T_n - \mu^2),\ \sqrt{n}(U_n - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2),$$

因为 $\sqrt{n}(T_n - U_n) = \sigma^2/\sqrt{n} \to 0$。

在 $\mu = 0$ 处，一阶导数消失。写 $Z_n = \sqrt{n}\bar{X}/\sigma \sim N(0,1)$，便有精确分布

$$nT_n \xrightarrow{d} \sigma^2\chi_1^2, \qquad nU_n \xrightarrow{d} \sigma^2(\chi_1^2 - 1).$$

此处应使用 n 尺度，且偏差修正改变极限分布。尺度和有效的一阶展开可能随参数点改变。

复习题

1. 若 $\sqrt{n}(T_n - g(\theta)) \xrightarrow{d} N(0, V)$，能否推出一致性？能否直接推出 $n\,\mathrm{MSE}_\theta(T_n) \to V$？
2. 计算上述 U_n 的精确方差，比较 $\mu = 0$ 与 $\mu \neq 0$ 时的误差尺度。

答案线索

第一题：弱收敛蕴含依概率有界，因此推出一致；矩收敛不能直接推出，需统一可积性等附加条件。第二题：令 $Z=\bar X-\mu$，使用 $\mathrm{E}\,Z^3=0$、$\mathrm{E}\,Z^4=3\sigma^4/n^2$，得到

$$\mathrm{Var}_\mu(U_n)=\frac{4\mu^2\sigma^2}{n}+\frac{2\sigma^4}{n^2}.$$

3.4 得分与 Fisher 信息

3.4.1 定义与正则条件

令 $\theta\in\Theta\subset\mathbb{R}^d$，单次观测密度为 p_θ，得分取列向量：

$$\ell_\theta(x)=\log p_\theta(x),\qquad s_\theta(x)=\nabla_\theta\ell_\theta(x),\qquad I(\theta)=\mathrm{E}_\theta[s_\theta(X)s_\theta(X)^\top].$$

信息矩阵总半正定，因为 $a^\top I(\theta)a=\mathrm{E}_\theta(a^\top s_\theta)^2\ge 0$，但不一定可逆。导数针对参数，求导时观测值固定；把 X 代入后，得分才成为随机向量。

以下是一组足以使用信息恒等式的局部条件：参数点位于开放参数空间内部；各密度在同一支撑上为正；除一个共同测度零集外，密度关于参数二次连续可微；密度的一、二阶导数在真值邻域内具有可积包络；得分二阶矩与对数密度 Hessian 的期望存在。这些条件使微分与积分可以交换。

得分与信息恒等式

在上述条件下，

$$\mathrm{E}_\theta\, s_\theta(X)=0,\qquad I(\theta)=\mathrm{Cov}_\theta(s_\theta(X))=-\,\mathrm{E}_\theta\,\nabla_\theta^2\ell_\theta(X).$$

证明 由 $\nabla p_\theta=p_\theta s_\theta$ 和密度归一化，

$$\mathrm{E}_\theta\, s_\theta=\int\nabla p_\theta\,\mathrm{d}\nu=\nabla\int p_\theta\,\mathrm{d}\nu=0.$$

逐坐标使用乘积法则，

$$\nabla^2 p_\theta=p_\theta\{\nabla^2\ell_\theta+s_\theta s_\theta^\top\}.$$

再对两边积分，左边为归一化常数的二阶导数 0，故得第二条恒等式。单个观测的负 Hessian 不必半正定；这里等于信息矩阵的是它的期望。

对于 i.i.d. 样本，记

$$\ell_n(\theta)=\sum_{i=1}^n\ell_\theta(X_i),\quad S_n(\theta)=\sum_{i=1}^n s_\theta(X_i),\quad H_n(\theta)=\nabla_\theta^2\ell_n(\theta).$$

独立性与得分均值为零使外积中的交叉项消失，故

$$I_n(\theta) = \mathrm{E}_\theta\, S_n S_n^\top = nI(\theta).$$

独立但不同分布时信息仍逐项相加；存在依赖时不能直接写成 nI。

3.4.2 指数族的归一化函数

自然指数族写成

$$p_\eta(x) = h(x)\exp\{\eta^\top T(x) - \zeta(\eta)\}, \qquad Z(\eta) = e^{\zeta(\eta)}.$$

在自然参数空间内部，直接微分归一化积分得到

$$\nabla\zeta(\eta) = \frac{\nabla Z(\eta)}{Z(\eta)} = \mathrm{E}_\eta\, T,$$

$$\nabla^2\zeta(\eta) = \frac{\nabla^2 Z}{Z} - \frac{\nabla Z \nabla Z^\top}{Z^2} = \mathrm{Cov}_\eta(T).$$

另一方面，$s_\eta = T - \nabla\zeta$，所以 $I(\eta) = \nabla^2\zeta(\eta)$。若 T 无非平凡的几乎必然仿射关系，则任意非零 a 均有 $\mathrm{Var}(a^\top T) > 0$，信息矩阵正定。

微分合法性来自参数空间的内部性。一维时，选取 $\eta_0 \pm 2a$ 仍在自然参数空间内。对 $m = 1, 2$ 及 $|\eta - \eta_0| \le a$，

$$|t|^m e^{\eta t} \le C_{m,a}\{e^{(\eta_0+2a)t} + e^{(\eta_0-2a)t}\}.$$

乘 h 后右边可积，给出导数所需的局部包络。多维时可用参数邻域内有限个立方体顶点的指数项之和控制。

3.4.3 参数变换与 Jacobian 的方向

设新参数 $\lambda \in \mathbb{R}^r$，旧参数为 $\theta = \psi(\lambda) \in \mathbb{R}^d$，Jacobian 定义为

$$J(\lambda) = D\psi(\lambda) = \left(\frac{\partial\theta_j}{\partial\lambda_r}\right)_{j,r} \in \mathbb{R}^{d\times r}.$$

链式法则给出

$$s_\lambda(X) = J(\lambda)^\top s_\theta(X), \qquad I_\lambda(\lambda) = J(\lambda)^\top I_\theta(\psi(\lambda))J(\lambda).$$

导数方向是“旧参数对新参数”，因为新得分对 λ 求导。这里没有变换样本 X；Jacobian 来自参数的链式求导，不是密度换元的行列式。

指数分布：尺度与率

尺度参数模型 $p_\theta(x) = \theta^{-1}e^{-x/\theta}\mathbf{1}\{x > 0\}$ 有

$$s_\theta(x) = \frac{x-\theta}{\theta^2}, \qquad I_\theta(\theta) = \frac{1}{\theta^2}.$$

改用率 $\lambda = 1/\theta$，$J = \mathrm{d}\theta/\mathrm{d}\lambda = -1/\lambda^2$，因此

$$I_\lambda(\lambda) = \frac{1}{\lambda^4}\, I_\theta(1/\lambda) = \frac{1}{\lambda^2}.$$

直接对 $\log p_\lambda(x) = \log\lambda - \lambda x$ 求导，也有 $s_\lambda = 1/\lambda - X$，其方差为 $1/\lambda^2$。只把 $\theta = 1/\lambda$ 代入旧信息所得的 λ^2，仍是旧坐标导数的二阶矩，缺少链式因子。

3.4.4 常见模型核对

模型与参数	单次得分	单次信息
$N(\mu, \sigma^2)$，σ^2 已知	$(X-\mu)/\sigma^2$	$1/\sigma^2$
Bernoulli(p)	$(X-p)/\{p(1-p)\}$	$1/\{p(1-p)\}$
Poisson(λ)	$X/\lambda - 1$	$1/\lambda$
指数分布，尺度 θ	$(X-\theta)/\theta^2$	$1/\theta^2$

Bernoulli 的自然参数为 $\eta = \log\{p/(1-p)\}$，其信息为 $p(1-p)$，不是原参数 p 下的信息。信息的数值必须连同参数坐标一起解释。

复习题

1. 若 Poisson 均值改写为 $\lambda = e^\eta$，用链式法则计算 I_η，再用对数密度直接验证。
2. 为什么从 $\int p_\theta = 1$ 合法求导，尚不足以保证可以从 $\int T p_\theta$ 合法求导?

答案线索

第一题：$I_\eta = (e^\eta)^2/e^\eta = e^\eta$；新得分是 $X - e^\eta$。第二题：多出的 T 可能无界，需要另行控制 $T\,\partial_\theta p_\theta$ 的可积性，例如提供局部可积包络。

3.5 Cramér–Rao 下界与等号条件

3.5.1 标量下界的完整证明

标量 Cramér–Rao 不等式

设标量参数模型满足前述得分恒等式，$0 < I_n(\theta) < \infty$。统计量 T 无偏估计可微目标 $g(\theta)$，且 $\mathrm{E}_\theta\, T^2 < \infty$。另假设在 $\mathrm{E}_\theta\, T = \int T p_\theta^{(n)}\, \mathrm{d}\nu^n$ 中可以交换微分与积分。则

$$\mathrm{Cov}_\theta(T, S_n) = g'(\theta), \qquad \mathrm{Var}_\theta(T) \geq \frac{g'(\theta)^2}{I_n(\theta)}.$$

i.i.d. 情形 $I_n = nI$。

证明 $T = T(x)$ 不依赖未知参数。对无偏性求导，

$$\begin{aligned} g'(\theta) &= \int T(x)\, \partial_\theta p_\theta^{(n)}(x)\, \mathrm{d}\nu^n(x) \\ &= \mathrm{E}_\theta[T S_n(\theta)] = \mathrm{Cov}_\theta(T, S_n), \end{aligned}$$

末步用了 $\mathrm{E}_\theta\, S_n = 0$。Cauchy–Schwarz 不等式给出

$$g'(\theta)^2 = \{\mathrm{E}_\theta[(T - g(\theta))S_n]\}^2 \leq \mathrm{Var}_\theta(T) I_n(\theta).$$

除以正的信息即得下界。等号成立当且仅当

$$T - g(\theta) = \frac{g'(\theta)}{I_n(\theta)} S_n(\theta) \quad P_\theta\text{-a.s.}$$

当 $g'(\theta) = 0$，下界为零，取等要求 $T = g(\theta)$ 几乎必然，而非任意估计量均取等。

3.5.2 投影分解与下界不可达的可能性

令

$$r = T - g(\theta) - \frac{g'(\theta)}{I_n(\theta)} S_n(\theta).$$

则 $\mathrm{E}_\theta\, r = 0$、$\mathrm{E}_\theta(r S_n) = 0$。平方展开得到精确分解

$$\mathrm{Var}_\theta(T) = \frac{g'(\theta)^2}{I_n(\theta)} + \mathrm{E}_\theta\, r^2.$$

这是 $L^2(P_\theta)$ 中把误差投影到得分方向的勾股关系。残差正交表示不相关，不一般表示独立。投影项可能依赖未知参数，因此不能自动把残差删去、构造一个合法的更好估计量；信息下界可能不可达。

正态均值与均值平方

已知 σ^2 时，$S_n(\mu)=n(\bar X-\mu)/\sigma^2$，$I_n=n/\sigma^2$。估计 $g(\mu)=\mu$，样本均值满足等号条件，方差 σ^2/n 达到下界。
估计 $g(\mu)=\mu^2$ 时，下界为 $4\mu^2\sigma^2/n$，而无偏估计 $U_n=\bar X^2-\sigma^2/n$ 的方差为

$$\operatorname{Var}_\mu(U_n)=\frac{4\mu^2\sigma^2}{n}+\frac{2\sigma^4}{n^2}.$$

它未达到有限样本下界。在 $\mu=0$，下界甚至为零。这并不证明存在方差更小的无偏估计，第四章的最优无偏理论还需单独判断。

3.5.3 有偏估计的修正

若 $\mathrm{E}_\theta T=g(\theta)+b(\theta)$，$b$ 可微且同样允许求导交换，则

$$\operatorname{Cov}_\theta(T,S_n)=g'(\theta)+b'(\theta).$$

因此

$$\operatorname{Var}_\theta(T)\ge\frac{\{g'(\theta)+b'(\theta)\}^2}{I_n(\theta)},$$

$$\operatorname{MSE}_\theta(T)\ge b(\theta)^2+\frac{\{g'(\theta)+b'(\theta)\}^2}{I_n(\theta)}.$$

例如 $X\sim N(\theta,1)$、$T=aX$，$g'=1$、$b'=a-1$，修正后的方差下界是 a^2，恰与实际方差相等。不能把无偏下界 1 用于这个有偏估计。

复习题

1. 指数尺度模型中，证明 $\bar X$ 达到估计 θ 的信息下界。
2. 正态均值模型下，常数估计 $T=m$ 方差为零，为何不违反信息下界？用有偏版本核对。

答案线索

第一题：$I_n=n/\theta^2$，$S_n=n(\bar X-\theta)/\theta^2$，等号条件直接成立。第二题：常数规则并非在整个模型中无偏，$b(\theta)=m-\theta$，故 $g'+b'=0$，有偏下界给出 $\mathrm{MSE}\ge(m-\theta)^2$，正好取等。

3.6 向量参数与矩阵信息下界

设 $\theta\in\mathbb{R}^d$，目标 $g(\theta)\in\mathbb{R}^k$，$T\in\mathbb{R}^k$ 无偏，Jacobian 约定为

$$Dg(\theta)=\left(\frac{\partial g_j}{\partial\theta_r}\right)_{j,r}\in\mathbb{R}^{k\times d}.$$

在二阶矩存在、均值逐分量可交换微分积分、得分正则及 $I_n(\theta)$ 正定的条件下，

$$\mathrm{Cov}_\theta(T, S_n) = Dg(\theta),$$

矩阵 Cramér–Rao 不等式

$$\mathrm{Cov}_\theta(T) \succeq Dg(\theta) I_n(\theta)^{-1} Dg(\theta)^\top.$$

$A \succeq B$ 指 $A - B$ 半正定，即 $u^\top (A-B) u \geq 0$ 对所有 u 成立，并非逐元素大小。估计参数本身时，下界为 I_n^{-1}。

证明 记 $E = T - g(\theta)$、$A = Dg(\theta)$、$B = I_n(\theta)$。则 $\mathrm{Cov}(E, S_n) = A$、$\mathrm{Cov}(S_n) = B$。令

$$U = E - AB^{-1} S_n,$$

得到 $\mathrm{E}\, U = 0$、$\mathrm{Cov}(U, S_n) = A - AB^{-1}B = 0$。因此

$$\mathrm{Cov}(T) = AB^{-1}A^\top + \mathrm{E}(UU^\top).$$

末项半正定，得到结论。矩阵等号成立当且仅当 $\mathrm{E}\,\|U\|^2 = 0$，即

$$T - g(\theta) = Dg(\theta) I_n(\theta)^{-1} S_n(\theta) \quad P_\theta\text{-a.s.}$$

这个证明也给出维度核对：$(k \times d)(d \times d)(d \times k) = k \times k$。

正态均值与未知方差

以 $\theta = (\mu, v)^\top$ 参数化 $N(\mu, v)$，$v > 0$。单次得分为

$$s_\theta(X) = \begin{pmatrix} (X-\mu)/v \\ -1/(2v) + (X-\mu)^2/(2v^2) \end{pmatrix}, \qquad I(\theta) = \begin{pmatrix} 1/v & 0 \\ 0 & 1/(2v^2) \end{pmatrix}.$$

交叉信息为零来自中心正态的三阶矩为零；右下项来自四阶矩 $3v^2$。估计 μ 时 $Dg = (1, 0)$，下界仍为 v/n，由 $\bar{X}$ 达到。
估计 v 时下界为 $2v^2/n$。无偏样本方差 S^2 的方差为 $2v^2/(n-1)$（$n \geq 2$），故未达到此界。方差参数的下界应由整个信息矩阵的逆取得，不能一般地直接用信息矩阵对角元的倒数。

若把 $\theta = (\psi, \lambda)$ 分为目标与干扰参数，对标量目标 ψ，分块信息在 $I_{\lambda\lambda}$ 可逆时给出

$$(I^{-1})_{\psi\psi} = \{ I_{\psi\psi} - I_{\psi\lambda} I_{\lambda\lambda}^{-1} I_{\lambda\psi} \}^{-1}.$$

这解释了为何未知干扰参数一般会减少有效信息。正态例中的交叉块为零是一个特殊情形。

复习题

1. 对目标 $g(\theta)=c^\top\theta$，写出标量方差下界。为什么不能逐元素解释矩阵不等式？
2. 在正态例中，改用参数 (μ,σ)，其中 $v=\sigma^2$，求新信息矩阵。

答案线索

第一题：下界为 $c^\top I(\theta)^{-1}c/n$；矩阵偏序同时约束全部线性方向的方差。第二题：旧参数对新参数的 Jacobian 是 $\mathrm{diag}(1,2\sigma)$，故新信息矩阵为 $\mathrm{diag}(1/\sigma^2,2/\sigma^2)$。

3.7 达到下界与指数族结构

3.7.1 自然统计量达到哪个目标的下界

固定样本量，将整份样本密度写作

$$p_\eta^{(n)}(x)=h_n(x)\exp\{\eta T(x)-\zeta(\eta)\}.$$

假设自然参数在归一化积分有限的开区间内变化，且 $\zeta''(\eta)>0$。由归一化函数的导数，

$$\mathrm{E}_\eta\,T=\zeta'(\eta),\qquad \mathrm{Var}_\eta(T)=I_n(\eta)=\zeta''(\eta).$$

对目标 $g(\eta)=\zeta'(\eta)$，信息下界恰为

$$\frac{g'(\eta)^2}{I_n(\eta)}=\zeta''(\eta)=\mathrm{Var}_\eta(T).$$

所以 T 达到其均值目标的下界。这里的 ζ 已是联合模型的归一化函数，不能再给信息乘一个 n。目标是 $\zeta'(\eta)$，并不自动是自然参数 η 本身。

Bernoulli 的自然参数

令 $\eta=\log\{p/(1-p)\}$，$Y=\sum_i X_i$，则

$$p_\eta^{(n)}(x)=\exp\{\eta Y-n\log(1+e^\eta)\}.$$

Y 的均值为 np，方差与样本信息均为 $np(1-p)$；Y 达到估计 np 的下界。相应地，Y/n 达到估计 p 的下界，但这没有提供自然参数 η 的无偏有效估计。

3.7.2 处处取等反推一维指数族

CR 等号的逆向结论

固定样本量，设标量参数在开区间 Θ 内变化，模型满足标量 CR 条件；密度在共同支撑上严格为正，除同一个固定测度零集外关于参数连续可微。另设 $I_n(\theta) > 0$ 与 $g'(\theta) \neq 0$ 连续。

若同一个无偏统计量 T 在每个 $\theta \in \Theta$ 均达到下界，则在一个共同满测度样本集合上，

$$p_\theta^{(n)}(x) = h_n(x) \exp\{\eta(\theta) T(x) - \zeta(\eta(\theta))\},$$

其中 $\eta'(\theta) = I_n(\theta)/g'(\theta) \neq 0$，并有 $g(\theta) = \zeta'(\eta(\theta))$。

证明 令 $k(\theta) = I_n(\theta)/g'(\theta)$。CR 等号给出

$$\partial_\theta \log p_\theta^{(n)}(x) = k(\theta)\{T(x) - g(\theta)\} \quad P_\theta\text{-a.s.}$$

不能直接固定 x 对整个参数区间积分，因为此时异常零集可能随参数改变。

取可数稠密集 $D \subset \Theta$。共同支撑上的密度严格为正，所以每个 $q \in D$ 下的概率零集也是支撑内的控制测度零集。把这些可数零集及密度连续可微的固定异常集一并剔除，得到共同满测度集合 F。对 $x \in F$，上式在所有 $q \in D$ 成立；由两边关于参数连续，遂在全部 Θ 成立。

固定参考点 θ_* 与 $x \in F$，对参数积分：

$$\log p_\theta^{(n)}(x) - \log p_{\theta_*}^{(n)}(x) = \left(\int_{\theta_*}^{\theta} k(t)\,\mathrm{d}t \right) T(x) - \int_{\theta_*}^{\theta} k(t) g(t)\,\mathrm{d}t.$$

定义 $\eta(\theta) = \int_{\theta_*}^{\theta} k(t)\,\mathrm{d}t$、$c(\theta) = \int_{\theta_*}^{\theta} k(t)g(t)\,\mathrm{d}t$，取 $h_n = p_{\theta_*}^{(n)}$，便得到指数形式。k 连续非零，在区间上不能变号，故 η 严格单调，其像为开区间。归一化给出

$$c(\theta) = \log \int h_n(x) e^{\eta(\theta)T(x)}\,\mathrm{d}\nu^n(x) = \zeta(\eta(\theta)).$$

最后由 $c' = kg$、$\eta' = k \neq 0$ 得 $\zeta'(\eta(\theta)) = g(\theta)$。

3.7.3 一点取等不足以推断整族结构

在样本空间 $\{-1, 0, 1\}$ 上，设

$$p_\theta(x) = \frac{1}{3}\left[1 + \theta x + \theta^2 \left(x^2 - \frac{2}{3}\right)\right], \qquad |\theta| < \frac{1}{2}.$$

三点概率均为正且总和为 1。取 $T = X$，则 $g(\theta) = 2\theta/3$。在 $\theta = 0$，得分为 X，$I(0) = \mathrm{Var}_0(X) = 2/3$，故

$$\frac{g'(0)^2}{I(0)} = \frac{2}{3} = \mathrm{Var}_0(X).$$

但若该族能以同一个 $T(x)=x$ 写成一维指数形式，则 $p_\theta(1)p_\theta(-1)/p_\theta(0)^2$ 必为常数，而实际等于

$$\frac{1-\theta^2/3+\theta^4/9}{1-4\theta^2/3+4\theta^4/9},$$

会随 θ 改变。这个反例否定的是“一点取等推出以 X 为自然统计量的整族结构”，不是否定模型嵌入更高维指数族的可能性。

复习题

1. 逆向证明中，为什么不能直接合并全部参数点的异常零集？可数稠密集之后为何还要连续性?
2. 联合 Poisson 模型中，$Y=\sum_i X_i$ 的自然参数归一化函数为 $\zeta(\eta)=ne^\eta$。说明 Y 和 Y/n 分别达到哪个目标的下界。

答案线索

第一题：不可数个零集的并未必为零集；可数稠密集先统一样本异常集，连续性再把等式推广至整个区间，才能固定样本点积分。第二题：Y 对 $n\lambda$ 有效，Y/n 对 λ 有效，方差分别为 $n\lambda$ 与 λ/n。

3.8 非正则模型、效率与 MLE 展开

3.8.1 移动支撑为什么使正则恒等式失效

均匀模型的边界项

设 $X_i\sim U(0,\theta)$，$\theta>0$。只在内部 $0<x<\theta$ 对 $\log p_\theta(x)=-\log\theta$ 求导，会得到形式上的内部得分 $-1/\theta$，其均值不为零。实际上

$$\frac{\mathrm{d}}{\mathrm{d}\theta}\int_0^\theta \frac{1}{\theta}\,\mathrm{d}x=\int_0^\theta -\frac{1}{\theta^2}\,\mathrm{d}x+\frac{1}{\theta}=0.$$

移动端点贡献的第二项不能省略。因此内部导数的平方均值 $1/\theta^2$ 不能直接代入正则 CR 公式。

记 $M_n=\max_i X_i$。在 $0<m<\theta$ 上，

$$P_\theta(M_n\le m)=(m/\theta)^n,\qquad \mathrm{E}_\theta\, M_n^r=\frac{n}{n+r}\theta^r\quad(r>0).$$

故 $T_n=(n+1)M_n/n$ 无偏，且

$$\mathrm{Var}_\theta(T_n)=\frac{\theta^2}{n(n+2)}.$$

这比误用正则公式得到的 θ^2/n 小，并不构成对定理的反例。模型的正则条件已经失效。

它的自然误差尺度是 n。对固定 $z \geq 0$，

$$P_\theta\{n(1 - M_n/\theta) > z\} = (1 - z/n)^n \to e^{-z}.$$

因此 $n(1 - M_n/\theta) \xrightarrow{d} E$、$E \sim \mathrm{Exp}(1)$，并有

$$n(T_n - \theta) \xrightarrow{d} \theta(1 - E).$$

更快速度来自支撑边界携带的信息；这里的非正态极限不应混同于正则模型中孤立参数点的超效率现象。

3.8.2 有限样本效率与渐近效率

无偏估计量达到正确的 CR 协方差界，称达到有限样本信息效率。这足以保证它在相应无偏类中无法被方差统一改进；未达到下界则不自动意味着可以改进，因为下界可能不可达。

正则模型中，估计可微目标 $g(\theta)$ 的一阶信息基准为

$$\sqrt{n}\{T_n - g(\theta)\} \xrightarrow{d} N_k\Big(0, Dg(\theta)I(\theta)^{-1}Dg(\theta)^\top\Big).$$

渐近效率的比较涉及适当的局部正则估计量类，不要求每个有限样本量都精确无偏。不能把有限样本无偏下界直接令 $n \to \infty$，便声称对一切估计量序列成立；弱收敛不自动给出风险收敛，偏差和局部行为也须控制。

3.8.3 从得分方程到渐近正态

设真参数为 θ_0，$\widehat{\theta}_n$ 是内部 MLE 或一个选定的得分根，并假设 $S_n(\widehat{\theta}_n) = 0$。多维时使用积分 Hessian，避免给所有分量强设同一个中间点：

$$\widetilde{H}_n = \int_0^1 H_n\{\theta_0 + t(\widehat{\theta}_n - \theta_0)\}\,\mathrm{d}t.$$

在线段位于可微参数邻域的事件上，微积分基本定理给出精确等式

$$0 = S_n(\theta_0) + \widetilde{H}_n(\widehat{\theta}_n - \theta_0).$$

若沿线段矩阵最终可逆，则

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) = \left(-\frac{\widetilde{H}_n}{n}\right)^{-1} \frac{S_n(\theta_0)}{\sqrt{n}}.$$

得分的多元中心极限定理给出

$$S_n(\theta_0)/\sqrt{n} \xrightarrow{d} N_d(0, I(\theta_0)).$$

若另有 $-\widetilde{H}_n/n \xrightarrow{P} I(\theta_0)$，且 $I(\theta_0)$ 正定，则由矩阵求逆的连续性与 Slutsky 定理，

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) \xrightarrow{d} N_d(0, I(\theta_0)^{-1}).$$

展开之外必须补的条件

固定点的大数定律 $-H_n(\theta_0)/n \xrightarrow{P} I(\theta_0)$ 尚不足以控制随机线段上的 Hessian。一组可用的充分条件是：所选根存在且一致；真值附近有凸邻域；该邻域内 $-H_n(v)/n$ 一致收敛到连续函数 $J_{\theta_0}(v)$，并满足 $J_{\theta_0}(\theta_0) = I(\theta_0)$ 正定。于是随机线段收缩至真值，得到所需收敛。

MLE 是否存在、所选根是否一致、最终是否位于内部、多个根如何选择，都不是得分方程本身保证的。边界极值也未必满足得分为零。本段给出的是在这些条件落实后的证明，不是无条件的一般 MLE 定理。

正态均值中的展开是精确恒等式

已知方差时，$S_n(\mu) = n(\bar{X} - \mu)/\sigma^2$，$H_n = -n/\sigma^2$ 为常数，MLE 为 $\bar{X}$。于是

$$\sqrt{n}(\bar{X} - \mu) = \sigma^2 \frac{S_n(\mu)}{\sqrt{n}} \sim N(0, \sigma^2).$$

这里没有 Taylor 余项，且极限方差 $I(\mu)^{-1} = \sigma^2$ 同时也是精确分布的方差。

复习题

1. 在均匀模型中，证明 $n(T_n - \theta) = O_{P_\theta}(1)$，并说明它为何不违背正则模型的信息下界。
2. MLE 渐近正态性的证明中，分别指出使用中心极限定理、大数型控制及 Slutsky 定理的位置。固定点 Hessian 收敛还缺少什么?

答案线索

第一题：$n^2 \operatorname{Var}(T_n) = n\theta^2/(n+2) \le \theta^2$，由 Chebyshev 即得随机有界；该模型支撑依赖参数，正则得分恒等式失效。第二题：CLT 用于真值处的得分，局部一致控制用于随机线段上的 Hessian，Slutsky 用于两者的乘积；仅有固定点收敛不能替代随机邻域控制。

第 4 章　最优无偏估计与 U 统计量

本章的前半部分在全部无偏估计中比较方差。充分性使条件化后的规则能够由数据计算，完备性把充分统计量的无偏函数确定下来。后半部分研究另一种构造：若总体量可以写成若干独立观测的函数的期望，就把同一个函数应用于所有同样大小的子样本，再取平均。所得 U 统计量通常含有相互依赖的核项，其方差与极限分布须由重叠结构和条件投影分析。

除特别说明外，估计量均为不含未知参数的可测数据函数；涉及方差的比较，均要求在每个参数分布下二阶矩有限。记 E_θ、Var_θ 为参数 θ 下的期望与方差。

4.1　条件化与一致最小方差无偏估计

4.1.1　UMVUE 的比较范围

一致最小方差无偏估计

设目标为 $g(\theta)$。若同一个统计量 U 满足

$$\mathrm{E}_\theta\, U = g(\theta), \qquad \mathrm{Var}_\theta(U) \le \mathrm{Var}_\theta(W)$$

对每个 $\theta \in \Theta$ 及每个有限方差无偏估计 W 均成立，则称 U 为 $g(\theta)$ 的一致最小方差无偏估计，简称 UMVUE。

这里的“一致”指同一规则在全部参数点上最优，并非一致收敛。统计量不能用到未知参数，因此“对每个 θ 单独找一个最优规则”不等于找到了 UMVUE。无偏条件下，平方误差风险为

$$\mathrm{E}_\theta\{[U - g(\theta)]^2\} = \mathrm{Var}_\theta(U).$$

因此方差最小等价于在无偏类中均方误差最小；该结论没有把有偏估计纳入比较。

4.1.2　条件期望的正交性质

先固定一个概率分布。对 $\mathrm{E}\,U^2 < \infty$，令

$$H = \mathrm{E}(U \mid T), \qquad R = U - H.$$

塔式法则给出 $\mathrm{E}\,H = \mathrm{E}\,U$；条件 Jensen 不等式给出 $\mathrm{E}\,H^2 \le \mathrm{E}\,U^2$。又因 $\mathrm{E}(R \mid T) = 0$，对每个二阶可积的 $a(T)$，

$$\begin{aligned}\mathrm{E}[Ra(T)] &= \mathrm{E}\{\mathrm{E}[Ra(T) \mid T]\} \\ &= \mathrm{E}\{a(T)\,\mathrm{E}(R \mid T)\} = 0.\end{aligned}$$

乘积的可积性由 Cauchy–Schwarz 不等式保证。取 $a(T) = H - \mathrm{E}\,U$，有

$$\mathrm{Var}(U) = \mathrm{Var}(H) + \mathrm{E}\,R^2 = \mathrm{Var}\{\mathrm{E}(U \mid T)\} + \mathrm{E}\{\mathrm{Var}(U \mid T)\}. \tag{4.1}$$

更一般地，对任意二阶可积的 $b(T)$，

$$\mathrm{E}\{[U - b(T)]^2\} = \mathrm{E}(U - H)^2 + \mathrm{E}\{[H - b(T)]^2\}.$$

所以条件期望是所有 T 的函数中对 U 最好的均方逼近。残差与这些函数正交；正交并不要求独立。

4.1.3 Rao–Blackwell 定理及共同版本

Rao–Blackwell 定理

设 T 充分，$\mathrm{E}_\theta\,U^2 < \infty$ 对所有参数成立。在通常的支配统计模型中，可以选取同一个参数无关的可测函数 u^*，使

$$U^* = u^*(T) = \mathrm{E}_\theta(U \mid T) \quad P_\theta\text{-几乎处处}, \quad \forall\theta.$$

它满足

$$\mathrm{E}_\theta\,U^* = \mathrm{E}_\theta\,U, \qquad \mathrm{Var}_\theta(U^*) \le \mathrm{Var}_\theta(U).$$

对指定的 θ，方差取等当且仅当 $U = U^*$，P_θ-几乎处处。

充分性的作用先于方差比较。一般的 $\mathrm{E}_\theta(U \mid T = t)$ 可能含未知参数，不能直接作为估计规则；充分性保证可选择整个模型共用的条件期望版本。在标准 Borel 样本空间上，用不依赖 θ 的样本条件分布核 $K(t, dx)$ 表示这一点，即

$$u^*(t) = \int U(x) K(t, dx).$$

对积分未定义或不有限的 t 可统一赋予任一固定值；由于 U 在每个参数下可积，这些例外在每个 P_θ^T 下均为零测集。如此得到的是同一个数据函数，而非为每个参数分别选择的公式。在不直接使用正则条件分布的表述中，只需使用充分性的共同条件期望版本。

固定任意参数，由塔式法则有 $\mathrm{E}_\theta\,U^* = \mathrm{E}_\theta\,U$。条件 Jensen 不等式保证 U^* 二阶可积，再由式 (4.1)，

$$\mathrm{Var}_\theta(U) - \mathrm{Var}_\theta(U^*) = \mathrm{E}_\theta(U - U^*)^2 \ge 0.$$

差为零等价于残差几乎处处为零，定理得证。定理本身不要求 U 无偏，只保持其期望；若原估计无偏，条件化后才随之无偏。若要断言每个参数点都严格改进，还须逐一证明 $P_\theta(U \neq U^*) > 0$。

Poisson 尾概率的条件化

设 $X_i \overset{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$，$\lambda > 0$，$n \geq 2$，欲估计 $e^{-\lambda}$。取

$$U = \mathbf{1}_{\{X_1=0\}}, \qquad T = \sum_{i=1}^{n} X_i.$$

联合概率质量函数为 $e^{-n\lambda}\lambda^{\sum x_i}/\prod x_i!$，故 T 充分。利用独立的 X_1 与 $T - X_1$，对 $0 \leq j \leq t$，

$$P(X_1 = j \mid T = t) = \binom{t}{j}\left(\frac{1}{n}\right)^j\left(1-\frac{1}{n}\right)^{t-j}.$$

所以 $X_1 \mid T = t \sim \text{Bin}(t, 1/n)$，

$$U^* = \left(1-\frac{1}{n}\right)^T.$$

Poisson 概率母函数 $\mathrm{E}\, s^T = \exp\{n\lambda(s-1)\}$ 给出

$$\mathrm{E}\, U^* = e^{-\lambda}, \qquad \text{Var}(U^*) = e^{-2\lambda+\lambda/n} - e^{-2\lambda}.$$

原指标函数的方差为 $e^{-\lambda} - e^{-2\lambda}$，故这里确有严格改进。

4.1.4 Lehmann–Scheffé 定理

完备充分统计量给出的 UMVUE

设 T 完备且充分，$g(\theta)$ 存在每个参数下均有有限方差的无偏估计。则存在 T 的无偏函数 $h(T)$，它是 $g(\theta)$ 的唯一 UMVUE。
更准确地，T 的任何可积无偏函数都与 $h(T)$ 在每个 P_θ 下几乎处处相等；所有估计量中的任何另一个 UMVUE 也具有同样的几乎处处唯一性。

证明。从任一有限方差无偏估计 U_0 出发，令 $h(T) = \mathrm{E}(U_0 \mid T)$。Rao–Blackwell 定理保证这是参数无关、二阶可积的无偏统计量。对任意无偏竞争者 W，同样令 $h_W(T) = \mathrm{E}(W \mid T)$。两者均估计 $g(\theta)$，因此

$$\mathrm{E}_\theta\{h_W(T) - h(T)\} = 0 \qquad \forall\theta.$$

差是 T 的可积函数，完备性给出 $h_W(T) = h(T)$，对每个参数几乎处处成立。于是

$$\text{Var}_\theta\{h(T)\} = \text{Var}_\theta\{h_W(T)\} \leq \text{Var}_\theta(W).$$

由于 W 任意，$h(T)$ 为 UMVUE。若 W 本身也是 UMVUE，则上述方差取等。由 Rao–Blackwell 的等号条件，$W = h_W(T) = h(T)$，P_θ-几乎处处。

最后，若 $\widetilde{h}(T)$ 只是可积无偏函数，则其与 $h(T)$ 的差仍满足完备性的条件，因而同样相等；不必预先对 $\widetilde{h}$ 另加二阶矩条件。 □

唯一性的范围

“T 的无偏函数唯一” 不等于 “所有无偏估计唯一”。例如 Poisson 例中的指标函数和条件化结果都无偏，但只有后者是 T 的函数。唯一性均按每个 P_θ 几乎处处理解，不是说公式在样本空间每一点都必须相同，也不自动承诺存在一个适用于不可数参数集的共同满测度集合。

4.2 UMVUE 的几种构造

已有完备充分统计量时，一种办法是把简单无偏估计条件化，另一种是直接解无偏方程 $\mathrm{E}_\theta\, h(T) = g(\theta)$。前者多用于事件概率，后者常用积分求导、幂级数比较或矩的偏差修正。两种办法都须核对可积性与有限方差。

4.2.1 均匀分布：积分方程与端点条件

设 $X_i \overset{\text{i.i.d.}}{\sim} U(0,\theta)$，$\theta > 0$，令 $T = X_{(n)}$。联合密度的参数相关部分为 $\theta^{-n}\mathbf{1}_{\{T<\theta\}}$，故 T 充分。其分布为

$$P_\theta(T \le t) = \left(\frac{t}{\theta}\right)^n, \qquad f_T(t;\theta) = \frac{n t^{n-1}}{\theta^n}\mathbf{1}_{(0,\theta)}(t).$$

若可积函数 $v(T)$ 在全部参数下期望为零，则

$$\int_0^\theta v(t)t^{n-1}\,dt = 0 \qquad \forall \theta > 0.$$

被积函数在每个 $(0,b)$ 上可积，故左侧作为上限的函数绝对连续，导数几乎处处为 $v(\theta)\theta^{n-1}$。因此 $v(t) = 0$ 在 $(0,\infty)$ 上 Lebesgue-几乎处处，各个 P_θ^T 都绝对连续，遂有 $v(T) = 0$，P_θ-几乎处处。这里不需要假设 v 连续。

由

$$\mathrm{E}_\theta\, T^r = \frac{n}{n+r}\theta^r \qquad (r > -n),$$

可知对 $r > 0$，

$$\widehat{\theta^r} = \frac{n+r}{n}T^r, \qquad \mathrm{Var}_\theta(\widehat{\theta^r}) = \frac{r^2\theta^{2r}}{n(n+2r)}.$$

它是完备充分统计量的有限方差无偏函数，故为 UMVUE。特别地，$\widehat{\theta} = (n+1)T/n$。

对一般连续可微目标 g，无偏方程为

$$n\int_0^\theta h(t)t^{n-1}\,dt=\theta^n g(\theta).$$

求导得到候选公式

$$h(t)=g(t)+\frac{t}{n}g'(t). \tag{4.2}$$

但求导会丢失积分常数。对 $0<\varepsilon<\theta$，代回候选函数可得

$$n\int_\varepsilon^\theta h(t)t^{n-1}\,dt=\theta^n g(\theta)-\varepsilon^n g(\varepsilon).$$

所以若 $t^n g(t)\to 0$ $(t\downarrow 0)$，且 $\mathrm{E}_\theta\, h(T)^2<\infty$ 对每个参数成立，才能令 $\varepsilon\downarrow 0$ 得到所需无偏性。

不能省略的端点核验

若把 $g(\theta)=\theta^{-n}$ 机械地代入式 (4.2)，所得 h 恒为零，显然不无偏估计正的 θ^{-n}。原因是 $t^n g(t)=1$，没有满足零端点条件。候选公式来自微分方程，并不自动满足原积分方程。

4.2.2 Poisson 分布：下降阶乘与幂级数

设 $X_i\sim\mathrm{Poisson}(\theta)$ 独立同分布，$T=\sum_i X_i\sim\mathrm{Poisson}(n\theta)$。自然参数 $\log\theta$ 遍历 $\mathbb{R}$，所以 T 完备且充分。记下降阶乘

$$(t)_{\underline{r}}=t(t-1)\cdots(t-r+1),\quad (t)_{\underline{0}}=1,$$

当非负整数 $t<r$ 时令其为零。直接计算可得

$$\begin{aligned}\mathrm{E}_\theta\,\frac{(T)_{\underline{r}}}{n^r}&=\sum_{t=r}^{\infty}\frac{t!}{n^r(t-r)!}e^{-n\theta}\frac{(n\theta)^t}{t!}\\&=\theta^r e^{-n\theta}\sum_{u=0}^{\infty}\frac{(n\theta)^u}{u!}=\theta^r.\end{aligned}$$

该统计量是 T 的多项式，Poisson 的所有整数阶矩有限。因此

$$\widehat{\theta^r}=\frac{(T)_{\underline{r}}}{n^r}$$

为 UMVUE。例如 $T(T-1)/n^2$ 无偏估计 θ^2，而 $(T/n)^2$ 的期望是 $\theta^2+\theta/n$。

若目标有在全部正实数处收敛的幂级数 $g(\theta)=\sum_{j\ge 0}a_j\theta^j$，无偏方程乘以 $e^{n\theta}$ 后，比较 θ^t 的系数，得到

$$h(t)=\frac{t!}{n^t}\sum_{j=0}^{t}\frac{n^{t-j}a_j}{(t-j)!}=\sum_{j=0}^{t}a_j\frac{(t)_{\underline{j}}}{n^j}.$$

这里收敛半径为无穷，故 $\sum_j |a_j|\theta^j < \infty$。由 Tonelli 及阶乘矩公式，

$$\mathrm{E}_\theta \sum_{j\ge 0} |a_j| \frac{(T)_j}{n^j} = \sum_{j\ge 0} |a_j|\theta^j < \infty,$$

所以允许交换求和与期望，证得无偏性。还须另验 $\mathrm{E}_\theta\, h(T)^2 < \infty$，才能按本章的有限方差定义称其为 UMVUE；幂级数绝对收敛不能替代二阶矩条件。

4.2.3 正态分布：偏差修正

设 $X_i \overset{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$，$n \ge 2$，$\mu \in \mathbb{R}$、$\sigma^2 > 0$ 均未知。自然统计量与自然参数分别为

$$\left(\sum_i X_i, \sum_i X_i^2 \right), \qquad \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right).$$

自然参数遍历开集 $\mathbb{R} \times (-\infty, 0)$，从而统计量完备且充分。令

$$\bar X = \frac{1}{n}\sum_i X_i, \qquad S^2 = \frac{1}{n-1}\sum_i (X_i - \bar X)^2.$$

两组统计量相互确定，因为 $\sum_i X_i^2 = (n-1)S^2 + n\bar X^2$，故 $(\bar X, S^2)$ 也完备且充分。

由平方和分解，

$$\sum_i (X_i - \bar X)^2 = \sum_i (X_i - \mu)^2 - n(\bar X - \mu)^2,$$

取期望得 $\mathrm{E}\, S^2 = \sigma^2$。又 $\mathrm{E}\, \bar X^2 = \mu^2 + \sigma^2/n$，因此

$$\widehat{\mu} = \bar X, \qquad \widehat{\sigma^2} = S^2, \qquad \widehat{\mu^2} = \bar X^2 - \frac{S^2}{n}$$

均为对应目标的 UMVUE。正态分布的矩保证其方差有限。最后一个估计可能为负，无偏性约束的是期望，并不强迫每次输出都落在目标值域内。

4.2.4 指数分布：条件概率

设 $X_i \overset{\text{i.i.d.}}{\sim} \mathrm{Exp}(\theta)$，这里 $\theta > 0$ 为尺度参数，密度为 $\theta^{-1} e^{-x/\theta} \mathbf{1}_{\{x>0\}}$。固定 $a > 0$，欲估计 $e^{-a/\theta} = P_\theta(X_1 > a)$。对 $n \ge 2$，取

$$U = \mathbf{1}_{\{X_1 > a\}}, \qquad T = \sum_i X_i.$$

$T \sim \mathrm{Gamma}(n, \text{scale } \theta)$，其自然参数 $-1/\theta$ 遍历 $(-\infty, 0)$，故 T 完备充分。令 $Y = T - X_1$，它与 X_1 独立，并服从形状 $n-1$ 的同尺度 Gamma 分布。由联合密度除以边缘密度，

$$\begin{aligned} f_{X_1 \mid T}(x \mid t) &= \frac{f_{X_1}(x) f_Y(t-x)}{f_T(t)} \\ &= \frac{n-1}{t}\left(1 - \frac{x}{t}\right)^{n-2}, \qquad 0 < x < t. \end{aligned}$$

因此 $X_1/T \mid T=t \sim \mathrm{Beta}(1, n-1)$，且

$$h(T)=\mathrm{E}(U \mid T)=\begin{cases}0, & T \le a,\\ (1-a/T)^{n-1}, & T>a.\end{cases}$$

第二种情形来自对条件密度在 (a,t) 上积分。塔式法则给出无偏性，$0 \le h \le 1$ 保证有限方差，Lehmann–Scheffé 定理遂给出唯一 UMVUE。

练习与核验

1. 在 $U(0,\theta)$ 模型中求 θ^{-r} 的 UMVUE，并说明有限方差条件。**线索：** 用 $\mathrm{E}\,T^s = n\theta^s/(n+s)$；当 $0<r<n/2$ 时，$(n-r)T^{-r}/n$ 有有限方差。
2. 在 Poisson 模型中无偏估计 θ^3。**答案：** $T(T-1)(T-2)/n^3$；比较它与 $\bar{X}^3$ 的期望。
3. 指数分布例中若 $n=1$，原指标函数是否为 UMVUE? **线索：** X_1 本身完备充分；上述 Beta 条件密度的推导不适用于 $n=1$，但结论可直接由 Lehmann–Scheffé 得出。

4.3 正交判别与参数空间的影响

4.3.1 与所有零均值方向正交

定义

$$\mathcal{U}_0=\{V(X): \mathrm{E}_\theta V=0,\ \mathrm{E}_\theta V^2<\infty \text{ 对所有}\theta\in\Theta\}.$$

这里 V 必须是固定的数据函数。虽然 $X_1-\theta$ 在位置模型中可能有零均值，它含未知参数，不能据此列入 $\mathcal{U}_0$。若 U, W 是同一目标的无偏估计，则 $W-U\in\mathcal{U}_0$；反之，$U+V$ 对每个 $V\in\mathcal{U}_0$ 都是无偏竞争者。

UMVUE 的正交判别

设 U 为有限方差无偏估计，则

$$U \text{ 为 UMVUE} \quad\Longleftrightarrow\quad \mathrm{E}_\theta(UV)=0 \quad \forall V\in\mathcal{U}_0,\ \forall\theta\in\Theta.$$

由于 $\mathrm{E}_\theta V=0$，右侧等价于 $\mathrm{Cov}_\theta(U,V)=0$。该判别不要求存在完备充分统计量。

证明。若 U 为 UMVUE，则对任意实数 c，$U+cV$ 仍无偏，因此

$$0\le \mathrm{Var}_\theta(U+cV)-\mathrm{Var}_\theta(U)=c^2A+2cB,$$

其中 $A=\mathrm{Var}_\theta(V)$、$B=\mathrm{Cov}_\theta(U,V)$。若 $A>0$ 而 $B\neq 0$，取 $c=-B/A$ 得矛盾；若 $A=0$，则 $V=0$，P_θ-几乎处处，亦有 $B=0$。

反之，任一竞争者可写为 $W = U + V$，$V \in \mathcal{U}_0$。正交性给出

$$\operatorname{Var}_\theta(W) = \operatorname{Var}_\theta(U) + \operatorname{Var}_\theta(V) \geq \operatorname{Var}_\theta(U),$$

故 U 为 UMVUE。 □

若 U_j 分别为 $g_j(\theta)$ 的 UMVUE，则对固定常数 c_j，$\sum_j c_j U_j$ 与所有零均值方向仍正交，因而是 $\sum_j c_j g_j(\theta)$ 的 UMVUE。这一性质只保证有限线性组合，不保证平方或其他非线性变换。若 U_1, U_2 为同一目标的 UMVUE，取 $V = U_1 - U_2$，则

$$\mathrm{E}_\theta\, V^2 = \mathrm{E}_\theta(U_1 V) - \mathrm{E}_\theta(U_2 V) = 0,$$

再次得到 UMVUE 的几乎处处唯一性。

若已有充分统计量 T，判断其无偏函数 $h(T)$ 是否为 UMVUE，只需检验

$$\mathrm{E}_\theta[h(T)v(T)] = 0$$

对所有零均值、二阶可积的 $v(T)$ 成立。事实上，对一般 $V \in \mathcal{U}_0$，令 $v(T) = \mathrm{E}(V \mid T)$。充分性、塔式法则和条件 Jensen 保证它属于所检验的类，且

$$\mathrm{E}_\theta[h(T)V] = \mathrm{E}_\theta[h(T)\,\mathrm{E}(V \mid T)] = \mathrm{E}_\theta[h(T)v(T)] = 0.$$

4.3.2 限制均匀模型中的改进

仍考虑 $U(0,\theta)$，现在参数只允许 $\theta \geq 1$。最大值 T 的密度不变，也仍充分。但 $\mathrm{E}_\theta\, v(T) = 0$ 对全部 $\theta \geq 1$ 成立，仅能推出

$$\int_0^1 v(t)t^{n-1}\,dt = 0, \qquad v(t) = 0 \text{ 在}(1,\infty) \text{ 上几乎处处.} \tag{4.3}$$

第一项由 $\theta = 1$ 得到，第二项由积分上限 $\theta > 1$ 的几乎处处求导得到；两条件也反过来保证零均值。区间 $(0,1)$ 上只剩一个积分约束，因此 T 不再完备。例如

$$v(t) = \left(\frac{n+1}{n}t - 1\right)\mathbf{1}_{\{t \leq 1\}}$$

是非零的有界函数，却满足式 (4.3)。

要使估计与所有此类函数正交，可以在 $t \leq 1$ 上取常数。尝试

$$h(t) = \begin{cases} c, & t \leq 1, \\ bt, & t > 1. \end{cases}$$

积分得

$$\mathrm{E}_\theta\, h(T) = \frac{bn}{n+1}\theta + \left(c - \frac{bn}{n+1}\right)\theta^{-n}.$$

取 $b=(n+1)/n$、$c=1$，得到

$$\widehat{\theta}_*=\begin{cases}1, & T\le 1,\\ (n+1)T/n, & T>1.\end{cases} \tag{4.4}$$

它无偏且在每个参数下有界。对零均值 $v(T)$，只有 $T\le 1$ 部分有贡献，而该处 $h(T)=1$，故

$$\mathrm{E}_\theta[h(T)v(T)]=\frac{n}{\theta^n}\int_0^1 v(t)t^{n-1}\,dt=0.$$

充分统计量上的正交判别证明式 (4.4) 为 UMVUE，无须完备性。

原估计 $U_0=(n+1)T/n$ 在限制模型中仍无偏。其与新估计的差为上述 $v(T)$，并与新估计正交。因此

$$\begin{aligned}\mathrm{Var}_\theta(U_0)-\mathrm{Var}_\theta(\widehat{\theta}_*)&=\mathrm{E}_\theta\, v(T)^2\\ &=\frac{n}{\theta^n}\int_0^1\left(\frac{n+1}{n}t-1\right)^2 t^{n-1}\,dt\\ &=\frac{\theta^{-n}}{n(n+2)}>0.\end{aligned}$$

于是

$$\mathrm{Var}_\theta(\widehat{\theta}_*)=\frac{\theta^2-\theta^{-n}}{n(n+2)}.$$

在 $\theta=1$ 处，新估计恒为 1，方差为零。缩小参数空间会放宽“对所有参数均无偏”的要求，可能出现更多零均值方向与竞争者；UMVUE 因而依赖整个模型，不能只看密度的形式。

练习与证明线索

1. 用正交判别证明两个 UMVUE 的固定线性组合仍为 UMVUE，再解释为什么 U^2 未必无偏估计 $g(\theta)^2$。
2. 将限制改成 $\theta\ge a>0$，求 θ 的 UMVUE。**答案：** $T\le a$ 时取 a，$T>a$ 时取 $(n+1)T/n$；方差为 $[\theta^2-a^{n+2}\theta^{-n}]/[n(n+2)]$。
3. 证明限制模型中的任一 UMVUE 若写成 $h(T)$，则它在 $(0,1)$ 上必须几乎处处为常数。**线索：** 令 $c=\mathrm{E}_1\,h(T)$，用 $(h(T)-c)\mathbf{1}_{\{T\le 1\}}$ 作零均值方向，在 $\theta=1$ 处应用正交性。

4.4 U 统计量：在所有子样本上平均

4.4.1 核与总体泛函

设 $X_1,\dots,X_n\overset{\text{i.i.d.}}{\sim}P$，总体量具有表示

$$\vartheta(P)=\mathrm{E}_P\,h(X_1,\dots,X_m),\qquad \mathrm{E}_P\,|h|<\infty,$$

其中 $m \le n$ 固定，h 是不含未知分布的可测函数，称为核。“泛函”表示它以分布 P 为输入，输出一个数；例如总体方差。这里的核既不是密度，也不要求为正定函数。

若原核不对称，可用

$$h_s(x_1,\dots,x_m)=\frac{1}{m!}\sum_{\pi} h(x_{\pi(1)},\dots,x_{\pi(m)})$$

代替，和式遍历全部排列。独立同分布保证排列后的向量同分布，所以 $\mathrm{E}\,h_s=\mathrm{E}\,h$；若有二阶矩，Jensen 还给出 $\mathrm{E}\,h_s^2\le \mathrm{E}\,h^2$。以下采用对称核。

单样本 U 统计量

由 m 元对称核 h 定义

$$U_n=\binom{n}{m}^{-1}\sum_{1\le i_1<\cdots<i_m\le n} h(X_{i_1},\dots,X_{i_m}).$$

每个核项期望均为 $\vartheta(P)$，故 $\mathrm{E}_P\,U_n=\vartheta(P)$。阶数 m 是每项使用的观测数，并非多项式次数。

4.4.2 独立随机子集的条件化解释

在数据之外引入独立随机变量 J，它从全部 m 元下标子集中均匀选取一个，令 $Z=h(X_j:j\in J)$。独立性是这里的条件：若根据观测大小偏向选择某些子集，以下等式一般不成立。

给定整份样本 X 后，唯一剩下的随机性是选中哪个子集。因 $P(J=A\mid X)=\binom{n}{m}^{-1}$，

$$\mathrm{E}(Z\mid X)=\sum_{|A|=m} h(X_i:i\in A)P(J=A\mid X)=U_n.$$

每个子集均有 m 个独立同分布观测，故 $\mathrm{E}\,Z=\vartheta$，塔式法则给出 $\mathrm{E}\,U_n=\vartheta$。若 $\mathrm{E}\,h^2<\infty$，则

$$\mathrm{Var}(Z)=\mathrm{Var}(U_n)+\mathrm{E}\{\mathrm{Var}(Z\mid X)\}\ge \mathrm{Var}(U_n).$$

这是消除额外抽选波动的方差比较，没有单凭此式断言 U_n 在任意参数模型中都是 UMVUE。

一份数据固定以后还剩什么随机性

取 $n=3,m=2$、$h(x,y)=(x+y)/2$。若观测为 $(1,3,8)$，三个可能子集给出 2、4.5、5.5，各以概率 1/3 被选中。条件平均为

$$\mathrm{E}(Z\mid X=(1,3,8))=\frac{2+4.5+5.5}{3}=4.$$

一般地，三个二元均值的平均正好为 $\bar X$。单次随机子集估计的方差为 $\sigma^2/2$，$U_3=\bar X$

的方差为 $\sigma^2/3$；平均消除了子集抽选造成的那部分波动。

4.4.3 均值的幂与样本方差

若 $\mathrm{E}|X|<\infty$、$\mu=\mathrm{E}\,X$，独立性给出 $\mathrm{E}(X_1\cdots X_m)=\mu^m$。因此乘积核产生 μ^m 的无偏估计。二阶时，

$$U_n=\frac{(\sum_i X_i)^2-\sum_i X_i^2}{n(n-1)}.$$

若二阶矩有限，还可写为 $\bar X^2-S^2/n$。这个无偏性并不限于正态总体；它在何种参数模型下为 UMVUE，要另行证明。

若 $\mathrm{E}\,X^2<\infty$，取 $h(x,y)=(x-y)^2/2$，则 $\mathrm{E}\,h(X_1,X_2)=\sigma^2$。利用

$$\begin{aligned}\sum_{i<j}(X_i-X_j)^2&=n\sum_i X_i^2-\left(\sum_i X_i\right)^2\\&=n\sum_i(X_i-\bar X)^2,\end{aligned}$$

对应的 U 统计量恰为

$$U_n=\frac{1}{n(n-1)}\sum_{i<j}(X_i-X_j)^2=S^2.$$

二阶矩足以保证此无偏性；分析其方差和通常的方差 CLT 则需四阶矩。包含重复下标的平均并非同一个对象，例如 $n^{-2}\sum_{i,j}X_iX_j=\bar X^2$ 含有对角项，通常有偏估计 μ^2，属于 V 统计量形式。

4.5 条件核与精确方差

本节及后续单样本理论均假定 m 与 P 固定，$\mathrm{E}\,h^2<\infty$，令 $n\to\infty$。若核阶数也随样本量变化，下面固定阶的余项估计不能直接沿用。

4.5.1 重叠下标决定协方差

定义条件核

$$h_k(x_1,\dots,x_k)=\mathrm{E}\,h(x_1,\dots,x_k,X_{k+1},\dots,X_m),\quad 1\le k\le m,$$

以及 $h_0=\vartheta$、$h_m=h$，并记

$$\zeta_k=\mathrm{Var}\{h_k(X_1,\dots,X_k)\},\qquad \zeta_0=0.$$

塔式法则和条件 Jensen 给出 $\mathrm{E}\,h_k=\vartheta$、$\mathrm{E}\,h_k^2\le\mathrm{E}\,h^2$。

对两个 m 元下标集 A, B，设 $C = A \cap B$、$|C| = k$。给定公共观测 X_C，两核其余输入来自互不相交的观测，因而条件独立。其中心化条件均值均为 $h_k(X_C) - \vartheta$，所以

$$\begin{aligned}\operatorname{Cov}\{h(X_A), h(X_B)\} &= \mathrm{E}\big[\mathrm{E}\{(h(X_A) - \vartheta)(h(X_B) - \vartheta) \mid X_C\}\big] \\ &= \mathrm{E}\{[h_k(X_C) - \vartheta]^2\} = \zeta_k.\end{aligned}$$

无公共下标时协方差为零；$A = B$ 时协方差为 $\zeta_m = \operatorname{Var}(h)$。

Hoeffding 精确方差公式

对 $n \geq m$，

$$\operatorname{Var}(U_n) = \binom{n}{m}^{-1} \sum_{k=1}^{m} \binom{m}{k}\binom{n-m}{m-k}\zeta_k. \tag{4.5}$$

选取数目不合法时，组合数按零处理。特别地，二阶核满足

$$\operatorname{Var}(U_n) = \frac{4(n-2)}{n(n-1)}\zeta_1 + \frac{2}{n(n-1)}\zeta_2.$$

计数证明。令 $N = \binom{n}{m}$，$H_A = h(X_A) - \vartheta$。展开

$$\operatorname{Var}(U_n) = \frac{1}{N^2} \sum_{|A|=m} \sum_{|B|=m} \mathrm{E}\, H_A H_B.$$

固定 A，要使 $|A \cap B| = k$，须从 A 内选 k 个下标，再从 A 外选 $m-k$ 个下标，恰有 $\binom{m}{k}\binom{n-m}{m-k}$ 种。外层有 N 个 A，故相应有序对数目为 $N\binom{m}{k}\binom{n-m}{m-k}$。双和原本计算有序对，不能再除以 2。代入协方差 ζ_k，并利用 $\zeta_0 = 0$，即得公式。当 $n = m$ 时只剩一项，公式为 $\operatorname{Var}(U_n) = \zeta_m$，与定义一致。 □

4.5.2 方差速度与退化阶数

令 $H_k = h_k(X_1, \ldots, X_k)$，$\mathcal{F}_k = \sigma(X_1, \ldots, X_k)$。逐次条件化给出 $\mathrm{E}(H_{k+1} \mid \mathcal{F}_k) = H_k$，因此

$$\zeta_{k+1} = \zeta_k + \mathrm{E}\{\operatorname{Var}(H_{k+1} \mid \mathcal{F}_k)\} \geq \zeta_k.$$

于是 $0 \leq \zeta_1 \leq \cdots \leq \zeta_m$。对固定 m, k，精确方差系数满足

$$\begin{aligned}c_{n,k} &:= \frac{\binom{m}{k}\binom{n-m}{m-k}}{\binom{n}{m}} \\ &= \frac{k!\binom{m}{k}^2}{n^k} \frac{\prod_{r=0}^{m-k-1}(1 - (m+r)/n)}{\prod_{r=0}^{m-1}(1 - r/n)} \\ &= \frac{k!\binom{m}{k}^2}{n^k} + O(n^{-k-1}).\end{aligned}$$

空乘积取 1。由于每个乘积的因子数固定，最后的比值为 $1+O(n^{-1})$。若第一个非零条件核方差为 ζ_k，则

$$\operatorname{Var}(U_n)=\frac{k!\binom{m}{k}^2\zeta_k}{n^k}+O(n^{-k-1}). \tag{4.6}$$

特别地，$\zeta_1>0$ 时方差为 $m^2\zeta_1/n+O(n^{-2})$；$\zeta_1=0$、$\zeta_2>0$ 时为 n^{-2} 量级。

各系数趋零，故 $\mathrm{E}(U_n-\vartheta)^2\to 0$，即 $U_n\to\vartheta$ 于 L^2，从而也依概率收敛。如果全部 $\zeta_k=0$，则核本身几乎处处为常数，结论仍成立。方差的速度给出可能的放大尺度，却不单独保证极限分布存在。

练习与答案线索

1. 对 $h(x,y)=xy$、$\mathrm{E}\,X=\mu$、$\operatorname{Var}(X)=\sigma^2<\infty$，求 $\vartheta,h_1,\zeta_1,\zeta_2$。**答案：** $\vartheta=\mu^2$，$h_1(x)=\mu x$，$\zeta_1=\mu^2\sigma^2$，$\zeta_2=\sigma^4+2\mu^2\sigma^2$。
2. 将上题代入精确公式，证明 $\operatorname{Var}(U_n)=4\mu^2\sigma^2/n+2\sigma^4/[n(n-1)]$。
3. 为什么不能把 $\binom{n}{m}$ 个核项当成独立项？**线索：** 即使样本观测独立，两个核项仍可能共享下标。逐一写出 $h(X_1,X_2)$ 与 $h(X_1,X_3)$ 的协方差。

4.6 Hájek 投影与非退化极限

4.6.1 投影到单变量加性函数

对独立观测 $X_1,\dots,X_n$ 及任意二阶可积 W，定义

$$a_i(X_i)=\mathrm{E}(W\mid X_i)-\mathrm{E}\,W,\qquad \widehat{W}=\mathrm{E}\,W+\sum_{i=1}^{n}a_i(X_i).$$

独立性保证当 $j\neq i$ 时 $\mathrm{E}[a_j(X_j)\mid X_i]=0$，从而

$$\mathrm{E}(W-\widehat{W}\mid X_i)=0.$$

所以残差与每个二阶可积单变量函数 $b_i(X_i)$ 正交，也与其有限和及常数正交。对任何加性函数 $Q=c+\sum_i b_i(X_i)$，

$$\mathrm{E}(W-Q)^2=\mathrm{E}(W-\widehat{W})^2+\mathrm{E}(\widehat{W}-Q)^2.$$

这称为 Hájek 投影：允许每个单变量函数非线性，但不保留不同观测间的交互项。它并不是对完整数据取条件期望；后者对统计量 W 仍给出 W 本身。例如零均值独立变量的乘积 X_1X_2，对两个单变量的条件期望均为零，所以其 Hájek 投影为零，而完整数据仍确定该乘积。

4.6.2 U 统计量的一阶项与余项

令

$$\varphi(x)=h_1(x)-\vartheta,\qquad \mathrm{E}\,\varphi(X)=0,\quad \operatorname{Var}\{\varphi(X)\}=\zeta_1.$$

固定下标 i，包含它的 m 元子集有 $\binom{n-1}{m-1}$ 个，不包含它的有 $\binom{n-1}{m}$ 个。因此

$$\mathrm{E}(U_n \mid X_i) - \vartheta = \frac{\binom{n-1}{m-1}}{\binom{n}{m}}\varphi(X_i) = \frac{m}{n}\varphi(X_i).$$

故投影为

$$\widehat{U}_n = \vartheta + L_n, \qquad L_n = \frac{m}{n}\sum_{i=1}^{n}\varphi(X_i), \qquad R_n = U_n - \widehat{U}_n. \tag{4.7}$$

由独立性，$\mathrm{Var}(L_n) = m^2\zeta_1/n$。同时

$$\begin{aligned}\mathrm{E}[(U_n-\vartheta)\varphi(X_i)] &= \mathrm{E}[\mathrm{E}(U_n-\vartheta \mid X_i)\varphi(X_i)] \\ &= \frac{m}{n}\zeta_1,\end{aligned}$$

因此 $\mathrm{Cov}(U_n, L_n) = m^2\zeta_1/n = \mathrm{Var}(L_n)$。展开残差平方得到精确恒等式

$$\mathrm{E}\,R_n^2 = \mathrm{Var}(U_n) - \frac{m^2\zeta_1}{n}. \tag{4.8}$$

这也就是 R_n 与 L_n 正交后的勾股关系，不需要二者独立。将方差展开代入，得 $\mathrm{E}\,R_n^2 = O(n^{-2})$，于是

$$P(|\sqrt{n}R_n| > \varepsilon) \le \frac{n\,\mathrm{E}\,R_n^2}{\varepsilon^2} \longrightarrow 0.$$

所以 $R_n = O_P(n^{-1})$，且

$$\sqrt{n}(U_n - \vartheta) = \frac{m}{\sqrt{n}}\sum_{i=1}^{n}\varphi(X_i) + o_P(1). \tag{4.9}$$

非退化 U 统计量的中心极限定理

若核阶数 m 固定、$\mathrm{E}\,h^2 < \infty$ 且 $\zeta_1 > 0$，则

$$\sqrt{n}(U_n - \vartheta) \xrightarrow{d} N(0, m^2\zeta_1).$$

证明。 $\varphi(X_i)$ 独立同分布，均值为零、有限方差为 ζ_1。普通中心极限定理给出 $n^{-1/2}\sum_i \varphi(X_i) \xrightarrow{d} N(0,\zeta_1)$；将式 (4.9) 代入 Slutsky 定理即可。 □

这里的极限方差来自一阶条件核，不是原核方差 ζ_m；核阶数还贡献系数 m^2。若 $\zeta_1 = 0$，同一推导只能得到 $\sqrt{n}(U_n - \vartheta) \xrightarrow{P} 0$，更细的波动须换用其他尺度。

4.6.3 样本方差：与 Delta 方法的核对

对 $h(x,y) = (x-y)^2/2$，$\vartheta = \sigma^2$。固定 x 并平均另一个观测，得

$$h_1(x) = \frac{1}{2}[(x-\mu)^2 + \sigma^2], \qquad \varphi(x) = \frac{1}{2}[(x-\mu)^2 - \sigma^2].$$

设 $\mu_4 = \mathrm{E}(X-\mu)^4 < \infty$。由于

$$(X_1 - X_2)^4 \le 8[(X_1-\mu)^4 + (X_2-\mu)^4],$$

核二阶矩有限，并且

$$4\zeta_1 = \mathrm{Var}\{(X-\mu)^2\} = \mu_4 - \sigma^4.$$

若 $\mu_4 > \sigma^4$，则

$$\sqrt{n}(S^2 - \sigma^2) \xrightarrow{d} N(0, \mu_4 - \sigma^4). \tag{4.10}$$

它与第一章通过样本一、二阶矩及 Delta 方法所得结果一致：两种方法找到的主导项都是 $(X-\mu)^2 - \sigma^2$。正态总体有 $\mu_4 = 3\sigma^4$，极限方差为 $2\sigma^4$。

还可计算精确方差。令 $Z_i = X_i - \mu$，独立性与 $\mathrm{E}\, Z_i = 0$ 给出

$$\mathrm{E}(Z_1 - Z_2)^4 = 2\mu_4 + 6\sigma^4, \qquad \zeta_2 = \frac{1}{2}(\mu_4 + \sigma^4).$$

代入二阶精确公式，得

$$\mathrm{Var}(S^2) = \frac{1}{n}\left[\mu_4 - \frac{n-3}{n-1}\sigma^4\right].$$

正态时为 $2\sigma^4/(n-1)$，与样本方差的精确卡方分布相符。

样本方差也可能一阶退化

若 $P(X = \mu + a) = P(X = \mu - a) = 1/2$，$a > 0$，则 $(X-\mu)^2 = a^2$ 恒定，故 $\mu_4 - \sigma^4 = 0$。式 (4.10) 的 $\sqrt{n}$ 极限退化为零，不能再除以该极限标准差做正态标准化。

写 $X_i = \mu + a\varepsilon_i$，其中 $P(\varepsilon_i = \pm 1) = 1/2$。则

$$S^2 = \frac{na^2}{n-1}(1 - \bar{\varepsilon}^2),$$

所以

$$n(S^2 - a^2) = \frac{n}{n-1}a^2\left[1 - \left(\frac{1}{\sqrt{n}}\sum_i \varepsilon_i\right)^2\right] \xrightarrow{d} a^2(1 - Z^2), \quad Z \sim N(0,1).$$

退化后出现的是中心化卡方型极限，而非非零方差的正态极限。

练习与答案线索

1. 对乘积核 $h(x,y) = xy$，在 $\mu \neq 0$、$\sigma^2 > 0$ 时求渐近分布。**答案：** $\sqrt{n}(U_n - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2)$。
2. 对 $h(x,y) = (x+y)/2$ 求 Hájek 投影和余项。**答案：** $U_n = \bar{X}$，投影等于统计量本身，余项恒为零；虽是二阶核，却没有真正的二阶交互。
3. 对 $X \sim U(0,1)$，求 $\sqrt{n}(S^2 - 1/12)$ 的极限方差。**答案：** $\mu_4 = 1/80$，故方差为

$1/80 - 1/144 = 1/180$。

4.7 两样本秩统计量

4.7.1 Mann–Whitney 与 Wilcoxon 秩和

本节的 m, n 均表示样本量，不再表示单样本核阶数。设 $X_1, \dots, X_m \sim F$、$Y_1, \dots, Y_n \sim G$，两组内部独立同分布，组间独立，F, G 连续。约定

$$h(x, y) = \mathbf{1}_{\{x > y\}}, \qquad \vartheta = P(X > Y), \qquad U_{m,n} = \frac{1}{mn} \sum_{i=1}^{m} \sum_{j=1}^{n} \mathbf{1}_{\{X_i > Y_j\}}.$$

它是所有跨组比较中 X 大于 Y 的比例，无偏估计 ϑ。部分教材或软件把未归一化的胜出次数 $mnU_{m,n}$ 称为 Mann–Whitney U，另一些使用相反的比较方向，核对约定后才能直接引用公式。

把 $m + n$ 个观测合并排序，无并列值时，记 X_i 的合并秩为 R_i，Wilcoxon 秩和为 $R_X = \sum_i R_i$。把 X 组内部排序为 $X_{(1)} < \cdots < X_{(m)}$，相应合并秩为 r_a。位于 $X_{(a)}$ 之前的 $r_a - 1$ 个观测中，$a - 1$ 个来自 X 组，所以

$$r_a - a = \#\{j : Y_j < X_{(a)}\}.$$

对 a 求和即得

$$R_X - \frac{m(m+1)}{2} = mnU_{m,n}. \tag{4.11}$$

因此秩和与跨组胜出次数是已知的线性变换，携带相同信息；U 统计量的分析可以直接转给秩和。若合并次序为 Y, X, Y, Y, X, Y, X，则 $m = 3, n = 4$，X 的秩为 $(2, 5, 7)$，胜出次数为 $1 + 3 + 4 = 8$，故 $R_X = 14$、$U_{3,4} = 2/3$。

4.7.2 两个一阶投影与余项控制

连续性给出 $\mathrm{E}[h(x, Y)] = G(x)$、$\mathrm{E}[h(X, y)] = 1 - F(y)$。定义

$$a(x) = G(x) - \vartheta, \qquad b(y) = 1 - F(y) - \vartheta,$$

以及

$$r(x, y) = h(x, y) - \vartheta - a(x) - b(y).$$

两个投影均值为零，且 $\mathrm{E}[r(X, Y) \mid X] = \mathrm{E}[r(X, Y) \mid Y] = 0$。于是有精确分解

$$U_{m,n} - \vartheta = \frac{1}{m} \sum_{i} a(X_i) + \frac{1}{n} \sum_{j} b(Y_j) + R_{m,n}, \tag{4.12}$$

其中 $R_{m,n} = (mn)^{-1} \sum_{i,j} r(X_i, Y_j)$。

残差核与两个单变量项均正交。两个不同配对若没有共享下标，则独立；若只共享 X_i，给定 X_i 后两残差核条件独立且条件均值零，协方差也为零；只共享 Y_j 同理。故仅完全相同的下标对贡献方差，

$$\mathrm{E}\, R_{m,n}^2 = \frac{\mathrm{E}\, r(X,Y)^2}{mn}.$$

若 $N = m+n$、$m/N \to \rho \in (0,1)$，则 $N/(mn) \to 0$，因而 $\sqrt{N} R_{m,n} \xrightarrow{P} 0$。两组主项相互独立，分别使用 CLT 得到

$$\sqrt{N}(U_{m,n} - \vartheta) \xrightarrow{d} N\left(0, \frac{\mathrm{Var}(G(X))}{\rho} + \frac{\mathrm{Var}(F(Y))}{1-\rho}\right).$$

若显示的极限方差为零，应另作退化分析，而不能使用非零方差的标准化。

4.7.3 相同分布原假设下的检验

在 $H_0 : F = G$ 下，连续性与交换性给出 $\vartheta = 1/2$，概率积分变换给出 $F(X), F(Y) \sim U(0,1)$。因此两个投影方差都是 $1/12$，有

$$\sqrt{m+n}\left(U_{m,n} - \frac{1}{2}\right) \xrightarrow{d} N\left(0, \frac{1}{12\rho(1-\rho)}\right),$$

等价地，

$$Z_{m,n} = \sqrt{\frac{12mn}{m+n}}\left(U_{m,n} - \frac{1}{2}\right) \xrightarrow{d} N(0,1).$$

于是 $|Z_{m,n}| > z_{1-\alpha/2}$ 为渐近双侧水平 α 的拒绝规则。渐近水平表示拒绝概率趋于 α，不表示每个有限样本都精确等于 α。

在原假设下，$\mathrm{Var}(h) = 1/4$。由核的正交分解，$\mathrm{E}\, r^2 = 1/4 - 1/12 - 1/12 = 1/12$，所以精确方差为

$$\mathrm{Var}_0(U_{m,n}) = \frac{1}{12m} + \frac{1}{12n} + \frac{1}{12mn} = \frac{m+n+1}{12mn}.$$

相应地，

$$\mathrm{E}_0\, R_X = \frac{m(m+n+1)}{2}, \qquad \mathrm{Var}_0(R_X) = \frac{mn(m+n+1)}{12}.$$

用精确方差作正态近似时，标准化可采用 $\sqrt{12mn/(m+n+1)}$，与上述渐近形式等价。有并列值时，须明确比较核、平均秩或其他并列处理，并重新修正方差；这里的无并列值公式不能直接照搬。

检验目标与练习

$F = G$ 蕴含 $P(X > Y) = 1/2$，反之不成立。例如 $X \sim N(0,1)$、$Y \sim N(0,4)$ 独立时，$X - Y$ 关于零对称，仍有 $P(X > Y) = 1/2$。因此该统计量不能保证对所有 $F \neq G$ 的备择都具有趋于 1 的功效。

1. 若改用 $\mathbf{1}_{\{X<Y\}}$，秩和等式如何变化？**答案：** 新统计量为 $1 - U_{m,n}$，故 $R_X = m(m+1)/2 + mn(1 - U_{m,n}^{\mathrm{new}})$。

2. 当 $m = n$ 时写出 $U_{m,n}$ 与秩和的原假设精确方差，再比较两种标准化。
3. 用条件均值零逐一证明残差核共享一个下标时协方差仍为零；这一步解释了为何两样本余项只保留 $1/(mn)$ 量级。

4.8 一阶退化与中心化卡方极限

本节保留一般证明，也先列出可用普通 CLT 与 LLN 独立核验的例子。需要额外借用的泛函分析结论只有平方可积对称核的谱展开；其余概率步骤均在此前工具范围内。

4.8.1 乘积核的直接计算

设 $\mathrm{E}\,X = 0$、$\mathrm{E}\,X^2 = \sigma^2 > 0$，取 $h(x, y) = xy$。此时 $\vartheta = 0$、$h_1(x) = 0$、$\zeta_2 = \sigma^4$，精确方差为 $2\sigma^4/[n(n-1)]$。由乘积恒等式，

$$nU_n = \frac{n}{n-1}\left[\left(\frac{1}{\sqrt{n}}\sum_i X_i\right)^2 - \frac{1}{n}\sum_i X_i^2\right].$$

CLT 给出括号第一项趋于 $\sigma^2 Z^2$，LLN 给出第二项依概率趋于 σ^2。因此

$$nU_n \xrightarrow{d} \sigma^2(Z^2 - 1), \qquad Z \sim N(0, 1).$$

这里只需二阶矩，因为 $\mathrm{E}\,h(X_1, X_2)^2 = (\mathrm{E}\,X^2)^2$。中心化卡方来自“和的平方减去平均平方”，而不是把退化情形继续当作非退化 CLT 使用。

4.8.2 积分算子是矩阵作用的推广

回到固定 $m \geq 2$ 的一般核，假设 $\zeta_1 = 0$、$\zeta_2 > 0$。定义

$$K(x, y) = h_2(x, y) - \vartheta.$$

因为 $h_1(X) = \vartheta$ 几乎处处，

$$\mathrm{E}[K(X_1, X_2) \mid X_1] = 0, \qquad \mathrm{E}\,K(X_1, X_2)^2 = \zeta_2.$$

一般非退化情形的二阶正交核应为 $h_2(x, y) - h_1(x) - h_1(y) + \vartheta$；在本节条件下，它才等于 K。

考虑 $L^2(P)$ 上的积分算子

$$(\mathcal{K}f)(x) = \int K(x, y) f(y)\, dP(y).$$

若 P 在 r 个点 $x_1, \ldots, x_r$ 等概率取值，积分变成

$$(\mathcal{K}f)(x_i) = \frac{1}{r}\sum_{j=1}^{r} K(x_i, x_j) f(x_j),$$

即矩阵 $(K(x_i,x_j)/r)_{i,j}$ 乘上函数值向量。一般分布只是把离散求和换成积分，把向量换成函数。特征方程为

$$\int K(x,y)e_j(y)\,dP(y)=\lambda_j e_j(x).$$

对称核给出自伴算子，核平方可积给出 Hilbert–Schmidt 性质。在通常的实值观测（标准 Borel）设置中，谱定理允许在 $L^2(P\times P)$ 意义下写为

$$K(x,y)=\sum_{j\ge 1}\lambda_j e_j(x)e_j(y),\qquad \sum_j \lambda_j^2=\zeta_2, \tag{4.13}$$

其非零特征值均实，特征函数正交归一，即 $\mathrm{E}[e_j(X)e_\ell(X)]=\mathbf{1}_{\{j=\ell\}}$。等式是均方收敛，不要求每个 (x,y) 都逐点成立。

退化性和对称性给出 $\int K(x,y)\,dP(x)=0$ 对几乎所有 y 成立。对特征方程积分，利用 Cauchy–Schwarz 保证绝对可积，可得

$$\lambda_j\,\mathrm{E}\,e_j(X)=\iint K(x,y)e_j(y)\,dP(y)dP(x)=0.$$

所以非零特征值对应的 e_j 均值为零。乘积例中只有一个方向：$e(x)=x/\sigma$、$\lambda=\sigma^2$，于是 $K(x,y)=\sigma^2e(x)e(y)$，正好恢复上一小节的极限。

一阶退化 U 统计量的极限

若 $m\ge 2$ 固定、$\mathrm{E}\,h^2<\infty$，且 $\zeta_1=0$、$\zeta_2>0$，则

$$n(U_n-\vartheta)\xrightarrow{d}\binom{m}{2}\sum_{j\ge 1}\lambda_j(Z_j^2-1), \tag{4.14}$$

其中 Z_j 相互独立且服从 $N(0,1)$，λ_j 为式 (4.13) 的非零特征值。无限和按 L^2 收敛理解，权重可以为正也可以为负。

4.8.3 第一步：严格降到二阶核

令

$$V_n=\binom{n}{2}^{-1}\sum_{i<j}K(X_i,X_j),$$

并定义扣除所有成对贡献后的核

$$q(x_1,\dots,x_m)=h(x_1,\dots,x_m)-\vartheta-\sum_{1\le a<b\le m}K(x_a,x_b).$$

它对称、均值为零且二阶可积。给定 X_1,X_2，原核的条件均值为 $h_2(X_1,X_2)$；成对和中只有 $K(X_1,X_2)$ 保留。只含一个已知下标的项因退化性条件均值零，两个下标都未知的项也均值零。因此

$$\mathrm{E}[q(X_1,\dots,X_m)\mid X_1,X_2]=h_2(X_1,X_2)-\vartheta-K(X_1,X_2)=0.$$

再取条件期望得一阶投影也为零。对称性保证任意一个或一对下标均有该性质。

固定样本中的一对下标，它在 $\binom{n-2}{m-2}$ 个 m 元子集中出现。于是

$$\begin{aligned} U_n - \vartheta &= \frac{\binom{n-2}{m-2}}{\binom{n}{m}} \sum_{i<j} K(X_i, X_j) + U_n(q) \\ &= \binom{m}{2} V_n + U_n(q). \end{aligned}$$

这给出了式 (4.14) 中不能遗漏的 $\binom{m}{2}$。若 $m \geq 3$，核 q 的前两阶条件方差均为零，精确方差公式只剩 $k \geq 3$ 项，故 $\operatorname{Var}\{U_n(q)\} = O(n^{-3})$，

$$\mathrm{E}\{[nU_n(q)]^2\} = O(n^{-1}) \to 0.$$

若 $m = 2$，q 恒为零。因此一般问题归结为证明 nV_n 的极限。

4.8.4 第二步：固定有限谱应用 CLT

令 $K_J(x, y) = \sum_{j=1}^{J} \lambda_j e_j(x) e_j(y)$，并记对应二阶 U 统计量为 $V_{n,J}$。利用成对乘积恒等式，

$$\begin{aligned} nV_{n,J} = \frac{n}{n-1} \sum_{j=1}^{J} \lambda_j \Bigg[\left(\frac{1}{\sqrt{n}} \sum_{i=1}^{n} e_j(X_i) \right)^2 \\ - \frac{1}{n} \sum_{i=1}^{n} e_j(X_i)^2 \Bigg]. \end{aligned} \tag{4.15}$$

对固定 J，向量 $(e_1(X_i), \ldots, e_J(X_i))$ 独立同分布，均值零、协方差为单位阵。多元 CLT 给出

$$\frac{1}{\sqrt{n}} \sum_{i=1}^{n} (e_1(X_i), \ldots, e_J(X_i))^{\mathsf{T}} \xrightarrow{d} (Z_1, \ldots, Z_J)^{\mathsf{T}} \sim N_J(0, I_J).$$

有限样本下，同一个 X_i 产生的各个 $e_j(X_i)$ 不必独立；正交性给出协方差阵，联合正态极限才使 Z_j 独立。又因 $\mathrm{E}\, e_j(X)^2 = 1$，LLN 给出 $n^{-1} \sum_i e_j(X_i)^2 \xrightarrow{P} 1$。这里只需 e_j^2 可积，不要求特征函数有四阶矩。连续映射与 Slutsky 因而给出

$$nV_{n,J} \xrightarrow{d} L_J := \sum_{j=1}^{J} \lambda_j (Z_j^2 - 1).$$

4.8.5 第三步：以统一均方界处理无限尾项

由于 $\operatorname{Var}(Z_j^2 - 1) = 2$，$\sum_j \lambda_j^2 < \infty$ 保证 L_J 在 L^2 中为 Cauchy 列，故存在

$$L = \sum_{j \geq 1} \lambda_j (Z_j^2 - 1), \qquad \mathrm{E}(L - L_J)^2 = 2 \sum_{j > J} \lambda_j^2 \to 0.$$

平方可和不保证绝对可和。因此上式须按中心化级数的 L^2 极限理解，不能拆成两个未必各自收敛的级数之差：

$$\sum_j \lambda_j Z_j^2 - \sum_j \lambda_j.$$

样本端同样需要尾项控制。核 $K - K_J$ 仍退化，其二阶矩为 $\sum_{j>J} \lambda_j^2$。由二阶退化精确方差公式，

$$\mathrm{E}\{[n(V_n - V_{n,J})]^2\} = \frac{2n}{n-1} \sum_{j>J} \lambda_j^2 \le 4 \sum_{j>J} \lambda_j^2, \qquad n \ge 2. \tag{4.16}$$

界不依赖 n，因此可以先固定 J 令 n 趋于无穷，再令 J 趋于无穷。严格地，对任一有界且 Lipschitz 常数不超过 1 的函数 b，

$$\begin{aligned} |\,\mathrm{E}\, b(nV_n) - \mathrm{E}\, b(L)| &\le \mathrm{E}\,|n(V_n - V_{n,J})| \\ &\quad + |\,\mathrm{E}\, b(nV_{n,J}) - \mathrm{E}\, b(L_J)| + \mathrm{E}\,|L_J - L|. \end{aligned}$$

固定 J 后，中间项随 $n \to \infty$ 趋零。两边项由 Cauchy–Schwarz 及式 (4.16)，分别不超过

$$2\left(\sum_{j>J} \lambda_j^2\right)^{1/2}, \qquad \left(2\sum_{j>J} \lambda_j^2\right)^{1/2},$$

再令 $J \to \infty$，二者均趋零。有界 Lipschitz 函数刻画依分布收敛，故 $nV_n \xrightarrow{d} L$。结合第一步的 $nU_n(q) \xrightarrow{P} 0$，使用 Slutsky 即得式 (4.14)。 □

退化情形的核验与练习

1. 对一般 m，用式 (4.6) 核对极限的方差系数。**答案：** $n^2 \operatorname{Var}(U_n) \to 2\binom{m}{2}^2 \zeta_2$，而极限和的方差正是 $2\binom{m}{2}^2 \sum_j \lambda_j^2$。
2. 取三阶核 $h(x,y,z) = xy + xz + yz$，总体均值零、方差 σ^2。求 h_2 与极限。**答案：** $h_2(x,y) = xy$，故 $nU_n \xrightarrow{d} 3\sigma^2(Z^2 - 1)$；直接计数也有 $U_n = 3\binom{n}{2}^{-1} \sum_{i<j} X_i X_j$。
3. 设 a, b 为均值零、正交归一的平方可积函数，核为 $K(x,y) = a(x)a(y) - 2b(x)b(y)$。**答案：** 二阶 U 统计量满足 $nU_n \xrightarrow{d} (Z_1^2 - 1) - 2(Z_2^2 - 1)$。负权重并不妨碍核对称或平方可积，极限也不必非负。
4. 指出无限谱证明中若只写“固定 J 的 CLT，再令 $J = \infty$”，缺了哪一步。**线索：** 必须同时控制样本端尾项与极限端尾项，且样本端的界须对 n 一致。

4.9 综合练习

1. **条件化与完备性。** 设 $X_i \sim \mathrm{Bernoulli}(p)$ 独立同分布，$0 < p < 1$，$n \ge 2$。从 $\mathbf{1}_{\{X_1=1, X_2=0\}}$ 出发，求 $p(1-p)$ 的 UMVUE，要求写出条件分布与有限方差核验。**解答线索：** 给定 $T = \sum_i X_i = t$，全部含 t 个 1 的序列等概率，所求条件概率为 $t(n-t)/[n(n-1)]$。T 的自然参数遍历 $\mathbb{R}$，完备充分；估计有界，故适用 Lehmann–Scheffé。

2. **同一核在不同参数点的变化**。设 $\mathrm{E}\,X^2 < \infty$、$\mathrm{Var}(X) = \sigma^2 > 0$。对乘积核 $h(x,y) = xy$，比较 $\mu \neq 0$ 与 $\mu = 0$ 时的方差速度、放大尺度和极限。
   解答线索： $\mu \neq 0$ 时为 n^{-1} 方差及 $\sqrt{n}$ 正态极限；$\mu = 0$ 时为 n^{-2} 方差及 $nU_n \xrightarrow{d} \sigma^2(Z^2-1)$。退化由分布和核共同决定，不是核公式本身的固定标签。
3. **构造但不误称最优**。独立同分布总体具有二阶矩，证明 $\bar{X}^2 - S^2/n$ 无偏估计 μ^2；再说明在哪个已讨论的模型中可以进一步称它为 UMVUE。
   解答线索： 一般总体由乘积核即可得到无偏性；正态双参数模型中它是完备充分统计量的函数，故为 UMVUE。无偏或 U 统计量形式本身不足以替代模型内的最优性论证。
4. **由秩恢复胜出次数**。两组各有三个观测，X 的合并秩为 $(2,4,6)$。求 $U_{3,3}$、原假设下 R_X 的均值与方差，并说明为什么仅此观测结果不能证明两总体相同。
   答案： $R_X = 12$，胜出次数 $12 - 6 = 6$，$U_{3,3} = 2/3$；原假设均值为 $21/2$、方差为 $21/4$。检验需参照零分布或近似分布，且不拒绝不等于证实原假设。
5. **证明题**。不直接引用全方差公式，从 $R = U - \mathrm{E}(U \mid T)$ 的条件均值为零出发，证明 Rao–Blackwell 方差比较及其等号条件；说明充分性用在何处。
   解答线索： 先证残差与所有二阶可积 T 的函数正交，再展开平方。方差恒等式对任意 T 成立，充分性用来保证条件期望可取同一个参数无关的版本。
6. **退化证明题**。在 $\zeta_1 = 0$、$\zeta_2 > 0$ 时，不依赖完整的高阶 Hoeffding 分解，证明扣除全部成对核后的余项在 n 尺度可忽略。
   解答线索： 构造本章的 q，证明它的一、二阶条件投影均为零，再用重叠计数方差公式得到 $O(n^{-3})$；$m = 2$ 时单独观察 $q = 0$。最后仍须用有限谱 CLT 和统一尾界，才能确定极限分布。

第 5 章　假设检验与置信集合

估计问题要求给出参数的数值，检验问题则要求根据样本在两个参数集合之间作出判断。本章先固定第一类错误的上界，再比较备择下的拒绝概率。似然比决定证据的排序；充分性与完备性负责处理干扰参数；置信集合由一族检验反演得到。

阅读范围

本章按完整课件整理。检验、p 值、Neyman–Pearson 引理、单侧 UMP 及双侧 UMP 不存在的内容，对应原课件第 1–27 页；无偏检验与 UMPU 从第 28 页开始。这里的收录范围不表示已独立完成全部证明和习题。

5.1　检验、功效与比较的范围

设样本 X 的分布属于 $\{P_\theta : \theta \in \Theta\}$，检验

$$H_0 : \theta \in \Theta_0, \qquad H_1 : \theta \in \Theta_1, \qquad \Theta_0 \cap \Theta_1 = \varnothing.$$

简单假设只指定一个分布；复合假设包含多个分布。例如正态模型中，若方差未知，即使把均值固定为 μ_0，原假设仍是复合假设。

检验、功效、大小与水平

检验是可测函数 $\varphi : \mathcal{X} \to [0,1]$，其值表示观察到 x 后拒绝原假设的概率。功效函数和大小分别为

$$\beta_\varphi(\theta) = \mathrm{E}_\theta\, \varphi(X), \qquad \operatorname{size}(\varphi) = \sup_{\theta \in \Theta_0} \beta_\varphi(\theta).$$

若大小不超过 α，称为水平 α 检验；若大小恰为 α，称为精确大小 α 的检验。在 Θ_0 上，β_φ 是第一类错误概率；在 Θ_1 上，$1 - \beta_\varphi$ 是第二类错误概率。

$\varphi(x) \in \{0,1\}$ 时规则不随机化。一般情形取与样本独立的 $V \sim U(0,1)$，在 $V \le \varphi(x)$ 时拒绝。对固定 x，有

$$P_V\{V \le \varphi(x)\} = \varphi(x),$$

故这个实施步骤确实产生规定的条件拒绝概率。φ 是规则，V 用于实施规则，两者不能与功效函数混淆。

总拒绝的功效恒为 1，但大小也为 1；总不拒绝没有第一类错误，却不能检出任何备择。因此最优性只能在规定的比较类中讨论。在水平约束下增大备择功效，等价于减小第二类错误，并不表示两个错误概率可以同时无约束地最小化。

MP 与 UMP

对固定简单备择，功效最大的水平 α 检验称为最有力检验（MP）。若同一个水平 α 检验 φ^* 满足

$$\mathrm{E}_\theta\,\varphi^* \geq \mathrm{E}_\theta\,\psi, \qquad \theta \in \Theta_1,$$

对每个水平 α 检验 ψ 都成立，则称为一致最有力检验（UMP）。这里的“一致”指同一个规则对所有备择都最优，与一致收敛无关。

精确大小是原假设上的上确界等于 α，不要求每个原假设参数处的拒绝率都是 α。这种逐点相等的性质称为相似性，后文另行讨论。

练习 5.1：水平与功效

设 $Z \sim N(\delta, 1)$，按 $Z > z_{1-\alpha}$ 拒绝，其中 $z_q = \Phi^{-1}(q)$。写出功效，并判断它是 $H_0 : \delta \leq 0$ 的什么水平。

答案线索。 $\beta(\delta) = 1 - \Phi(z_{1-\alpha} - \delta)$ 随 δ 递增，故 $\sup_{\delta \leq 0} \beta(\delta) = \beta(0) = \alpha$。参数越负，拒绝率越低，说明精确大小不等于各点拒绝率相同。

5.2 p 值与离散边界随机化

5.2.1 观察值与重复抽样

先考虑简单原假设 P_0，且统计量 T 越大越支持备择。对已经观察到的数据 x，常规右尾 p 值为

$$p(x) = P_0\{T(X') \geq T(x)\}, \qquad X' \sim P_0.$$

此时 x 和 $T(x)$ 已固定，概率针对假想的重新抽样 X'。这个数衡量原假设下出现至少同样偏向备择的结果有多罕见，不是原假设为真的概率。实验前的 $p(X)$ 则是一个随机变量。

正态右侧检验

设 $X_1, \dots, X_{25}$ 独立服从 $N(\mu, 10^2)$，检验 $\mu = 100$ 对 $\mu > 100$。若观察到 $\bar{x} = 104$，则

$$z = \frac{\bar{x} - 100}{10/\sqrt{25}} = 2, \qquad p(x) = P(Z' \geq 2) = 1 - \Phi(2) \approx 0.0228.$$

在水平 0.05 下拒绝，在水平 0.01 下不拒绝。连续型统计量恰好等于观察值的概率为零，故用整块尾部概率衡量极端程度。

5.2.2 与嵌套拒绝域的联系

若拒绝域 R_α 随 α 单调扩张，定义

$$p_R(x) = \inf\{\alpha \in (0, 1] : x \in R_\alpha\}, \qquad R_1 = \mathcal{X}.$$

假设对 $0 < u < 1$ 有集合意义的右连续性

$$R_u = \bigcap_{v>u} R_v.$$

则

$$\{x : p_R(x) \le u\} = R_u.$$

证明如下：若 $x \in R_u$，下确界自然不超过 u。反之，若下确界不超过 u，则对每个 $v > u$ 都能找到某个 $\alpha < v$ 使 $x \in R_\alpha$；由嵌套性 $x \in R_v$，再用右连续性得到 $x \in R_u$。因此若 $P_0(R_u) \le u$，便有 $P_0\{p_R(X) \le u\} \le u$。

正态右尾取 $R_\alpha = \{z : z \ge \Phi^{-1}(1-\alpha)\}$，直接计算

$$z \in R_\alpha \iff \alpha \ge 1 - \Phi(z),$$

所以 $p_R(x) = 1 - \Phi(z) = p(x)$。任意嵌套族的下确界不一定等于上述右尾概率；两者相等还依赖拒绝域按同一统计量的尾部排序构造。离散模型尤其要说明采用的边界与随机化约定。

5.2.3 均匀性、超均匀性与复合原假设

若 T 在简单原假设下的分布函数 F_0 连续，则概率积分变换给出

$$F_0(T) \sim U(0,1), \qquad p(X) = 1 - F_0(T) \sim U(0,1).$$

故 $P_0\{p(X) \le u\} = u$。连续性已经足够，不必额外要求 F_0 严格递增。

一般称 p 值有效，若

$$P_\theta\{p(X) \le u\} \le u, \qquad 0 \le u \le 1, \quad \theta \in \Theta_0.$$

这种性质称为超均匀性，使规则 $p \le \alpha$ 控制水平。复合原假设必须对其中每个参数都成立，不能任取一个原假设参数计算尾概率。

一种通用构造是：若每个简单原假设下都有有效的 p_θ，且上确界可测，则

$$p_{\sup}(x) = \sup_{\theta \in \Theta_0} p_\theta(x)$$

在复合原假设下有效。因为真值为 θ 时，$p_{\sup} \ge p_\theta$，故

$$P_\theta(p_{\sup} \le u) \le P_\theta(p_\theta \le u) \le u.$$

存在最不利边界分布时，这个上确界常可简化为边界处的尾概率。

5.2.4 离散概率质量怎样补足

对离散 T，记

$$a_t = P_0(T > t), \qquad m_t = P_0(T = t).$$

若选 c 使 $m_c > 0$ 且 $a_c \le \alpha \le a_c + m_c$，则取

$$\gamma = \frac{\alpha - a_c}{m_c}, \qquad \varphi(x) = \mathbf{1}_{\{T(x)>c\}} + \gamma \mathbf{1}_{\{T(x)=c\}}.$$

于是 $\mathrm{E}_0\,\varphi = a_c + \gamma m_c = \alpha$。分子是尚缺的拒绝概率，分母是边界整块概率；二者的比值正是边界上应拒绝的比例。

二项分布：15% 的边界拒绝与 10% 的总拒绝

设 $T \sim \mathrm{Bin}(4, 1/2)$，要求大小 $\alpha = 0.10$。只拒绝 $T = 4$ 的大小为 $1/16$；再把 $T = 3$ 全部加入便成为 $5/16$，超过预算。故

$$c = 3, \qquad \gamma = \frac{1/10 - 1/16}{4/16} = \frac{3}{20} = 0.15.$$

$T = 4$ 时全拒绝，$T = 3$ 时取独立 $V \sim U(0,1)$，按 $V \le 0.15$ 拒绝，其他值不拒绝。总拒绝概率为

$$\frac{1}{16} + \frac{4}{16} \times 0.15 = 0.10.$$

0.15 是给定边界事件后的拒绝概率；0.10 是对全部可能数据平均后的拒绝概率。

定义随机化 p 值

$$p_{\mathrm{rand}}(x, v) = a_{T(x)} + v m_{T(x)}, \qquad V \sim U(0,1), \quad V \perp X.$$

观察到 $T = t$ 后，它在区间 $[a_t, a_t + m_t]$ 内均匀分布。这个区间的长度恰为该取值的概率 m_t。对任意 $u \in [a_c, a_c + m_c]$，由独立性，

$$\begin{aligned} P_0\{p_{\mathrm{rand}}(X, V) \le u\} &= P_0(T > c) + P_0(T = c) P\left(V \le \frac{u - a_c}{m_c}\right) \\ &= a_c + m_c \frac{u - a_c}{m_c} = u. \end{aligned}$$

各原子区间的内部互不相交，长度总和为 $\sum_t m_t = 1$。给定 $T = t$ 时的条件密度为 $1/m_t$，再乘上选中该区间的概率 m_t，得到区间内无条件密度为 1；其余部分的 Lebesgue 测度为零。因此在简单离散原假设下

$$p_{\mathrm{rand}}(X, V) \sim U(0,1).$$

按 $p_{\mathrm{rand}} \le \alpha$ 拒绝，恰好等价于前述边界随机化规则。常规尾概率 $p(X) = a_T + m_T$ 满足 $p(X) \ge p_{\mathrm{rand}}(X, V)$，从而

$$P_0\{p(X) \le u\} \le u.$$

这同时说明离散常规 p 值为何通常保守。

练习 5.2：区分三种概率

在上述二项例子中，观察到 $T=3$。求常规 p 值、随机化 p 值，并写出其在水平 0.10 下拒绝的条件。再证明常规 p 值对应的非随机检验大小为 $1/16$。

答案线索。 $p=5/16$，$p_{\text{rand}}=1/16+V/4$；后者不超过 0.10 当且仅当 $V\le 0.15$。常规规则只在 $T=4$ 时拒绝，所以大小为 $1/16<0.10$。

5.3 Neyman–Pearson 引理

5.3.1 定理及临界值的存在

设 P_0,P_1 对同一 σ-有限测度 ν 有密度 f_0,f_1。目标是

$$\max_{0\le\varphi\le 1}\mathrm{E}_1\,\varphi,\qquad \mathrm{E}_0\,\varphi\le\alpha.$$

用密度差比直接相除更方便：当 $f_0=0<f_1$ 时，该点只支持备择，应拒绝。

Neyman–Pearson 引理

对 $0<\alpha<1$，存在有限 $c\ge 0$ 及 $\gamma\in[0,1]$，使

$$\varphi^*=\mathbf{1}_{\{f_1>cf_0\}}+\gamma\mathbf{1}_{\{f_1=cf_0\}},\qquad \mathrm{E}_0\,\varphi^*=\alpha.$$

它是检验 P_0 对 P_1 的 MP 水平 α 检验。任何同样最优的水平检验，在 $\{f_1\ne cf_0\}$ 上都与它相等，ν-几乎处处。若 $c>0$，所有最优检验都必须具有精确大小 α；$c=0$ 时最优功效为 1，不一定需要用满大小。

临界值存在的证明。在 P_0 下，$f_0(X)>0$ 且两个密度可取有限版本，故似然比 $L=f_1(X)/f_0(X)$ 几乎处处有限且非负。令

$$q(t)=P_0(L>t),\qquad c=\inf\{t:q(t)\le\alpha\}.$$

q 单调不增，$t<0$ 时为 1，$t\to\infty$ 时趋于 0；它右连续，且左极限为 $q(t-)=P_0(L\ge t)$。所以 $c\in[0,\infty)$，并有

$$q(c)\le\alpha\le q(c-).$$

若差为正，令 $\gamma=[\alpha-q(c)]/[q(c-)-q(c)]$；若差为零，则两端均为 α，取 $\gamma=0$。这使

$$\mathrm{E}_0\,\varphi^*=q(c)+\gamma P_0(L=c)=\alpha.$$

在 P_0 零概率但 $f_1>0$ 的区域按密度差规则全拒绝，不影响大小。

5.3.2 最优性与等号条件的证明

任取 $0 \le \psi \le 1$ 且 $\mathrm{E}_0\,\psi \le \alpha$。逐点有

$$D = (\varphi^* - \psi)(f_1 - c f_0) \ge 0.$$

因为密度差为正处 $\varphi^* = 1$，为负处 $\varphi^* = 0$，等于零处乘积为零。因此

$$\begin{aligned}\mathrm{E}_1\,\varphi^* - \mathrm{E}_1\,\psi &= \int (\varphi^* - \psi)(f_1 - c f_0)\,d\nu + c\int (\varphi^* - \psi) f_0\,d\nu \\ &= \int D\,d\nu + c(\alpha - \mathrm{E}_0\,\psi) \ge 0.\end{aligned}$$

若 ψ 也最优，两个非负项都必须为零。$\int D = 0$ 给出 $D = 0$ 几乎处处，于是密度差严格为正处必须 $\psi = 1$，严格为负处必须 $\psi = 0$。等号边界的安排不受这一乘积限制，所以最优规则不一定唯一。若 $c > 0$，第二项为零还强迫 $\mathrm{E}_0\,\psi = \alpha$。

若 $c = 0$，$\varphi^* = 1$ 于 $\{f_1 > 0\}$，故其功效已为 1。更一般地，若规则 ψ 的大小 $a < \alpha$ 且功效 $b < 1$，令

$$\varepsilon = \frac{\alpha - a}{1 - a}, \qquad \widetilde{\psi} = \psi + \varepsilon(1 - \psi).$$

则新规则大小恰为 α，功效为 $b + \varepsilon(1 - b) > b$。所以功效尚未到 1 的最优规则必须用满大小；这个结论不要求唯一性。

5.3.3 似然比平台与不同的最优规则

均匀分布端点：两个不同的 MP 检验

设 X_i 独立服从 $U(0,\theta)$，$M = X_{(n)}$，检验 θ_0 对 $\theta_1 > \theta_0$。在原假设支持上，似然比恒为 $k = (\theta_0/\theta_1)^n$；在 $\theta_0 \le M < \theta_1$ 的新增支持上为 $+\infty$。任意水平检验都满足

$$\begin{aligned}\mathrm{E}_{\theta_1}\,\varphi &= k\,\mathrm{E}_{\theta_0}\,\varphi + \mathrm{E}_{\theta_1}[\varphi \mathbf{1}_{\{M \ge \theta_0\}}] \\ &\le k\alpha + 1 - k = 1 - (1 - \alpha)(\theta_0/\theta_1)^n.\end{aligned}$$

令 $c_\alpha = \theta_0(1 - \alpha)^{1/n}$，则

$$\varphi_A = \mathbf{1}_{\{M > c_\alpha\}}, \qquad \varphi_B = \mathbf{1}_{\{M > \theta_0\}} + \alpha \mathbf{1}_{\{M \le \theta_0\}}$$

在 θ_0 下大小都为 α，在 θ_1 下功效都达到上述上界。它们在原假设支持内采取不同安排，却没有改变任何相对证据的排序，因为该处似然比完全相同。

练习 5.3：最优性与预算例外

设 $P_0 = U(0,1)$，$P_1 = U(0,\delta)$，其中 $0 < \delta < \alpha$。证明 $\varphi = \mathbf{1}_{\{X < \delta\}}$ 最优，但大小严格小于 α。再指出 NP 引理的哪个条件允许这一现象。

答案线索。大小为 δ，功效为 1，已达到上限；可取密度差阈值 $c = 0$，所以不能使

用 $c>0$ 时的精确大小结论。

5.4 单调似然比与单侧 UMP

5.4.1 单调似然比与随机单调性

单调似然比（MLR）

对任意 $\theta_1<\theta_2$，若 $f_{\theta_2}/f_{\theta_1}$ 在相关支持上可写成 T 的非递减函数，则称模型在 T 中有 MLR；分母为零、分子为正时按 $+\infty$ 处理。其交叉乘积形式要求：若 $T(x)\le T(y)$，则

$$f_{\theta_2}(y)f_{\theta_1}(x)\ge f_{\theta_2}(x)f_{\theta_1}(y).$$

各参数对的密度可选择适当版本，使上述比较在相关支持上成立。当 $T(x)=T(y)$ 时须同时作两个方向的比较，因而交叉乘积相等，保证同一个 T 值对应同一个扩展似然比；只要求严格小于时的不等式不足以表达这一点。它表示较大的 T 相对更支持较大的参数。共同支持是常用的充分背景条件，并非 MLR 的必要条件。

MLR 推出随机单调性的证明。在 $A=\{T\le t\}$、$B=\{T>t\}$ 上积分交叉乘积不等式，Tonelli 定理给出

$$P_{\theta_1}(A)P_{\theta_2}(B)\ge P_{\theta_2}(A)P_{\theta_1}(B).$$

令 $p_i=P_{\theta_i}(T>t)$，化为 $(1-p_1)p_2\ge(1-p_2)p_1$，故 $p_2\ge p_1$。同理 $P_\theta(T\ge t)$ 也随参数非递减。因此对固定 c,γ，

$$\mathrm{E}_\theta[\mathbf{1}_{\{T>c\}}+\gamma\mathbf{1}_{\{T=c\}}]=(1-\gamma)P_\theta(T>c)+\gamma P_\theta(T\ge c)$$

随参数非递减。这是分布的尾概率比较，不是不同参数下样本值的逐点比较。

对共同支持上的指数族

$$f_\theta(x)=\exp\{\eta(\theta)T(x)-A(\theta)\}h(x),$$

若 η 非递减，则两参数的似然比为

$$\exp\{[\eta(\theta_2)-\eta(\theta_1)]T-A(\theta_2)+A(\theta_1)\},$$

所以在 T 中有 MLR。η 递减时应改用 $-T$。Cauchy 位置族在 $T=X$ 中不是 MLR：其两参数似然比在正、负无穷处都趋于 1，却在两个位置参数处分别小于和大于 1，不可能单调。

5.4.2 Karlin–Rubin 定理及证明

单侧 UMP 定理

若模型在 T 中有 MLR，取

$$\varphi^* = \mathbf{1}_{\{T>c\}} + \gamma \mathbf{1}_{\{T=c\}}, \qquad \mathrm{E}_{\theta_0}\, \varphi^* = \alpha \in (0,1).$$

则它是 $H_0 : \theta \le \theta_0$ 对 $H_1 : \theta > \theta_0$ 的 UMP 水平 α 检验；对点原假设 $\theta = \theta_0$ 也成立。其功效随参数非递减。

证明。随机单调性给出

$$\sup_{\theta \le \theta_0} \mathrm{E}_\theta\, \varphi^* = \mathrm{E}_{\theta_0}\, \varphi^* = \alpha,$$

所以复合原假设水平确实受控。固定任意 $\theta > \theta_0$，MLR 保证上尾规则按 f_θ / f_{θ_0} 的大小拒绝：在比值平台上的部分选择属于 NP 等号边界的允许安排。因此它是 P_{θ_0} 对 P_θ 的 MP 检验。每个复合原假设水平检验 ψ 都满足 $\mathrm{E}_{\theta_0}\, \psi \le \alpha$，由 NP 引理

$$\mathrm{E}_\theta\, \varphi^* \ge \mathrm{E}_\theta\, \psi.$$

临界值只由边界分布和 α 决定，不依赖所选的具体备择，故对每个 $\theta > \theta_0$ 都成立，得到 UMP。

同一规则若在另一参数 θ' 处的功效为 $a \in (0,1)$，重新以 θ' 为边界，就成为水平 a 的右侧 UMP。对 $\theta < \theta_0$，补检验 $1 - \varphi^*$ 是从边界检验较小参数的 NP 最优规则，所以在所有满足 $\mathrm{E}_{\theta_0}\, \psi = \alpha$ 的规则中，

$$\mathrm{E}_\theta\, \varphi^* \le \mathrm{E}_\theta\, \psi.$$

即该上尾规则在较小参数处还具有最小拒绝概率。

若各参数分布具有共同正支持，$0 < \alpha < 1$ 保证所有参数处功效均严格介于 0 与 1。若两个参数的似然比不是常数，功效还严格增加。否则令 $a = \beta(\theta_1) = \beta(\theta_2)$，常数检验 a 在该简单检验问题中也最优；NP 等号条件却要求它在严格大于阈值处等于 1、严格小于阈值处等于 0。因 $0 < a < 1$，只能是似然比几乎处处恒定，矛盾。

5.4.3 例子与方向

Poisson、二项与指数分布

若 $X_i \sim \mathrm{Poisson}(\theta)$ 独立，则 $S = \sum X_i \sim \mathrm{Poisson}(n\theta)$，自然参数 $\log \theta$ 递增。检验 $\theta \le \theta_0$ 对 $\theta > \theta_0$ 时选

$$P_{\theta_0}(S > c) \le \alpha \le P_{\theta_0}(S \ge c), \qquad \gamma = \frac{\alpha - P_{\theta_0}(S > c)}{P_{\theta_0}(S = c)}.$$

按大 S 拒绝即为 UMP。二项族的似然比同样随成功数递增，前节 $\mathrm{Bin}(4, 1/2)$ 的边界规则因而对所有 $p > 1/2$ 同时最优。

若 $X_i \sim \mathrm{Exp}(\lambda)$，以率参数 λ 表示，则密度中的自然参数是 $-\lambda$。较大的率对应较短的等待时间，检验较大 λ 应拒绝较小的 $\sum X_i$，方向不能照搬。

均匀端点族在 M 中有 MLR。前节的 φ_A, φ_B 对所有 $\theta > \theta_0$ 都达到 NP 功效上界，又都满足复合原假设水平，因此都是 UMP。两者完整功效为

$$\beta_A(\theta) = \begin{cases} 0, & \theta \le c_\alpha, \\ 1 - (c_\alpha/\theta)^n, & \theta > c_\alpha, \end{cases}$$

$$\beta_B(\theta) = \begin{cases} \alpha, & \theta \le \theta_0, \\ 1 - (1-\alpha)(\theta_0/\theta)^n, & \theta > \theta_0. \end{cases}$$

备择一侧功效相同，不要求原假设一侧也相同；支持随参数改变时，某些参数处功效可为零。

练习 5.4：把物理参数换成自然参数

对率参数指数样本，检验 $\lambda \le \lambda_0$ 对 $\lambda > \lambda_0$。利用 $2\lambda_0 \sum X_i \sim \chi^2_{2n}$ 写出 UMP 规则，并说明最坏原假设参数。

答案线索。以 $-\sum X_i$ 为 MLR 统计量，拒绝 $2\lambda_0 \sum X_i < \chi^2_{2n,\alpha}$。拒绝率随 λ 增大，原假设最大值在 λ_0 处取得；连续分布不需要随机化。

5.5 双侧困难与无偏约束

5.5.1 正态双侧问题不存在 UMP

设 $Z \sim N(\delta, 1)$，检验 $\delta = 0$ 对 $\delta \neq 0$。似然比

$$f_\delta(z)/f_0(z) = e^{\delta z - \delta^2/2}$$

在 $\delta > 0$ 时严格递增，在 $\delta < 0$ 时严格递减。因连续分布的边界概率为零，NP 引理的唯一性给出：对任意固定正备择，唯一 MP 规则是 $\varphi_+ = \mathbf{1}_{\{Z > z_{1-\alpha}\}}$；对任意固定负备择，唯一 MP 规则是 $\varphi_- = \mathbf{1}_{\{Z < z_\alpha\}}$。

若双侧 UMP 存在，它必须在 P_0 下同时等于这两个规则。但在

$$\{Z > \max(z_\alpha, z_{1-\alpha})\}$$

上，前者拒绝、后者不拒绝，该集合的原假设概率为 $\min(\alpha, 1-\alpha) > 0$，矛盾。此证明对所有 $0 < \alpha < 1$ 成立。把左右两尾各改为 $\alpha/2$ 只能控制总大小，不能恢复对每个固定单侧备择的 NP 最优性。

5.5.2 无偏性给出的两个矩方程

无偏检验与 UMPU

水平 α 检验若对每个备择满足 $\beta_\varphi(\theta) \geq \alpha$，称为无偏检验。若它在所有无偏水平 α 检验中对每个备择都最有力，称为 UMPU。常数规则 $\varphi \equiv \alpha$ 是比较基线。检验无偏性不是估计量期望等于参数。

设 θ_0 为参数区间内点，功效在该点连续可微，并允许对固定检验在积分号下求导。无偏性与水平条件先给出

$$\beta(\theta_0) = \alpha.$$

因为邻近备择的功效至少为 α，连续性给出边界处至少为 α，水平又给出不超过 α。又因该点是功效的局部最小点，$\beta'(\theta_0) = 0$。

令原假设得分 $S_0 = \dot{f}_{\theta_0}/f_{\theta_0}$，由密度归一化求导及功效求导，

$$\mathrm{E}_0\, S_0 = 0, \qquad \mathrm{E}_0\, \varphi = \alpha, \qquad \mathrm{E}_0(\varphi S_0) = 0.$$

共同正支持、导数绝对可积及相应的积分求导条件需实际核验；含参数支持边界的模型不能直接套用。

在正则自然指数族 $f_\eta = e^{\eta T - A(\eta)} h$ 中，$S_0 = T - m$，其中 $m = \mathrm{E}_0\, T = A'(\eta_0)$，故必要条件化为

$$\boxed{\mathrm{E}_0\, \varphi = \alpha, \qquad \mathrm{E}_0(T\varphi) = \alpha m.}$$

第一个方程固定总拒绝概率；第二个要求拒绝区域内的正负中心化一阶矩平衡。它们只是无偏性的必要局部条件，候选规则的全局无偏性仍要证明。

对连续双尾规则，第二个方程可写为

$$\int_{t<c_1} (m - t)\, dP_0^T(t) = \int_{t>c_2} (t - m)\, dP_0^T(t).$$

它平衡的是距均值的加权概率，不是两尾面积。对称分布常得到等尾，偏态分布通常不是每尾 $\alpha/2$。

练习 5.5：必要条件为什么不充分

设 $Z \sim N(\delta, 1)$。选择 $c > 0$ 使 $P_0(|Z| \leq c) = \alpha$，令 $\varphi = \mathbf{1}_{\{|Z| \leq c\}}$。验证它满足大小和原假设处的导数条件，却不是双侧无偏检验。

答案线索。对称性给出 $\mathrm{E}_0(Z\varphi) = 0$，大小为 α；但 $|\delta| \to \infty$ 时 $P_\delta(|Z| \leq c) \to 0 < \alpha$。在原点导数为零并不能控制全部备择。

5.6 广义 Neyman–Pearson 引理

5.6.1 多个矩约束下的符号规则

设 $g, g_1, \dots, g_k$ 对 σ-有限测度 ν 绝对可积，允许取正负值。记

$$\Phi = \{\varphi : 0 \le \varphi \le 1,\ \varphi \text{ 可测}\}, \qquad \mathcal{C}_b = \left\{\varphi \in \Phi : \int \varphi g_j \, d\nu = b_j,\ j = 1, \dots, k\right\}.$$

目标是在非空的 $\mathcal{C}_b$ 中最大化 $\int \varphi g \, d\nu$。

广义 NP 引理

最大值可以取到。若某个可行 φ^* 和有限实数乘子 a_j 满足：令

$$\Delta = g - \sum_{j=1}^{k} a_j g_j,$$

则 $\varphi^* = 1$ 于 $\{\Delta > 0\}$、$\varphi^* = 0$ 于 $\{\Delta < 0\}$，它就最优。等号边界可随机化。
进一步令

$$M = \left\{ \left(\int \varphi g_j \, d\nu \right)_{j=1}^{k} : \varphi \in \Phi \right\}.$$

若 b 为 M 的内点，则存在有限实数乘子，使所有最优解都具有上述符号形式，几乎处处成立。

充分性的证明。对任意 $\psi \in \mathcal{C}_b$，逐点有 $(\varphi^* - \psi)\Delta \ge 0$，而矩约束相同，故

$$\begin{aligned} \int (\varphi^* - \psi) g \, d\nu &= \int (\varphi^* - \psi)\Delta \, d\nu + \sum_j a_j \int (\varphi^* - \psi) g_j \, d\nu \\ &= \int (\varphi^* - \psi)\Delta \, d\nu \ge 0. \end{aligned}$$

相同功效时，非负乘积几乎处处为零，故 $\Delta \ne 0$ 处具有同样的唯一性。

若约束改成 $\int \varphi g_j \, d\nu \le b_j$，充分条件相应为 $a_j \ge 0$、符号规则、可行性和互补松弛

$$a_j \left(b_j - \int \varphi^* g_j \, d\nu \right) = 0.$$

此时上式中乘子项等于 $\sum_j a_j (b_j - \int \psi g_j \, d\nu) \ge 0$。等式约束允许任意实数乘子，不等式上界约束才要求非负。

5.6.2 存在性与逆结论的证明

这部分使用两个标准分析结果：Hilbert 空间有界序列存在弱收敛子序列；有限维闭凸集的边界点存在支撑超平面。它们分别保证最优解取到，以及有限乘子的存在。

记录每个检验的矩向量和目标值：

$$u_\varphi = \left(\int \varphi g_j \, d\nu \right)_j, \quad v_\varphi = \int \varphi g \, d\nu, \quad K = \{ (u_\varphi, v_\varphi) : \varphi \in \Phi \}.$$

K 显然凸。为证紧，利用 ν 的 σ-有限性选取严格正的可积 q，设

$$w = q + |g| + \sum_j |g_j|, \qquad C = \int w \, d\nu, \qquad d\mu = (w/C)\, d\nu.$$

μ 是与 ν 等价的概率测度。每个检验的 $L^2(\mu)$ 范数不超过 1，所以任意检验序列有弱收敛子序列 $\varphi_{n_\ell} \rightharpoonup \varphi$。对任意可测集 A，以 $\mathbf{1}_A$ 为测试函数，有

$$0 \le \int_A \varphi \, d\mu \le \mu(A).$$

分别取 $A = \{\varphi < 0\}$ 和 $A = \{\varphi > 1\}$，得 $0 \le \varphi \le 1$ 几乎处处。又因 Cg_j/w、Cg/w 有界，均属于 $L^2(\mu)$，弱收敛给出

$$\int \varphi_{n_\ell} g_j \, d\nu \longrightarrow \int \varphi g_j \, d\nu, \qquad \int \varphi_{n_\ell} g \, d\nu \longrightarrow \int \varphi g \, d\nu.$$

所以每列可达向量都有仍可达的收敛子序列，K 在有限维空间中紧。选可行检验的目标值趋于上确界，紧性给出某个可行检验达到最大值 v^*。

再定义向下延伸的闭凸集

$$H = \{ (u, v - t) : (u, v) \in K,\ t \ge 0 \}.$$

闭性由 K 的紧性直接验证。最优点 (b, v^*) 在其上边界，故存在非零 (p, s)，使

$$p^\top (u - b) + s(v - v^*) \le 0, \qquad (u, v) \in H.$$

因 H 可向下无限延伸，必有 $s \ge 0$。若 $s = 0$，则 $p \neq 0$；$b \in \operatorname{int} M$ 允许取 $u = b + \varepsilon p \in M$，将对应点代入便得 $\varepsilon \|p\|^2 \le 0$，矛盾。因此 $s > 0$。令 $a = -p/s$，便有

$$v_\varphi - a^\top u_\varphi \le v^* - a^\top b, \qquad \varphi \in \Phi.$$

最优解达到等号，因此它在全部 Φ 中最大化 $\int \varphi \Delta \, d\nu$。这个无约束积分逐点最大化时，正系数处必须取 1，负系数处必须取 0，得到逆结论。内点条件正是排除 $s = 0$ 的竖直支撑面。

练习 5.6：从两个约束得到一条直线

在 $\mathrm{E}_0 \varphi = \alpha$、$\mathrm{E}_0(T\varphi) = \alpha m$ 下最大化 $\mathrm{E}_\eta \varphi$。写出广义 NP 的 g, g_1, g_2 与密度差，并解释乘子为何不需要非负。

答案线索。取 $g = f_\eta$、$g_1 = f_0$、$g_2 = T f_0$，于是 $\Delta = f_\eta - (a + bT) f_0$。原约束为等式，故 a, b 为任意有限实数。

5.7 一参数指数族的双侧 UMPU

5.7.1 定理、可行性与双尾结构

考虑共同正支持上的自然指数族

$$f_\eta(x) = \exp\{\eta T(x) - A(\eta)\}h(x), \qquad \eta \in I,$$

其中 I 为开区间，$\eta_0 \in I$，T 非恒定，$0 < \alpha < 1$。开自然参数区间保证在 η_0 两侧有指数矩，从而可交换局部求导与积分，并有 $m = \mathrm{E}_0\, T = A'(\eta_0)$。

一参数指数族双侧 UMPU

检验 $\eta = \eta_0$ 对 $\eta \neq \eta_0$，存在满足

$$\mathrm{E}_0\, \varphi^* = \alpha, \qquad \mathrm{E}_0(T\varphi^*) = \alpha m$$

的双尾规则：

$$\varphi^*(x) = \begin{cases} 1, & T < c_1 \text{ 或} T > c_2, \\ \gamma_i, & T = c_i, \quad i = 1, 2, \\ 0, & c_1 < T < c_2. \end{cases}$$

每个这样标定的双尾规则都是 UMPU。若临界点重合，使用一个边界随机化值；若 T 恒定，模型不随 η 改变，常数规则 α 即可。

第一步：验证广义 NP 的内点条件。设 $\mathcal{C}_b$ 为上述两矩约束类，常数规则 α 可行。考虑

$$\varphi_{s,t} = \alpha + s + t\mathbf{1}_{\{T>m\}}, \qquad |s| + |t| < \min(\alpha, 1-\alpha).$$

它是合法检验，矩向量的改变量为

$$\begin{pmatrix} 1 & P_0(T > m) \\ m & \mathrm{E}_0[T\mathbf{1}_{\{T>m\}}] \end{pmatrix} \begin{pmatrix} s \\ t \end{pmatrix}.$$

矩阵行列式为 $\mathrm{E}_0[(T-m)\mathbf{1}_{\{T>m\}}] > 0$，因为非恒定可积变量不可能仅在均值的一侧取值。因此小扰动覆盖 $b = (\alpha, \alpha m)^\top$ 附近的二维邻域，内点条件成立。

第二步：由严格凸性得到双尾。固定 $\eta \neq \eta_0$，广义 NP 保证有最优解，且按

$$d_\eta(t) = r_\eta(t) - (a + bt), \qquad r_\eta(t) = e^{(\eta-\eta_0)t - A(\eta) + A(\eta_0)}$$

的正负拒绝。因

$$d_\eta''(t) = (\eta - \eta_0)^2 r_\eta(t) > 0,$$

负值区间是一个区间，规则在其外拒绝，内部接受，至多在两个零点随机化。

单尾情形不能满足两个矩约束。因为对任何常数 c 都有

$$\mathrm{E}_0[(T-c)(\varphi-\alpha)]=0.$$

若 φ 为上尾规则，则乘积在 $T<c$ 时为 $\alpha(c-T)>0$，在 $T>c$ 时为 $(1-\alpha)(T-c)>0$，在 $T=c$ 时为零。非恒定性使其期望严格为正，矛盾；下尾规则则严格为负。恒为 0 或 1 也不符合大小约束。因此可取双尾形式，包含在有限支持边界上随机化和两个临界点重合的情形。

5.7.2 同一个规则对全部备择都最优

第三步：固定临界点，用割线逐一比较。固定已得到的两矩可行双尾规则，设 $c_1<c_2$。对任意新的备择 $\eta\neq\eta_0$，连接指数曲线上的 $(c_1,r_\eta(c_1))$、$(c_2,r_\eta(c_2))$，得到直线 $\ell_\eta(t)=a_\eta+b_\eta t$。严格凸性给出

$$r_\eta(t)-\ell_\eta(t)\begin{cases}>0, & t<c_1 \text{ 或} t>c_2,\\ <0, & c_1<t<c_2,\\ =0, & t=c_1,c_2.\end{cases}$$

区间内曲线低于割线；区间外的严格不等式由割线斜率的单调性得到。例如 $t<c_1$ 时，

$$\frac{r_\eta(c_1)-r_\eta(t)}{c_1-t}<\frac{r_\eta(c_2)-r_\eta(c_1)}{c_2-c_1}=b_\eta,$$

移项即得曲线高于延长线。于是固定的 φ^* 对每个备择都满足广义 NP 的充分符号规则，所以

$$\mathrm{E}_\eta\,\varphi^*\geq\mathrm{E}_\eta\,\psi,\qquad \psi\in\mathcal{C}_b,\quad \eta\neq\eta_0.$$

改变备择时，改变的是割线的斜率和截距，临界点与检验本身均不变。

第四步：证明全局无偏并限制比较类。取 $\psi\equiv\alpha$ 得 $\mathrm{E}_\eta\,\varphi^*\geq\alpha$，证明候选确实无偏。每个无偏水平检验又都满足前文两个必要矩方程，因此属于 $\mathcal{C}_b$，上述功效比较覆盖所有无偏竞争者，UMPU 得证。

若 $c_1=c_2=c$，将割线改为 r_η 在 c 处的切线。严格凸性保证除 c 外差均为正，规则因而在 $T\neq c$ 全拒绝，在 $T=c$ 随机化。记 $p=P_0(T=c)$，矩方程给出

$$(1-\gamma)p=1-\alpha,\qquad m-(1-\gamma)cp=\alpha m.$$

所以 $c=m$ 且 $\gamma=1-(1-\alpha)/p$，要求 $p\geq1-\alpha$。连续分布没有这样的重合情形。

已知方差的双侧正态检验

对独立正态样本 $N(\mu,\sigma^2)$，σ 已知，检验 $\mu=\mu_0$。令 $Z=\sqrt{n}(\bar{X}-\mu_0)/\sigma$，则

$$\varphi^*=\mathbf{1}_{\{|Z|>z_{1-\alpha/2}\}}$$

在原假设下大小为 α。又因中心化正态分布对称，

$$\mathrm{E}_{\mu_0}[(\bar{X}-\mu_0)\varphi^*]=0,$$

所以两个矩方程都成立，双侧 z 检验为 UMPU。这与双侧不存在 UMP 不矛盾：两者的竞争类不同。

练习 5.7：两尾为什么不一定等概率

设 T 在原假设下服从偏态连续分布，均值为 m。分别写出双侧 UMPU 临界值的面积方程与一阶矩方程。解释仅令两尾各为 $\alpha/2$ 为何通常不足。

答案线索。要求 $P_0(T<c_1)+P_0(T>c_2)=\alpha$ 及 $\mathrm{E}_0[(T-m)\mathbf{1}_{\{T<c_1\ 或 T>c_2\}}]=0$。尾概率未包含距均值的权重，等面积一般不能推出矩平衡。

5.8 干扰参数与条件 UMPU

5.8.1 相似性、Neyman 结构与完备性

考虑参数 (η,λ)，η 为研究对象，λ 为干扰参数。固定 $\eta=\eta_0$ 的边界族记为 $\mathcal{P}_b=\{P_{\eta_0,\lambda}:\lambda\in\Lambda\}$。

相似检验与 Neyman 结构

若对每个 λ 都有 $\mathrm{E}_{\eta_0,\lambda}\,\varphi=\alpha$，称检验在边界族上相似。设 U 对边界族充分，若

$$\mathrm{E}_{\eta_0,\lambda}(\varphi\mid U)=\alpha\quad P_{\eta_0,\lambda}\text{-几乎处处，对每个}\lambda,$$

则称具有 Neyman 结构。塔式法则立即给出后者蕴含相似性。

若 U 对边界族充分，则以下两项等价：U 有界完备；每个大小 $\alpha\in(0,1)$ 的相似检验都具有 Neyman 结构。

证明。充分性允许选取对所有 λ 共用的条件期望函数。对相似检验令

$$h(U)=\mathrm{E}_{\eta_0,\lambda}(\varphi\mid U)-\alpha.$$

它有界，且对每个 λ 期望为零，有界完备性推出 $h=0$，即 Neyman 结构。反之，若有界完备性失败，存在有界 $q(U)$，对所有 λ 期望为零，但并非在每个分布下几乎处处为零。若 $|q|\le M$，取

$$0<\varepsilon<\min(\alpha,1-\alpha)/M.$$

则 $\varphi=\alpha+\varepsilon q(U)$ 是相似检验，但它本身为 U 的函数，故条件期望就是自身，不具有 Neyman 结构，矛盾。

5.8.2 条件似然比与两个条件矩

设模型为共同正支持上的正则指数族

$$f_{\eta,\lambda}(x) = \exp\{\eta T(x) + \lambda^{\top} U(x) - A(\eta,\lambda)\} h(x),$$

其中 $(\eta,\lambda) \in I \times \Lambda$，$I$ 为含 η_0 的开区间，Λ 为开集；假设存在通常样本空间上的正则条件分布。开自然参数邻域保证所需的局部积分求导。边界族中 U 充分。给定 $U = u$ 后，λ 的因子在归一化中消去，条件似然比为

$$\frac{dQ_{\eta,u}}{dQ_{\eta_0,u}} = \frac{\exp\{(\eta-\eta_0)T\}}{\mathrm{E}_{\eta_0}[\exp\{(\eta-\eta_0)T\} \mid U = u]}.$$

右侧不含干扰参数，条件问题成为一参数指数倾斜。分母必须保留，它使条件密度积分为 1。

任取全模型中的无偏水平检验 ψ。固定 λ，由原假设处功效的连续性与可微性，

$$\mathrm{E}_{\eta_0,\lambda}\, \psi = \alpha, \qquad \mathrm{E}_{\eta_0,\lambda}[T(\psi - \alpha)] = 0.$$

充分性允许选择共同函数

$$h(U) = \mathrm{E}_0(\psi - \alpha \mid U), \qquad g(U) = \mathrm{E}_0[T(\psi - \alpha) \mid U].$$

二者对所有 λ 的期望为零。h 有界，有界完备性足以消去；g 未必有界，仅有

$$\mathrm{E}_0\, |g(U)| \le \mathrm{E}_0\, |T| < \infty.$$

所以要把第二个约束也传入条件层，需要完整的完备性。若 U 对边界族完备充分，便有

$$\boxed{\mathrm{E}_0(\psi \mid U) = \alpha, \qquad \mathrm{E}_0(T\psi \mid U) = \alpha\, \mathrm{E}_0(T \mid U).}$$

这里只为第一个条件使用有界完备性，不能据此省略第二个条件的可积性和完备性要求。

条件 UMPU 定理

在上述正则共同正支持模型中，取 $0 < \alpha < 1$，设 U 对边界族完备充分。若可测的临界值及端点随机化给出逐层双尾规则 φ^*，并满足

$$\mathrm{E}_0(\varphi^* \mid U) = \alpha, \qquad \mathrm{E}_0(T\varphi^* \mid U) = \alpha\, \mathrm{E}_0(T \mid U),$$

则 φ^* 是 $\eta = \eta_0$ 对 $\eta \ne \eta_0$、干扰参数不受限制时的 UMPU 检验。条件层上 T 恒定时用常数规则 α。

证明。任意无偏竞争者 ψ 都满足上述两个条件矩。条件似然比不含干扰参数，故在几乎每个 $U = u$ 层内，可以用一参数结果的割线证明得到

$$\mathrm{E}_{\eta,\lambda}(\varphi^* - \psi \mid U = u) \ge 0.$$

共同正支持使原假设与备择的分布相互绝对连续，因而它们的 U 分布也具有相同零测集，原假设下忽略的条件层不会在备择下突然有正概率。按备择下 U 的分布平均，

$$\mathrm{E}_{\eta,\lambda}(\varphi^* - \psi) = \mathrm{E}_{\eta,\lambda}[\mathrm{E}_{\eta,\lambda}(\varphi^* - \psi \mid U)] \geq 0.$$

候选的条件大小给出每个干扰参数处的大小为 α；再取也满足条件矩的常数规则 $\psi \equiv \alpha$，得到候选在每个备择下功效至少为 α。它自身无偏，且优于全部无偏竞争者，结论成立。临界值的可测性是拼成合法检验的必要条件，不能只逐个条件层抽象选取而不加说明。

5.8.3 未知方差的正态均值检验

设 $X_i \sim N(\mu, \sigma^2)$ 独立，$n \geq 2$，检验 $\mu = \mu_0$。令

$$Y = \bar{X} - \mu_0, \qquad U = \sum_i (X_i - \mu_0)^2.$$

平方展开后，联合密度可写成

$$f_{\mu,\sigma^2}(x) = (2\pi\sigma^2)^{-n/2} e^{-n(\mu-\mu_0)^2/(2\sigma^2)} \exp\left\{ \frac{n(\mu-\mu_0)}{\sigma^2} Y - \frac{U}{2\sigma^2} \right\}.$$

目标自然参数 $\eta = n(\mu - \mu_0)/\sigma^2 \in \mathbb{R}$，干扰自然参数 $\lambda = -1/(2\sigma^2) < 0$；原假设等价于 $\eta = 0$。在边界族中 $U/\sigma^2 \sim \chi^2_n$，因子分解与开自然参数区间给出 U 对未知方差完备充分。

原假设下同时把各 $X_i - \mu_0$ 变号，U 不变而 Y 变为 $-Y$，故给定 U 时 Y 关于零对称。因此按 $|Y| > c(U)$ 拒绝，只要条件大小为 α，就自动满足第二个条件矩。

令 $V_0 = Y/\sqrt{U}$。边界族下写 $X_i - \mu_0 = \sigma Z_i$，则

$$V_0 = \frac{\bar{Z}}{\sqrt{\sum_i Z_i^2}},$$

分布不依赖 σ^2，所以它对边界族辅助。Basu 定理给出 $V_0 \perp U$，可取常数 d 使 $P_0(|V_0| > d) = \alpha$，则

$$P_0(|V_0| > d \mid U) = \alpha, \qquad c(u) = d\sqrt{u}.$$

设 $S^2 = (n-1)^{-1} \sum_i (X_i - \bar{X})^2$。由 $U = (n-1)S^2 + nY^2$，有

$$t = \frac{\sqrt{n}Y}{S} = \frac{\sqrt{n(n-1)}V_0}{\sqrt{1 - nV_0^2}}.$$

$|V_0| < 1/\sqrt{n}$ 几乎处处成立，右侧是严格递增的奇函数，其导数为 $\sqrt{n(n-1)}(1-nV_0^2)^{-3/2}$。故 $|V_0| > d$ 等价于 $|t| > k$。正态均值方向与正交残差独立，给出原假设下 $t \sim t_{n-1}$，从而

$$\boxed{\varphi^* = \mathbf{1}_{\{|\sqrt{n}(\bar{X}-\mu_0)/S| > t_{n-1,1-\alpha/2}\}}}$$

是对所有 $\sigma^2 > 0$ 都成立的双侧 UMPU 检验。Basu 在这里用于固定 μ_0 的边界族，不是整个双参数模型。

5.8.4 两个 Poisson 强度的条件检验

设 $X_j \sim \mathrm{Poisson}(\rho_j)$ 独立，$\rho_1, \rho_2 > 0$，检验 $\rho_1 = \rho_2$。令

$$T = X_1, \quad U = X_1 + X_2, \quad \eta = \log(\rho_1/\rho_2), \quad \lambda = \log \rho_2.$$

联合概率函数为

$$p(x_1, x_2) = \frac{\exp\{\eta T + \lambda U - e^{\lambda}(1 + e^{\eta})\}}{x_1! x_2!}.$$

给定 $U = u$，直接相除得到

$$X_1 \mid U = u \sim \mathrm{Bin}\left(u, \frac{\rho_1}{\rho_1 + \rho_2}\right).$$

原假设下成功概率为 $1/2$，干扰强度消失，且 $U \sim \mathrm{Poisson}(2\rho)$ 对边界族完备充分。在每层选择关于 $u/2$ 对称的二项双尾规则，并作对称边界随机化达到条件大小 α，就有

$$\mathrm{E}_0[(X_1 - u/2)\varphi \mid U = u] = 0.$$

两个条件矩均成立，故得到强度不等的 UMPU 检验。$u = 0$ 时条件统计量恒定；$u = 1$ 时两个矩方程迫使两个可能取值处的拒绝概率均为 α，这两层都用常数随机化。

练习 5.8：小计数层的精确检验

取 $u = 2$、$\alpha = 0.05$，在 $X_1 = 0, 2$ 时以同一概率 γ 拒绝，$X_1 = 1$ 时不拒绝。求 γ，验证两个条件矩。

答案线索。原假设条件概率为 $(1/4, 1/2, 1/4)$，故 $\gamma/2 = 0.05$，得到 $\gamma = 0.10$；$\mathrm{E}_0(X_1\varphi \mid U = 2) = 2\gamma/4 = 0.05 = \alpha\ \mathrm{E}_0(X_1 \mid U = 2)$。

5.9 检验反演与最优置信集合

5.9.1 覆盖率与错误候选的纳入概率

对每个候选 θ_0，给出检验该点原假设的非随机水平 α 规则 φ_{θ_0}，定义

$$C(X) = \{\theta_0 : \varphi_{\theta_0}(X) = 0\}.$$

即固定同一份数据，保留所有未被拒绝的参数候选。结果一般是集合，不必是一个区间。假设有关集合事件可测，则真值为 θ 时

$$P_\theta\{\theta \in C(X)\} = 1 - \mathrm{E}_\theta\, \varphi_\theta(X) \geq 1 - \alpha.$$

若每个点原假设下的拒绝概率恰为 α，覆盖率就精确为 $1 - \alpha$。对另一个候选 $\theta_0 \neq \theta$，

$$P_\theta\{\theta_0 \in C(X)\} = 1 - \mathrm{E}_\theta\, \varphi_{\theta_0}(X).$$

θ 决定数据的真分布，θ_0 决定被检验的候选，两个下标各有作用。

随机化检验先取统一的独立 $V \sim U(0,1)$，定义 $C(X, V) = \{\theta_0 : V > \varphi_{\theta_0}(X)\}$。相同公式仍成立，但概率同时对数据和辅助随机数计算。

5.9.2 UMP 与 UMA 的对偶

一致最准确（UMA）在本章指：满足覆盖保证的前提下，对规定方向上的每个错误候选，其纳入概率最小。

对偶证明。设 $D(X)$ 为另一满足覆盖率至少 $1-\alpha$ 的置信集合。对固定候选 θ_0 定义

$$\psi_{\theta_0}(X) = \mathbf{1}_{\{\theta_0 \notin D(X)\}}.$$

覆盖保证给出 $\mathrm{E}_{\theta_0}\,\psi_{\theta_0} \le \alpha$，所以它是一个合法水平检验。若 φ_{θ_0} 在所考虑的备择方向为 UMP，则

$$\mathrm{E}_{\theta}\,\varphi_{\theta_0} \ge \mathrm{E}_{\theta}\,\psi_{\theta_0}.$$

两边从 1 中减去，便有

$$P_\theta(\theta_0 \in C) \le P_\theta(\theta_0 \in D).$$

最有力的拒绝转成了对错误候选最小的纳入概率。若比较对象本身随机化，用其条件拒绝概率代替上述指示函数，论证相同。

正态均值的单侧下置信界

已知方差时，检验 $\mu = \mu_0$ 对 $\mu > \mu_0$ 的 UMP 规则在 $\sqrt{n}(\bar{X} - \mu_0)/\sigma > z_{1-\alpha}$ 时拒绝。接受候选的条件等价于

$$\mu_0 \ge \bar{X} - z_{1-\alpha}\frac{\sigma}{\sqrt{n}},$$

所以反演为

$$C(X) = \left[\bar{X} - z_{1-\alpha}\frac{\sigma}{\sqrt{n}},\ \infty\right).$$

其 UMA 结论针对 $\mu_0 < \mu$ 的错误候选，即对应检验的备择方向。不能据此声称它对真值两侧的所有错误候选都最准确。

5.9.3 UMPU 与无偏置信集合

本章称置信集合无偏，若它对每个真参数有覆盖率至少 $1-\alpha$，并且对每个错误候选 $\theta_0 \neq \theta$ 都有

$$P_{\theta,\lambda}(\theta_0 \in C) \le 1 - \alpha.$$

反演双侧无偏检验立即得到这个性质，因为错误候选对应备择下的拒绝概率至少为 α。反之，对任意这样的竞争集合 D，规则 $\psi_{\theta_0} = \mathbf{1}_{\{\theta_0 \notin D\}}$ 既有水平保证，也在每个备择下功效至少为 α，所以属于无偏检验类。

因此反演 UMPU 检验，得到在无偏置信集合类中对每个错误候选纳入概率都最小的集合，称为一致最准确无偏（UMAU）置信集合。这里的最优指标是逐个错误候选的纳入概率，不是笼统的“长度最短”。

双侧 t 区间

正态未知方差时，接受候选 μ_0 的条件是

$$\left|\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\right| \le t_{n-1,1-\alpha/2}.$$

故反演得到

$$C(X)=\left[\bar{X}-t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}},\quad \bar{X}+t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}\right].$$

对所有 $\mu\in\mathbb{R}$、$\sigma^2>0$，其覆盖率都恰为 $1-\alpha$；由条件 UMPU 与反演对偶，它在无偏置信集合类中具有 UMAU 性质。已知方差时将 t 分位数与 S 分别换成 z 分位数与 σ，结论相同。

覆盖率描述固定真参数下的重复抽样行为。观测数据后的区间端点已固定，频率覆盖结论本身不赋予参数一个后验分布。

练习 5.9：反演的方向与最优性的含义

从已知方差正态均值检验 $H_0:\mu=\mu_0$ 对 $H_1:\mu<\mu_0$ 出发，求单侧置信集合，并说明其 UMA 性质针对哪一侧错误候选。再说明双侧 t 区间的 UMAU 性质为何不能直接译成“所有置信区间中长度最短”。

答案线索。接受条件为 $\sqrt{n}(\bar{X}-\mu_0)/\sigma\ge z_\alpha$，所以 $C=(-\infty,\bar{X}+z_{1-\alpha}\sigma/\sqrt{n}]$；比较针对 $\mu_0>\mu$。UMAU 限于无偏集合类，比较的是错误候选的纳入概率，并非直接比较每次样本的长度或期望长度。

5.10 本章结果的使用条件

问题	主要工具	必须核验的条件
简单对简单	NP 引理	大小、似然比边界与随机化
单侧复合假设	MLR 与单侧 UMP	自然参数方向、边界水平、规则不随备择改变
一参数双侧问题	广义 NP 与 UMPU	正则求导、两个矩方程、全局无偏
存在干扰参数	条件 UMPU	边界族完备充分、条件两矩、可测性与零测集转移
构造置信集合	检验反演	覆盖率、候选与真值的下标、比较方向和集合类

一项功效比较只有同时说明假设、水平和竞争类，结论才完整。NP 在全部水平检验中处理固定备择；MLR 使同一排序适用于所有单侧备择；双侧问题借无偏性限定竞争者，再以矩约束和凸性完成统一比较。条件化与反演保留的正是这些约束，因此最优性名称不能脱离适用范围单独使用。

附录 A　充分性与分布变换习题

本组对应第一次作业第 7–12 题。第 1–6 题在本轮学习讨论中没有完整解答，不计入已整理范围。以下重述数学问题并给出解答；几乎必然等式均指对每个模型分布分别成立，所用统计量和表示函数不含未知参数。

A.1　柯西位置尺度族的最小充分统计量

设 $X_1,\dots,X_n$ 独立同分布于 $C(\mu,\sigma)$，$\mu\in\mathbb{R}$、$\sigma>0$ 均未知。证明全部次序统计量组成的向量最小充分。

解。联合密度处处为正，且

$$p_{\mu,\sigma}(x)=\frac{\sigma^n}{\pi^n\prod_i[(x_i-\mu)^2+\sigma^2]}.$$

排序不改变乘积，所以因子分解给出 $T=(X_{(1)},\dots,X_{(n)})$ 充分。若两条似然成比例，令 $\sigma\to\infty$，两边分母同为首项系数 1 的 σ^{2n} 多项式，比例常数必为 1。于是对所有 $\mu\in\mathbb{R}$、$\sigma>0$，

$$\prod_i[(x_i-\mu)^2+\sigma^2]=\prod_i[(y_i-\mu)^2+\sigma^2].$$

固定 μ 并令 $\sigma\downarrow 0$，得 $P_x(\mu)^2=P_y(\mu)^2$，其中 $P_x(z)=\prod_i(z-x_i)$、$P_y(z)=\prod_i(z-y_i)$。因此多项式 $(P_x-P_y)(P_x+P_y)$ 恒为零。实多项式环无零因子，且两个多项式均首一，所以 $P_x=P_y$。实根及其重数相同，故排序后的样本相同。反之，排序相同显然使似然相同。由第二章的似然成比例判别，T 最小充分。

A.2　均匀位置族：最小充分但不完备

设 $n\ge 2$、$X_i\sim U(\theta,\theta+1)$ 独立同分布。证明 $T=(X_{(1)},X_{(n)})$ 最小充分而不完备。

解。对正似然样本，允许的参数集合为

$$(x_{(n)}-1,x_{(1)}),\qquad p_\theta(x)=\mathbf{1}_{\{x_{(n)}-1<\theta<x_{(1)}\}}.$$

因子分解给出充分性。两条非零似然成比例，等价于上述非空开区间相同，因而两个端点分别相同，得到最小充分性。比较的是完整似然，不是可能出现 $0/0$ 的密度比。

令 $R=X_{(n)}-X_{(1)}$。由 $X_i=\theta+U_i$，R 的分布不含 θ。其密度及期望为

$$f_R(r)=n(n-1)r^{n-2}(1-r)\mathbf{1}_{(0,1)}(r),\qquad \mathrm{E}\,R=\frac{n-1}{n+1}.$$

于是固定有界函数 $g(T)=R-(n-1)/(n+1)$ 对所有参数均值为零，却不几乎必然为零。因此 T 不有界完备，也不完备。第二章给出了该密度及 Basu 反证的详细推导。

A.3 可以恢复充分统计量的统计量仍充分

在本讲义的受支配模型框架内，设 T 充分且 $T=\psi(S)$，ψ 为不含参数的可测函数，证明 S 充分。

解。在受支配模型中，由因子分解，$p_\theta(x)=a_\theta(T(x))h(x)$。代入得

$$p_\theta(x)=a_\theta(\psi(S(x)))h(x).$$

右端仍是 $S(x)$ 的函数与参数无关因子的乘积，故 S 充分。方向不可颠倒：充分统计量的任意函数未必充分，例如把它映射成常数。

A.4 完备充分统计量与最小充分统计量的关系

设 T 完备（或有界完备）且充分，最小充分统计量 S 存在。证明 T 最小充分，且 S 也完备（或有界完备）。

解。最小充分性先给出 $S=\psi(T)$。若 $a(S)$ 可积（在有界版本中要求有界）且所有参数下均值为零，则 $a(\psi(T))$ 具有相同性质；由 T 的完备性，它几乎必然为零，所以 S 完备。

为证明反向可恢复性，任取有界可测 b。S 充分，故可统一选取不含参数的 k，使

$$k(S)=\mathrm{E}_\theta[b(T)\mid S].$$

若 $|b|\le M$，可取 $|k|\le M$。残差 $b(T)-k(\psi(T))$ 是 T 的固定有界函数，所有参数下均值为零，故由有界完备性

$$b(T)=k(S)\quad P_\theta\text{-a.s.}$$

实值时取 $b(t)=\arctan t$，反解得到 $T=\tan(k(S))$；逆函数在有效像外可补定义。有限维统计量对每个坐标分别如此处理。一般标准 Borel 值域可用有界 Borel 编码。任意充分统计量 U 都能恢复 S，从而恢复 T，所以 T 最小充分。不能直接对未保证可积的 T 作条件期望，也不能把一般无界残差用于有界完备性。

A.5 平移指数分布的间距与独立性

设 $n>2$，样本密度为

$$f_{a,\theta}(x)=\theta^{-1}e^{-(x-a)/\theta}\mathbf{1}_{\{x>a\}},\quad a\in\mathbb{R},\quad \theta>0.$$

证明 $X_{(1)}$ 与 $Q=\sum_i(X_i-X_{(1)})$ 独立；再证明向量

$$Z_i=\frac{X_{(n)}-X_{(i)}}{X_{(n)}-X_{(n-1)}},\quad 1\le i\le n-2,$$

与 $(X_{(1)}, Q)$ 独立。

解。定义缩放间距

$$W_1 = n(X_{(1)} - a), \quad W_j = (n-j+1)(X_{(j)} - X_{(j-1)}), \quad 2 \le j \le n.$$

反变换为 $X_{(j)} = a + W_1/n + \sum_{k=2}^{j} W_k/(n-k+1)$，其 Jacobian 绝对值为 $1/n!$。次序统计量密度为

$$n!\theta^{-n} \exp\{-\textstyle\sum_j (x_j - a)/\theta\} \mathbf{1}_{\{a<x_1<\cdots<x_n\}}.$$

又有 $\sum_j (x_j - a) = \sum_j w_j$，故

$$f_W(w) = \prod_{j=1}^{n} \theta^{-1} e^{-w_j/\theta} \mathbf{1}_{\{w_j>0\}}.$$

即 W_j 独立同分布于尺度为 θ 的指数分布。计数每个间距出现的次数，得

$$Q = \sum_{j=2}^{n} W_j, \qquad X_{(1)} = a + W_1/n,$$

所以第一问成立。

令 $P_j = W_j/Q$，$j = 2, \ldots, n$；只需 $P_2, \ldots, P_{n-1}$ 为自由变量。变换 $w_j = q p_j$ 的 Jacobian 为 q^{n-2}，于是

$$f_{Q,P}(q,p) = \frac{q^{n-2} e^{-q/\theta}}{(n-2)!\theta^{n-1}} \mathbf{1}_{\{q>0\}} \cdot (n-2)! \mathbf{1}_{\Delta}(p),$$

其中 $\Delta = \{p_j > 0, \sum_{j=2}^{n-1} p_j < 1\}$。前者是 Gamma 密度，后者在体积为 $1/(n-2)!$ 的单纯形上积分为 1，故 $Q \perp\!\!\!\perp P$。再由 W_1 与 $(W_2, \ldots, W_n)$ 独立，联合密度分解为 $f_{W_1} f_Q f_P$，得到 $P \perp\!\!\!\perp (W_1, Q)$。这是联合独立性，不能仅由两次两两独立直接推断。

最后

$$Z_i = \frac{\sum_{k=i+1}^{n} P_k/(n-k+1)}{P_n}, \quad P_n > 0 \text{ a.s.}$$

整个 Z 向量是 P 的函数，$(X_{(1)}, Q)$ 是 (W_1, Q) 的函数，故第二问成立。该结论不声称 Z_i 之间相互独立。

A.6 两段支撑模型的最小充分统计量

设 $\theta > 0$，X_i 独立同分布，密度为

$$f_\theta(x) = \frac{1}{2\theta}[\mathbf{1}_{(0,\theta)}(x) + \mathbf{1}_{(2\theta,3\theta)}(x)].$$

求一个最小充分统计量。

解。只需考虑共同满测集 $(0,\infty)^n$。令

$$\begin{aligned} M &= \max_i x_i, \\ A &= \max(\{x_i : x_i < M/2\} \cup \{0\}), \\ B &= \min\{x_i : x_i \geq M/2\}, \\ L &= \max(M/3, A), \qquad U = B/2. \end{aligned}$$

B 总有定义，因为最大值属于相应集合。令 $(L^*, U^*) = (L, U)$ 若 $L < U$，否则令其为 $(0,0)$。下面证明 $T = (M, L^*, U^*)$ 最小充分。

由最大值所在区间，正似然参数必满足 $\theta > M$ 或 $M/3 < \theta < M/2$。前者使全部观测落入第一段。后者中，$x_i < M/2$ 时只能属于第一段，要求 $x_i < \theta$；$x_i \geq M/2$ 时只能属于第二段，要求 $2\theta < x_i$，而 $x_i < 3\theta$ 已由 $x_i \leq M < 3\theta$ 保证。故正似然参数集合恰为

$$C(x) = (M, \infty) \cup (L, U).$$

空区间用 $(L^*, U^*) = (0,0)$ 统一编码。联合密度为

$$p_\theta(x) = (2\theta)^{-n}[\mathbf{1}_{\{\theta > M\}} + \mathbf{1}_{\{L^* < \theta < U^*\}}],$$

给出充分性。

若 $p_\theta(x) = c\, p_\theta(y)$ 对所有参数成立，取 $\theta > \max(M_x, M_y)$，有 $c = 1$，所以 $C(x) = C(y)$。该集合唯一无界连通分支的左端点恢复 M；剩余非空有界分支恢复 L, U，剩余为空则恢复编码 $(0,0)$。因此 $T(x) = T(y)$。反之 T 相同使似然相同。由似然成比例判别，T 最小充分。

支撑与空区间

记录区间端点时必须把所有空区间统一编码。否则不同的 $L \geq U$ 可能对应同一条似然，额外保留无用端点便不能由上述判别得到最小性。

附录 B　估计、信息与 U 统计量习题

本组对应第二次作业的全部 11 题。题意按数学条件重新表述。风险比较均在平方损失下进行；最优性总是相对于明确给定的模型和规则类。第 10 题沿用第 9 题的投影记号。

B.1　第 1 题二项分布中不存在 1/p 的无偏估计

题意。 $X \sim \mathrm{Bin}(n,p)$，n 已知，$p \in (0,1)$ 未知，证明 p^{-1} 不存在无偏估计。

样本空间只有 $n+1$ 个点，任何统计量的期望都是关于 p 的至多 n 次多项式，不可能在整个 $(0,1)$ 上等于 $1/p$。

证明。反设存在统计量 $\delta(X)$，使得

$$E_p\delta(X) = \frac{1}{p}, \qquad 0 < p < 1.$$

记 $\delta(j) = d_j$。由于每个点 $j = 0,\dots,n$ 在每个 $p \in (0,1)$ 下都有正概率，而无偏估计要求期望存在且有限，故每个 d_j 都是有限实数。于是

$$P(p) := E_p\delta(X) = \sum_{j=0}^{n} d_j \binom{n}{j} p^j (1-p)^{n-j}$$

是至多 n 次多项式。无偏性给出

$$pP(p) - 1 = 0, \qquad 0 < p < 1.$$

左边是一个多项式，却在区间 $(0,1)$ 上有无穷多个零点，因此必为零多项式。代入 $p = 0$，得到 $-1 = 0$，矛盾。因此

$$\boxed{\text{不存在} p^{-1} \text{ 的无偏估计。}}$$

这里把 $p = 0$ 代入的是已经证明恒为零的多项式，不是擅自把参数空间扩大到 $p = 0$。也可直接令 $p \downarrow 0$：左边期望趋于有限的 d_0，右边 $1/p \to \infty$。

B.2　第 2 题平方误差下的最优规则与最优线性无偏估计

题意。 $X_1,\dots,X_n$ 有共同有限均值 μ 和有限方差，估计 μ，损失为 $(\delta-\mu)^2$。

B.2.1 (a) 所有估计量组成的规则类中不存在统一最优规则

任意常数规则都允许时，假如存在一个处处最优的规则，它必须在每个参数点都达到零风险，即从一份样本精确知道未知均值。正态子模型已经能排除这种可能。

证明。假设 $\delta^*(X)$ 在所有估计量中统一最优。对每个固定实数 c，常数规则 $\delta_c(X) \equiv c$ 都属于允许的规则类。因此在均值为 μ 的任意模型分布下，

$$R_\mu(\delta^*) \le R_\mu(\delta_\mu) = 0.$$

这里 δ_μ 的意思是：在比较真值 μ 处风险时，从全部常数规则中取数值恰为 μ 的那一个；并未允许实际估计规则依赖未知参数。

风险非负，故上式强迫

$$E_\mu(\delta^* - \mu)^2 = 0, \qquad \delta^* = \mu \quad P_\mu\text{-a.s.}$$

现在只考虑题目允许的子模型

$$X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} N(\mu, 1), \qquad \mu \in \mathbb{R}.$$

取两个不同的均值 $\mu_0 \neq \mu_1$。这两个样本分布在 $\mathbb{R}^n$ 上的密度均处处为正，因此具有相同的零测集。由

$$\delta^* = \mu_0 \quad P_{\mu_0}\text{-a.s.}$$

可推出

$$\delta^* = \mu_0 \quad P_{\mu_1}\text{-a.s.}$$

但最优性同时要求 $\delta^* = \mu_1$，P_{μ_1}-几乎处处成立，与 $\mu_0 \neq \mu_1$ 矛盾。故不存在统一最优规则。

适用范围。仅凭 “共同均值、有限方差” 不能对任意另外指定的小模型都断言无最优规则。例如若模型只有 $X_1 = \cdots = X_n = \mu$ 几乎处处的退化分布，则 X_1 风险恒为零。上述证明针对本题通常意指的完整分布类；它包含正态子模型，所以结论成立。

B.2.2 (b) 独立、方差不同时的最优权重

设

$$\operatorname{Var}(X_i) = \frac{\sigma^2}{a_i}, \qquad a_i > 0, \quad \sigma^2 > 0,$$

其中 a_i 已知。考虑

$$\mathcal{I}_2 = \left\{ \sum_{i=1}^{n} c_i X_i : \ c_i \in \mathbb{R}, \ \sum_{i=1}^{n} c_i = 1 \right\}.$$

解。对 $\delta_c = \sum_i c_i X_i$，

$$E\delta_c = \sum_i c_i \mu = \mu,$$

故类内所有规则均无偏。利用独立性，

$$R(\delta_c) = \mathrm{Var}(\delta_c) = \sigma^2 \sum_{i=1}^{n} \frac{c_i^2}{a_i}.$$

由 Cauchy–Schwarz 不等式，

$$1 = \left(\sum_i c_i \right)^2 = \left(\sum_i \frac{c_i}{\sqrt{a_i}} \sqrt{a_i} \right)^2 \le \left(\sum_i \frac{c_i^2}{a_i} \right) \left(\sum_i a_i \right).$$

因此

$$R(\delta_c) \ge \frac{\sigma^2}{\sum_i a_i}.$$

等号成立当且仅当存在常数 λ，使

$$\frac{c_i}{\sqrt{a_i}} = \lambda \sqrt{a_i}, \qquad c_i = \lambda a_i.$$

结合 $\sum_i c_i = 1$，得 $\lambda = (\sum_i a_i)^{-1}$。所以

$$\boxed{\delta^* = \frac{\sum_{i=1}^{n} a_i X_i}{\sum_{i=1}^{n} a_i}}, \qquad \boxed{R(\delta^*) = \frac{\sigma^2}{\sum_{i=1}^{n} a_i}}.$$

权重与方差的倒数成正比；公共未知因子 σ^2 在权重归一化时消去，因此规则不依赖未知参数。

B.2.3 (c) 同分布且任意两项具有相同相关系数

设共同方差为 $\sigma^2 > 0$，且对所有 $i \ne j$，

$$\mathrm{Cov}(X_i, X_j) = \rho \sigma^2.$$

对 $\sum_i c_i = 1$ 的规则仍有无偏性，并且

$$
\begin{aligned}
R(\delta_c) &= \sigma^2 \sum_i c_i^2 + 2\rho\sigma^2 \sum_{i<j} c_i c_j \\
&= \sigma^2 \left[(1-\rho) \sum_i c_i^2 + \rho \left(\sum_i c_i \right)^2 \right] \\
&= \sigma^2 \left[(1-\rho) \sum_i c_i^2 + \rho \right].
\end{aligned}
$$

相关矩阵必须半正定，故当 $n \geq 2$ 时，

$$
-\frac{1}{n-1} \leq \rho \leq 1.
$$

若 $\rho < 1$，最小化风险等价于最小化 $\sum_i c_i^2$。再次用 Cauchy–Schwarz，

$$
1 = \left(\sum_i c_i \right)^2 \leq n \sum_i c_i^2,
$$

等号当且仅当 $c_1 = \cdots = c_n = 1/n$。因此

$$
\boxed{\delta^* = \bar{X}}, \qquad \boxed{R(\bar{X}) = \frac{\sigma^2}{n}[1 + (n-1)\rho]}.
$$

若 $\rho = 1$，上式风险对任何满足 $\sum_i c_i = 1$ 的权重都等于 σ^2，所以所有类内规则均最优，$\bar{X}$ 仍是其中之一。若 $\rho = -1/(n-1)$，$\bar{X}$ 的风险为零。

B.3 第 3 题有限参数空间中的一致性与任意收敛速度

题意。参数空间 $\Theta = \{\theta_1, \ldots, \theta_k\}$ 有限，估计量 T_n 也只取这些值。证明一致性等价于选对参数的概率趋于 1，并证明一致估计量具有任意正数列所指定的 $O_P(1)$ 收敛速度。

B.3.1 (a) 一致性当且仅当选对概率趋于 1

若参数空间只有一个点，结论显然。以下设至少有两个不同参数，并记

$$
d = \min_{i \neq j} |\theta_i - \theta_j| > 0.
$$

固定真值 $\theta \in \Theta$。因为 $T_n \in \Theta$，只要 $T_n \neq \theta$，就有 $|T_n - \theta| \geq d$，所以

$$
\{T_n \neq \theta\} = \{|T_n - \theta| > d/2\}.
$$

若 $T_n \xrightarrow{P_\theta} \theta$，则

$$P_\theta(T_n \neq \theta) = P_\theta(|T_n - \theta| > d/2) \to 0.$$

反过来，若 $P_\theta(T_n = \theta) \to 1$，则对任意 $\varepsilon > 0$，

$$P_\theta(|T_n - \theta| > \varepsilon) \le P_\theta(T_n \neq \theta) \to 0.$$

因而

$$\boxed{T_n \xrightarrow{P_\theta} \theta \iff P_\theta(T_n = \theta) \to 1.}$$

B.3.2 (b) 任意正数列放大后的误差仍依概率趋于零

取任意确定性正数列 a_n，无需限制增长速度。对每个 $\varepsilon > 0$，

$$\{|a_n(T_n - \theta)| > \varepsilon\} \subseteq \{T_n \neq \theta\}.$$

因此由 (a)，

$$P_\theta(|a_n(T_n - \theta)| > \varepsilon) \le P_\theta(T_n \neq \theta) \to 0.$$

所以

$$\boxed{a_n(T_n - \theta) \xrightarrow{P_\theta} 0}.$$

特别地，$a_n(T_n - \theta) = O_{P_\theta}(1)$，即通常定义下的 a_n-一致性。

错误时，放大后的误差可能极大；但只要估计恰好正确，放大多少倍都仍是零。错误事件的概率趋于零已经足够控制依概率收敛。这里并没有推出放大误差的方差或期望也趋于零。

B.4 第 4 题样本均值与样本中程的风险比较

题意。 $n > 2$，X_i 独立同分布，二阶矩有限。记

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad T = \frac{X_{(1)} + X_{(n)}}{2}.$$

在平方误差下比较二者估计位置参数 θ 的风险。

B.4.1 (a) 正态模型中样本均值严格优于中程

设 $X_i \overset{\text{i.i.d.}}{\sim} N(\theta, \sigma^2)$，$\sigma > 0$。

第一步：写出均值与残差分解。令

$$R_i = X_i - \bar{X}, \qquad D = \frac{\min_i R_i + \max_i R_i}{2}.$$

将每个观测都减去同一数 $\bar{X}$ 不改变排序，故

$$T = \bar{X} + D.$$

由于 $|D| \le \max_i |R_i|$，有 $D^2 \le \sum_i R_i^2$，故 $ED^2 < \infty$。

第二步：证明 D 与样本均值独立且均值为零。对每个 i，

$$\mathrm{Cov}(\bar{X}, R_i) = \mathrm{Cov}(\bar{X}, X_i) - \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n} - \frac{\sigma^2}{n} = 0.$$

$(\bar{X}, R_1, \ldots, R_n)$ 联合正态，因此 $\bar{X}$ 与整个残差向量独立，从而与 D 独立。

残差向量关于零对称，即 $(R_i)_i$ 与 $(-R_i)_i$ 同分布，而

$$D(-R_1, \ldots, -R_n) = -D(R_1, \ldots, R_n).$$

因此 $ED = 0$，于是 $ET = \theta$。利用独立性，

$$R_\theta(T) = \mathrm{Var}(T) = \frac{\sigma^2}{n} + \mathrm{Var}(D) \ge \frac{\sigma^2}{n} = R_\theta(\bar{X}).$$

第三步：证明严格不等号。函数

$$d(x) = \frac{\min_i x_i + \max_i x_i}{2} - \frac{1}{n}\sum_i x_i$$

连续，并且在 $x = (0, \ldots, 0, 1)$ 处，

$$d(x) = \frac{1}{2} - \frac{1}{n} > 0$$

（这里使用了 $n > 2$）。所以在该点的某个开邻域内，$d(x) > 0$。正态样本的联合密度处处为正，该邻域具有正概率，故 $P(D \ne 0) > 0$。结合 $ED = 0$，得到 $\mathrm{Var}(D) > 0$。

因此对所有 $\theta \in \mathbb{R}, \sigma > 0$，

$$\boxed{R_\theta(\bar{X}) < R_\theta(T)}.$$

上述分解也说明 $E(T \mid \bar{X}) = \bar{X}$，因此可以把结论理解为 Rao–Blackwell 改进；严格性仍需第三步，不能仅凭“条件期望不增方差”省略。

B.4.2 (b) 单位长度均匀模型中中程严格优于样本均值

设 $X_i \sim U(\theta - \frac{1}{2}, \theta + \frac{1}{2})$。令

$$Y_i = X_i - \theta + \frac{1}{2} \sim U(0,1), \qquad A = Y_{(1)}, \quad B = Y_{(n)}.$$

于是

$$T - \theta = \frac{A + B - 1}{2}.$$

先计算所需次序统计量矩。最小值与最大值的密度分别为

$$f_A(a) = n(1-a)^{n-1}, \quad f_B(b) = nb^{n-1}, \qquad 0 < a, b < 1.$$

利用积分 $\int_0^1 u^r (1-u)^s du = r!s!/(r+s+1)!$，得到

$$EA = \frac{1}{n+1}, \qquad EA^2 = \frac{2}{(n+1)(n+2)},$$

$$EB = \frac{n}{n+1}, \qquad EB^2 = \frac{n}{n+2}.$$

从而

$$\mathrm{Var}(A) = \mathrm{Var}(B) = \frac{n}{(n+1)^2(n+2)}.$$

为计算协方差，使用二者联合密度

$$f_{A,B}(a,b) = n(n-1)(b-a)^{n-2}, \qquad 0 < a < b < 1.$$

该密度来自：选一个观测落在最小值附近、一个落在最大值附近，其余 $n-2$ 个都落在长度为 $b-a$ 的区间内。于是

$$\begin{aligned} E(AB) &= n(n-1) \int_0^1 \int_0^b ab(b-a)^{n-2} \, da \, db \\ &= n(n-1) \int_0^1 b^{n+1} \, db \int_0^1 u(1-u)^{n-2} \, du \\ &= n(n-1) \frac{1}{n+2} \frac{1}{n(n-1)} = \frac{1}{n+2}. \end{aligned}$$

第二行用了 $a = bu$。因此

$$\mathrm{Cov}(A,B) = \frac{1}{n+2} - \frac{n}{(n+1)^2} = \frac{1}{(n+1)^2(n+2)}.$$

因为 $EA + EB = 1$，T 无偏，而且

$$R_\theta(T) = \frac{1}{4}\left[\mathrm{Var}(A) + \mathrm{Var}(B) + 2\,\mathrm{Cov}(A, B)\right] = \boxed{\frac{1}{2(n+1)(n+2)}}.$$

另一方面，$\bar{X}$ 无偏，且

$$R_\theta(\bar{X}) = \frac{\mathrm{Var}(X_1)}{n} = \frac{1}{12n}.$$

二者之差为

$$R_\theta(\bar{X}) - R_\theta(T) = \frac{(n+1)(n+2) - 6n}{12n(n+1)(n+2)} = \frac{(n-1)(n-2)}{12n(n+1)(n+2)} > 0.$$

所以

$$\boxed{R_\theta(T) < R_\theta(\bar{X}), \qquad n > 2.}$$

B.4.3 (c) 构造互不支配的模型族

取

$$\boxed{\mathcal{P} = \{N(\theta, 1) : \theta \in \mathbb{R}\} \ \cup \ \{U(\theta - \tfrac{1}{2}, \theta + \tfrac{1}{2}) : \theta \in \mathbb{R}\}.}$$

估计目标统一定义为分布的均值 θ。其中分布类型也未知，可以看成一个额外的干扰参数。

在正态子族内，(a) 给出 $\bar{X}$ 的风险严格更小；在均匀子族内，(b) 给出 T 的风险严格更小。因此在整个 $\mathcal{P}$ 上，两种规则都不能处处支配另一种，即

$$\boxed{\bar{X} \text{ 与} T \text{ 互不支配。}}$$

这并不意味着二者在所有规则中都可容许；这里只证明它们彼此不能支配对方。

B.5 第 5 题统计量不能增加 Fisher 信息

题意。样本 X 的密度为 f_θ，统计量 $T = T(X)$ 的密度为 g_θ，$\theta \in \mathbb{R}^k$。两种密度关于参数可微，且在参数有界区域内，其一阶导数分别有相对于支配测度可积的包络。证明：

1. $I_X(\theta) - I_T(\theta)$ 半正定；
2. 若 T 充分，则两者相等。

以下在参数空间内点讨论，并按通常定义假设涉及的 Fisher 信息矩阵各项有限，以使矩阵差有意义。若某个方向的信息为无穷，应把结论理解为该方向上的扩展非负不等式，而不写“无穷减无穷”。

先证明“统计量的得分 = 样本得分在统计量条件下的平均”，再把信息之差写成残差的二阶矩。

B.5.1 准备得分恒等式

将得分都写成列向量：

$$S_X(X) = \nabla_\theta \log f_\theta(X), \qquad S_T(T) = \nabla_\theta \log g_\theta(T).$$

密度为零处可把得分定义为零。在参数内点，非负可微函数 $\theta \mapsto f_\theta(x)$ 若在当前点为零，其梯度也为零；对 g_θ 同理。因此

$$S_X(x) f_\theta(x) = \nabla_\theta f_\theta(x), \qquad S_T(t) g_\theta(t) = \nabla_\theta g_\theta(t)$$

在积分意义下成立。题目的可积包络允许交换积分与求导，故

$$E_\theta S_X = \int \nabla_\theta f_\theta \, d\nu = \nabla_\theta 1 = 0, \qquad E_\theta S_T = 0.$$

取任意有界可测标量函数 b。由 T 的分布是 X 经统计量映射得到的分布，

$$\int b(T(x)) f_\theta(x) \, d\nu(x) = \int b(t) g_\theta(t) \, d\lambda(t).$$

两侧关于 θ 求导，有

$$\int b(T(x)) \nabla_\theta f_\theta(x) \, d\nu(x) = \int b(t) \nabla_\theta g_\theta(t) \, d\lambda(t).$$

于是

$$E_\theta[b(T) S_X] = E_\theta[b(T) S_T(T)].$$

$S_T(T)$ 是 T 的可测函数，上式又对所有有界可测 b 成立，因此由条件期望的刻画，

$$\boxed{E_\theta(S_X \mid T) = S_T(T).} \tag{5.1}$$

B.5.2 (a) 信息差为非负定矩阵

令 $D = S_X - S_T(T)$。由 (5.1)，

$$E_\theta(D \mid T) = 0.$$

因此

$$E_\theta[DS_T(T)^\top] = E_\theta[E_\theta(D \mid T)S_T(T)^\top] = 0,$$

转置方向的交叉项也为零。展开得

$$\begin{aligned} I_X(\theta) &= E_\theta(S_X S_X^\top) \\ &= E_\theta[(S_T + D)(S_T + D)^\top] \\ &= I_T(\theta) + E_\theta(DD^\top). \end{aligned}$$

所以

$$\boxed{I_X(\theta) - I_T(\theta) = E_\theta[(S_X - S_T)(S_X - S_T)^\top] \succeq 0.}$$

具体而言，对任意 $a \in \mathbb{R}^k$，

$$a^\top[I_X - I_T]a = E_\theta[(a^\top D)^2] \geq 0,$$

这正是半正定的定义。

B.5.3 (b) 充分统计量保留全部 Fisher 信息

需要证明的关键点是 $S_X = S_T(T)$ 几乎处处。只知道 (5.1) 还不够，因为一般条件平均会消去一部分随机波动。

由充分性，对每个有界可测函数 $a(x)$，可以选择一个不依赖参数的函数 $K_a(t)$，使

$$E_\theta[a(X) \mid T] = K_a(T)$$

对所有 θ 成立，且 $|K_a| \leq \sup|a|$。于是

$$E_\theta a(X) = E_\theta K_a(T).$$

对参数求导，题目的包络条件给出

$$E_\theta[a(X)S_X(X)] = E_\theta[K_a(T)S_T(T)].$$

再利用条件期望，

$$E_\theta[K_a(T)S_T(T)] = E_\theta[E_\theta(a(X) \mid T)S_T(T)] = E_\theta[a(X)S_T(T)].$$

因此对所有有界可测 a，

$$E_\theta[a(X)(S_X - S_T(T))] = 0.$$

对差向量的第 j 个分量 D_j，分别取 $a(X) = \mathbf{1}_{\{D_j>0\}}$ 和 $a(X) = \mathbf{1}_{\{D_j<0\}}$，得到其正部、负部的期望均为零，故 $D_j = 0$ 几乎处处。逐分量可得

$$S_X = S_T(T) \quad P_\theta\text{-a.s.}$$

代入 (a) 的信息差公式，

$$\boxed{I_X(\theta) = I_T(\theta).}$$

证明中的分工。可积包络负责交换求导与积分；充分性负责使 K_a 对所有参数是同一个函数。若 K_a 也随参数变化，求导时就会多出一项，上述证明不能照搬。

B.6 第 6 题用似然比差分推导无偏估计的方差下界

题意。$X_1, \dots, X_n$ 独立同分布，密度 $f_\theta(x) > 0$，$\theta \in \Theta \subset \mathbb{R}$。证明原题给出的差分信息下界，并在整数均值的正态模型中计算其最大值。

Cramér–Rao 不等式用“参数的微小导数”与估计误差建立协方差。本题改用两个不同参数之间的似然比，不要求参数空间包含开区间。

B.6.1 (a) 一般下界

证明。固定 θ，取任意 $\Delta \neq 0$ 且 $\theta + \Delta \in \Theta$。定义样本似然比

$$L_\Delta = \prod_{i=1}^{n} \frac{f_{\theta+\Delta}(X_i)}{f_\theta(X_i)}.$$

密度处处为正，故比值有定义。它是从 $P_\theta^{\otimes n}$ 到 $P_{\theta+\Delta}^{\otimes n}$ 的 Radon–Nikodym 导数，因此

$$E_\theta L_\Delta = 1, \qquad E_\theta[T L_\Delta] = E_{\theta+\Delta} T.$$

由 T 对所有参数无偏，

$$E_\theta T = \theta, \qquad E_{\theta+\Delta} T = \theta + \Delta.$$

所以

$$\begin{aligned} E_\theta[(T-\theta)(L_\Delta-1)] &= E_\theta(TL_\Delta) - E_\theta T - \theta E_\theta L_\Delta + \theta \\ &= (\theta+\Delta) - \theta - \theta + \theta \\ &= \Delta. \end{aligned}$$

若相关二阶矩有限，由 Cauchy–Schwarz，

$$\Delta^2 \le E_\theta(T-\theta)^2\, E_\theta(L_\Delta-1)^2 = \mathrm{Var}_\theta(T)[E_\theta L_\Delta^2 - 1].$$

独立性给出

$$\begin{aligned} E_\theta L_\Delta^2 &= \prod_{i=1}^n E_\theta\left[\frac{f_{\theta+\Delta}(X_i)^2}{f_\theta(X_i)^2}\right] \\ &= \left[\int_{\mathbb{R}} \frac{f_{\theta+\Delta}(x)^2}{f_\theta(x)}\,dx\right]^n. \end{aligned}$$

于是

$$\mathrm{Var}_\theta(T) \ge \frac{\Delta^2}{\left[\displaystyle\int_{\mathbb{R}} \frac{f_{\theta+\Delta}(x)^2}{f_\theta(x)}\,dx\right]^n - 1}.$$

该不等式对每个允许的 Δ 都成立，取上确界得

$$\boxed{\mathrm{Var}_\theta(T) \ge \sup_{\substack{\Delta\neq 0 \\ \theta+\Delta\in\Theta}} \frac{\Delta^2}{\left[\displaystyle\int_{\mathbb{R}} \frac{f_{\theta+\Delta}(x)^2}{f_\theta(x)}\,dx\right]^n - 1}.}$$

若 $\mathrm{Var}_\theta(T)=\infty$，结论显然；若某个 Δ 的似然比二阶矩为无穷，则该项下界按 0 理解。若分母为零，则 $L_\Delta = 1$ 几乎处处，两个样本分布相同，不可能同时有期望 θ 和 $\theta+\Delta$；所以在确有无偏估计的前提下，不会出现这一冲突。

B.6.2 (b) 整数均值的正态模型

设 f_θ 是 $N(\theta,\sigma^2)$ 的密度，$\sigma^2>0$ 已知，$\Theta=\mathbb{Z}$。一份观测的密度比为

$$\frac{f_{\theta+\Delta}(x)}{f_\theta(x)} = \exp\left\{\frac{\Delta(x-\theta)}{\sigma^2} - \frac{\Delta^2}{2\sigma^2}\right\}.$$

利用 $X-\theta\sim N(0,\sigma^2)$ 的矩母函数，

$$\begin{aligned}\int \frac{f_{\theta+\Delta}(x)^2}{f_\theta(x)}\,dx &= E_\theta \exp\left\{\frac{2\Delta(X-\theta)}{\sigma^2} - \frac{\Delta^2}{\sigma^2}\right\}\\ &= \exp\left\{\frac{1}{2}\sigma^2\left(\frac{2\Delta}{\sigma^2}\right)^2 - \frac{\Delta^2}{\sigma^2}\right\}\\ &= e^{\Delta^2/\sigma^2}.\end{aligned}$$

因此

$$\mathrm{Var}_\theta(T) \geq \sup_{\Delta\in\mathbb{Z}\setminus\{0\}} \frac{\Delta^2}{e^{n\Delta^2/\sigma^2}-1}.$$

下面确定上确界。令 $c = n/\sigma^2 > 0$，考虑

$$\psi(u) = \frac{u}{e^{cu}-1}, \qquad u > 0.$$

其导数为

$$\psi'(u) = \frac{e^{cu}(1-cu)-1}{(e^{cu}-1)^2}.$$

令 $v = cu > 0$，$r(v) = e^v(1-v)-1$，则 $r(0) = 0$ 且

$$r'(v) = -ve^v < 0,$$

故 $r(v) < 0$，进而 $\psi'(u) < 0$。所以目标函数随 Δ^2 严格减小。在非零整数中，最小的 Δ^2 是 1，恰由 $\Delta = \pm 1$ 取得。因此

$$\boxed{\mathrm{Var}_\theta(T) \geq \frac{1}{e^{n/\sigma^2}-1},}$$

且上确界在 $\Delta = \pm 1$ 处取得。

这里“上确界取得”是指选择差分 Δ 的最优化，不能据此断言存在无偏估计量达到这个方差下界。

B.7 第 7 题一个有限离散模型中的 UMVUE 存在性

题意。单个观测 X 的分布为

$$P_p(X=-1) = 2p(1-p), \qquad P_p(X=k) = p^k(1-p)^{3-k},\ k = 0,1,2,3,$$

其中 $0 < p < 1$。分别判断 p 与 $p(1-p)$ 是否存在 UMVUE。

记 $q = 1 - p$。先核对概率和：

$$2pq + q^3 + pq^2 + p^2q + p^3 = 2pq + (p^3 + q^3) + pq(p + q) = 1.$$

在有限样本空间中，列出所有 “期望恒为零的统计量”，再使用 UMVUE 的正交判别。

B.7.1 准备一 UMVUE 的正交判别及证明

设 δ 是目标函数的无偏估计。则

$$\boxed{\delta \text{ 是 UMVUE} \iff E_p[\delta Z] = 0 \text{ 对所有零均值无偏统计量} Z \text{ 及所有} p.}$$

这里 “零均值无偏统计量” 是指同一个 $Z(X)$ 满足 $E_pZ = 0$ 对全部 p 成立。

必要性。$\delta + cZ$ 对任意实数 c 仍然无偏。如果 δ 最优，则固定 p 后，二次函数

$$\mathrm{Var}_p(\delta + cZ) = \mathrm{Var}_p(\delta) + 2c\,\mathrm{Cov}_p(\delta, Z) + c^2\,\mathrm{Var}_p(Z)$$

必须在 $c = 0$ 取得最小值。其一次项必须为零，即 $\mathrm{Cov}_p(\delta, Z) = 0$。因 $E_pZ = 0$，这等价于 $E_p(\delta Z) = 0$。

充分性。任意其他无偏估计 $\tilde{\delta}$ 都可写为 $\delta + Z$，其中 $E_pZ = 0$。由正交性，

$$\mathrm{Var}_p(\tilde{\delta}) = \mathrm{Var}_p(\delta) + \mathrm{Var}_p(Z) \geq \mathrm{Var}_p(\delta).$$

故 δ 是 UMVUE。

B.7.2 准备二求所有均值恒为零的统计量

设 Z 在 $-1, 0, 1, 2, 3$ 处的值分别为 $z_{-1}, z_0, z_1, z_2, z_3$。则

$$E_pZ = 2z_{-1}p(1-p) + z_0(1-p)^3 + z_1p(1-p)^2 + z_2p^2(1-p) + z_3p^3.$$

它在整个 $(0, 1)$ 上为零，当且仅当各次幂系数为零：

$$\begin{cases} z_0 = 0, \\ 2z_{-1} - 3z_0 + z_1 = 0, \\ -2z_{-1} + 3z_0 - 2z_1 + z_2 = 0, \\ -z_0 + z_1 - z_2 + z_3 = 0. \end{cases}$$

依次得到

$$z_0 = 0, \qquad z_1 = -2z_{-1}, \qquad z_2 = -2z_{-1}, \qquad z_3 = 0.$$

所以所有零均值统计量均为下列 Z_0 的常数倍：

x	-1	0	1	2	3
$Z_0(x)$	1	0	-2	-2	0

B.7.3 准备三把正交条件化为三个函数值相等

记 $\delta_x = \delta(x)$。则

$$\begin{aligned} E_p(\delta Z_0) &= 2pq\delta_{-1} - 2pq^2\delta_1 - 2p^2q\delta_2 \\ &= 2pq[\delta_{-1} - (1-p)\delta_1 - p\delta_2]. \end{aligned}$$

由于 $pq > 0$，该式对所有 p 为零，当且仅当

$$\boxed{\delta_{-1} = \delta_1 = \delta_2.} \tag{7.1}$$

因此，一个无偏估计是 UMVUE，当且仅当它满足 (7.1)。

B.7.4 (a) p 不存在 UMVUE

若 δ 对 p 无偏，即 $E_p\delta = p$，比较上述期望多项式与 p 的系数，可得全部无偏估计为

x	-1	0	1	2	3
$\delta_a(x)$	a	0	$1-2a$	$2-2a$	1

其中 $a \in \mathbb{R}$ 是不依赖未知参数的常数。

验证过程为：常数项给出 $\delta_0 = 0$；一次项给出 $\delta_1 = 1 - 2a$；二次项给出 $\delta_2 = 2 - 2a$；三次项给出 $\delta_3 = 1$。

但对所有 a，

$$\delta_a(2) - \delta_a(1) = 1,$$

不可能满足 (7.1)。因此

$$\boxed{p \text{ 有无偏估计，但不存在 UMVUE。}}$$

例如取 $a = 0$ 就给出一个无偏估计。不存在 UMVUE 不是因为无偏估计类为空，而是不存在一个无偏规则能在所有 p 下同时达到该类的最小方差。

还可直接看出矛盾来源：固定 p 时，$\delta_a = \delta_0 + aZ_0$ 的方差最小点为

$$a^*(p) = -\frac{E_p(\delta_0 Z_0)}{E_p Z_0^2} = \frac{2pq(1+p)}{6pq} = \frac{1+p}{3}.$$

它随未知 p 变化，不能用一个固定的 a 同时实现。

B.7.5 (b) p(1-p) 存在 UMVUE

按照 (7.1)，寻找在 $-1,1,2$ 处同取常数 c 的无偏估计。令在 $0,3$ 处均为零，则其期望为

$$c(2pq + pq^2 + p^2 q) = 3cpq.$$

取 $c = 1/3$ 即得

$$\boxed{\delta^*(X) = \frac{1}{3}\mathbf{1}_{\{X\in\{-1,1,2\}\}}.}$$

它满足

$$E_p\delta^* = \frac{1}{3}(3pq) = pq,$$

且在 $-1,1,2$ 处函数值相等，故由正交判别，确为 UMVUE。

其方差为

$$\boxed{\mathrm{Var}_p(\delta^*) = \frac{1}{9}(3pq)(1-3pq) = \frac{pq}{3} - p^2q^2.}$$

不完备并不意味着“所有目标都没有 UMVUE”。这里同一个不完备模型中，p 没有 UMVUE，而 $p(1-p)$ 有。

B.8 第 8 题正态均值指数函数的 UMVUE 与 CR 下界

题意。 $X_i \overset{\text{i.i.d.}}{\sim} N(\mu,\sigma^2)$，$\mu\in\mathbb{R}$ 未知，$\sigma^2>0$ 已知，$t\neq 0$ 固定。求 $e^{t\mu}$ 的 UMVUE，比较其方差与 CR 下界，并求二者比值的极限。

B.8.1 (a) 构造并证明 UMVUE

由于

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

正态矩母函数给出

$$E_\mu e^{t\bar{X}} = \exp\left(t\mu + \frac{t^2\sigma^2}{2n}\right).$$

因此

$$\widehat{g} = \exp\left(t\bar{X} - \frac{t^2\sigma^2}{2n}\right)$$

满足 $E_\mu \widehat{g} = e^{t\mu}$，是无偏估计。

再证明其最优性。联合密度可写为

$$f_\mu(x) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_i x_i^2}{2\sigma^2}\right) \exp\left\{\frac{\mu}{\sigma^2}\sum_i x_i - \frac{n\mu^2}{2\sigma^2}\right\}.$$

由因子分解定理，$\sum_i X_i$ 充分。它构成自然参数 $\eta = \mu/\sigma^2 \in \mathbb{R}$ 的一参数指数族，自然参数空间含非空开区间，因此由指数族完备性定理，$\sum_i X_i$ 完备。$\bar{X}$ 是它的一一变换，亦完备且充分。

$\widehat{g}$ 是完备充分统计量 $\bar{X}$ 的无偏函数，且正态指数矩有限，故由 Lehmann–Scheffé 定理，

$$\boxed{\mathrm{UMVUE}(e^{t\mu}) = \exp\left(t\bar{X} - \frac{t^2\sigma^2}{2n}\right).}$$

B.8.2 (b) 精确方差严格大于 CR 下界

记 $a = t^2\sigma^2/n > 0$。先计算二阶矩：

$$\begin{aligned} E_\mu \widehat{g}^2 &= e^{-t^2\sigma^2/n} E_\mu e^{2t\bar{X}} \\ &= e^{-t^2\sigma^2/n} \exp\left(2t\mu + \frac{(2t)^2\sigma^2}{2n}\right) \\ &= \exp(2t\mu + a). \end{aligned}$$

所以

$$\boxed{\mathrm{Var}_\mu(\widehat{g}) = e^{2t\mu}(e^a - 1).}$$

另一方面，一份观测的得分与信息为

$$S_\mu(X) = \frac{X-\mu}{\sigma^2}, \qquad I_1(\mu) = \frac{1}{\sigma^2}.$$

样本信息为 $I_n(\mu) = n/\sigma^2$。对 $g(\mu) = e^{t\mu}$，有 $g'(\mu) = te^{t\mu}$，故无偏估计的 CR 下界为

$$\mathrm{CRLB} = \frac{[g'(\mu)]^2}{I_n(\mu)} = \frac{t^2\sigma^2}{n} e^{2t\mu} = ae^{2t\mu}.$$

当 $a > 0$ 时，由

$$e^a - 1 = \int_0^a e^u \, du > \int_0^a 1 \, du = a,$$

可得

$$\boxed{\mathrm{Var}_\mu(\widehat{g}) > \mathrm{CRLB}.}$$

B.8.3 (c) 方差与下界之比趋于 1

由前面的公式，

$$\frac{\mathrm{Var}_\mu(\widehat{g})}{\mathrm{CRLB}} = \frac{e^a - 1}{a}.$$

固定 t, σ^2，当 $n \to \infty$ 时 $a \to 0$，且

$$\frac{e^a - 1}{a} = \int_0^1 e^{av} \, dv \to 1.$$

因此

$$\boxed{\frac{\mathrm{Var}_\mu(\widehat{g})}{\mathrm{CRLB}} \longrightarrow 1.}$$

UMVUE 的意思是在所有无偏估计中方差最小，不意味着必须达到 CR 下界。本题中有限样本下界不可达，但 UMVUE 的方差与下界在一阶渐近意义下相同。

B.9 第 9 题 U 统计量的条件投影及协方差

题意与记号。 $X_1, \ldots, X_n$ 独立同分布，h 为对称的 m 元核，$m \le n$。假定

$$Eh(X_1, \ldots, X_m)^2 < \infty.$$

定义

$$U_n = \binom{n}{m}^{-1} \sum_{1 \le i_1 < \cdots < i_m \le n} h(X_{i_1}, \ldots, X_{i_m}),$$

$$\vartheta = Eh(X_1, \ldots, X_m).$$

$$h_k(x_1,\dots,x_k)=E[h(x_1,\dots,x_k,X_{k+1},\dots,X_m)],\qquad k=1,\dots,m,$$

其中 $h_m=h$。记

$$\widetilde{h}_k=h_k-\vartheta,\qquad \widetilde{h}=h-\vartheta,\qquad \zeta_k=\mathrm{Var}(h_k(X_1,\dots,X_k)).$$

h_k 保留前 k 个观测，把剩下的 $m-k$ 个观测平均掉。作为随机变量，

$$h_k(X_1,\dots,X_k)=E[h(X_1,\dots,X_m)\mid X_1,\dots,X_k]. \tag{9.1}$$

二阶可积性保证 h 一阶可积，故可以使用 Fubini 定理与条件期望；由条件 Jensen 不等式，

$$E[h_k(X_1,\dots,X_k)^2]\le E[h(X_1,\dots,X_m)^2]<\infty.$$

对任意具体 $x_1,\dots,x_k$ 的积分公式在积分存在处使用；条件期望恒等式均按几乎处处理解。仅有题目的二阶矩条件，不需要也不能额外假定每个样本空间点上的截面积分都有限。

B.9.1 (a) 逐次积分恒等式

证明。对 $1\le k\le m-1$，利用独立同分布性和 Fubini 定理，

$$\begin{aligned}
&E[h_{k+1}(x_1,\dots,x_k,X_{k+1})]\\
&=\int h_{k+1}(x_1,\dots,x_k,u_{k+1})\,dP(u_{k+1})\\
&=\int\cdots\int h(x_1,\dots,x_k,u_{k+1},\dots,u_m)\prod_{j=k+1}^{m}dP(u_j)\\
&=h_k(x_1,\dots,x_k).
\end{aligned}$$

所以

$$\boxed{h_k(x_1,\dots,x_k)=E[h_{k+1}(x_1,\dots,x_k,X_{k+1})].}$$

随机变量形式就是塔式法则：

$$E[h_{k+1}(X_1,\dots,X_{k+1})\mid X_1,\dots,X_k]=h_k(X_1,\dots,X_k).$$

B.9.2 (b) 中心化 U 统计量等于中心化核的平均

每一个 m 元子样本都与 $(X_1,\dots,X_m)$ 同分布，所以每项核的期望均为 ϑ。求和中共有 $\binom{n}{m}$ 项，因此

$$EU_n = \binom{n}{m}^{-1}\binom{n}{m}\vartheta = \vartheta.$$

于是

$$\begin{aligned} U_n - EU_n &= \binom{n}{m}^{-1} \sum_{i_1<\cdots<i_m} h(X_{i_1},\dots,X_{i_m}) - \vartheta \\ &= \binom{n}{m}^{-1} \sum_{i_1<\cdots<i_m} [h(X_{i_1},\dots,X_{i_m}) - \vartheta] \\ &= \boxed{\binom{n}{m}^{-1} \sum_{i_1<\cdots<i_m} \widetilde{h}(X_{i_1},\dots,X_{i_m})}. \end{aligned}$$

B.9.3 (c) 重叠下标数决定两个核的协方差

证明。先考虑 $1 \le k < m$。因为核对称且样本独立同分布，可以把两组核中的共同观测记为向量 Z，各自剩余观测记为 A, B。其中 Z 有 k 项，A, B 各有 $m-k$ 项，三组相互独立。

两项中心化核可写成

$$\widetilde{h}(Z,A), \qquad \widetilde{h}(Z,B).$$

给定 Z 后，A 与 B 仍相互独立，因此两个核条件独立。由条件期望与 (9.1)，

$$E[\widetilde{h}(Z,A) \mid Z] = h_k(Z) - \vartheta,$$

对另一个核同样成立。故

$$\begin{aligned} E[\widetilde{h}(Z,A)\widetilde{h}(Z,B)] &= E\{E[\widetilde{h}(Z,A)\widetilde{h}(Z,B) \mid Z]\} \\ &= E\{E[\widetilde{h}(Z,A) \mid Z]\, E[\widetilde{h}(Z,B) \mid Z]\} \\ &= E[(h_k(Z) - \vartheta)^2] \\ &= \mathrm{Var}(h_k(Z)) \\ &= \zeta_k. \end{aligned}$$

倒数第二步用了 $Eh_k(Z) = \vartheta$，这也是塔式法则的直接结果。

若 $k = m$，两组下标完全相同，核对称使两项核相同，此时期望直接等于

$$E\widetilde{h}^2 = \mathrm{Var}(h) = \zeta_m.$$

因此对所有题设的 k，

$$\boxed{E[\widetilde{h}(X_{i_1},\dots,X_{i_m})\widetilde{h}(X_{j_1},\dots,X_{j_m})] = \zeta_k.}$$

补充：若没有共同下标，即 $k=0$，两项核独立且已中心化，协方差为零。

B.9.4 (d) 投影方差随保留的变量个数单调不减

记

$$H_k = h_k(X_1,\dots,X_k), \qquad \mathcal{F}_k = \sigma(X_1,\dots,X_k).$$

由 (a)，$E(H_{k+1}\mid\mathcal{F}_k) = H_k$。利用全方差公式，

$$\begin{aligned}\zeta_{k+1} &= \mathrm{Var}(H_{k+1})\\ &= \mathrm{Var}(E[H_{k+1}\mid\mathcal{F}_k]) + E[\mathrm{Var}(H_{k+1}\mid\mathcal{F}_k)]\\ &= \zeta_k + E[\mathrm{Var}(H_{k+1}\mid\mathcal{F}_k)]\\ &\ge \zeta_k.\end{aligned}$$

所以

$$\boxed{0 \le \zeta_1 \le \zeta_2 \le \cdots \le \zeta_m.}$$

保留的观测越多，平均掉的随机性越少，条件平均本身可以有更大的波动。这里不是说“信息越多，估计误差越大”，而是在比较同一个核的不同条件投影的方差。

B.10 第 10 题三个观测之和为负的 U 统计量

题意。 $n\ge 3$，X_i 为独立同分布实值随机变量，核为

$$h(x_1,x_2,x_3) = \mathbf{1}_{\{x_1+x_2+x_3<0\}}.$$

沿用第 9 题记号，写出 U_n、h_1,h_2,h_3 和 ζ_1,ζ_2,ζ_3。

B.10.1 第一步约定分布函数并处理严格不等号

设

$$F(u) = P(X_1 \le u), \qquad F(u-) = P(X_1 < u).$$

记两个独立观测之和的分布函数为

$$F_2(u) = P(X_1 + X_2 \le u), \qquad F_2(u-) = P(X_1 + X_2 < u).$$

题目没有假设连续分布，所以阈值处可能有正概率，必须保留左极限。令

$$\vartheta = P(X_1 + X_2 + X_3 < 0).$$

B.10.2 第二步写出 U 统计量

核显然对称，且 $0 \le h \le 1$，故二阶矩条件自动满足。所求统计量为

$$\boxed{U_n = \binom{n}{3}^{-1} \sum_{1 \le i < j < \ell \le n} \mathbf{1}_{\{X_i + X_j + X_\ell < 0\}}.}$$

它是所有三元子样本中“总和为负”的比例，且 $EU_n = \vartheta$。

B.10.3 第三步计算条件投影

固定第一个观测为 x，对其余两个取期望：

$$\begin{aligned} h_1(x) &= P(x + X_2 + X_3 < 0) \\ &= P(X_2 + X_3 < -x) \\ &= \boxed{F_2((-x)-)} \\ &= \int_{\mathbb{R}} F((-x-y)-)\, dF(y). \end{aligned}$$

这里 $F_2((-x)-)$ 表示在点 $-x$ 处的左极限。

固定前两个观测为 x_1, x_2，则

$$h_2(x_1, x_2) = P(X_3 < -x_1 - x_2) = \boxed{F((-x_1 - x_2)-)}.$$

三个观测都固定时，没有剩余随机变量需要平均，所以

$$\boxed{h_3(x_1, x_2, x_3) = \mathbf{1}_{\{x_1 + x_2 + x_3 < 0\}}.}$$

同时，

$$\vartheta = \int F_2((-x)-)\,dF(x) = \iint F((-x-y)-)\,dF(x)\,dF(y).$$

B.10.4 第四步计算三个投影方差

由于 $Eh_k = \vartheta$，

$$\zeta_k = Eh_k^2 - \vartheta^2.$$

逐一代入得

$$\boxed{\zeta_1 = \int_{\mathbb{R}} [F_2((-x)-)]^2\,dF(x) - \vartheta^2,}$$

$$\boxed{\zeta_2 = \iint_{\mathbb{R}^2} [F((-x-y)-)]^2\,dF(x)\,dF(y) - \vartheta^2.}$$

最后 h_3 是概率为 ϑ 的 0–1 随机变量，故

$$\boxed{\zeta_3 = \vartheta(1-\vartheta).}$$

原题没有指定共同分布 F，因此这些分布积分就是一般情形下的完整答案，不能给出统一数值。若另有连续分布假设，才可以将相应左极限写成通常的分布函数值。

B.11 第 11 题均值与倒数均值乘积的 U 统计量

题意。 $n \geq 2$，X_i 独立同分布，并满足

$$EX_1^2 < \infty, \qquad EX_1^{-2} < \infty.$$

记

$$\mu = EX_1, \qquad \bar{\mu} = E(X_1^{-1}).$$

构造 $\mu\bar{\mu}$ 的无偏 U 统计量，求精确方差及渐近分布。

为避免将题目的 $\bar{\mu}$ 与样本均值混淆，下文令

$$\beta = \bar{\mu} = E(X_1^{-1}), \qquad \tau = \mu\beta, \qquad A = EX_1^2, \quad B = EX_1^{-2}.$$

逆二阶矩有限意味着 $P(X_1 = 0) = 0$；由 Cauchy–Schwarz，$E|X_1|$ 与 $E|X_1^{-1}|$ 均有限。因此下面涉及的期望都有定义。

B.11.1 (a) 构造对称二元核并验证无偏性

两个独立观测满足

$$E\frac{X_1}{X_2} = EX_1 \cdot EX_2^{-1} = \mu\beta.$$

但 x_1/x_2 不是对称核，所以取对称化

$$\boxed{h(x,y) = \frac{1}{2}\left(\frac{x}{y} + \frac{y}{x}\right)}.$$

于是

$$Eh(X_1, X_2) = \frac{1}{2}(\mu\beta + \mu\beta) = \tau.$$

对应的二阶 U 统计量为

$$\begin{aligned} U_n &= \binom{n}{2}^{-1} \sum_{i<j} \frac{1}{2}\left(\frac{X_i}{X_j} + \frac{X_j}{X_i}\right) \\ &= \boxed{\frac{1}{n(n-1)} \sum_{i \neq j} \frac{X_i}{X_j}}. \end{aligned}$$

每项的期望均为 τ，共有 $n(n-1)$ 项，所以

$$\boxed{EU_n = \tau = \mu\bar{\mu}.}$$

为了后续渐近分析，再记

$$\bar{X}_n = \frac{1}{n}\sum_i X_i, \qquad \bar{Y}_n = \frac{1}{n}\sum_i X_i^{-1}.$$

由于

$$\left(\sum_i X_i\right)\left(\sum_j X_j^{-1}\right) = \sum_{i \neq j} \frac{X_i}{X_j} + n,$$

得到重要的等价表达式

$$\boxed{U_n = \frac{n\bar{X}_n\bar{Y}_n - 1}{n-1}.} \tag{11.1}$$

注意 $\bar{Y}_n$ 是 “倒数的平均”，一般不等于 $1/\bar{X}_n$。

B.11.2 (b) 计算一阶投影方差与核方差

固定第一个变量为 x，有

$$h_1(x) = E[h(x, X_2)] = \frac{1}{2}\left(xEX_2^{-1} + \frac{EX_2}{x}\right) = \boxed{\frac{1}{2}\left(\beta x + \frac{\mu}{x}\right)}.$$

其期望为 τ。平方后，

$$h_1(X_1)^2 = \frac{1}{4}\left(\beta^2 X_1^2 + \mu^2 X_1^{-2} + 2\mu\beta\right).$$

因此

$$Eh_1(X_1)^2 = \frac{1}{4}(\beta^2 A + \mu^2 B + 2\tau),$$

$$\boxed{\zeta_1 = \frac{1}{4}(\beta^2 A + \mu^2 B + 2\tau - 4\tau^2).} \tag{11.2}$$

再计算核的二阶矩。由 X_1/X_2 与 X_2/X_1 的乘积恒为 1，

$$h(X_1, X_2)^2 = \frac{1}{4}\left(\frac{X_1^2}{X_2^2} + \frac{X_2^2}{X_1^2} + 2\right).$$

独立性给出 $E(X_1^2/X_2^2) = AB$，所以

$$Eh(X_1, X_2)^2 = \frac{1}{2}(AB + 1) < \infty.$$

因此

$$\boxed{\zeta_2 = \frac{1}{2}(AB + 1) - \tau^2.} \tag{11.3}$$

B.11.3 (c) 通过核项重叠计数求精确方差

记 $H_{ij} = h(X_i, X_j)$，$i < j$，以及 $N = \binom{n}{2}$。则

$$\mathrm{Var}(U_n) = \frac{1}{N^2}\sum_{i<j}\sum_{k<\ell}\mathrm{Cov}(H_{ij}, H_{k\ell}).$$

对固定的无序下标对 $\{i, j\}$，内层的 $\{k, \ell\}$ 分三类：

1. 完全相同：只有 1 对，协方差为 ζ_2。
2. 恰有 1 个共同下标：从 i, j 中选共同的一个，再从其余 $n-2$ 个中选另一个，共 $2(n-2)$ 对。由第 9(c) 题，协方差为 ζ_1。

3. 没有共同下标：两项核独立，协方差为 0。

外层共有 N 对，故

$$\begin{aligned}\mathrm{Var}(U_n) &= \frac{N[\zeta_2 + 2(n-2)\zeta_1]}{N^2} \\ &= \boxed{\frac{4(n-2)}{n(n-1)}\zeta_1 + \frac{2}{n(n-1)}\zeta_2}.\end{aligned} \tag{11.4}$$

这里双重求和本身就是有序的“核项对”求和，所以 $2(n-2)$ 不需再除以 2。

代入 (11.2)、(11.3)，也可写为

$$\boxed{\mathrm{Var}(U_n) = \frac{(n-2)(\beta^2 A + \mu^2 B + 2\tau - 4\tau^2) + AB + 1 - 2\tau^2}{n(n-1)}}. \tag{11.5}$$

当 $n = 2$ 时，(11.4) 给出 $\mathrm{Var}(U_2) = \zeta_2$，与 $U_2 = h(X_1, X_2)$ 一致。

B.11.4 (d) 一般的一阶渐近分布

令

$$V_i = \begin{pmatrix} X_i \\ X_i^{-1} \end{pmatrix}.$$

因为两项都有有限二阶矩，多元中心极限定理给出

$$\sqrt{n}\begin{pmatrix} \bar{X}_n - \mu \\ \bar{Y}_n - \beta \end{pmatrix} \xrightarrow{d} \begin{pmatrix} G_1 \\ G_2 \end{pmatrix} \sim N_2(0, \Sigma),$$

其中

$$\Sigma = \begin{pmatrix} A - \mu^2 & 1 - \tau \\ 1 - \tau & B - \beta^2 \end{pmatrix}. \tag{11.6}$$

非对角项来自

$$\mathrm{Cov}(X_1, X_1^{-1}) = E(X_1 X_1^{-1}) - \mu\beta = 1 - \tau.$$

写

$$D_{X,n} = \bar{X}_n - \mu, \qquad D_{Y,n} = \bar{Y}_n - \beta.$$

直接展开乘积：

$$\bar{X}_n\bar{Y}_n - \tau = \beta D_{X,n} + \mu D_{Y,n} + D_{X,n}D_{Y,n}. \tag{11.7}$$

由 CLT，$D_{X,n}, D_{Y,n} = O_P(n^{-1/2})$，故

$$\sqrt{n}D_{X,n}D_{Y,n} = O_P(n^{-1/2}) = o_P(1).$$

由 (11.1)，

$$\begin{aligned}\sqrt{n}(U_n - \tau) &= \frac{n}{n-1}\sqrt{n}(\bar{X}_n\bar{Y}_n - \tau) + \frac{\sqrt{n}}{n-1}(\tau - 1)\\ &= \frac{n}{n-1}\left[\beta\sqrt{n}D_{X,n} + \mu\sqrt{n}D_{Y,n}\right] + o_P(1).\end{aligned}$$

应用连续映射与 Slutsky 定理，

$$\sqrt{n}(U_n - \tau) \xrightarrow{d} \beta G_1 + \mu G_2.$$

极限为均值零的正态变量，其方差为

$$\begin{aligned}V &= (\beta, \mu)\Sigma(\beta, \mu)^\top\\ &= \beta^2(A - \mu^2) + \mu^2(B - \beta^2) + 2\mu\beta(1 - \tau)\\ &= \beta^2 A + \mu^2 B + 2\tau - 4\tau^2\\ &= 4\zeta_1.\end{aligned}$$

因此一般成立

$$\boxed{\sqrt{n}(U_n - \mu\bar{\mu}) \xrightarrow{d} N\left(0,\, \bar{\mu}^2 EX_1^2 + \mu^2 EX_1^{-2} + 2\mu\bar{\mu} - 4\mu^2\bar{\mu}^2\right).} \tag{11.8}$$

这里允许方差为零；$N(0,0)$ 表示集中在零点的退化分布。若 $V > 0$，还可写成通常的标准化形式

$$\boxed{\frac{\sqrt{n}(U_n - \tau)}{\sqrt{V}} \xrightarrow{d} N(0,1).}$$

B.11.5 (e) 一阶退化时的极限

题设未假定 $\zeta_1 > 0$，故需区分一阶退化情形。若 $\zeta_1 = 0$，(11.8) 仍正确，但只告诉我们 $\sqrt{n}(U_n - \tau) \to_P 0$。下面给出此时 n 尺度的极限。

由 $4\zeta_1 = 0$，均值为零的随机变量

$$W = \beta(X_1 - \mu) + \mu(X_1^{-1} - \beta)$$

方差为零，故

$$W = 0 \quad \text{a.s.}$$

于是对每个 n，

$$\beta D_{X,n} + \mu D_{Y,n} = 0 \quad \text{a.s.}$$

代入 (11.7)，得到精确等式

$$\bar{X}_n \bar{Y}_n - \tau = D_{X,n} D_{Y,n}.$$

再由 (11.1)，

$$n(U_n - \tau) = \frac{n}{n-1}\left[(\sqrt{n} D_{X,n})(\sqrt{n} D_{Y,n}) + \tau - 1\right].$$

使用联合 CLT 与连续映射定理，得到

$$\boxed{n(U_n - \tau) \xrightarrow{d} G_1 G_2 + \tau - 1, \qquad \zeta_1 = 0,} \tag{11.9}$$

其中 (G_1, G_2) 的协方差仍由 (11.6) 给出。这个极限一般不是正态；若模型进一步退化，也可能恒为零。

具体例子。若 $P(X_1 = 1) = P(X_1 = -1) = 1/2$，则

$$\mu = \beta = 0, \quad A = B = 1, \quad X_1^{-1} = X_1.$$

所以 $\tau = 0, \zeta_1 = 0$，并且 $G_1 = G_2 = Z$，$Z \sim N(0,1)$。此时

$$U_n = \frac{n\bar{X}_n^2 - 1}{n-1}, \qquad \boxed{nU_n \xrightarrow{d} Z^2 - 1 = \chi_1^2 - 1.}$$

这说明题设确实允许一阶退化，补充分支不是多余假设。